

STAT 415

Pengantar Statistika Matematis

Edisi Bahasa Indonesia

Laman utama dan Pelajaran 00-12

Sumber: Departemen Statistika, The Pennsylvania State University

Terjemahan dan rekonstruksi: OpenAI Codex gpt-5.6-sol, Ultra

Edisi: 26 Agustus 2026

Preservasi: 10.5281/zenodo.22077422

Daftar Isi

1. STAT 415 | Pengantar Statistika Matematis
2. 0: Tinjauan Konsep dari STAT 414
3. 1 Statistik Urutan
4. 2 Pendugaan (Bagian I)
5. 3 Pendugaan (Bagian II)
6. 4 Pendugaan Kemungkinan Maksimum (MLE) (Bagian I)
7. 5 Pendugaan Kemungkinan Maksimum (MLE) (Bagian II)
8. 6 Selang Kepercayaan
9. 7 Distribusi Asimtotik MLE (Bagian I)
10. 8 Distribusi Asimtotik MLE (Bagian II)
11. 9 Uji Hipotesis (Bagian I)
12. 10 Uji Hipotesis (Bagian II)
13. 11 Metode Bayesian
14. 12 Regresi Linear Sederhana
15. Provenans, hak, dan perubahan

STAT 415 | Pengantar Statistika Matematis

Tentang mata kuliah ini

Selamat datang di catatan mata kuliah STAT 415: Pengantar Statistika Matematis. Catatan ini dirancang dan dikembangkan oleh [Departemen Statistika Penn State](#) dan disediakan sebagai sumber daya pendidikan terbuka. Catatan ini dapat digunakan secara gratis berdasarkan lisensi Creative Commons [CC BY-NC 4.0](#).

Mata kuliah ini merupakan bagian dari program Magister Statistika Terapan daring yang ditawarkan oleh World Campus Penn State.

[Siap mendaftar?](#)

Sudah terdaftar?

Jika Anda saat ini terdaftar sebagai mahasiswa dalam mata kuliah ini, silakan lihat [Canvas](#) untuk silabus, tugas, video pelajaran, dan komunikasi dari pengajar Anda.

Pelajaran



0: Tinjauan Konsep dari STAT 414

[Distribusi](#)

[Bayes](#)

[Peluang](#)

[Teorema Limit Pusat](#)

[8/19/26](#)



Statistik Urutan

Statistik Urutan

Fungsi Kepadatan Peluang

8/19/26



Estimasi (Bagian I)

Estimasi Titik

Estimasi Tak Bias

Bias

Varians dan Rata-Rata Kuadrat

Faktorisasi

Kecukupan

Metode Momen

8/19/26



Estimasi (Bagian II)

[Estimasi Titik](#)

[Estimasi Tak Bias](#)

[Bias](#)

[Varians dan Rata-Rata Kuadrat](#)

[Faktorisasi](#)

[Kecukupan](#)

[Metode Momen](#)

[8/19/26](#)



Pendugaan Kemungkinan Maksimum (MLE) (Bagian I)

[MLE](#)

[R](#)

[8/19/26](#)



Pendugaan Kemungkinan Maksimum (MLE) (Bagian II)

Estimasi Titik

Estimasi Tak Bias

Bias

Varians dan Rata-Rata Kuadrat

Faktorisasi

Kecukupan

Metode Momen

8/19/26



Selang Kepercayaan

Selang Kepercayaan

8/19/26



Distribusi Asimtotik MLE (Bagian I)

[MLE](#)

[Interval Kepercayaan Asimtotik](#)

[Aproksimasi Numerik](#)

[Bootstrap](#)

[8/19/26](#)



Distribusi Asimtotik MLE (Bagian II)

[MLE](#)

[Interval Kepercayaan Asimtotik](#)

[Aproksimasi Numerik](#)

[Bootstrap](#)

[8/19/26](#)



Uji Hipotesis (Bagian I)

Uji Hipotesis

Uji tentang Proporsi

Uji tentang Satu Rata-Rata

Nilai-p

8/19/26



Uji Hipotesis (Bagian II)

Kuasa

Selang Kepercayaan

Uji Wald

Uji Hipotesis

8/19/26



Metode Bayesian

Bayesian

Peluang Subjektif

Selang Kredibel

8/19/26



Regresi Linear Sederhana

Regresi

8/19/26

Tidak ada item yang cocok

1. [Pelajaran](#)
2. [0: Tinjauan Konsep dari STAT 414](#)

0: Tinjauan Konsep dari STAT 414

Distribusi
Bayes
Peluang
Teorema Limit Pusat

Gambaran Umum

Banyak konsep dari STAT 414: Pengantar Teori Peluang akan digunakan kembali dalam mata kuliah ini. Dalam unit ini, beberapa rumus dan teorema penting disajikan untuk ditinjau kembali.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu mengingat dan menggunakan pengetahuan sebelumnya untuk:

1. Mendefinisikan istilah dan teorema kunci yang berkaitan dengan peluang.
2. Merangkum sifat dan penerapan peubah acak diskret.
3. Membedakan peubah acak kontinu dari peubah acak diskret, serta memberikan contoh dan menjelaskan perbedaannya.
4. Menjelaskan rumus dan definisi peubah acak yang berdistribusi bersama serta menerapkannya untuk menyelesaikan masalah yang melibatkan distribusi peluang bersama.
5. Menjelaskan konsep inferensi statistik dan perannya dalam menarik kesimpulan tentang populasi berdasarkan data sampel.

0.1: Peluang

Dalam bagian ini, kita meninjau beberapa definisi dan teorema penting dalam peluang. Sebaiknya Anda menyegarkan kembali pemahaman tentang konsep-konsep ini dan mengerjakan beberapa latihan.

Definisi 1 (Kejadian) Misalkan ruang hasil (atau ruang sampel) dinotasikan dengan $\mathbf{S}$. Sebuah **kejadian** adalah himpunan bagian dari ruang sampel. Kejadian sering dinotasikan dengan huruf kapital, $A, B, C, \dots$. Oleh karena itu, jika A merupakan kejadian dalam $\mathbf{S}$, maka $A \subset \mathbf{S}$.

Definisi 2 (Peluang) Peluang adalah kerangka logis untuk mengukur ketidakpastian atau keacakan secara berprinsip. Kerangka ini terutama digunakan untuk menjelaskan ketidakpastian atau keacakan dalam memperoleh data yang sedang diamati.

Definisi 3 (Kejadian Saling Lepas) Kejadian A dan B disebut **saling lepas** (atau **tidak beririsan**) jika $A \cap B = \emptyset$.

Definisi 4 (Peluang Bersyarat) Peluang bersyarat suatu kejadian A dengan syarat bahwa kejadian B telah terjadi adalah:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

asalkan $P(B) > 0$.

Definisi 5 (Kejadian Saling Bebas) Kejadian A dan B merupakan **kejadian saling bebas** jika terjadinya salah satu kejadian tidak memengaruhi peluang terjadinya kejadian yang lain. Dengan kata lain, dua kejadian saling bebas jika salah satu dari

$$P(B|A) = P(B)$$

dengan syarat $P(A) > 0$. Kejadian A dan B merupakan kejadian saling bebas jika dan hanya jika

$$P(A \cap B) = P(A)P(B)$$

Jika tidak, A dan B disebut **kejadian saling bergantung**.

Teorema 1 (Teorema Bayes) Misalkan m kejadian $B_1, B_2, \dots, B_m$ membentuk suatu partisi ruang sampel S . Artinya, B_i saling lepas:

$$B_i \cap B_j = \emptyset \text{ for } i \neq j$$

dan mencakup seluruh ruang sampel:

$$S = B_1 \cup B_2 \cup B_3 \cup \dots \cup B_m$$

Selain itu, misalkan peluang prior kejadian B_i bernilai positif, yaitu $P(B_i) > 0$ untuk $i = 1, \dots, m$.

Sekarang, jika A merupakan suatu kejadian, maka A dapat ditulis sebagai gabungan dari m kejadian yang saling lepas, yaitu:

$$A = (A \cap B_1) \cup (A \cap B_2) \cup \dots \cup (A \cap B_m)$$

Oleh karena itu,

$$\begin{aligned} P(A) &= P(A \cap B_1) + P(A \cap B_2) + \dots + P(A \cap B_m) \\ &= \sum_{i=1}^m P(A \cap B_i) = \sum_{i=1}^m P(B_i)P(A|B_i) \end{aligned}$$

Dengan demikian, asalkan $P(A) > 0$, peluang posterior kejadian B_k dengan syarat kejadian A telah terjadi adalah:

$$P(B_k|A) = \frac{P(B_k)P(A|B_k)}{\sum_{i=1}^m P(B_i)P(A|B_i)}$$

0.2: Distribusi

Kita akan banyak menggunakan distribusi dalam mata kuliah ini. Karena itu, penting untuk meninjau kembali definisi dan ekspektasi peubah acak. Kita mulai dengan tinjauan singkat distribusi diskret, lalu beralih ke distribusi kontinu.

Distribusi Diskret

Definisi 6 (Fungsi Massa Peluang) Untuk peubah acak diskret, X , **fungsi massa peluang** (pmf atau PMF) adalah fungsi yang memenuhi sifat-sifat berikut:

- $f(x) = P(X = x) > 0$, untuk semua $x \in$ himpunan dukungan S
- $\sum_{x \in S} f(x) = 1$
- $P(X \in A) = \sum_{x \in A} f(x)$, dengan kejadian A

Penting diperhatikan bahwa pmf adalah peluang bahwa X mengambil nilai tertentu, x .

Definisi 7 (Fungsi Distribusi Kumulatif) Untuk peubah acak diskret, X , **fungsi distribusi kumulatif** (cdf atau CDF), yang dinotasikan dengan $F(x)$ didefinisikan sebagai:

$$F(x) = P(X \leq x)$$

Cdf dari peubah acak X memiliki sifat-sifat berikut:

- $F_X(t)$ merupakan fungsi tak menurun terhadap t , untuk $-\infty < t < \infty$.
- $F_X(t)$ bernilai dari 0 sampai 1.
- Jika X merupakan peubah acak diskret dengan nilai minimum a , maka

$$F_X(a) = P(X \leq a) = P(X = a) = f_X(a)$$

Jika c lebih kecil daripada a , maka $F_X(c) = 0$.

- Jika nilai maksimum X adalah b , maka $F_X(b) = 1$.
- Disebut juga *fungsi distribusi*.
- Semua peluang yang berkaitan dengan X dapat dinyatakan dalam F .

Berikut adalah daftar beberapa distribusi diskret bernama dari mata kuliah sebelumnya. Anda perlu mengingat fungsi massa peluang, nilai harapan, dan varians dari distribusi-distribusi diskret ini.

Bernoulli: (p) dengan $0 < p < 1$

$$f(x) = p^x(1-p)^{1-x}, \quad x = 0, 1$$

$$E(X) = p, \quad \text{Var}(X) = p(1-p)$$

Catatan!

Distribusi Bernoulli merupakan kasus khusus distribusi Binomial dengan $n = 1$.

Binomial: (n, p) dengan $0 < p < 1$

$$f(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n$$

$$E(X) = np, \quad \text{Var}(X) = np(1-p)$$

Geometrik: (p) dengan $0 < p < 1$

$$f(x) = p(1-p)^x, \quad x = 0, 1, 2, 3, \dots$$

$$E(X) = \frac{1}{p}, \quad \text{Var}(X) = \frac{1-p}{p^2}$$

Binomial Negatif: (r, p) dengan $0 < p < 1$ dan $r = 1, 2, \dots$

$$f(x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, r+2, \dots$$

$$E(X) = r \left(\frac{1}{p} \right), \quad \text{Var}(X) = \frac{r(1-p)}{p^2}$$

Catatan!

Distribusi Geometrik merupakan kasus khusus distribusi Binomial Negatif dengan $r = 1$.

Hipergeometrik: (n, N_1, N_2) dengan $N_1 > 0, N_2 > 0, N = N_1 + N_2, 1 \leq n \leq N_1 + N_2$

$$f(x) = \frac{\binom{N_1}{x} \binom{N_2}{n-x}}{\binom{N}{n}}, \quad x \leq n, \quad x \leq N_1, \quad n-x \leq N_2$$

$$E(X) = n \left(\frac{N_1}{N} \right), \quad \text{Var}(X) = n \left(\frac{N_1}{N} \right) \left(\frac{N_2}{N} \right) \left(\frac{N-n}{N-1} \right)$$

Poisson: (λ) dengan $\lambda > 0$

$$f(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, 3, \dots$$

$$E(X) = \lambda, \quad \text{Var}(X) = \lambda$$

Distribusi Kontinu

Dalam bagian ini, kita menyajikan beberapa distribusi bernama untuk peubah acak kontinu.

Definisi 8 (Fungsi Kepadatan Peluang) Untuk peubah acak kontinu, X , **fungsi kepadatan peluang** (pdf atau PDF) adalah fungsi yang memenuhi sifat-sifat berikut:

- $f(x) > 0$, untuk semua $x \in$ himpunan dukungan S
- Luas di bawah kurva $f(x)$ pada himpunan dukungan sama dengan 1. Yaitu:

$$\int_{x \in S} f(x) = 1$$

- Jika A merupakan suatu interval, maka peluang bahwa x termasuk dalam A adalah:

$$P(X \in A) = \int_A f(x) dx$$

Penting diperhatikan bahwa, berbeda dengan fungsi massa peluang (pmf) dari peubah acak diskret, $f(x) \neq P(X = x)$ untuk peubah acak kontinu, X . Bahkan, $P(X = x) = 0$ jika X merupakan peubah acak kontinu.

Selanjutnya, kita akan meninjau distribusi-distribusi kontinu bernama. Sekali lagi, Anda perlu mengenali fungsi kepadatan peluang, nilai harapan, dan varians dari distribusi-distribusi kontinu ini.

Beta: (α, β) , dengan $\alpha > 0$ dan $\beta > 0$

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1$$

$$E(X) = \frac{\alpha}{\alpha + \beta}, \quad \text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta + 1)(\alpha + \beta)^2}$$

Eksponensial: (θ) , dengan $\theta > 0$

$$f(x) = \frac{1}{\theta} e^{-x/\theta}, \quad 0 < x$$

$$E(X) = \theta, \quad \text{Var}(X) = \theta^2$$

Catatan!

Distribusi eksponensial merupakan kasus khusus distribusi Gamma dengan $\alpha = 1$.

Khi-kuadrat: $\chi^2(r)$, dengan $r > 0$

$$f(x) = \frac{1}{\Gamma(r/2)2^{r/2}} x^{r/2-1} e^{-x/2}, \quad 0 < x$$
$$E(X) = r, \quad \text{Var}(X) = 2r$$

Catatan! Distribusi khi-kuadrat merupakan kasus khusus distribusi Gamma dengan $\alpha = r/2$ dan $\theta = 2$.

Gamma: (α, θ) dengan $\alpha > 0$ dan $\theta > 0$

$$f(x) = \frac{1}{\Gamma(\alpha)\theta^\alpha} x^{\alpha-1} e^{-x/\theta}, \quad x > 0$$
$$E(X) = \alpha\theta, \quad \text{Var}(X) = \alpha\theta^2$$

Normal: (μ, σ^2) dengan $\sigma > 0$

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, \quad -\infty < x < \infty$$
$$E(X) = \mu, \quad \text{Var}(X) = \sigma^2$$

Seragam: (a, b)

$$f(x) = \frac{1}{b-a}, \quad a < x < b$$
$$E(X) = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

0.3: Ekspektasi Matematis

Anda harus mampu menentukan nilai harapan dan varians suatu peubah acak, serta nilai harapan fungsi dari peubah acak. Ekspektasi akan menjadi sangat penting ketika kita mempelajari sifat-sifat penaksir dalam beberapa pelajaran berikutnya.

Definisi 9 (Ekspektasi Matematis untuk peubah acak diskret) Jika $f(x)$ merupakan fungsi massa peluang (pmf) dari peubah acak diskret X dengan himpunan dukungan S , dan jika penjumlahan

$$\sum_{x \in S} u(x)f(x)$$

ada (yaitu, nilainya lebih kecil dari ∞), maka jumlah yang dihasilkan disebut ekspektasi matematis atau nilai harapan dari fungsi $u(X)$. Ekspektasi tersebut dinotasikan dengan

$$E[u(X)] = \sum_{x \in S} u(x)f(x)$$

Definisi 10 (Ekspektasi Matematis untuk peubah acak kontinu) Untuk peubah acak kontinu, X , dengan fungsi kepadatan peluang (pdf), $f(x)$, nilai harapan fungsi dari X , $u(X)$ adalah

$$E(u(X)) = \int_{-\infty}^{\infty} u(x)f(x) dx$$

Ekspektasi matematis khusus:

- Jika $u(x) = x$ maka $E(u(X)) = \mu$
- Jika $u(x) = (x - \mu)^2$, maka $E(u(X)) = \sigma^2 = \text{Var}(X)$.

Catatan:

Ingat: $\text{Var}(X) = E(X^2) - E(X)^2$ dan oleh karena itu $E(X^2) = \sigma^2 + \mu^2$.

0.4: Distribusi Bivariat

Dalam mata kuliah ini, penting untuk mengingat kembali distribusi bivariat dan mampu memperluasnya ke distribusi multivariat. Sebuah **distribusi peluang bersama (bivariat)** menyatakan peluang bahwa suatu objek yang dipilih secara acak dari populasi memiliki dua karakteristik yang diminati.

Ingat kembali definisi fungsi massa peluang bersama (bivariat).

Def. 11 (Fungsi Massa Peluang Bersama) Misalkan X dan Y adalah dua peubah acak diskret, dan misalkan S menyatakan himpunan dukungan dua dimensi bagi X dan Y . Fungsi $f(x, y) = P(X = x, Y = y)$ merupakan **fungsi massa peluang bersama (PMF)** jika memenuhi tiga syarat berikut:

1. $0 \leq f(x, y) \leq 1$
2. $\sum_{(x,y) \in S} f(x, y) = 1$
3. $P[(X, Y) \in A] = \sum_{(x,y) \in A} f(x, y)$, dengan A merupakan subhimpunan dari himpunan dukungan S .

Def. 12 (Fungsi Kepadatan Peluang Bersama) Misalkan X dan Y adalah dua peubah acak kontinu, dan misalkan S menyatakan himpunan dukungan dua dimensi bagi X dan Y . Maka fungsi $f(x, y)$ merupakan **fungsi kepadatan peluang bersama (PDF)** jika memenuhi tiga syarat berikut:

1. $f(x, y) \geq 0$
2. $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$
3. $P[(X, Y) \in A] = \int_A f(x, y) dx dy$

dengan $\{(X, Y) \in A\}$ merupakan kejadian pada bidang xy .

Def. 13 (Fungsi Massa Peluang Marginal) Misalkan X adalah peubah acak diskret dengan himpunan dukungan S_1 , dan misalkan Y adalah peubah acak diskret dengan himpunan dukungan S_2 . Misalkan X dan Y memiliki fungsi massa peluang bersama $f(x, y)$ dengan himpunan dukungan S . Maka fungsi massa peluang X saja, yang disebut **fungsi massa peluang marginal X** , didefinisikan sebagai:

$$f_X(x) = \sum_y f(x, y) = P(X = x), \quad x \in S_1$$

dengan penjumlahan, untuk setiap x dalam himpunan dukungan S_1 , dilakukan atas semua nilai yang mungkin dari y .

Demikian pula, fungsi massa peluang Y saja, yang disebut **fungsi massa peluang marginal Y** , didefinisikan sebagai:

$$f_Y(y) = \sum_x f(x, y) = P(Y = y), \quad y \in S_2$$

dengan penjumlahan, untuk setiap y dalam himpunan dukungan S_2 , dilakukan atas semua nilai yang mungkin dari x .

Def. 14 (Fungsi Kepadatan Peluang Marginal) Misalkan X adalah peubah acak kontinu dengan himpunan dukungan S_1 , dan misalkan Y adalah peubah acak kontinu dengan himpunan dukungan S_2 . Misalkan X dan Y memiliki fungsi kepadatan peluang bersama $f(x, y)$ dengan himpunan dukungan S . Maka fungsi kepadatan peluang X saja, yang disebut **fungsi kepadatan peluang marginal X** , didefinisikan sebagai:

$$f_X(x) = \int_y f(x, y) dy, \quad x \in S_1$$

Demikian pula, fungsi kepadatan peluang Y saja, yang disebut **fungsi kepadatan peluang marginal Y** , didefinisikan sebagai:

$$f_Y(y) = \int_x f(x, y) dx, \quad y \in S_2$$

Misalkan kita ingin menentukan apakah dua peubah acak saling bebas berdasarkan distribusi peluang bersama dan distribusi marginalnya. Peubah acak X dan Y adalah **saling bebas** jika dan hanya jika

$$f(x, y) = f_X(x)f_Y(y)$$

untuk semua $x \in S_1$, $y \in S_2$. Jika tidak, X dan Y dikatakan **saling bergantung**.

Distribusi Bersyarat

Distribusi bersyarat perlu diingat kembali karena akan sangat berguna dalam mata kuliah ini, khususnya ketika kita membahas statistika Bayes.

Sebuah **distribusi peluang bersyarat** adalah distribusi peluang untuk suatu subpopulasi. Dengan kata lain, distribusi bersyarat menyatakan peluang bahwa objek yang dipilih secara acak dari suatu subpopulasi memiliki *satu karakteristik yang diminati*.

Def. 15 (Fungsi Massa Peluang Bersyarat) Fungsi **massa peluang bersyarat** dari X , dengan diketahui $Y = y$, didefinisikan sebagai:

$$g(x|y) = \frac{f(x, y)}{f_Y(y)}, \quad \text{provided } f_Y(y) > 0$$

Distribusi Jumlah Beberapa Peubah Acak

Dalam mata kuliah ini, kita perlu menentukan distribusi fungsi dari satu maupun beberapa peubah acak. Teorema-teorema berikut berguna untuk menentukan distribusi jumlah beberapa peubah acak.

Teorema 2 Misalkan $X_1, X_2, \dots, X_n$ adalah sampel acak dari distribusi Bernoulli dengan parameter p . Maka $Y = \sum_{i=1}^n X_i \sim \text{Bin}(n, p)$.

Teorema 3 Misalkan $X_1, X_2, \dots, X_n$ adalah peubah-peubah acak yang saling bebas dan masing-masing berdistribusi Binomial dengan parameter n_i dan p , untuk $i = 1, 2, \dots, n$. Maka $Y = \sum_{i=1}^n X_i \sim \text{Bin}(\sum n_i, p)$.

Teorema 4 Misalkan $X_1, X_2, \dots, X_n$ adalah peubah-peubah acak yang saling bebas dan masing-masing berdistribusi Poisson dengan parameter λ_i , untuk $i = 1, 2, \dots, n$. Maka $Y = \sum_{i=1}^n X_i \sim \text{Pois}(\sum \lambda_i)$.

Teorema 5 Misalkan $X_1, X_2, \dots, X_n$ adalah sampel acak dari distribusi Eksponensial dengan parameter θ , untuk $i = 1, 2, \dots, n$. Maka $Y = \sum_{i=1}^n X_i \sim \Gamma(\alpha = n, \theta)$.

Teorema 6 Misalkan $X_1, X_2, \dots, X_n$ adalah peubah-peubah acak yang saling bebas dan masing-masing berdistribusi Gamma dengan parameter α_i dan θ , untuk $i = 1, 2, \dots, n$. Maka $Y = \sum_{i=1}^n X_i \sim \Gamma(\sum_{i=1}^n \alpha_i, \theta)$.

Fungsi Acak yang Berkaitan dengan Distribusi Normal

Ada banyak teorema dari mata kuliah statistika sebelumnya yang perlu diingat kembali karena akan berguna

pada semester ini.

Teorema 7 Jika $X_1, X_2, \dots, X_n$ merupakan peubah-peubah acak normal yang saling bebas dengan rata-rata $\mu_1, \mu_2, \dots, \mu_n$ dan varians $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$, berturut-turut, maka kombinasi linearnya:

$$Y = \sum_{i=1}^n c_i X_i$$

mengikuti distribusi Normal:

$$N\left(\sum_{i=1}^n c_i \mu_i, \sum_{i=1}^n c_i^2 \sigma_i^2\right)$$

Akibat 1 Jika $X_1, X_2, \dots, X_n$ merupakan pengamatan dari sampel acak berukuran n dari populasi $N(\mu, \sigma^2)$, maka rata-rata sampelnya:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

berdistribusi normal dengan rata-rata μ dan varians $\frac{\sigma^2}{n}$.

Teorema 8 Misalkan $X_1, X_2, \dots, X_n$ merupakan pengamatan dari sampel acak berukuran n dari distribusi Normal $N(\mu, \sigma^2)$. Misalkan $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ dan $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ masing-masing adalah rata-rata sampel dan varians sampel. Maka, $\bar{X}$ dan S^2 saling bebas. Selain itu,

$$\frac{(n-1)S^2}{\sigma^2}$$

mengikuti distribusi khi-kuadrat dengan $n - 1$ derajat kebebasan.

Def. 16 (Distribusi t) Jika $Z \sim N(0, 1)$ dan $U \sim \chi^2(r)$ saling bebas, maka peubah acak

$$T = \frac{Z}{\sqrt{\frac{U}{r}}}$$

mengikuti distribusi t dengan r derajat kebebasan.

Teorema 9 (Teorema Limit Pusat) Misalkan $X_1, X_2, \dots, X_n$ adalah sampel acak dari suatu distribusi dengan rata-rata hingga μ dan varians hingga σ^2 . Jika ukuran sampel, n , cukup besar, maka:

- rata-rata sampel $\bar{X}$ mengikuti distribusi normal secara hampiran
- dengan rata-rata $\mu_{\bar{X}} = \mu$
- dan varians $\sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$.

0.5: Contoh Tinjauan

Pada bagian ini, kami menyajikan beberapa contoh untuk membantu Anda mengingat kembali materi dari mata kuliah Pengantar Peluang.

Contoh 1 Seorang perempuan yang semula diperkirakan memiliki risiko kanker sebesar 1% memperoleh hasil mamogram positif. Mamogram mengklasifikasikan dengan tepat sekitar 80% tumor ganas dan 90% tumor jinak. Berapakah peluang perempuan tersebut mengidap kanker jika diketahui hasil mamogramnya positif?

Penyelesaian Misalkan kejadian C menyatakan kanker dan kejadian P menyatakan hasil positif. Kita mengetahui: $P(C) = 0.01$ dan dengan demikian $P(C') = 1 - P(C) = 1 - 0.01 = 0.99$. Selain itu, $P(P|C) = 0.8$ dan $P(P|C') = 0.9$, yang menyiratkan $P(P|C') = 0.1$. Dengan menggabungkan semuanya, kita memperoleh:

$$P(C|P) = \frac{P(P|C)P(C)}{P(P|C)P(C) + P(P|C')P(C')} = \frac{0.8(0.01)}{0.8(0.01) + 0.1(0.99)} = 0.075$$

Contoh 2 Ketika Anda memasukkan uang ke mesin kopi di Student Center, sebuah gelas kertas turun lalu diisi kopi. Anda seharusnya memperoleh 8 oz kopi. Namun, banyaknya kopi yang benar-benar dikeluarkan merupakan peubah acak normal dengan nilai harapan yang sama dengan setelan mesin dan varians sebesar 0,0625 oz.

Berapakah setelan mesin yang diperlukan agar, dalam jangka panjang, hanya 2% minuman berisi kurang dari 8 oz?

Penyelesaian

$$P(X \leq 8) = P\left(Z \leq \frac{8 - \mu}{\sqrt{0.0625}}\right) = 0.02, \quad \text{table value } -2.0537$$
$$-2.0537 = \frac{8 - \mu}{\sqrt{0.0625}} \Rightarrow \mu = 8.513425$$

Contoh 3 Misalkan peubah acak X memiliki fungsi kepadatan peluang (pdf) berikut

$$f(x) = \begin{cases} cx^2, & -1 \leq x < 0 \\ cx, & 0 \leq x \leq 2 \\ 0, & \text{otherwise} \end{cases}$$

dengan c merupakan suatu konstanta.

1. Tentukan nilai c agar fungsi di atas merupakan fungsi kepadatan peluang yang sah.
2. Tentukan nilai harapan peubah acak tersebut.
3. Tentukan fungsi distribusi kumulatif (cdf) dari X .
4. Tentukan median peubah acak tersebut.

Penyelesaian

$$1. \frac{1}{c} = \int_{-1}^0 x^2 dx + \int_0^2 x dx = \frac{1}{3} x^3 \Big|_{-1}^0 + \frac{1}{2} x^2 \Big|_0^2 = \frac{1}{3} + 2 = \frac{7}{3}, \quad c = \frac{3}{7}$$

$$2. E(X) = \int_{-1}^0 \frac{3}{7} x^3 dx + \int_0^2 \frac{3}{7} x^2 dx = \frac{3}{28} x^4 \Big|_{-1}^0 + \frac{1}{7} x^3 \Big|_0^2 = -\frac{3}{28} + \frac{8}{7} = \frac{29}{28}$$

$$3. F(x) = \begin{cases} \int_{-1}^x \frac{3}{7}x^2 dx = \frac{1}{7}x^3 \Big|_{-1}^x = \frac{1}{7}(x^3 + 1), & -1 \leq x < 0 \\ \frac{1}{7} + \int_0^x \frac{3}{7}x dx = \frac{1}{7} + \frac{3}{14}x^2, & 0 \leq x < 2 \\ 1, & x \geq 2 \end{cases}$$

$$4. 0.5 = \frac{1}{7} + \frac{3}{14}x^2, \quad \Rightarrow \frac{5}{14} = \frac{3}{14}x^2, \quad \Rightarrow x = \sqrt{\frac{5}{3}} \approx 1.29$$

Contoh 4 Masa pakai (dalam bulan) dua komponen sebuah mesin memiliki fungsi kepadatan peluang bersama

$$f(x, y) = c(50 - x - y), \quad 0 < x < 50 - y < 50$$

dan bernilai nol untuk kasus lainnya.

1. Tentukan konstanta c , agar $f(x, y)$ merupakan fungsi kepadatan peluang bersama yang sah. Anda boleh membiarkan konstanta tersebut dalam bentuk c .
2. Tentukan distribusi marginalnya.
3. Tentukan distribusi bersyarat dari X jika diketahui $Y = y$. Jika memudahkan, Anda boleh membiarkan konstanta tersebut dalam bentuk c .

Penyelesaian

$$\frac{1}{c} = \int_0^{50} \int_0^{50-y} 50 - x - y \, dx \, dy = \int_0^{50} \left[50x - \frac{1}{2}x^2 - yx \Big|_0^{50-y} \right] dy$$

$$1. = \int_0^{50} \frac{1}{2}y^2 - 50y + 1250 \, dy = \frac{1}{6}y^3 - 25y^2 + 1250y \Big|_0^{50} = \frac{125000}{6}$$

$$\Rightarrow c = \frac{6}{125000}$$

$$2. f(x) = c \int_0^{50-x} 50 - x - y \, dy = \frac{c}{2}(x - 50)^2, \quad 0 \leq x \leq 50$$

$$f(y) = c \int_0^{50-y} 50 - x - y \, dx = \frac{c}{2}(y - 50)^2, \quad 0 \leq y \leq 50$$

$$3. f(x|y) = \frac{f(x, y)}{f(y)} = \frac{c(50 - x - y)}{\frac{c}{2}(y - 50)^2} = \frac{2(50 - x - y)}{(y - 50)^2}, \quad 0 < x < 50 - y$$

Contoh 5 Misalkan cdf dari peubah acak diskret X adalah

$$F(x) = \frac{x(x+1)}{20}, \quad x = 1, 2, 3, 4.$$

1. Tentukan fungsi massa peluang (pmf) dari X . Anda boleh menyajikannya dalam bentuk tabel.
2. Tentukan persentil 30^{th} dari X .
3. Tentukan nilai harapan dari X .
4. Tentukan simpangan baku dari X .

Penyelesaian

1. Ingat bahwa cdf didefinisikan sebagai $F(x) = P(X \leq x)$. Mulailah dengan $x = 1$. Kita mengetahui $F(1) = P(X \leq 1)$. Karena tidak ada nilai yang lebih kecil dari 1, diperoleh

$$F(1) = P(X \leq 1) = P(X = 1) = \frac{1(2)}{20} = \frac{2}{20}$$
$$f(1) = P(X = 1) = \frac{1}{10}$$

Selanjutnya, tinjau $x = 2$.

$$F(2) = P(X \leq 2) = \frac{2(3)}{20} = \frac{3}{10} = 0.3$$

Kita juga mengetahui bahwa

$$F(2) = P(X \leq 2) = P(X = 1) + P(X = 2)$$

Oleh karena itu,

$$0.3 = P(X = 1) + P(X = 2),$$
$$P(X = 2) = 0.3 - P(X = 1) = 0.3 - 0.1 = 0.2$$

Dengan demikian, $f(2) = P(X = 2) = 0.2$. Dengan cara yang sama, kita dapat melanjutkan untuk menentukan pmf bagi nilai-nilai x lainnya. Bentuk tabel pmf dari X adalah:

x	1	2	3	4
$f(x)$	0.1	0.2	0.3	0.4

2. Tentukan persentil 30th dari X .

$$0.3 = \frac{x(x+1)}{20} \Rightarrow 6 = x^2 + x \Rightarrow x^2 + x - 6 = 0$$
$$= (x+3)(x-2) = 0 \Rightarrow x = 2$$

3. Tentukan nilai harapan dari X .

$$E(X) = 0(0) + 1\left(\frac{2}{20}\right) + 2\left(\frac{4}{20}\right) + 3\left(\frac{6}{20}\right) + 4\left(\frac{8}{20}\right) = \frac{60}{20} = 3$$

4. Tentukan simpangan baku dari X .

$$E(X^2) = 0(0) + 1\left(\frac{2}{20}\right) + 4\left(\frac{4}{20}\right) + 9\left(\frac{6}{20}\right) + 16\left(\frac{8}{20}\right) = \frac{200}{20} = 10$$
$$\text{Var}(X) = E(X^2) - E(X)^2 = 10 - 3^2 = 10 - 9 = 1$$
$$\text{SD}(X) = \sqrt{1} = 1$$

0.6: Garis Besar STAT 415

Misalkan kita memperoleh data x dari suatu model statistik dengan parameter yang tidak diketahui θ . Bayangkan bahwa θ mengindeks suatu keluarga distribusi yang mungkin bagi x , dan bahwa nilai sebenarnya dari θ menentukan proses pembangkitan data yang sebenarnya. Selanjutnya, kita akan mempertimbangkan pertanyaan-pertanyaan seperti:

Estimasi Titik: Apa yang dimaksud dengan penaksir yang **baik** untuk θ ? Jawabannya bergantung pada definisi 'baik', dan kita akan memperkenalkan beberapa kriteria untuk menilai penaksir. Menyajikan penaksir titik $\hat{\theta}$ saja tanpa gambaran mengenai ketidakpastiannya biasanya tidak memuaskan. Karena itu, inferensi statistik

menekankan agar penaksir titik disertai informasi mengenai ketidakpastiannya; misalnya, kita mungkin dapat menjelaskan distribusi $\hat{\theta}$ atau setidaknya menyebutkan simpangan bakunya. Simpangan baku suatu penaksir disebut galat baku.

Estimasi Interval: Secara intuitif, pernyataan seperti “Saya menaksir θ sebesar 2,5” akan jauh lebih informatif jika disertai suatu interval, misalnya dengan mengatakan:

“Saya yakin 95% bahwa θ berada dalam interval tertutup antara 2,3 dan 2,8.”

Namun, apa arti ‘yakin’ di sini? Dalam mata kuliah ini, kita akan mendefinisikan secara tepat makna pemberian estimasi interval dan mempelajari berbagai cara untuk menyusun estimasi tersebut.

Jika θ merupakan konstanta, maka nilainya pasti berada atau tidak berada dalam interval $[2.3, 2.8]$; jadi, apa arti 95% tersebut?

Uji Hipotesis (evaluasi model): Dalam banyak penerapan di bidang ilmu fisik, biologi, dan sosial, seorang peneliti ingin menguji hipotesis yang dapat dinyatakan dalam bentuk $\theta = \theta_0$ atau, secara lebih umum, sebagai $\theta \in H_0$ untuk suatu himpunan H_0 . Uji hipotesis berkaitan erat dengan estimasi interval—dan dapat dikatakan bahwa estimasi interval lebih berguna—serta dapat ditinjau dari berbagai sudut pandang.

1. [Pelajaran](#)
2. [1 Statistik Urutan](#)

1 Statistik Urutan

Statistik Urutan
Fungsi Kepadatan Peluang

Gambaran Umum

Biasanya kita tidak memberikan perhatian khusus pada urutan sekumpulan peubah acak $X_1, X_2, \dots, X_n$. Namun, bagaimana jika urutannya kita perhatikan? Misalkan, sebagai contoh, kita perlu mengetahui peluang bahwa nilai terbesar ketiga kurang dari 72. Atau, misalkan kita perlu mengetahui persentil ke-80 dari suatu sampel acak denyut jantung. Dalam kedua kasus tersebut, kita perlu memahami perilaku data setelah diurutkan. Dengan kata lain, kita perlu memahami fungsi kepadatan peluang dari statistik urutan $Y_1, Y_2, \dots, Y_n$. Itulah yang akan kita bahas dalam pelajaran ini.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Mengidentifikasi statistik urutan berdasarkan definisinya,
2. Menurunkan fungsi kepadatan peluang untuk statistik urutan dengan indeks r^{th} tersebut, dan
3. Menurunkan fungsi distribusi kumulatif untuk statistik urutan dengan indeks r^{th} tersebut.

1.1 Konsep Dasar

Contoh 1.1 Mari kita memotivasi definisi sekumpulan statistik urutan melalui sebuah contoh sederhana.

Misalkan sebuah sampel acak yang terdiri atas lima ekor tikus menghasilkan bobot berikut (dalam gram):

$$x_1 = 602 \quad x_2 = 781 \quad x_3 = 709 \quad x_4 = 742 \quad x_5 = 633$$

Apa statistik urutan teramati dari kumpulan data ini?

Penyelesaian

Bahkan tanpa mengetahui definisi formal statistik urutan, kita tidak perlu menjadi ilmuwan roket untuk menyadari bahwa data harus disusun dalam urutan numerik menaik. Dengan demikian, statistik urutan yang teramati adalah:

$$y_1 = 602 < y_2 = 633 < y_3 = 709 < y_4 = 742 < y_5 = 781$$

Satu-satunya hal yang mungkin menyulitkan dalam contoh sederhana ini adalah jika dua tikus memiliki bobot yang sama, karena nilai yang sama memang mungkin teramati. Namun, kita akan mengesampingkan peluang terjadinya hal itu dengan membuat asumsi yang berlaku sepanjang pelajaran ini—dan seterusnya. **Kita akan mengasumsikan bahwa n pengamatan yang saling bebas berasal dari suatu distribusi kontinu, sehingga peluang bahwa dua pengamatan mana pun bernilai sama adalah nol.** Tentu saja, dalam praktiknya nilai yang sama masih mungkin dijumpai. Namun, asumsi bahwa peluang terjadinya nilai yang sama nyaris nol memungkinkan kita mengembangkan teori distribusi statistik urutan yang setidaknya berlaku sebagai hampiran ketika nilai yang sama muncul. Selanjutnya, mari kita definisikan sekumpulan statistik urutan secara formal.

Def. 1.1 (Statistik Urutan) Jika $X_1, X_2, \dots, X_n$ merupakan pengamatan dari sampel acak berukuran n dari suatu distribusi kontinu, kita menetapkan peubah-peubah acak:

$$Y_1 < Y_2 < \dots < Y_n$$

menyatakan statistik urutan sampel tersebut, dengan:

Y_1 merupakan nilai terkecil di antara $X_1, X_2, \dots, X_n$ tersebut

Y_2 merupakan nilai terkecil kedua di antara $X_1, X_2, \dots, X_n$ tersebut


....

Y_{n-1} merupakan nilai terbesar kedua di antara $X_1, X_2, \dots, X_n$ tersebut

Y_n merupakan nilai terbesar di antara $X_1, X_2, \dots, X_n$ tersebut

Sekarang, kita akan secara bertahap mencari fungsi kepadatan peluang untuk setiap anggota dari n statistik urutan tersebut, yakni statistik urutan dengan indeks r^{th} yang dilambangkan dengan Y_r . Dengan demikian, kita dapat memahami perilaku statistik urutan dan memakai pengetahuan itu untuk menarik kesimpulan, misalnya tentang mobil tercepat dalam perlombaan atau tikus terberat pada pola makan tertentu. Untuk mencari fungsi kepadatan peluang, kita akan menggunakan teknik fungsi distribusi. Mungkin sudah cukup lama sejak teknik ini terakhir digunakan. Sebagai pengingat, strategi kita adalah terlebih dahulu mencari fungsi distribusi $G_r(y)$ dari statistik urutan dengan indeks r^{th} tersebut, lalu mengambil turunannya untuk memperoleh fungsi kepadatan peluang $g_r(y)$ bagi statistik urutan dengan indeks r^{th} tersebut. Namun, pembahasan kita sudah sedikit melompat ke depan. Itulah yang akan kita lakukan pada halaman berikutnya. Agar pembahasan tersebut lebih mudah dipahami, mari kita lihat dahulu sebuah contoh konkret di sini.

Contoh 1.2



Misalkan $Y_1 < Y_2 < Y_3 < Y_4 < Y_5 < Y_6$ adalah statistik urutan yang berkaitan dengan $n = 6$ pengamatan saling bebas yang masing-masing berasal dari distribusi dengan fungsi kepadatan peluang:


$$f(x) = \frac{1}{2}x$$

untuk $0 < x < 2$.

1. Berapakah peluang bahwa statistik urutan terbesar kedua, yaitu Y_5 , bernilai kurang dari 1? Dengan kata lain, berapakah $P(Y_5 < 1)$?


Penyelesaian

Kunci untuk menemukan peluang yang diminta adalah menyadari bahwa satu-satunya cara statistik urutan kelima, Y_5 , bernilai kurang dari satu adalah jika sedikitnya 5 dari peubah acak $X_1, X_2, X_3, X_4, X_5, X_6$ bernilai kurang dari satu. Untuk mempermudah, misalkan lima nilai teramati pertama x_1, x_2, x_3, x_4, x_5 bernilai kurang dari satu, tetapi nilai keenam x_6 tidak demikian. Dalam hal ini, statistik urutan kelima yang teramati, y_5 , akan bernilai kurang dari satu:



Gambar 1.1

Statistik urutan kelima yang teramati, y_5 , juga akan bernilai kurang dari satu jika keenam nilai teramati $x_1, x_2, x_3, x_4, x_5, x_6$ bernilai kurang dari satu:



Gambar 1.2

Statistik urutan kelima yang teramati, y_5 , tidak akan bernilai kurang dari satu jika empat nilai teramati pertama x_1, x_2, x_3, x_4 bernilai kurang dari satu, tetapi nilai kelima x_5 dan nilai keenam x_6 tidak demikian:



Gambar 1.3

Sekali lagi, satu-satunya cara statistik urutan kelima, Y_5 , bernilai kurang dari satu adalah jika 5 atau 6—yakni, sedikitnya 5—dari peubah acak X_1, X_2, X_3, X_4, X_5 , and X_6 bernilai kurang dari satu. Untuk mempermudah, kita hanya meninjau lima atau enam peubah acak pertama. Namun, sebenarnya sembarang lima atau enam peubah acak yang bernilai kurang dari satu akan menghasilkan keadaan yang sama. Kita hanya perlu melakukan “pemilihan” untuk menghitung banyaknya cara memperoleh sembarang lima atau enam peubah acak yang bernilai kurang dari satu.

Jika kita perhatikan, ini merupakan perhitungan peluang binomial. Jika kejadian $\{X_i < 1\}, i = 1, 2, \dots, 6$ dianggap sebagai “keberhasilan,” dan kita misalkan Z = banyaknya keberhasilan dalam enam percobaan yang saling bebas, maka Z merupakan peubah acak binomial dengan $n = 6$ dan $p = 0.25$:

$$P(X_i \leq 1) = \frac{1}{2} \int_0^1 x dx = \frac{1}{2} \left[\frac{x^2}{2} \right]_{x=0}^{x=1} = \frac{1}{2} \left(\frac{1}{2} - 0 \right) = \frac{1}{4}$$

Menentukan peluang bahwa statistik urutan kelima, Y_5 , kurang dari satu dapat direduksi menjadi perhitungan binomial. Yaitu:

$$P(Y_5 < 1) = P(Z = 5) + P(Z = 6) = \binom{6}{5} \left(\frac{1}{4} \right)^5 \left(\frac{3}{4} \right)^1 + \binom{6}{6} \left(\frac{1}{4} \right)^6 \left(\frac{3}{4} \right)^0 = 0.0046$$

Kecilnya peluang yang dihitung tersebut semestinya masuk akal jika kita memperhatikan fungsi kepadatan peluang yang diberikan untuk X . Lagi pula, setiap X_i lebih berpeluang berada di atas daripada di bawah satu. Karena itu, tidak lazim jika sebanyak lima atau enam peubah yang dilambangkan X , semuanya bernilai kurang dari satu.

2. **Apa fungsi distribusi kumulatif, $G_5(y)$, dari statistik urutan kelima Y_5 ?**

Penyelesaian

Mengingat kembali definisi fungsi distribusi kumulatif, $G_5(y)$ didefinisikan sebagai peluang bahwa statistik urutan kelima Y_5 kurang dari suatu nilai y . Yaitu:

$$G_5(y) = P(Y_5 < y)$$

Dalam perhitungan di atas, kita telah menentukan peluang bahwa statistik urutan kelima Y_5 kurang dari nilai tertentu, yaitu 1. Kita hanya perlu menggeneralisasi perhitungan tersebut agar berlaku untuk sembarang nilai y . Jika kejadian $\{X_i < y\}$, $i = 1, 2, \dots, 6$ dianggap sebagai “keberhasilan,” dan kita misalkan Z = banyaknya keberhasilan dalam enam percobaan yang saling bebas, maka Z merupakan peubah acak binomial dengan $n = 6$ dan peluang keberhasilan:

$$P(X_i \leq y) = \frac{1}{2} \int_0^y x dx = \frac{1}{2} \left[\frac{x^2}{2} \right]_{x=0}^{x=y} = \frac{1}{2} \left(\frac{y^2}{2} - 0 \right) = \frac{y^2}{4}$$

Oleh karena itu, fungsi distribusi kumulatif $G_5(y)$ dari statistik urutan kelima Y_5 adalah:

$$G_5(y) = P(Y_5 < y) = P(Z = 5) + P(Z = 6) = \binom{6}{5} \left(\frac{y^2}{4} \right)^5 \left(1 - \frac{y^2}{4} \right) + \left(\frac{y^2}{4} \right)^6$$

untuk $0 < y < 2$.

3. **Apa fungsi kepadatan peluang, $g_5(y)$, dari statistik urutan kelima Y_5 ?**

Penyelesaian

Untuk menentukan fungsi kepadatan peluang $g_5(y)$ kita cukup mengambil turunan fungsi distribusi $G_5(y)$ terhadap y . Dengan demikian, diperoleh:

$$g_5(y) = G'_5(y) = \binom{6}{5} \left(\frac{y^2}{4} \right)^5 \left(\frac{-2y}{4} \right) + \binom{6}{5} \left(1 - \frac{y^2}{4} \right) 5 \left(\frac{y^2}{4} \right)^4 \left(\frac{2y}{4} \right) + 6 \left(\frac{y^2}{4} \right)^5 \left(\frac{2y}{4} \right)$$

Dengan memperhatikan bahwa:

$$\binom{6}{5} = 6 \text{ and } \binom{6}{5} \times 5 = \frac{6!}{5!1!} \times 5 = \frac{6!}{4!1!}$$

kita melihat bahwa suku tengah dapat disederhanakan, sedangkan suku pertama merupakan negatif dari suku ketiga; karena itu, keduanya saling meniadakan:

$$g_5(y) = \binom{6}{5} \left(\frac{y^2}{4} \right)^5 \left(\frac{-2y}{4} \right) + \frac{6!}{4!1!} \left(1 - \frac{y^2}{4} \right) \left(\frac{y^2}{4} \right)^4 \left(\frac{2y}{4} \right) + 6 \left(\frac{y^2}{4} \right)^5 \left(\frac{2y}{4} \right)$$

Oleh karena itu, fungsi kepadatan peluang statistik urutan kelima Y_5 adalah:

$$g_5(y) = \frac{6!}{4!1!} \left(1 - \frac{y^2}{4} \right) \left(\frac{y^2}{4} \right)^4 \left(\frac{1}{2} y \right)$$

untuk $0 < y < 2$. Ketika kita menggeneralisasi hasil ini pada halaman berikutnya, perlu dicatat bahwa karena fungsi kepadatan dan fungsi distribusi setiap X masing-masing adalah:

$$f(x) = \frac{1}{2}x \text{ and } F(x) = \frac{x^2}{4}$$

secara berurutan, ketika $0 < x < 2$, kita juga dapat menulis fungsi kepadatan peluang statistik urutan kelima Y_5 sebagai:

$$g_5(y) = \frac{6!}{4!1!} [F(y)]^4 [1 - F(y)] f(y)$$

Selesai!

Baik, sekarang mari kita lanjutkan ke kasus yang lebih umum, yaitu menentukan fungsi kepadatan peluang untuk statistik urutan dengan indeks r^{th} tersebut.

1.2 Fungsi Kepadatan Peluang

Perhitungan pada halaman sebelumnya untuk menentukan fungsi kepadatan peluang suatu statistik urutan tertentu, yakni statistik urutan kelima dari sekumpulan enam peubah acak, akan membantu ketika kita menentukan fungsi kepadatan peluang sembarang statistik urutan, yaitu statistik urutan dengan indeks r^{th} tersebut.

Teorema 1.1 Misalkan $Y_1 < Y_2 < \dots < Y_n$ merupakan statistik urutan dari n pengamatan yang saling bebas dan berasal dari distribusi kontinu dengan fungsi distribusi kumulatif $F(x)$ dan fungsi kepadatan peluang:

$$f(x) = F'(x)$$

dengan $0 < F(x) < 1$ pada himpunan dukungan $a < x < b$. Maka, fungsi kepadatan peluang statistik urutan r^{th} adalah:

$$g_r(y) = \frac{n!}{(r-1)!(n-r)!} [F(y)]^{r-1} [1 - F(y)]^{n-r} f(y)$$

pada himpunan dukungan $a < y < b$.

Bukti

Sekali lagi, kita mengikuti strategi dengan terlebih dahulu menentukan fungsi distribusi kumulatif $G_r(y)$ dari statistik urutan r^{th} tersebut, lalu menurunkan terhadap y untuk memperoleh fungsi kepadatan peluang $g_r(y)$. Sekarang, jika kejadian $\{X_i \leq y\}$, $i = 1, 2, \dots, n$ dianggap sebagai “keberhasilan,” dan kita misalkan Z = banyaknya keberhasilan tersebut dalam n percobaan yang saling bebas, maka Z merupakan peubah acak binomial dengan n percobaan dan peluang keberhasilan:

$$F(y) = P(X_i \leq y)$$

Sekarang, untuk statistik urutan dengan indeks r^{th} yang dilambangkan dengan Y_r berlaku bahwa nilainya kurang dari atau sama dengan y hanya jika sekurang-kurangnya r dari n pengamatan $x_1, x_2, \dots, x_n$ bernilai kurang dari atau sama dengan y , yang menyiratkan:

$$G_r(y) = P(Y_r \leq y) = P(Z = r) + P(Z = r + 1) + \dots + P(Z = n)$$

yang dapat ditulis dengan notasi penjumlahan sebagai:

$$G_r(y) = \sum_{k=r}^n P(Z = k)$$

Sekarang, kita dapat mengganti $P(Z = k)$ dengan fungsi massa peluang dari peubah acak binomial berparameter n dan $p = F(y)$. Dengan demikian, kita memperoleh:

$$G_r(y) = \sum_{k=r}^n \binom{n}{k} [F(y)]^k [1 - F(y)]^{n-k}$$

Dengan sedikit menulis ulang dan mengeluarkan suku berindeks n^{th} dari notasi penjumlahan, kita memperoleh:

$$G_r(y) = \sum_{k=r}^{n-1} \binom{n}{k} [F(y)]^k [1 - F(y)]^{n-k} + [F(y)]^n$$

Selanjutnya, kita tinggal mengambil turunan dari $G_r(y)$ terhadap y . Dengan menerapkan aturan hasil kali bersama aturan rantai pada suku-suku dalam penjumlahan, serta aturan pangkat bersama aturan rantai, kita memperoleh:

$$\begin{aligned} g_r(y) &= \sum_{k=r}^{n-1} \binom{n}{k} (k) [F(y)]^{k-1} f(y) [1 - F(y)]^{n-k} \\ &+ \sum_{k=r}^{n-1} \binom{n}{k} [F(y)]^k (n-k) [1 - F(y)]^{n-k-1} (-f(y)) \\ &+ n [F(y)]^{n-1} f(y) \end{aligned} \quad (1.1)$$

Selanjutnya, kita cukup mengenali bahwa:

$$\binom{n}{k} k = \frac{n!}{\underbrace{k!}_{\cancel{k}(k-1)!}} (n-k)! \times \cancel{k} = \frac{n!}{(k-1)!(n-k)!}$$

dan

$$\binom{n}{k} (n-k) = \frac{n!}{k! \underbrace{(n-k)!}_{(\cancel{n-k})(n-k-1)!}} \times \cancel{(n-k)} = \frac{n!}{k!(n-k-1)!}$$

Setelah itu, kita melihat bahwa PDF statistik urutan dengan indeks r^{th} yang dilambangkan dengan Y_r hanyalah suku pertama dalam penjumlahan pada $g_r(y)$. Dengan kata lain:

$$g_r(y) = \frac{n!}{(r-1)!(n-r)!} [F(y)]^{r-1} [1 - F(y)]^{n-r} f(y)$$

untuk $a < y < b$. Terbukti! Cukup sederhana! Baiklah, mungkin agak berlebihan menyebutnya sederhana karena langkahnya memang tidak sepenuhnya jelas, bukan? Sebagai latihan, Anda akan diminta menuliskan, untuk kasus $n = 6$ dan $r = 3$, suku-suku dalam [Persamaan 1.1](#). Dengan mengerjakannya, Anda akan melihat bahwa setiap suku positif dalam persamaan berbintang, kecuali suku pertama, mempunyai pasangan suku negatif; karena itu, semua suku selain yang pertama saling meniadakan. Setelah Anda menyelesaikan latihan tersebut, barulah mungkin wajar menyebutnya cukup sederhana!

Contoh 1.3 Misalkan $Y_1 < Y_2 < Y_3 < Y_4 < Y_5 < Y_6$ merupakan statistik urutan yang berkaitan dengan $n = 6$ pengamatan yang saling bebas, masing-masing berasal dari distribusi dengan fungsi kepadatan peluang:

$$f(x) = \frac{1}{2}x$$

untuk $0 < x < 2$. Apa fungsi kepadatan peluang dari statistik urutan pertama, keempat, dan keenam?

Penyelesaian

Ketika mengerjakan contoh ini pada halaman sebelumnya, kita telah menunjukkan bahwa fungsi distribusi kumulatif dari X adalah:

$$F(x) = \frac{x^2}{4}$$

untuk $0 < x < 2$. Oleh karena itu, dengan menerapkan teorema di atas untuk $n = 6$ dan $r = 1$, fungsi kepadatan peluang (PDF) dari Y_1 adalah:

$$g_1(y) = \frac{6!}{0!(6-1)!} \left[\frac{y^2}{4} \right]^{1-1} \left[1 - \frac{y^2}{4} \right]^{6-1} \left(\frac{1}{2}y \right)$$

untuk $0 < y < 2$, yang dapat disederhanakan menjadi:

$$g_1(y) = 3y \left(1 - \frac{y^2}{4} \right)^5$$

Dengan menerapkan teorema untuk $n = 6$ dan $r = 4$, fungsi kepadatan peluang (PDF) dari Y_4 adalah:

$$g_4(y) = \frac{6!}{3!(6-4)!} \left[\frac{y^2}{4} \right]^{4-1} \left[1 - \frac{y^2}{4} \right]^{6-4} \left(\frac{1}{2}y \right)$$

untuk $0 < y < 2$, yang dapat disederhanakan menjadi:

$$g_4(y) = \frac{15}{32} y^7 \left(1 - \frac{y^2}{4} \right)^2$$


Dengan menerapkan teorema untuk $n = 6$ dan $r = 6$, fungsi kepadatan peluang (PDF) dari Y_6 adalah:

$$g_6(y) = \frac{6!}{5!(6-6)!} \left[\frac{y^2}{4} \right]^{6-1} \left[1 - \frac{y^2}{4} \right]^{6-6} \left(\frac{1}{2}y \right)$$

untuk $0 < y < 2$, yang dapat disederhanakan menjadi:

$$g_6(y) = \frac{3}{1024} y^{11}$$

Untungnya, ketika ketiga fungsi tersebut kita gambarkan pada satu plot:



Gambar 1.4: Plot kepadatan untuk $r = 1, 4, 6$

kita memperoleh hasil yang masuk akal secara intuitif: ketika peringkat statistik urutan meningkat, PDF tersebut “bergeser ke kanan” pada selang dukungan.

1.3 Ringkasan

Dalam pelajaran ini, kita mengeksplorasi gagasan baru yang awalnya mungkin terasa agak berbeda—apa yang terjadi jika urutan data benar-benar penting bagi kita? Alih-alih sekadar melihat sekumpulan nilai dari sampel acak, kita mengajukan pertanyaan seperti: berapa peluang nilai terkecil ketiga berada di bawah suatu angka? Atau, seperti apa distribusi pengamatan terbesar? Pertanyaan-pertanyaan seperti ini membawa kita ke ranah statistik urutan.

Kita mempelajari cara mendefinisikan dan mengidentifikasi statistik urutan, seperti nilai terkecil, terbesar, atau nilai terkecil ke- r dalam suatu sampel. Selanjutnya, kita mempelajari cara menentukan fungsi distribusi kumulatif (CDF) dan fungsi kepadatan peluang (PDF) dari statistik urutan tertentu. Menariknya, fungsi-fungsi tersebut dapat diturunkan dengan alat yang sudah kita kenal—seperti distribusi binomial dan kalkulus. Anda telah melihat bahwa PDF statistik urutan bergeser sesuai peringkat yang ditinjau (misalnya, yang terkecil dibandingkan yang terbesar), sehingga membantu menjelaskan pola dalam data dunia nyata, seperti kejadian cuaca ekstrem atau nilai ujian.

Pelajaran ini menyiapkan kita untuk menggunakan statistik urutan dalam masalah inferensi dan penerapan nyata—setiap kali yang penting bukan hanya datanya, melainkan juga bagaimana data tersebut diurutkan.

Pokok-Pokok Penting:

- Jika $X_1, X_2, \dots, X_n$, yang merupakan sampel acak sederhana berukuran n , diurutkan dari nilai terkecil hingga nilai terbesar, statistik urutannya, yang dinotasikan dengan $Y_1, Y_2, \dots, Y_n$ memenuhi sifat bahwa Y_i merupakan pengamatan berperingkat i^{th} dalam urutan menaik di antara $X_1, X_2, \dots, X_n$ dan $Y_1 < Y_2 < \dots < Y_n$
- Fungsi kepadatan peluang statistik urutan dengan indeks r^{th} adalah:
$$g_r(y) = \frac{n!}{(n-r)!(r-1)!} [F(y)]^{r-1} [1 - F(y)]^{n-r} f(y)$$

1. [Pelajaran](#)
2. [2 Pendugaan \(Bagian I\)](#)

2 Pendugaan (Bagian I)

Pendugaan Titik
Pendugaan Tak Bias
Bias
Varians dan Rataan Kuadrat
Faktorisasi
Kecukupan
Metode Momen

Gambaran Umum

Pelajaran ini memperkenalkan konsep-konsep mendasar pendugaan titik, yang merupakan salah satu landasan inferensi statistik. Anda akan mempelajari cara menduga parameter populasi yang tidak diketahui, seperti rata-rata dan proporsi, dengan menggunakan data sampel. Melalui pelajaran ini, Anda akan mengembangkan keterampilan untuk menghitung nilai dugaan kemungkinan maksimum bagi berbagai model berparameter tunggal serta mengevaluasi kualitas penduga berdasarkan sifat-sifat utama seperti bias, varians, dan rata-rata kuadrat galat. Contoh-contoh praktis, termasuk menduga cakupan asuransi kesehatan di kalangan mahasiswa dan menganalisis tingkat kematian akibat COVID-19, akan mengilustrasikan konsep-konsep tersebut. Pada akhir pelajaran ini, Anda akan memiliki pemahaman yang kukuh tentang pendugaan titik dan siap mempelajari topik-topik lanjutan dalam pendugaan statistik.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Menentukan distribusi penduga,
2. Menghitung dan menafsirkan bias suatu penduga,
3. Menghitung varians dan rata-rata kuadrat galat suatu penduga, serta
4. Menggunakan sifat-sifat penduga untuk membandingkan dan mengidentifikasi penduga yang lebih baik berdasarkan kriteria tertentu.

2.1 Pendugaan Titik

Misalkan kita memiliki parameter populasi yang tidak diketahui, seperti rata-rata populasi μ atau proporsi populasi p , yang ingin kita duga. Sebagai contoh, misalkan kita ingin menduga:

- p = proporsi mahasiswa Amerika berusia 18–24 tahun yang memiliki asuransi kesehatan (proporsi ini tidak diketahui)
- μ = rata-rata jumlah hari yang diperlukan pasien penyakit Alzheimer untuk mencapai tonggak tertentu (rata-rata ini tidak diketahui)

Dalam kedua kasus tersebut, tentu tidak mungkin kita menyurvei seluruh populasi. Artinya, kita tidak dapat menyurvei semua mahasiswa Amerika yang berusia antara 18 dan 24 tahun. Kita juga tidak dapat menyurvei semua pasien penyakit Alzheimer. Oleh karena itu, sewajarnya kita mengambil sampel acak dari populasi dan menggunakan data yang diperoleh untuk menduga nilai parameter populasi. Tentu saja, kita menginginkan nilai dugaan yang ‘baik’ dalam suatu pengertian.

Kita juga akan mempelajari cara menilai apakah suatu penduga titik ‘baik’. Kita akan melakukannya dengan mendefinisikan makna tak bias dan cukup bagi suatu penduga, menentukan varians penduga tersebut, serta rata-rata kuadrat galatnya.

Definisi dan Notasi

Kita akan mengawali pelajaran ini dengan beberapa definisi formal. Untuk itu, ingatlah bahwa kita menyatakan n peubah acak yang berasal dari suatu sampel acak dengan huruf kapital berindeks bawah:

$$X_1, X_2, \dots, X_n$$

Nilai teramati yang bersesuaian dari suatu sampel acak tertentu kemudian dinyatakan dengan huruf kecil berindeks bawah:

$$x_1, x_2, \dots, x_n$$

Def. 2.1 (Ruang Parameter) Rentang nilai yang mungkin dari parameter θ disebut **ruang parameter** Ω (huruf Yunani ‘omega’).

Contoh 2.1 Jika μ menyatakan rata-rata indeks prestasi semua mahasiswa, maka ruang parameternya (dengan mengasumsikan skala penilaian 4 poin) adalah:

$$\Omega = \{\mu : 0 \leq \mu \leq 4\}$$

Jika p adalah proporsi mahasiswa yang merokok, maka ruang parameternya adalah:

$$\Omega = \{p : 0 \leq p \leq 1\}$$

2.1.1 Penduga Titik

Fungsi dari $X_1, X_2, \dots, X_n$, yaitu statistik $u(X_1, X_2, \dots, X_n)$, yang digunakan untuk menduga θ disebut **penduga titik** bagi θ .

Contoh 2.2 Sebagai contoh, fungsi berikut:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

merupakan penduga titik bagi rata-rata populasi μ .

Ketika $X_i = 0$ atau 1, fungsi berikut:

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

merupakan penduga titik bagi proporsi populasi p .

Fungsi berikut:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

merupakan penduga titik bagi varians populasi σ^2 .

2.1.2 Nilai Dugaan Titik

Fungsi $u(x_1, x_2, \dots, x_n)$ yang dihitung dari sekumpulan data merupakan suatu **nilai dugaan titik** teramati bagi θ .

Contoh 2.3 Jika $x_i, i = 1, \dots, 88$ adalah indeks prestasi yang teramati pada sampel 88 mahasiswa, maka

$$\bar{x} = \frac{1}{88} \sum_{i=1}^{88} x_i = 3.12$$

merupakan nilai dugaan titik bagi μ , yaitu rata-rata indeks prestasi semua mahasiswa dalam populasi.

Ingatlah kembali bahwa fungsi kepadatan peluang (PDF) ataupun fungsi massa peluang (PMF) dari suatu peubah acak telah didefinisikan sebagai $f(x)$. Kita mendefinisikan model peluang untuk data sebagai berikut:

$$x_i \sim f_x(x_i|\theta)$$

dengan f_x merupakan distribusi peluang dan θ merupakan satu atau beberapa parameter dalam model tersebut.

Jika θ diketahui, tugas kita selesai. Tujuan mata kuliah ini adalah memahami apa yang harus dilakukan ketika θ tidak diketahui. Kita mendefinisikan penduga bagi θ sebagai $\hat{\theta}$. $\hat{\theta}$ merupakan fungsi dari data kita, yaitu $\hat{\theta} = g(X_1, X_2, \dots, X_n)$. Kita akan menggunakan fungsi data ini untuk membantu kita memahami θ . Kita akan melakukan inferensi statistik. **Inferensi Statistik** adalah penggunaan data untuk menyimpulkan sifat-sifat suatu distribusi yang mendasarinya.

Mari kita bahas sebuah contoh motivasi yang menggunakan beberapa istilah tersebut dan menunjukkan arah pembahasan kita.

Contoh 2.4 Misalkan seorang peneliti tertarik pada COVID-19. Gunakan notasi - $n_{c,y}$ = jumlah orang yang terjangkit COVID-19 di negara c dan pada tahun y - $d_{c,y}$ = jumlah orang yang meninggal akibat COVID-19 di negara c dan pada tahun y

Sebagai contoh, $n_{USA,2021}$ adalah jumlah orang yang terjangkit COVID-19 di Amerika Serikat pada tahun 2021.

Misalkan kita ingin menjawab apakah tingkat kematian akibat COVID-19 pada 2022 (setelah vaksin tersedia) lebih rendah daripada pada 2021 (sebelum vaksin tersedia) untuk suatu negara tertentu. Kita perlu mendefinisikan model peluang bagi $(n_{c,y}, d_{c,y})$. Misalkan modelnya adalah:

$$d_{c,y} \sim \text{Bin}(n_{c,y}, p_y)$$

Dalam model ini, parameternya adalah p_y , yaitu peluang kematian akibat COVID-19 pada tahun y . Karena kita ingin membandingkan 2022 dan 2021, kita memiliki dua parameter, p_{2021} dan p_{2022} . Jika parameter-parameter tersebut diketahui, kita dapat menjawab pertanyaan itu. Karena tidak diketahui, kita perlu menduga $\theta = (p_{2021}, p_{2022})$.

Lalu bagaimana? Apa itu $\hat{\theta}$? Bagaimana kita menentukan penduganya? Mungkinkah terdapat lebih dari satu penduga? Sebentar lagi kita akan mempelajari cara menemukan penduga bagi parameter yang tidak diketahui. Untuk saat ini, kita akan mempelajari cara membandingkan penduga.

2.2 Sifat-Sifat Penduga

Misalkan kita diberikan beberapa penduga bagi suatu parameter yang tidak diketahui, θ . Bagaimana kita mengetahui pilihan yang 'lebih baik'? Perhatikan contoh berikut.

Contoh 2.5 Misalkan kita memiliki sampel yang bebas dan berdistribusi identik (i.i.d.) berukuran $n = 3$ sedemikian sehingga

$$X_i \stackrel{iid}{\sim} \text{Bin}(10, p)$$

Parameter yang tidak diketahui dalam kasus ini adalah p , yaitu peluang keberhasilan. Definisikan tiga penduga yang mungkin bagi p sebagai berikut:

$$\begin{aligned}\hat{p}_1 &= \frac{X_1}{10} \\ \hat{p}_2 &= \frac{\frac{X_1}{10} + \frac{X_2}{10} + \frac{X_3}{10}}{3} = \frac{X_1 + X_2 + X_3}{30} \\ \hat{p}_3 &= \hat{p}_2 + 0.1 = \frac{X_1 + X_2 + X_3}{30} + 0.1\end{aligned}$$

Penduga manakah yang lebih baik dalam menduga p ? Kita dapat memulainya dengan mendefinisikan bias suatu penduga.

Def. 2.2 (Pendugaan Tak Bias) Salah satu ukuran bagi penduga yang “baik” adalah “ketakbiasan”. Suatu penduga dikatakan tak bias jika nilai harapan penduga tersebut sama dengan parameter yang tidak diketahui θ .

2.2.1 Bias

Jika persamaan berikut berlaku:

$$E[u(X_1, X_2, \dots, X_n)] = \theta$$

maka statistik $u(X_1, X_2, \dots, X_n)$ merupakan **penduga tak bias** bagi parameter θ . Jika tidak, $u(X_1, X_2, \dots, X_n)$ merupakan **penduga berbias** bagi θ . Besarnya **bias** statistik tersebut didefinisikan sebagai:

$$\text{Bias} = E(u(X_1, X_2, \dots, X_n)) - \theta$$

Perhatikan bahwa penduga tak bias akan memiliki bias sebesar $\text{Bias} = E(u(X_1, X_2, \dots, X_n)) - \theta = 0$.

Contoh 2.6 Tinjau contoh sebelumnya. Dalam contoh tersebut, penduga-penduga bagi p didefinisikan sebagai berikut:

$$\begin{aligned}\hat{p}_1 &= \frac{X_1}{10} \\ \hat{p}_2 &= \frac{X_1 + X_2 + X_3}{30} \\ \hat{p}_3 &= \hat{p}_2 + 0.1 = \frac{X_1 + X_2 + X_3}{30} + 0.1\end{aligned}$$

Berapakah bias masing-masing penduga?

Penyelesaian

Untuk menentukan bias setiap penduga, kita perlu menentukan nilai harapannya. Ingat bahwa untuk peubah acak binomial, X , kita ketahui bahwa $E(X) = np$ dan $\text{Var}(X) = np(1-p)$. Mari kita mulai dengan $\hat{p}_1$.

$$\begin{aligned}\text{Bias}_1 &= E(\hat{p}_1) - p = E\left[\frac{X_1}{10}\right] - p = 0 \\ \text{Bias}_2 &= E(\hat{p}_2) - p = E\left[\frac{X_1 + X_2 + X_3}{30}\right] - p = 0 \\ \text{Bias}_3 &= E(\hat{p}_3) - p = E(\hat{p}_2 + 0.1) - p = 0.1\end{aligned}$$

Contoh 2.7 Jika X_i merupakan peubah-peubah acak yang berdistribusi normal dengan rata-rata μ dan varians σ^2 , tinjaulah kedua penduga bagi μ dan σ^2 , secara berturut-turut:

$$\begin{aligned}\hat{\mu} &= \frac{1}{n} \sum_{i=1}^n X_i, \\ \hat{\sigma}^2 &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}\end{aligned}$$

Apakah kedua penduga tersebut tak bias bagi parameternya masing-masing?

Penyelesaian

Ingat bahwa jika X_i merupakan peubah acak yang berdistribusi normal dengan rata-rata μ dan varians σ^2 , maka

$E(X_i) = \mu$ dan $\text{Var}(X_i) = \sigma^2$. Oleh karena itu,

$$\begin{aligned} E(\bar{X}) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n} \sum_{i=1}^n E(X_i) \\ &= \frac{1}{n} \sum_{i=1}^n \mu \\ &= \frac{1}{n}(n\mu) = \mu \end{aligned}$$

Kesamaan pertama berlaku karena kita hanya mengganti $\bar{X}$ dengan definisinya. Kesamaan kedua berlaku berdasarkan sifat nilai harapan dari kombinasi linear. Kesamaan ketiga berlaku karena $E(X_i) = \mu$. Kesamaan keempat berlaku karena ketika nilai μ dijumlahkan sebanyak n kali, hasilnya adalah $n\mu$. Tentu saja, kesamaan terakhir diperoleh melalui aljabar sederhana.

Singkatnya, telah kita tunjukkan bahwa $E(\bar{X}) = \mu$. Oleh karena itu, $\hat{\mu}$ merupakan penduga tak bias bagi μ . Sekarang, mari kita periksa penduga bagi σ^2 . Penduganya adalah:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

Rumus tersebut dapat ditulis ulang sebagai:

$$\hat{\sigma}^2 = \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right) - \bar{X}^2$$

karena

$$\begin{aligned} \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \frac{1}{n} \sum_{i=1}^n (x_i^2 - 2x_i\bar{x} + \bar{x}^2) \\ &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \frac{2\bar{x}}{n} \sum_{i=1}^n x_i + \bar{x}^2 \\ &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \end{aligned}$$

Sekarang, tentukan nilai harapannya:

$$E(\hat{\sigma}^2) = E\left[\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2\right] = \left[\frac{1}{n} \sum_{i=1}^n E(X_i^2)\right] - E(\bar{X}^2)$$

Ingat bahwa $\sigma^2 = E(X^2) - \mu^2$ untuk suatu peubah acak X . Secara aljabar, dengan menyelesaikan persamaan terhadap $E(X^2)$, diperoleh $E(X^2) = \sigma^2 + \mu^2$. Oleh karena itu,

$$E(\hat{\sigma}^2) = \left[\frac{1}{n} \sum_{i=1}^n E(X_i^2)\right] - E(\bar{X}^2) = \frac{1}{n} \sum_{i=1}^n (\sigma^2 + \mu^2) - \left(\frac{\sigma^2}{n} + \mu^2\right)$$

Kesamaan kedua berlaku karena $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ dan $E(\bar{X}) = \mu$. Selanjutnya,

$$\begin{aligned} E(\hat{\sigma}^2) &= \frac{1}{n} \sum_{i=1}^n (\sigma^2 + \mu^2) - \left(\frac{\sigma^2}{n} + \mu^2 \right) \\ &= \frac{1}{n} (n\sigma^2 + n\mu^2) - \frac{\sigma^2}{n} - \mu^2 \\ &= \sigma^2 - \frac{\sigma^2}{n} \\ &= \frac{n\sigma^2 - \sigma^2}{n} = \frac{(n-1)\sigma^2}{n} \end{aligned}$$

Dengan demikian, telah kita tunjukkan bahwa

$$E(\hat{\sigma}^2) \neq \sigma^2$$

Statistik $\hat{\sigma}^2$ merupakan penduga berbias bagi σ^2 .

Contoh 2.8 Jika X_i merupakan peubah-peubah acak yang berdistribusi normal dengan rata-rata μ dan varians σ^2 , apakah $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$ merupakan penduga tak bias bagi σ^2 ?

Penyelesaian

Ingat bahwa jika X_i merupakan peubah acak yang berdistribusi normal dengan rata-rata μ dan varians σ^2 , maka:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Selain itu, ingat bahwa nilai harapan peubah acak khi-kuadrat sama dengan derajat kebebasannya. Artinya, jika:

$$X \sim \chi_{(r)}^2$$

maka $E(X) = r$. Oleh karena itu,

$$\begin{aligned} E(S^2) &= E\left[\frac{\sigma^2}{n-1} \cdot \frac{(n-1)S^2}{\sigma^2} \right] \\ &= \frac{\sigma^2}{n-1} E\left[\frac{(n-1)S^2}{\sigma^2} \right] \\ &= \frac{\sigma^2}{n-1} (n-1) \\ &= \sigma^2 \end{aligned}$$

Kesamaan pertama berlaku karena kita pada dasarnya mengalikan varians sampel dengan 1. Kesamaan kedua berlaku berdasarkan sifat nilai harapan yang menyatakan bahwa konstanta dapat dikeluarkan dari operasi nilai harapan. Kesamaan ketiga berlaku berdasarkan dua fakta yang diingat kembali di atas. Dengan kata lain:

$$E\left[\frac{(n-1)S^2}{\sigma^2} \right] = n-1$$

Kesamaan terakhir sekali lagi diperoleh melalui aljabar sederhana.

Singkatnya, telah kita tunjukkan bahwa jika X_i merupakan peubah acak yang berdistribusi normal dengan rata-rata μ dan varians σ^2 , maka S^2 merupakan penduga tak bias bagi σ^2 . Namun, ternyata S^2 memang *selalu* merupakan penduga tak bias bagi σ^2 , yakni untuk *setiap* model, bukan hanya model normal. Menariknya, meskipun S^2 selalu merupakan penduga tak bias bagi σ^2 , S ternyata *bukan* penduga tak bias bagi σ .

Selanjutnya, mari kita tinjau contoh dengan peubah acak yang tidak mengikuti distribusi bernama yang telah kita kenal.

Contoh 2.9 Misalkan $Y_1, Y_2, \dots, Y_n$ merupakan sampel acak berukuran n dari suatu distribusi dengan fungsi kepadatan peluang berikut:

$$f(y) = \frac{1}{\theta} y^{\frac{1-\theta}{\theta}}, \quad 0 < y < 1, \quad 0 < \theta$$

Tentukan apakah statistik $\hat{\theta} = -\frac{1}{n} \sum_{i=1}^n \ln Y_i$ merupakan penduga tak bias bagi parameter yang tidak diketahui, θ .

Penyelesaian

Kita dapat memulai dengan menggunakan sifat-sifat nilai harapan.

$$E(\hat{\theta}) = E\left(-\frac{1}{n} \sum_{i=1}^n \ln Y_i\right) = -\frac{1}{n} \sum_{i=1}^n E(\ln Y_i)$$

Karena sampel tersebut merupakan sampel acak, $E(\ln Y_i)$ bernilai sama untuk semua $i = 1, \dots, n$. Oleh karena itu, diperoleh:

$$\begin{aligned} E(\hat{\theta}) &= -\frac{1}{n} \sum_{i=1}^n E(\ln Y_i) \\ &= -\frac{1}{n} (n) E(\ln Y_i) \\ &= -E(\ln Y_i) \end{aligned}$$

Oleh karena itu, kita hanya perlu menentukan $E(\ln Y_i)$. Dengan menggunakan definisi nilai harapan, diperoleh:

$$E(\ln Y_i) = \int_0^1 \frac{\ln y}{\theta} y^{(1-\theta)/\theta} dy$$

Dengan menggunakan integrasi parsial, dengan $u = \ln y$ dan $dv = \frac{1}{\theta} y^{1/\theta-1} dy$, diperoleh

$$E(\ln Y_i) = \lim_{a \rightarrow 0} \left[y^{1/\theta} \ln y - \theta y^{1/\theta} \right]_a^1 = -\theta$$

Dengan menggabungkan semua hasil tersebut, diperoleh:

$$E(\hat{\theta}) = -E(\ln Y_i) = -(-\theta) = \theta$$

Oleh karena itu, statistik tersebut merupakan penduga tak bias bagi θ .


Wajar jika sifat tak bias dianggap sebagai sifat penduga yang diinginkan. Namun, seperti dalam contoh kita, bagaimana cara menentukan penduga yang “lebih baik” di antara beberapa penduga tak bias? Secara logis, kita perlu mempertimbangkan bukan hanya nilai harapan penduga, melainkan juga variansnya. Pada pelajaran berikutnya, kita akan membahas varians penduga serta rata-rata kuadrat galat.

2.2.2 Varians dan Rataan Kuadrat Galat

Pada bagian sebelumnya, kita mendefinisikan bias dan makna sifat tak bias suatu penduga bagi parameter yang tidak diketahui, θ . Walaupun sifat tak bias merupakan sifat yang diinginkan, sifat itu saja belum mendefinisikan suatu “penduga yang baik”. Perhatikan contoh lemparan dart berikut yang menggambarkan perbedaan antara **akurasi** dan **presisi**.

Akurasi adalah istilah yang menunjukkan seberapa dekat suatu hasil dengan “nilai sebenarnya”. Bagi penduga, akurasi analog dengan sifat tak bias. Presisi adalah istilah yang menunjukkan seberapa dekat suatu hasil dengan hasil pengukuran lainnya. Bayangkan kita melempar dart ke papan sasaran, dengan pusat sasaran sebagai “nilai

sebenarnya”. Misalkan empat orang masing-masing melempar empat dart dan kita ingin menilai siapa pemain dart yang “lebih baik” berdasarkan nilai sebenarnya. Hasil lemparan mereka ditunjukkan di bawah ini.



Gambar 2.1

Mari kita telaah setiap pemain. Akurasi Pemain A rendah dan dart-nya tersebar. Pemain B tidak melempar dekat pusat sasaran, tetapi hasil lemparannya berdekatan satu sama lain. Oleh karena itu, akurasi Pemain B rendah, tetapi presisinya lebih baik. Pemain C tampaknya memiliki akurasi yang lebih tinggi daripada Pemain A dan B, tetapi presisinya buruk. Terakhir, Pemain D memiliki akurasi dan presisi yang tinggi. Berdasarkan gambar, saya akan menilai bahwa Pemain D adalah pemain yang lebih baik.

Tujuannya adalah memilih penduga yang akurat dan presisi. Kita telah membahas bahwa sifat tak bias analog dengan akurasi. Untuk menilai presisi suatu penduga, ukuran yang baik adalah varians penduga tersebut.

Contoh 2.10 Perhatikan kembali contoh sebelumnya yang memiliki tiga calon penduga:

$$\begin{aligned}\hat{p}_1 &= \frac{X_1}{10} \\ \hat{p}_2 &= \frac{X_1 + X_2 + X_3}{30} \\ \hat{p}_3 &= \hat{p}_2 + 0.1\end{aligned}$$

dengan $X_i \stackrel{iid}{\sim} \text{Bin}(10, p)$. Dari pembahasan sebelumnya, diketahui bahwa baik $\hat{p}_1$ maupun $\hat{p}_2$ merupakan penduga tak bias bagi p , sedangkan $\hat{p}_3$ merupakan penduga yang bias. Tentukan varians setiap penduga.

Penyelesaian

Untuk menentukan varians setiap penduga, kita perlu mengingat tiga aturan dari STAT 414: - Untuk peubah acak binomial X , $\text{Var}(X) = np(1 - p)$. - $\text{Var}(aX + b) = a^2\text{Var}(X)$ untuk peubah acak X . - Jika peubah acak X dan Y saling bebas, maka $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$.

Sekarang, mari kita tentukan varians $\hat{p}_1$:

$$\begin{aligned}\text{Var}(\hat{p}_1) &= \text{Var}\left(\frac{X_1}{10}\right) \\ &= \left(\frac{1}{10}\right)^2 \text{Var}(X_1) \\ &= \frac{10p(1 - p)}{100} \\ &= \frac{p(1 - p)}{10}\end{aligned}$$

Berikutnya, tentukan varians $\hat{p}_2$:

$$\begin{aligned}\text{Var}(\hat{p}_2) &= \text{Var}\left(\frac{X_1 + X_2 + X_3}{30}\right) \\ &= \frac{1}{30^2} \text{Var}(X_1 + X_2 + X_3) \\ &= \frac{\text{Var}(X_1) + \text{Var}(X_2) + \text{Var}(X_3)}{30^2} \\ &= \frac{10p(1 - p) + 10p(1 - p) + 10p(1 - p)}{30^2} \\ &= \frac{30p(1 - p)}{30^2} = \frac{p(1 - p)}{30}\end{aligned}$$


Terakhir, tentukan varians $\hat{p}_3$:

$$\text{Var}(\hat{p}_3) = \text{Var}(\hat{p}_2 + 0.1) = \text{Var}(\hat{p}_2) = \frac{p(1 - p)}{30}$$

Jadi, diperoleh bahwa baik $\hat{p}_1$ maupun $\hat{p}_2$ merupakan penduga tak bias. Di atas, juga diperoleh bahwa $\text{Var}(\hat{p}_1) > \text{Var}(\hat{p}_2)$. Berdasarkan dua sifat penduga yang telah kita pelajari sejauh ini, tampaknya $\hat{p}_2$ merupakan penduga yang lebih baik.

Dalam contoh di atas, kita memilih penduga tak bias dengan varians terkecil. Apakah kita akan pernah menggunakan penduga yang bias? Jika ya, mengapa?

Dalam keadaan tertentu, varians dapat dikurangi secara drastis dengan memasukkan sedikit bias. Sebagai contoh, perhatikan dua penduga, $\hat{\theta}_1$ dan $\hat{\theta}_2$. Perhatikan grafik fungsi kepadatan peluang (PDF) kedua penduga tersebut.



Gambar 2.2

Terlihat bahwa fungsi kepadatan peluang (PDF) dari $\hat{\theta}_1$ berpusat di sekitar nilai sebenarnya, yaitu θ . Namun, $\hat{\theta}_1$ memiliki varians yang lebih besar. Namun, $\hat{\theta}_2$ tidak berpusat di sekitar nilai sebenarnya, tetapi memiliki varians yang jauh lebih kecil.

Contoh 2.11 Perhatikan kembali contoh sebelumnya, yaitu sampel acak berukuran n dari distribusi normal dengan rata-rata μ dan varians σ^2 . Telah ditunjukkan bahwa

$$\hat{\sigma}_1^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

merupakan penduga yang bias bagi σ^2 . Kita juga memperoleh bahwa

$$\hat{\sigma}_2^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$$

merupakan penduga tak bias. Kita memperoleh bahwa:

$$E(\hat{\sigma}_2^2) = \frac{n-1}{n} \sigma^2$$

Namun, ketika n menuju tak hingga, nilai harapannya menuju σ^2 . Oleh karena itu, $\hat{\sigma}_1^2$ bersifat **tak bias secara asimtotik**. Oleh karena itu, ketika ukuran sampel makin besar, bias penduga dapat menuju 0.

Adakah ukuran yang dapat membantu kita menemukan keseimbangan yang baik antara bias penduga dan variansnya? Jawabannya ada. Salah satu ukuran tersebut adalah **rataan kuadrat galat** (MSE).

Def. 2.3 (Rataan Kuadrat Galat bagi Penduga Titik $\hat{\theta}$) Nilai **rataan kuadrat galat** dari suatu penduga titik $\hat{\theta}$

didefinisikan sebagai

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

Rataan kuadrat galat suatu penduga adalah rata-rata kuadrat jarak antara penduga dan parameter sebenarnya, θ .

Berdasarkan definisi MSE, jelas bahwa penduga yang diinginkan memiliki rata-rata kuadrat galat terkecil.

Rataan kuadrat galat $\hat{\theta}$, sebagai ukuran bagi suatu penduga, merupakan fungsi dari bias dan variansnya. Dapat ditunjukkan bahwa

$$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$$

dengan $\text{Bias}(\hat{\theta})$ merupakan bias dari $\hat{\theta}$. Pastikan sendiri bahwa hubungan di atas berlaku. Hubungan tersebut mungkin ditanyakan dalam tugas.

Contoh 2.12 Perhatikan kembali contoh sebelumnya dengan tiga penduga berikut untuk parameter binomial p , dengan $n = 10$. Penduga-penduganya adalah:

$$\begin{aligned}\hat{p}_1 &= \frac{X_1}{10} \\ \hat{p}_2 &= \frac{X_1 + X_2 + X_3}{30} \\ \hat{p}_3 &= \hat{p}_2 + 0.1\end{aligned}$$

Tentukan MSE setiap penduga.

Penyelesaian

Sebelumnya, kita telah memperoleh varians dan nilai harapan setiap penduga. Hasilnya diringkas di sini untuk memudahkan.

$$\begin{aligned}E(\hat{p}_1) &= p, & \text{Var}(\hat{p}_1) &= \frac{p(1-p)}{10} \\ E(\hat{p}_2) &= p, & \text{Var}(\hat{p}_2) &= \frac{p(1-p)}{30} \\ E(\hat{p}_3) &= p + 0.1, & \text{Var}(\hat{p}_3) &= \frac{p(1-p)}{30}\end{aligned}$$

Untuk menentukan rata-rata kuadrat galat, kita perlu menentukan bias setiap penduga.

$$\begin{aligned}\text{Bias}(\hat{p}_1) &= E(\hat{p}_1) - p = 0 \\ \text{Bias}(\hat{p}_2) &= E(\hat{p}_2) - p = 0 \\ \text{Bias}(\hat{p}_3) &= E(\hat{p}_3) - p = p + 0.1 - p = 0.1\end{aligned}$$

Dengan demikian, nilai MSE masing-masing adalah:

$$\begin{aligned}\text{MSE}(\hat{p}_1) &= \text{Var}(\hat{p}_1) + [\text{Bias}(\hat{p}_1)]^2 = \frac{p(1-p)}{10} \\ \text{MSE}(\hat{p}_2) &= \text{Var}(\hat{p}_2) + [\text{Bias}(\hat{p}_2)]^2 = \frac{p(1-p)}{30} \\ \text{MSE}(\hat{p}_3) &= \text{Var}(\hat{p}_3) + [\text{Bias}(\hat{p}_3)]^2 = \frac{p(1-p)}{30} + 0.1^2 = \frac{p(1-p)}{30} + 0.01\end{aligned}$$

Dengan demikian, penduga dengan MSE terkecil adalah $\hat{p}_2$.

Pada pelajaran berikutnya, kita akan membahas sifat lain yang diinginkan dari suatu penduga, yaitu kecukupan.

2.3 Ringkasan

Pelajaran ini memperkenalkan gagasan penggunaan data sampel untuk menduga parameter populasi yang tidak diketahui. Fokus kita adalah pada **pendugaan titik** dan menelaah hal-hal yang membuat suatu penduga diinginkan dengan mengkaji **bias**, **varians**, dan **rataan kuadrat galat (MSE)**. Melalui contoh dan penurunan, kita mempelajari cara mengevaluasi dan membandingkan penduga dengan menggunakan sifat-sifat tersebut. Pelajaran ini membangun landasan untuk menilai kualitas penduga, baik dalam konteks teoretis maupun terapan.

Pokok-Pokok Penting

- **Bias** mengukur seberapa jauh rataan suatu penduga dari parameter sebenarnya.
- **Varians** mencerminkan keragaman nilai suatu penduga di berbagai sampel.
- **Rataan Kuadrat Galat (MSE)** menggabungkan bias dan varians untuk menilai akurasi secara keseluruhan. Membandingkan MSE membantu menentukan penduga mana yang lebih baik dalam praktik.

1. [Pelajaran](#)
2. [3 Pendugaan \(Bagian II\)](#)

3 Pendugaan (Bagian II)

Pendugaan Titik
Pendugaan Tak Bias
Bias
Varians dan Rataan Kuadrat
Faktorisasi
Kecukupan
Metode Momen

Gambaran Umum

Berlandaskan konsep-konsep dasar pendugaan titik dari Pelajaran 2, pelajaran ini membahas lebih dalam konsep penting kecukupan dan memperkenalkan metode momen sebagai teknik untuk menurunkan penduga. Anda akan mempelajari bagaimana statistik cukup menangkap seluruh informasi yang relevan tentang suatu parameter populasi dari data sampel dengan menggunakan perangkat seperti Teorema Faktorisasi dan Kriteria Eksponensial. Melalui contoh-contoh yang melibatkan distribusi Bernoulli, Poisson, normal, dan eksponensial, Anda akan belajar mengidentifikasi statistik cukup bagi satu maupun beberapa parameter. Selain itu, Anda akan diperkenalkan dengan metode momen, yaitu pendekatan praktis untuk menduga parameter dengan menyamakan momen sampel dengan padanan teoretisnya. Pada akhir pelajaran ini, Anda akan mampu mengevaluasi dan menyusun penduga dengan pemahaman yang lebih mendalam mengenai sifat-sifatnya, sebagai persiapan untuk mempelajari teknik inferensi statistik tingkat lanjut.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Menerapkan Teorema Faktorisasi untuk mengidentifikasi statistik cukup bagi distribusi berparameter tunggal,
2. Menerapkan Kriteria Eksponensial untuk mengidentifikasi statistik cukup bagi distribusi berparameter tunggal, serta
3. Menentukan penduga bagi satu atau beberapa parameter populasi dengan menggunakan Metode Momen.

3.1 Kecukupan

Dalam proses menduga parameter semacam itu, kita merangkum, atau mereduksi, informasi dalam sampel berukuran n , $X_1, X_2, \dots, X_n$, menjadi satu bilangan, seperti rata-rata sampel $\bar{X}$. Nilai sampel yang sebenarnya tidak lagi penting bagi kita. Artinya, jika kita menggunakan rata-rata sampel 3 untuk menduga rata-rata populasi μ , tidak menjadi masalah apakah nilai data semula adalah (1, 3, 5) atau (2, 3, 4). Apakah proses mereduksi n titik data menjadi satu bilangan ini telah mempertahankan seluruh informasi mengenai μ yang terkandung dalam n titik data semula? Ataukah sebagian informasi mengenai parameter telah hilang dalam proses perangkuman data? Dalam pelajaran ini, kita akan mempelajari cara menemukan statistik yang merangkum seluruh informasi dalam sampel mengenai parameter yang dikehendaki. Statistik semacam itu disebut **statistik cukup**, dan itulah asal nama pelajaran ini.

Definisi Kecukupan

Kecukupan adalah jenis topik yang barangkali paling baik dipelajari dengan langsung masuk ke dalamnya dan menyatakan definisinya. Mari kita lakukan!

Def. 3.1 (Cukup) Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari suatu distribusi peluang dengan

parameter tak diketahui θ . Maka, statistik berikut:

$$Y = u(X_1, X_2, \dots, X_n)$$

dikatakan cukup bagi θ jika distribusi bersyarat dari $X_1, X_2, \dots, X_n$, dengan diketahui statistik Y , tidak bergantung pada parameter θ .

Contoh 3.1 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari n percobaan Bernoulli dengan ketentuan:

- $X_i = 1$ jika subjek i^{th} menyukai Pepsi
- $X_i = 0$ jika subjek i^{th} tidak menyukai Pepsi

Jika p adalah peluang bahwa subjek i menyukai Pepsi, untuk $i = 1, 2, \dots, n$, maka:

- $X_i = 1$ dengan peluang p
- $X_i = 0$ dengan peluang $q = 1 - p$

Misalkan, dalam sampel acak berisi $n = 40$ orang, terdapat $Y = \sum_{i=1}^n X_i = 22$ orang yang menyukai Pepsi. Jika kita mengetahui nilai Y , yaitu jumlah keberhasilan dalam n percobaan, dapatkah kita memperoleh informasi lebih lanjut mengenai parameter p dengan mempertimbangkan fungsi-fungsi lain dari data $X_1, X_2, \dots, X_n$? Dengan kata lain, apakah Y cukup bagi p ?

Penyelesaian

Definisi kecukupan menyatakan bahwa jika distribusi bersyarat dari $X_1, X_2, \dots, X_n$, dengan diketahui statistik Y , tidak bergantung pada p , maka Y merupakan statistik cukup bagi p . Distribusi bersyarat dari $X_1, X_2, \dots, X_n$, dengan diketahui Y , menurut definisi adalah:

$$P(X_1 = x_1, \dots, X_n = x_n | Y = y) = \frac{P(X_1 = x_1, \dots, X_n = x_n, Y = y)}{P(Y = y)} \quad (3.1)$$

Sekarang, agar lebih konkret, misalkan kita mengamati sampel acak berukuran $n = 3$ dengan $x_1 = 1, x_2 = 0$, and $x_3 = 1$. Dalam hal ini:

$$P(X_1 = 1, X_2 = 0, X_3 = 1, Y = 1) = 0$$

karena jumlah nilai data, $\sum_{i=1}^n X_i$, adalah $1 + 0 + 1 = 2$, tetapi Y , yang didefinisikan sebagai jumlah semua X_i , bernilai 1. Hal ini karena $2 \neq 1$, kejadian pada pembilang [Persamaan 3.1](#) merupakan kejadian mustahil sehingga peluangnya 0.

Sekarang, mari kita tinjau kejadian yang mungkin, yaitu ($X_1 = 1, X_2 = 0, X_3 = 1, Y = 2$). Dalam hal ini, berdasarkan kebebasan, kita peroleh:

$$P(X_1 = 1, X_2 = 0, X_3 = 1, Y = 2) = p(1 - p)p = p^2(1 - p)$$

Jadi, secara umum:

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n, Y = y) = 0 \text{ if } \sum_{i=1}^n x_i \neq y$$

dan:

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n, Y = y) = p^y(1 - p)^{n-y} \text{ if } \sum_{i=1}^n x_i = y$$

Sekarang, penyebut dalam [Persamaan 3.1](#) di atas adalah peluang binomial untuk memperoleh tepat y keberhasilan dalam n percobaan dengan peluang keberhasilan p . Artinya, penyebutnya adalah:

$$P(Y = y) = \binom{n}{y} p^y (1 - p)^{n-y}$$

untuk $y = 0, 1, 2, \dots, n$. Dengan menggabungkan pembilang dan penyebut, jika $y = 0, 1, 2, \dots, n$, kita peroleh peluang bersyarat:

$$P(X_1 = x_1, \dots, X_n = x_n | Y = y) = \frac{p^y(1-p)^{n-y}}{\binom{n}{y} p^y(1-p)^{n-y}} = \frac{1}{\binom{n}{y}} \text{ if } \sum_{i=1}^n x_i = y$$

dan:

$$P(X_1 = x_1, \dots, X_n = x_n | Y = y) = 0 \text{ if } \sum_{i=1}^n x_i \neq y$$

Nah! Kita baru saja menunjukkan bahwa distribusi bersyarat dari $X_1, X_2, \dots, X_n$ dengan diketahui Y tidak bergantung pada p . Oleh karena itu, Y memang cukup bagi p . Artinya, setelah nilai Y diketahui, tidak ada fungsi lain dari $X_1, X_2, \dots, X_n$ yang akan memberikan informasi tambahan mengenai kemungkinan nilai p .

Teorema Faktorisasi

Walaupun definisi kecukupan yang diberikan pada halaman sebelumnya mungkin masuk akal secara intuitif, tidak selalu mudah menentukan distribusi bersyarat dari $X_1, X_2, \dots, X_n$ dengan diketahui Y . Belum lagi, kita harus menentukan distribusi bersyarat dari $X_1, X_2, \dots, X_n$ dengan diketahui Y untuk setiap Y yang ingin kita pertimbangkan sebagai statistik cukup yang mungkin! Oleh karena itu, menggunakan definisi formal kecukupan sebagai cara mengidentifikasi statistik cukup bagi parameter θ sering kali merupakan jalan yang sulit ditempuh. Syukurlah, suatu teorema yang sering disebut Teorema Faktorisasi menyediakan alternatif yang lebih mudah! Kita nyatakan teorema itu di sini tanpa bukti.

Teorema 3.1 (Faktorisasi) Misalkan $X_1, X_2, \dots, X_n$ menyatakan peubah-peubah acak dengan fungsi kepadatan peluang bersama atau fungsi massa peluang bersama $f(x_1, x_2, \dots, x_n; \theta)$, yang bergantung pada parameter θ . Maka, statistik $Y = u(X_1, X_2, \dots, X_n)$ cukup bagi θ jika dan hanya jika PDF (atau PMF) tersebut dapat difaktorkan menjadi dua komponen, yaitu:

$$f(x_1, x_2, \dots, x_n; \theta) = \phi[u(x_1, x_2, \dots, x_n); \theta] h(x_1, x_2, \dots, x_n)$$

dengan:

ϕ merupakan fungsi yang bergantung pada data $x_1, x_2, \dots, x_n$ hanya melalui fungsi $u(x_1, x_2, \dots, x_n)$, dan fungsi $h(x_1, x_2, \dots, x_n)$ tidak bergantung pada parameter θ

Mari kita terapkan teorema ini pada beberapa contoh!

Contoh 3.2 Misalkan $X_1, X_2, \dots, X_n$ menyatakan sampel acak dari distribusi Poisson dengan parameter $\lambda > 0$. Tentukan statistik cukup bagi parameter λ .

Penyelesaian

Karena $X_1, X_2, \dots, X_n$ merupakan sampel acak, fungsi massa peluang bersama dari $X_1, X_2, \dots, X_n$ berdasarkan kebebasan adalah:

$$f(x_1, x_2, \dots, x_n; \lambda) = f(x_1; \lambda) \times f(x_2; \lambda) \times \dots \times f(x_n; \lambda)$$

Dengan memasukkan fungsi massa peluang peubah acak Poisson berparameter λ , fungsi massa peluang bersama tersebut menjadi:

$$f(x_1, x_2, \dots, x_n; \lambda) = \frac{e^{-\lambda} \lambda^{x_1}}{x_1!} \times \frac{e^{-\lambda} \lambda^{x_2}}{x_2!} \times \dots \times \frac{e^{-\lambda} \lambda^{x_n}}{x_n!}$$

Sekarang, dengan menyederhanakannya melalui penjumlahan seluruh n buah λ pada eksponen, serta seluruh n buah x_i pada eksponen, kita peroleh:

$$f(x_1, x_2, \dots, x_n; \lambda) = (e^{-n\lambda} \lambda^{\sum x_i}) \times \left(\frac{1}{x_1! x_2! \dots x_n!} \right)$$

Hei, lihatlah! Kita baru saja memfaktorkan PMF bersama menjadi dua fungsi, satu (ϕ) yang hanya merupakan fungsi dari statistik $Y = \sum_{i=1}^n X_i$ dan yang lain (h) tidak bergantung pada parameter λ :

$$f(x_1, x_2, \dots, x_n; \lambda) = \underbrace{(e^{-n\lambda} \lambda^{\sum x_i})}_{\phi(\sum_{i=1}^n x_i; \lambda)} \times \underbrace{\left(\frac{1}{x_1! x_2! \dots x_n!} \right)}_{h(x_1, x_2, \dots, x_n)}$$

Oleh karena itu, Teorema Faktorisasi menyatakan bahwa $Y = \sum_{i=1}^n X_i$ merupakan statistik cukup bagi λ . Namun, tunggu sebentar! Kita juga dapat menulis PMF bersama tersebut sebagai:

$$f(x_1, x_2, \dots, x_n; \lambda) = (e^{-n\lambda} \lambda^{n\bar{x}}) \times \left(\frac{1}{x_1! x_2! \dots x_n!} \right)$$

Oleh karena itu, Teorema Faktorisasi menyatakan bahwa $Y = \bar{X}$ juga merupakan statistik cukup bagi λ !

Jika dipikirkan, masuk akal bahwa $Y = \bar{X}$ dan $Y = \sum_{i=1}^n X_i$ keduanya merupakan statistik cukup karena jika kita mengetahui $Y = \bar{X}$, kita dapat dengan mudah menentukan $Y = \sum_{i=1}^n X_i$. Dan jika kita mengetahui $Y = \sum_{i=1}^n X_i$, kita dapat dengan mudah menentukan $Y = \bar{X}$.

Contoh sebelumnya menunjukkan bahwa dapat ada lebih dari satu statistik cukup bagi parameter θ . Secara umum, jika Y merupakan statistik cukup bagi parameter θ , maka setiap fungsi satu-satu dari Y yang tidak melibatkan θ juga merupakan statistik cukup bagi θ . Mari kita lihat contoh lain.

Contoh 3.3 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi normal dengan rata-rata μ dan varians 1. Tentukan statistik cukup bagi parameter μ .

Penyelesaian

Karena $X_1, X_2, \dots, X_n$ merupakan sampel acak, fungsi kepadatan peluang bersama dari $X_1, X_2, \dots, X_n$ berdasarkan kebebasan adalah:

$$f(x_1, x_2, \dots, x_n; \mu) = f(x_1; \mu) \times f(x_2; \mu) \times \dots \times f(x_n; \mu)$$

Dengan memasukkan fungsi kepadatan peluang peubah acak normal yang kita ketahui, dengan rata-rata μ dan varians 1, fungsi kepadatan peluang bersama tersebut menjadi:

$$f(x_1, x_2, \dots, x_n; \mu) = \frac{1}{(2\pi)^{1/2}} \exp\left[-\frac{1}{2}(x_1 - \mu)^2\right] \times \frac{1}{(2\pi)^{1/2}} \exp\left[-\frac{1}{2}(x_2 - \mu)^2\right] \times \dots \times \frac{1}{(2\pi)^{1/2}} \exp\left[-\frac{1}{2}(x_n - \mu)^2\right]$$

Dengan menggabungkan suku-suku sejenis, kita peroleh:

$$f(x_1, x_2, \dots, x_n; \mu) = \frac{1}{(2\pi)^{n/2}} \exp\left[-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\right]$$

Salah satu cara agar pemfaktoran PDF bersama lebih mudah adalah menambahkan 0 pada kuantitas di dalam tanda kurung dalam penjumlahan tersebut. Yaitu:

$$f(x_1, x_2, \dots, x_n; \mu) = \frac{1}{(2\pi)^{n/2}} \exp\left[-\frac{1}{2} \sum_{i=1}^n \underbrace{(x_i - \bar{x} + \bar{x} - \mu)}_0^2\right]$$

Sekarang, dengan mengkuadratkan kuantitas di dalam tanda kurung, kita peroleh:

$$f(x_1, x_2, \dots, x_n; \mu) = \frac{1}{(2\pi)^{n/2}} \exp \left[-\frac{1}{2} \sum_{i=1}^n [(x_i - \bar{x})^2 + 2(x_i - \bar{x})(\bar{x} - \mu) + (\bar{x} - \mu)^2] \right]$$

Kemudian, dengan mendistribusikan penjumlahan, kita peroleh:

$$f(x_1, x_2, \dots, x_n; \mu) = \frac{1}{(2\pi)^{n/2}} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2 - (\bar{x} - \mu) \sum_{i=1}^n (x_i - \bar{x}) - \frac{1}{2} \sum_{i=1}^n (\bar{x} - \mu)^2 \right]$$

Namun, suku tengah pada eksponen bernilai 0, sedangkan suku terakhir, karena tidak bergantung pada indeks i , dapat dijumlahkan sebanyak n kali:

$$f(x_1, x_2, \dots, x_n; \mu) = \frac{1}{(2\pi)^{n/2}} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2 - (\bar{x} - \mu) \underbrace{\sum_{i=1}^n (x_i - \bar{x})}_0 - \frac{1}{2} \sum_{i=1}^n (\bar{x} - \mu)^2 \right]$$

$n(\bar{x} - \mu)^2$

Jadi, setelah disederhanakan, kita peroleh:

$$f(x_1, x_2, \dots, x_n; \mu) = \left\{ \exp \left[-\frac{n}{2} (\bar{x} - \mu)^2 \right] \right\} \times \left\{ \frac{1}{(2\pi)^{n/2}} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2 \right] \right\}$$

Ringkasnya, kita telah memfaktorkan fungsi kepadatan peluang bersama menjadi dua fungsi, yang satu (ϕ) hanya merupakan fungsi dari statistik $Y = \bar{X}$ dan yang lain (h) tidak bergantung pada parameter μ :

$$f(x_1, x_2, \dots, x_n; \mu) = \underbrace{\left\{ \exp \left[-\frac{n}{2} (\bar{x} - \mu)^2 \right] \right\}}_{\phi(\bar{x}; \mu)} \times \underbrace{\left\{ \frac{1}{(2\pi)^{n/2}} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2 \right] \right\}}_{h(x_1, x_2, \dots, x_n)}$$

Oleh karena itu, Teorema Faktorisasi menyatakan bahwa $Y = \bar{X}$ merupakan statistik cukup bagi μ . Sekarang, $Y = \bar{X}^3$ juga cukup bagi μ , karena jika kita diberikan nilai $\bar{X}^3$, kita dapat dengan mudah memperoleh nilai $\bar{X}$ melalui fungsi satu-satu $w = y^{1/3}$. Artinya:

$$W = (\bar{X}^3)^{1/3} = \bar{X}$$

Sebaliknya, $Y = \bar{X}^2$ bukan merupakan statistik cukup bagi μ . Sampel konstan (a, ..., a) dan (-a, ..., -a) memberikan nilai $\bar{X}^2$ yang sama, tetapi rasio fungsi kemungkinan keduanya adalah $\exp(2na\mu)$, yang bergantung pada parameter. Jadi, kriteria rasio fungsi kemungkinan membuktikan bahwa statistik tersebut tidak cukup.

$$w = y^{1/2}$$

kita memperoleh dua nilai yang mungkin, yaitu:

$$-\bar{X} \text{ and } +\bar{X}$$

Kita makin mahir dalam hal ini; mari kita lihat satu contoh lagi!

Contoh 3.4 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi eksponensial dengan parameter θ . Tentukan statistik cukup bagi parameter θ .

Penyelesaian

Karena $X_1, X_2, \dots, X_n$ merupakan sampel acak, fungsi kepadatan peluang bersama dari $X_1, X_2, \dots, X_n$ dapat

ditulis, berdasarkan sifat saling bebas, sebagai:

$$f(x_1, x_2, \dots, x_n; \theta) = f(x_1; \theta) \times f(x_2; \theta) \times \dots \times f(x_n; \theta)$$

Dengan menyubstitusikan fungsi kepadatan peluang peubah acak eksponensial berparameter θ , fungsi kepadatan peluang bersamanya adalah:

$$f(x_1, x_2, \dots, x_n; \theta) = \frac{1}{\theta} \exp\left(\frac{-x_1}{\theta}\right) \times \frac{1}{\theta} \exp\left(\frac{-x_2}{\theta}\right) \times \dots \times \frac{1}{\theta} \exp\left(\frac{-x_n}{\theta}\right)$$

Sekarang, dengan menyederhanakan, yaitu mengalikan seluruh n faktor yang memuat θ dan menjumlahkan seluruh n x_i pada eksponen, diperoleh:

$$f(x_1, x_2, \dots, x_n; \theta) = \frac{1}{\theta^n} \exp\left(-\frac{1}{\theta} \sum_{i=1}^n x_i\right)$$

Sekali lagi, kita telah memfaktorkan fungsi kepadatan peluang bersama menjadi dua fungsi, yang satu (ϕ) hanya merupakan fungsi dari statistik $Y = \sum_{i=1}^n X_i$ dan yang lain (h) tidak bergantung pada parameter θ :

$$f(x_1, x_2, \dots, x_n; \theta) = \underbrace{\frac{1}{\theta^n} \exp\left(-\frac{1}{\theta} \sum_{i=1}^n x_i\right)}_{\phi(\sum_{i=1}^n x_i; \theta)} \times \underbrace{1}_{h(x_1, x_2, \dots, x_n)}$$

Oleh karena itu, Teorema Faktorisasi menyatakan bahwa $Y = \sum_{i=1}^n X_i$ merupakan statistik cukup bagi θ . Dan, karena $Y = \bar{X}$ merupakan fungsi satu-satu dari $Y = \sum_{i=1}^n X_i$, hal ini menyiratkan bahwa $Y = \bar{X}$ juga merupakan statistik cukup bagi θ .

Bentuk Eksponensial

Mungkin Anda belum menyadari bahwa dalam semua contoh yang telah kita bahas sejauh ini, setiap fungsi kepadatan peluang atau fungsi massa peluang dapat disajikan dalam representasi yang lazim disebut **bentuk eksponensial**, yaitu:

$$f(x; \theta) = \exp[K(x)p(\theta) + S(x) + q(\theta)]$$

dengan

1. $K(x)$ dan $S(x)$ merupakan fungsi yang hanya bergantung pada x
2. $p(\theta)$ dan $q(\theta)$ merupakan fungsi yang hanya bergantung pada parameter θ
3. Himpunan dukungannya tidak bergantung pada parameter θ .

Pertama, kita memiliki peubah acak Bernoulli dengan fungsi massa peluang yang ditulis dalam bentuk eksponensial sebagai:

$$f(x; p) = p^x (1-p)^{1-x} = \exp\left[\underbrace{x \ln\left(\frac{p}{1-p}\right)}_{\underbrace{k(x)p(p)}} + \underbrace{\ln(1)}_{s(x)} + \underbrace{\ln(1-p)}_{q(p)}\right]$$

dengan:

1. $K(x)$ dan $S(x)$ merupakan fungsi yang hanya bergantung pada x
2. $p(p)$ dan $q(p)$ merupakan fungsi yang hanya bergantung pada parameter p
3. Himpunan dukungan $x = 0, 1$ tidak bergantung pada parameter p

Baiklah, kita baru saja melewati banyak langkah pada tanda sama dengan kedua, yaitu saat beralih dari titik A (fungsi massa peluang yang lazim) ke titik B (fungsi massa peluang yang ditulis dalam bentuk eksponensial). Jadi, mari kita telaah peralihan itu lebih cermat. Kita mulai dengan:

$$f(x; p) = p^x (1 - p)^{1-x}$$

Apakah fungsi massa peluang tersebut sudah berbentuk eksponensial? Tampaknya belum! Kita jelas memerlukan 'exp' di bagian depan. Satu-satunya cara untuk memunculkannya tanpa mengubah fungsi yang mendasarinya adalah dengan sekaligus menerapkan fungsi inversnya, yaitu logaritma natural ('ln'). Dengan demikian, diperoleh:

$$f(x; p) = \exp[\ln(p^x (1 - p)^{1-x})]$$

Apakah fungsi massa peluang tersebut sekarang sudah berbentuk eksponensial? Belum, tetapi setidaknya bentuknya tampak lebih menjanjikan. Semua langkah berikutnya menggunakan sifat-sifat logaritma yang telah kita ketahui. Karena logaritma natural suatu hasil kali adalah jumlah logaritma natural faktor-faktornya, diperoleh:

$$f(x; p) = \exp[\ln(p^x) + \ln((1 - p)^{1-x})]$$

Apakah fungsi massa peluang tersebut sekarang sudah berbentuk eksponensial? Belum, karena $K(x)$, $p(p)$, $S(x)$, dan $q(p)$ belum dapat dikenali sesuai dengan bentuk eksponensial, tetapi kita jelas makin dekat. Karena logaritma suatu pangkat sama dengan pangkat tersebut dikalikan logaritma basisnya, diperoleh:

$$f(x; p) = \exp[x \ln(p) + (1 - x) \ln(1 - p)]$$

Ini mulai melelahkan. Apakah fungsi massa peluang tersebut sudah berbentuk eksponensial? Sayangnya, belum. Mari kita distribusikan $(1 - x)$ pada suku terakhir tersebut. Dengan demikian, diperoleh:

$$f(x; p) = \exp[x \ln(p) + \ln(1 - p) - x \ln(1 - p)]$$

Apakah fungsi massa peluang tersebut sekarang sudah berbentuk eksponensial? Mari kita periksa lebih cermat. Pada suku pertama, kita dapat mengenali $K(x)p(p)$, dan pada suku tengah terlihat fungsi yang hanya bergantung pada parameter p :

$$f(x; p) = \exp[x \ln p + \ln(1 - p) - x \ln(1 - p)]$$

Sekarang, kita hanya perlu membuat suku terakhir bergantung pada x , lalu semuanya beres. Aduh! Suku terakhir bergantung pada x dan p . Jadi, kita masih harus melanjutkan! Karena logaritma suatu hasil bagi adalah selisih antara logaritma pembilang dan penyebutnya, diperoleh:

$$f(x; p) = \exp\left[x \ln\left(\frac{p}{1 - p}\right) + \ln(1 - p)\right]$$

Apakah fungsi massa peluang tersebut sekarang sudah berbentuk eksponensial? Hampir! Mari tambahkan 0 (dalam bentuk logaritma natural dari 1) agar hal itu tampak jelas. Dengan demikian, diperoleh:

$$f(x; p) = \exp\left[x \ln\left(\frac{p}{1 - p}\right) + \ln(1) + \ln(1 - p)\right]$$

Ya, akhirnya kita telah menulis fungsi massa peluang Bernoulli dalam bentuk eksponensial:

$$f(x; p) = \exp\left[\underbrace{x \ln\left(\frac{p}{1 - p}\right)}_{\substack{k(x) \\ p(p)}} + \underbrace{\ln(1)}_{s(x)} + \underbrace{\ln(1 - p)}_{q(p)}\right]$$

Fiuh! Jadi, kita telah membahas tuntas cara menulis fungsi massa peluang Bernoulli dalam bentuk eksponensial! Mari kembali meninjau semua fungsi massa peluang yang telah kita jumpai dalam pelajaran ini. Kita memiliki peubah acak Poisson yang fungsi massa peluangnya dapat ditulis dalam bentuk eksponensial sebagai:

$$f(x; \lambda) = \frac{e^{-\lambda} \lambda^x}{x!} = \exp \left[\underbrace{x}_{k(x)} \underbrace{\ln \lambda}_{p(\lambda)} + \underbrace{(-\ln(x!))}_{s(x)} + \underbrace{(-\lambda)}_{q(\lambda)} \right]$$

dengan

1. $K(x)$ dan $S(x)$ merupakan fungsi yang hanya bergantung pada x
2. $p(\lambda)$ dan $q(\lambda)$ merupakan fungsi yang hanya bergantung pada parameter λ
3. Himpunan dukung $x = 0, 1, 2, \dots$ tidak bergantung pada parameter λ

Kemudian, kita memiliki peubah acak yang berdistribusi $N(\mu, 1)$ dengan fungsi kepadatan peluang yang dapat ditulis dalam bentuk eksponensial sebagai:

$$f(x; \mu) = \frac{1}{\sqrt{2\pi}} e^{-(x-\mu)^2/2} = \exp \left\{ \underbrace{x}_{k(x)} \underbrace{\mu}_{p(\mu)} + \underbrace{\left(-\frac{x^2}{2}\right)}_{s(x)} + \underbrace{\left(-\frac{\mu^2}{2} - \frac{1}{2} \ln(2\pi)\right)}_{q(\mu)} \right\}$$

dengan

1. $K(x)$ dan $S(x)$ merupakan fungsi yang hanya bergantung pada x
2. $p(\mu)$ dan $q(\mu)$ merupakan fungsi yang hanya bergantung pada parameter μ
3. Himpunan dukung $-\infty < x < \infty$ tidak bergantung pada parameter μ

Kemudian, kita memiliki peubah acak eksponensial yang fungsi kepadatan peluangnya dapat ditulis dalam bentuk eksponensial sebagai:

$$f(x; \theta) = \frac{1}{\theta} e^{-x/\theta} = \exp \left\{ \underbrace{-x}_{k(x)} \underbrace{\left(\frac{1}{\theta}\right)}_{p(\theta)} + \underbrace{\ln(1)}_{s(x)} - \underbrace{\ln \theta}_{q(\theta)} \right\}$$

dengan

1. $K(x)$ dan $S(x)$ merupakan fungsi yang hanya bergantung pada x
2. $p(\theta)$ dan $q(\theta)$ merupakan fungsi yang hanya bergantung pada parameter θ
3. Himpunan dukung $x \geq 0$ tidak bergantung pada parameter θ .

Syukurlah, ternyata menulis fungsi kepadatan peluang dan fungsi massa peluang dalam bentuk eksponensial memberi kita cara ketiga untuk mengidentifikasi statistik cukup bagi parameter. Teorema berikut menjelaskan caranya.

Teorema 3.2 (Kriteria Eksponensial) Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari suatu distribusi dengan fungsi kepadatan peluang atau fungsi massa peluang berbentuk eksponensial:

$$f(x; \theta) = \exp[K(x)p(\theta) + S(x) + q(\theta)]$$

dengan himpunan dukungan yang tidak bergantung pada θ . Maka, statistik:

$$\sum_{i=1}^n K(X_i)$$

merupakan statistik cukup bagi θ .

Bukti

Karena $X_1, X_2, \dots, X_n$ merupakan sampel acak, fungsi kepadatan peluang bersama (atau fungsi massa peluang bersama) dari

$$X_1, X_2, \dots, X_n$$

dapat ditulis, berdasarkan sifat saling bebas, sebagai:

$$f(x_1, x_2, \dots, x_n; \theta) = f(x_1; \theta) \times f(x_2; \theta) \times \dots \times f(x_n; \theta)$$

Dengan menyubstitusikan fungsi massa peluang atau fungsi kepadatan peluang dalam bentuk eksponensial, diperoleh:

$$f(x_1, \dots, x_n; \theta) = \exp[K(x_1)p(\theta) + S(x_1) + q(\theta)] \times \dots \times \exp[K(x_n)p(\theta) + S(x_n) + q(\theta)]$$

Dengan menggabungkan suku-suku sejenis pada eksponen, diperoleh:

$$f(x_1, \dots, x_n; \theta) = \exp \left[p(\theta) \sum_{i=1}^n K(x_i) + \sum_{i=1}^n S(x_i) + nq(\theta) \right]$$

yang dapat difaktorkan sebagai:

$$f(x_1, \dots, x_n; \theta) = \left\{ \exp \left[p(\theta) \sum_{i=1}^n K(x_i) + nq(\theta) \right] \right\} \times \left\{ \exp \left[\sum_{i=1}^n S(x_i) \right] \right\}$$

Kita telah memfaktorkan fungsi massa peluang bersama atau fungsi kepadatan peluang bersama menjadi dua fungsi, yang satu (ϕ) hanya merupakan fungsi dari statistik $Y = \sum_{i=1}^n K(X_i)$ dan yang lain (h) tidak bergantung pada parameter θ :

$$f(x_1, \dots, x_n; \theta) = \underbrace{\left\{ \exp \left[p(\theta) \sum_{i=1}^n K(x_i) + nq(\theta) \right] \right\}}_{\phi(\sum_{i=1}^n K(x_i); \theta)} \times \underbrace{\left\{ \exp \left[\sum_{i=1}^n S(x_i) \right] \right\}}_{h(x_1, \dots, x_n)}$$

Oleh karena itu, Teorema Faktorisasi menyatakan bahwa $Y = \sum_{i=1}^n K(X_i)$ merupakan statistik cukup bagi θ .

Mari kita terapkan Kriteria Eksponensial pada sebuah contoh.

Contoh 3.5 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi geometrik dengan parameter p . Tentukan statistik cukup bagi parameter p .

Penyelesaian

Fungsi massa peluang peubah acak geometrik adalah:

$$f(x; p) = (1 - p)^{x-1} p$$

untuk $x = 1, 2, 3, \dots$. Fungsi massa peluang tersebut dapat ditulis dalam bentuk eksponensial sebagai:

$$f(x; p) = \exp \left[x \log(1 - p) + \log(1) + \log \left(\frac{p}{1 - p} \right) \right]$$

Oleh karena itu, $Y = \sum_{i=1}^n X_i$ merupakan statistik cukup bagi p . Mudah sekali!

Perlu dicatat bahwa hampir setiap fungsi massa peluang atau fungsi kepadatan peluang yang kita jumpai dalam mata kuliah ini dapat ditulis dalam bentuk eksponensial. Karena itu, saat mencoba menentukan statistik cukup bagi suatu parameter, Anda dapat menjadikan Kriteria Eksponensial sebagai alat pertama yang digunakan.

Dua Parameter atau Lebih

Dalam setiap contoh yang telah kita bahas sejauh ini dalam pelajaran ini, hanya ada satu parameter. Apa yang terjadi jika suatu distribusi peluang memiliki dua parameter, θ_1 dan θ_2 , misalnya, dan kita ingin menentukan pasangan statistik yang secara bersama-sama cukup bagi kedua parameter itu, katakanlah Y_1 dan Y_2 ? Untungnya, definisi kecukupan dapat dengan mudah diperluas untuk mencakup dua (atau lebih) parameter. Mari kita mulai dengan memperluas Teorema Faktorisasi.

3.1.1 Teorema Faktorisasi

Misalkan $X_1, X_2, \dots, X_n$ menyatakan peubah-peubah acak dengan fungsi kepadatan peluang bersama (atau fungsi massa peluang bersama):

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2)$$

yang bergantung pada parameter θ_1 dan θ_2 . Maka, statistik $Y_1 = u_1(X_1, X_2, \dots, X_n)$ dan $Y_2 = u_2(X_1, X_2, \dots, X_n)$ merupakan statistik yang secara bersama-sama cukup bagi θ_1 dan θ_2 jika dan hanya jika:

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \phi[u_1(x_1, \dots, x_n), u_2(x_1, \dots, x_n); \theta_1, \theta_2] h(x_1, \dots, x_n)$$

dengan:

ϕ adalah fungsi yang bergantung pada data $(x_1, x_2, \dots, x_n)$ hanya melalui fungsi $u_1(x_1, x_2, \dots, x_n)$ dan $u_2(x_1, x_2, \dots, x_n)$, serta

fungsi $h(x_1, \dots, x_n)$ tidak bergantung pada parameter θ_1 maupun θ_2 .

Mari kita uji teorema yang telah diperluas ini pada sebuah contoh.

Contoh 3.6 Misalkan $X_1, X_2, \dots, X_n$ menyatakan sampel acak dari distribusi normal $N(\theta_1, \theta_2)$. Artinya, θ_1 menyatakan rata-rata μ dan θ_2 menyatakan varians σ^2 . Gunakan Teorema Faktorisasi untuk menentukan statistik yang secara bersama-sama cukup bagi θ_1 dan θ_2 .

Penyelesaian

Karena $X_1, X_2, \dots, X_n$ merupakan sampel acak, fungsi kepadatan peluang bersama dari $X_1, X_2, \dots, X_n$ dapat ditulis, berdasarkan sifat saling bebas, sebagai:

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = f(x_1; \theta_1, \theta_2) \times f(x_2; \theta_1, \theta_2) \times \dots \times f(x_n; \theta_1, \theta_2)$$

Dengan menyubstitusikan fungsi kepadatan peluang peubah acak normal dengan rata-rata θ_1 dan varians θ_2 , fungsi kepadatan peluang bersamanya adalah:

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{1}{2} \frac{(x_1 - \theta_1)^2}{\theta_2} \right] \times \dots \times \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{1}{2} \frac{(x_n - \theta_1)^2}{\theta_2} \right]$$

Dengan menyederhanakan melalui penggabungan suku-suku sejenis, diperoleh:

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \left(\frac{1}{\sqrt{2\pi\theta_2}} \right)^n \exp \left[-\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \theta_1)^2}{\theta_2} \right]$$

Dengan menuliskan ulang faktor pertama, mengkuadratkan besaran dalam tanda kurung, serta mendistribusikan penjumlahan pada faktor kedua, diperoleh:

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \exp \left[n \log \left(\frac{1}{\sqrt{2\pi\theta_2}} \right) - \frac{1}{2\theta_2} \left\{ \sum_{i=1}^n x_i^2 - 2\theta_1 \sum_{i=1}^n x_i + \sum_{i=1}^n \theta_1^2 \right\} \right]$$

Dengan menyederhanakannya lebih lanjut, diperoleh:

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \exp \left[-\frac{1}{2\theta_2} \sum_{i=1}^n x_i^2 + \frac{\theta_1}{\theta_2} \sum_{i=1}^n x_i - \frac{n\theta_1^2}{2\theta_2} - n \log \sqrt{2\pi\theta_2} \right]$$

Perhatikan! Kita telah memfaktorkan fungsi kepadatan peluang bersama (PDF) menjadi dua fungsi, fungsi pertama (ϕ) hanya merupakan fungsi dari statistik $Y_1 = \sum_{i=1}^n X_i^2$ dan $Y_2 = \sum_{i=1}^n X_i$, sedangkan fungsi lainnya (h) tidak bergantung pada parameter θ_1 dan θ_2 :

$$f(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \underbrace{\exp \left[-\frac{1}{2\theta_2} \sum_{i=1}^n x_i^2 + \frac{\theta_1}{\theta_2} \sum_{i=1}^n x_i - \frac{n\theta_1^2}{2\theta_2} - n \log \sqrt{2\pi\theta_2} \right]}_{\phi[u_1(\sum_i x_i^2), u_2(\sum_i x_i); \theta_1, \theta_2]} \times \underbrace{1}_{h(x_1, \dots, x_n)}$$

Oleh karena itu, Teorema Faktorisasi menyatakan bahwa $Y_1 = \sum_{i=1}^n X_i^2$ dan $Y_2 = \sum_{i=1}^n X_i$ secara bersama-sama merupakan statistik cukup bagi θ_1 dan θ_2 . Selain itu, fungsi satu-satu dari Y_1 dan Y_2 , yaitu:

$$\begin{aligned} \bar{X} &= \frac{Y_2}{n} = \frac{1}{n} \sum_{i=1}^n X_i \\ \text{and} \\ S^2 &= \frac{Y_1 - (Y_2^2/n)}{n-1} \\ &= \frac{1}{n-1} \left[\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right] \end{aligned}$$

juga secara bersama-sama merupakan statistik cukup bagi θ_1 dan θ_2 . Nah! Kita baru saja menunjukkan bahwa penduga intuitif bagi μ dan σ^2 juga merupakan penduga cukup. Artinya, data tidak memuat informasi lebih banyak daripada yang dimuat oleh penduga $\bar{X}$ dan S^2 mengenai parameter μ dan σ^2 ! Tampaknya ini hal yang baik!

Kita baru saja memperluas Teorema Faktorisasi. Kriteria Eksponensial juga dapat diperluas untuk menangani dua (atau lebih) parameter. Bentuk perluasannya dinyatakan di sini tanpa bukti.

Catatan Kriteria Eksponensial

Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari suatu distribusi dengan fungsi kepadatan peluang (PDF) atau fungsi massa peluang (PMF) berbentuk eksponensial:

$$f(x; \theta_1, \theta_2) = \exp[K_1(x)p_1(\theta_1, \theta_2) + K_2(x)p_2(\theta_1, \theta_2) + S(x) + q(\theta_1, \theta_2)]$$

dengan himpunan dukungan yang tidak bergantung pada parameter θ_1 dan θ_2 . Maka, statistik $Y_1 = \sum_{i=1}^n K_1(X_i)$ dan $Y_2 = \sum_{i=1}^n K_2(X_i)$ secara bersama-sama cukup bagi θ_1 dan θ_2 .

Mari kita terapkan kriteria eksponensial yang diperluas pada contoh sebelumnya.

Contoh 3.7 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi normal $N(\theta_1, \theta_2)$. Artinya, θ_1 menyatakan rata-rata μ dan θ_2 menyatakan varians σ^2 . Gunakan Kriteria Eksponensial untuk menentukan pasangan statistik yang secara bersama-sama cukup bagi θ_1 dan θ_2 .

Penyelesaian

Fungsi kepadatan peluang suatu peubah acak normal dengan rata-rata θ_1 dan varians θ_2 dapat dituliskan dalam bentuk eksponensial sebagai berikut:

$$f(x; \theta_1, \theta_2) = \exp \left[-\frac{1}{2\theta_2} \underbrace{x^2}_{K_1(x)} + \frac{\theta_1}{\theta_2} \underbrace{x}_{K_2(x)} - \underbrace{\log(1)}_{S(x)} + \underbrace{\left(-\frac{\theta_1^2}{2\theta_2} - \log \sqrt{2\pi\theta_2} \right)}_{q(\theta_1, \theta_2)} \right]$$

Oleh karena itu, statistik $Y_1 = \sum_{i=1}^n X_i^2$ dan $Y_2 = \sum_{i=1}^n X_i$ secara bersama-sama merupakan statistik cukup bagi θ_1 dan θ_2 .

3.2 Metode Momen

Sejauh ini, kita selalu diberi suatu penduga lalu menghitung sifat-sifat penduga tersebut. Bagaimana jika kita belum memiliki penduga? Bagaimana cara menentukannya?

Pada pelajaran ini, kita memperkenalkan suatu metode sederhana untuk menentukan penduga, yaitu Metode Momen. Pada bagian berikutnya, kita akan membahas secara terperinci cara menentukan penduga kemungkinan maksimum.

Singkatnya, Metode Momen dilakukan dengan menyamakan momen sampel dengan momen teoretis. Mari kita mulai dengan mengingat kembali definisi momen teoretis serta mempelajari definisi momen sampel.

Definisi

1. $E(X^k)$ adalah momen teoretis orde k^{th} dari distribusi (**terhadap titik asal**), untuk $k = 1, 2, \dots$
2. $E[(X - \mu)^k]$ adalah momen teoretis orde k^{th} dari distribusi (**terhadap rata-rata, yaitu momen pusat**), untuk $k = 1, 2, \dots$
3. $M_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ adalah momen sampel orde k^{th} , untuk $k = 1, 2, \dots$
4. $M_k^* = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ adalah momen sampel orde k^{th} terhadap rata-rata, untuk $k = 1, 2, \dots$

Salah Satu Bentuk Metode Ini

Gagasan dasar bentuk metode ini adalah:

1. Samakan momen sampel pertama terhadap titik asal $M_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$ dengan momen teoretis pertama $E(X)$.
2. Samakan momen sampel kedua terhadap titik asal $M_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$ dengan momen teoretis kedua $E(X^2)$.
3. Lanjutkan dengan menyamakan momen sampel terhadap titik asal, M_k , dengan momen teoretis yang bersesuaian $E(X^k)$, $k = 3, 4, \dots$ hingga jumlah persamaannya sama dengan jumlah parameter.
4. Selesaikan persamaan-persamaan tersebut untuk memperoleh parameternya.

Nilai yang dihasilkan disebut **penduga metode momen**. Metode ini wajar diharapkan menghasilkan nilai dugaan yang baik karena distribusi empiris berkonvergensi, dalam pengertian tertentu, ke distribusi peluang. Oleh karena itu, momen-momen yang bersesuaian seharusnya kurang lebih sama.

Contoh 3.8 Misalkan $X_1, X_2, \dots, X_n$ merupakan peubah acak Bernoulli dengan parameter p . Berapakah penduga metode momen bagi p ?

Penyelesaian

Di sini, momen teoretis pertama terhadap titik asal adalah:

$$E(X_i) = p$$

Kita hanya hendak menurunkan penduga metode momen bagi satu parameter. Oleh karena itu, kita hanya memerlukan satu persamaan. Dengan menyamakan momen teoretis pertama terhadap titik asal dengan momen sampel yang bersesuaian, diperoleh:

$$p = \frac{1}{n} \sum_{i=1}^n X_i$$

Sekarang, kita hanya perlu menyelesaikan persamaan tersebut untuk p . Ternyata, dalam kasus ini, persamaannya sudah terselesaikan untuk p . Selesai! Kita hanya perlu membubuhkan tanda topi (^) pada parameter untuk memperjelas bahwa parameter tersebut kini menjadi penduga. Kita juga dapat memberi subskrip “MM” pada penduga untuk menandai bahwa penduga itu adalah penduga metode momen:

$$\hat{p}_{MM} = \frac{1}{n} \sum_{i=1}^n X_i$$

Jadi, dalam kasus ini, penduga metode momen sama dengan penduga kemungkinan maksimum, yaitu proporsi sampel.

Contoh 3.9 Misalkan $X_1, X_2, \dots, X_n$ merupakan peubah acak normal dengan rata-rata μ dan varians σ^2 . Berapakah penduga metode momen bagi rata-rata μ dan varians σ^2 ?

Penyelesaian

Momen teoretis pertama dan kedua terhadap titik asal adalah:

$$E(X_i) = \mu \quad E(X_i^2) = \sigma^2 + \mu^2$$

(Sebagai tambahan, jika belum jelas, momen kedua tersebut dapat diturunkan dengan memanipulasi rumus ringkas varians.) Dalam kasus ini, kita hendak menurunkan penduga metode momen bagi dua parameter. Oleh karena itu, kita memerlukan dua persamaan. Dengan menyamakan momen teoretis pertama terhadap titik asal dengan momen sampel yang bersesuaian, diperoleh:

$$E(X) = \mu = \frac{1}{n} \sum_{i=1}^n X_i$$

Selanjutnya, dengan menyamakan momen teoretis kedua terhadap titik asal dengan momen sampel yang bersesuaian, diperoleh:

$$E(X^2) = \sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

Sekarang, persamaan pertama menunjukkan bahwa penduga metode momen bagi rata-rata μ adalah rata-rata sampel:

$$\hat{\mu}_{MM} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

Selanjutnya, dengan menyubstitusikan rata-rata sampel untuk μ dalam persamaan kedua lalu menyelesaikannya terhadap σ^2 , diperoleh bahwa penduga metode momen bagi varians σ^2 adalah:

$$\hat{\sigma}_{MM}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \hat{\mu}_{MM}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

yang dapat ditulis ulang sebagai:

$$\hat{\sigma}_{MM}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Sekali lagi, dalam contoh ini, penduga metode momen sama dengan penduga kemungkinan maksimum.

Dalam beberapa kasus, alih-alih menggunakan momen sampel terhadap titik asal, lebih mudah menggunakan momen sampel terhadap rata-rata. Cara ini menghasilkan bentuk alternatif Metode Momen.

Bentuk Lain Metode Ini

Gagasan dasar bentuk metode ini adalah:

1. Samakan momen sampel pertama terhadap titik asal $M_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$ dengan momen teoretis pertama $E(X)$.
2. Samakan momen sampel kedua terhadap rata-rata $M_2^* = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ dengan momen teoretis kedua terhadap rata-rata $E[(X - \mu)^2]$.
3. Lanjutkan dengan menyamakan momen sampel terhadap rata-rata M_k^* dengan momen teoretis terhadap rata-rata yang bersesuaian $E[(X - \mu)^k]$, $k = 3, 4, \dots$ hingga jumlah persamaannya sama dengan jumlah parameter.
4. Selesaikan persamaan-persamaan tersebut untuk memperoleh parameternya.

Sekali lagi, nilai yang dihasilkan disebut **penduga metode momen**.

Contoh 3.10 Misalkan $X_1, X_2, \dots, X_n$ merupakan peubah acak gamma dengan parameter α dan θ , sehingga fungsi kepadatan peluangnya adalah:

$$f(x_i) = \frac{1}{\Gamma(\alpha)\theta^\alpha} x_i^{\alpha-1} e^{-x_i/\theta}$$

untuk $x_i > 0$. Oleh karena itu, fungsi kemungkinan:

$$L(\alpha, \theta) = \left(\frac{1}{\Gamma(\alpha)\theta^\alpha} \right)^n (x_1 x_2 \dots x_n)^{\alpha-1} \exp \left[-\frac{1}{\theta} \sum x_i \right]$$

sulit didiferensiasikan karena adanya fungsi gamma $\Gamma(\alpha)$. Jadi, alih-alih menentukan penduga kemungkinan maksimum, berapakah penduga metode momen bagi α dan θ ?

Penyelesaian

Momen teoretis pertama terhadap titik asal adalah:

$$E(X_i) = \alpha\theta$$

Selanjutnya, momen teoretis kedua terhadap rata-rata adalah:

$$\text{Var}(X_i) = E[(X_i - \mu)^2] = \alpha\theta^2$$

Sekali lagi, karena kita hendak menurunkan penduga metode momen bagi dua parameter, kita memerlukan dua persamaan. Dengan menyamakan momen teoretis pertama terhadap titik asal dengan momen sampel yang bersesuaian, diperoleh:

$$E(X) = \alpha\theta = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

Selanjutnya, dengan menyamakan momen teoretis kedua terhadap rata-rata dengan momen sampel yang bersesuaian, diperoleh:

$$\text{Var}(X) = \alpha\theta^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Sekarang, kita hanya perlu menyelesaikan kedua persamaan tersebut terhadap parameter α dan θ . Mari mulai dengan menentukan α dari persamaan pertama ($E(X)$). Dengan demikian, diperoleh:

$$\alpha = \frac{\bar{X}}{\theta}$$

Sekarang, dengan menyubstitusikan $\alpha = \frac{\bar{X}}{\theta}$ ke dalam persamaan kedua ($\text{Var}(X)$), diperoleh:

$$\alpha\theta^2 = \left(\frac{\bar{X}}{\theta}\right)\theta^2 = \bar{X}\theta = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Sekarang, dengan menentukan θ dari persamaan terakhir tersebut, lalu membubuhkan tanda topi, diperoleh bahwa penduga metode momen bagi θ adalah:

$$\hat{\theta}_{MM} = \frac{1}{n\bar{X}} \sum_{i=1}^n (X_i - \bar{X})^2$$

Selanjutnya, dengan menyubstitusikan nilai θ tersebut kembali ke dalam persamaan untuk α , lalu membubuhkan tanda topi, diperoleh bahwa penduga metode momen bagi α adalah:

$$\hat{\alpha}_{MM} = \frac{\bar{X}}{\hat{\theta}_{MM}} = \frac{\bar{X}}{(1/n\bar{X}) \sum_{i=1}^n (X_i - \bar{X})^2} = \frac{n\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Contoh 3.11 Mari kita kembali ke contoh dengan $X_1, X_2, \dots, X_n$ merupakan peubah acak normal dengan rata-rata μ dan varians σ^2 . Berapakah penduga metode momen bagi rata-rata μ dan varians σ^2 ?

Penyelesaian

Momen teoretis pertama terhadap titik asal adalah:

$$E(X_i) = \mu$$

Selanjutnya, momen teoretis kedua terhadap rata-rata adalah:

$$\text{Var}(X_i) = E[(X_i - \mu)^2] = \sigma^2$$

Sekali lagi, karena kita hendak menurunkan penduga metode momen bagi dua parameter, kita memerlukan dua persamaan. Dengan menyamakan momen teoretis pertama terhadap titik asal dengan momen sampel yang bersesuaian, diperoleh:

$$E(X) = \mu = \frac{1}{n} \sum_{i=1}^n X_i$$

Selanjutnya, dengan menyamakan momen teoretis kedua terhadap rata-rata dengan momen sampel yang bersesuaian, diperoleh:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Sekarang, kita hanya perlu menyelesaikan kedua persamaan itu terhadap kedua parameter tersebut. Ternyata, dalam kasus ini, persamaannya sudah terselesaikan terhadap μ dan σ^2 . Selesai! Kita hanya perlu membubuhkan tanda topi (^) pada parameter untuk memperjelas bahwa keduanya adalah penduga. Dengan demikian, diperoleh bahwa penduga metode momen bagi μ adalah:

$$\hat{\mu}_{MM} = \bar{X}$$

(yang, berdasarkan pembahasan sebelumnya, kita ketahui bersifat tak bias). Penduga metode momen bagi σ^2 adalah:

$$\hat{\sigma}_{MM}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

(yang, berdasarkan pembahasan sebelumnya, kita ketahui bersifat bias). Bersama contoh kedua, contoh ini menunjukkan bahwa kedua bentuk metode tersebut dapat memerlukan tingkat usaha yang berbeda, bergantung pada situasi.

3.3 Ringkasan

Dalam pelajaran ini, kita menelaah cara menurunkan penduga. Kita memperkenalkan Metode Momen, yang menyamakan momen sampel dengan momen populasi untuk menduga parameter. Kita juga memperdalam pemahaman tentang kecukupan dengan mempelajari cara mengidentifikasi statistik yang menangkap seluruh informasi mengenai suatu parameter menggunakan Teorema Faktorisasi dan Kriteria Eksponensial. Perangkat ini membantu menyederhanakan data yang kompleks sekaligus mempertahankan hal-hal yang esensial bagi inferensi.

Pokok-Pokok Penting

- Metode Momen menyediakan cara langsung untuk menentukan penduga.
- Statistik cukup memuat seluruh informasi yang diperlukan untuk menduga suatu parameter dan memungkinkan kita mereduksi data tanpa kehilangan daya inferensial.
- Teorema Faktorisasi membantu menentukan apakah suatu statistik bersifat cukup.
- Kriteria Eksponensial merupakan jalan pintas untuk memeriksa kecukupan pada model keluarga eksponensial.

1. [Pelajaran](#)
2. [4 Pendugaan Kemungkinan Maksimum \(MLE\) \(Bagian I\)](#)

4 Pendugaan Kemungkinan Maksimum (MLE) (Bagian I)

MLE

R

Gambaran Umum

Pada pelajaran sebelumnya, kita memperkenalkan cara menentukan penduga dengan Metode Momen. Pada pelajaran ini, kita akan memperkenalkan cara lain untuk menentukan penduga, yaitu dengan memaksimumkan fungsi kemungkinan.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Menuliskan fungsi kemungkinan dan fungsi log-kemungkinan untuk data dari suatu model peluang tertentu,
2. Menghitung secara analitik nilai dugaan kemungkinan maksimum (MLE) untuk berbagai model berparameter tunggal ketika nilai datanya diberikan,
3. Menghitung secara analitik penduga kemungkinan maksimum untuk berbagai model berparameter tunggal ketika data dipandang sebagai peubah acak yang belum teramati,
4. Menghitung secara analitik nilai dugaan kemungkinan maksimum (MLE) untuk berbagai model berparameter tunggal ketika nilai datanya diberikan (misalnya, $x=(1.6, 3.1, 7.8)$),
5. Menghitung secara analitik penduga kemungkinan maksimum untuk model multiparameter ketika data dipandang sebagai peubah acak yang belum teramati, dan
6. Menghitung secara analitik penduga kemungkinan maksimum untuk berbagai model berparameter tunggal ketika data dipandang sebagai peubah acak yang belum teramati dan himpunan dukungannya bergantung pada parameter.

4.1 Gagasan Dasar

Wajar jika nilai dugaan yang baik bagi parameter tak diketahui θ adalah nilai θ yang **memaksimumkan** fungsi massa atau kepadatan peluang bersama pada data yang kita amati—yakni fungsi kemungkinannya. Dari sinilah nama ‘kemungkinan maksimum’ berasal.

Definisi 4.1 (Fungsi Kemungkinan) Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari suatu distribusi dengan parameter tak diketahui, $\theta_1, \theta_2, \dots, \theta_m$. Misalkan fungsi kepadatan peluang (atau fungsi massa peluang) dinotasikan dengan $f(x_i|\theta_1, \theta_2, \dots, \theta_m)$. Misalkan $(\theta_1, \theta_2, \dots, \theta_m)$ dibatasi pada suatu ruang parameter tertentu Ω . **fungsi kemungkinan**, $L(\theta_1, \theta_2, \dots, \theta_m)$, adalah fungsi massa atau kepadatan peluang bersama sampel yang dievaluasi pada data teramati dan kemudian dipandang sebagai fungsi dari parameter. Jadi:

$$L(\theta_1, \theta_2, \dots, \theta_m) = \prod_{i=1}^n f(x_i|\theta_1, \theta_2, \dots, \theta_m) = f(x_1|\theta_1, \theta_2, \dots, \theta_m)f(x_2|\theta_1, \theta_2, \dots, \theta_m) \cdots f(x_n|\theta_1, \theta_2, \dots, \theta_m)$$

Perhatikan!

simbol $\prod$ berarti ‘hasil kali’. Perhatikan pula bahwa fungsi kemungkinan kita pandang sebagai fungsi dari $\theta_1, \theta_2, \dots, \theta_m$. Karena peubah acaknya saling bebas, fungsi massa atau kepadatan peluang bersama sama dengan hasil kali fungsi individualnya.

Contoh 4.1 Misalkan $X_i \stackrel{iid}{\sim} \text{Bin}(10, p)$ untuk $i = 1, 2, 3, 4, 5$. Dengan kata lain, misalkan $X_1, X_2, \dots, X_5$ merupakan sampel yang saling bebas dan berdistribusi identik dari distribusi binomial dengan parameter $n = 10$ dan p . Tentukan fungsi kemungkinan (yang sering disingkat sebagai kemungkinan).

Penyelesaian

Fungsi kemungkinan adalah hasil kali fungsi massa peluang masing-masing pengamatan. Oleh karena itu,

$$L(p) = \prod_{i=1}^n f(x_i|p) = \prod_{i=1}^n \binom{10}{x_i} p^{x_i} (1-p)^{10-x_i} = \left[\prod_{i=1}^n \binom{10}{x_i} \right] p^{\sum_{i=1}^n x_i} (1-p)^{10n - \sum_{i=1}^n x_i}$$

Sekarang, setelah memiliki definisi formal tentang kemungkinan, gagasan dasar pendugaan kemungkinan maksimum adalah memperlakukan fungsi kemungkinan $L(\theta)$ sebagai fungsi dari θ lalu menentukan nilai θ yang memaksimumkannya. Untuk sementara, mari kita tinjau kasus dengan satu parameter tak diketahui saja, θ . Ingat kembali dari kalkulus bahwa untuk menentukan maksimum dari $L(\theta)$ (atau $\text{argmax}(L(\theta))$), mula-mula kita ambil turunan fungsi tersebut terhadap θ . Berikutnya, kita samakan turunannya dengan 0 dan selesaikan terhadap θ . Dengan demikian kita memperoleh titik kritis; untuk menentukan apakah titik tersebut merupakan maksimum, kita masih harus menelaah bentuk fungsi—misalnya melalui turunan kedua—serta batas ruang parameter.

Contoh 4.2 Tinjau kembali contoh sebelumnya, dengan $X_i \stackrel{iid}{\sim} \text{Bin}(10, p)$ untuk $i = 1, 2, 3, 4, 5$. Kita telah memperoleh fungsi kemungkinan:

$$L(p) = \left[\prod_{i=1}^n \binom{10}{x_i} \right] p^{\sum_{i=1}^n x_i} (1-p)^{10n - \sum_{i=1}^n x_i}$$


Penyelesaian

Langkah pertama adalah menentukan fungsi kemungkinan, yang sudah kita miliki. Berikutnya, kita tentukan turunan pertama fungsi kemungkinan terhadap p . Sekarang saatnya menggunakan kalkulus.

$$\frac{d}{dp} L(p) = \left[\prod_{i=1}^n \binom{10}{x_i} \right] \left(\sum x_i \right) p^{\sum x_i - 1} (1-p)^{10n - \sum x_i} - \left[\prod_{i=1}^n \binom{10}{x_i} \right] p^{\sum x_i} (10n - \sum x_i) (1-p)^{10n - \sum x_i - 1}$$

Langkah berikutnya adalah menyamakan turunan dengan 0 dan menyelesaikannya terhadap p . Tunggu—adakah cara yang lebih mudah untuk menyelesaikan masalah ini?

Kita akan menggunakan sebuah ‘trik’ yang sering mempermudah proses diferensiasi. Perhatikan bahwa logaritma natural merupakan fungsi yang naik tegas pada x .



Gambar 4.1

Artinya, untuk dua nilai positif dengan $x_1 < x_2$, logaritma natural mempertahankan urutan; demikian pula, jika suatu fungsi positif memenuhi $f(x_1) < f(x_2)$ maka logaritma fungsi itu mempertahankan urutan tersebut bagi setiap x . Karena itu, nilai x yang memaksimumkan $f(x)$ juga akan memaksimumkan logaritma natural fungsi tersebut. Sekarang, mari kita terapkan gagasan ini pada contoh sebelumnya.

Contoh 4.3 Sekali lagi, kita memiliki $X_i \stackrel{iid}{\sim} \text{Bin}(10, p)$ untuk $i = 1, 2, 3, 4, 5$ dan fungsi kemungkinan:

$$L(p) = \left[\prod_{i=1}^n \binom{10}{x_i} \right] p^{\sum_{i=1}^n x_i} (1-p)^{10n - \sum_{i=1}^n x_i}$$

Tentukan nilai p yang memaksimumkan fungsi kemungkinan.

Penyelesaian

Mari kita tinjau logaritma natural dari $L(p)$, yang disebut **fungsi log-kemungkinan**.

$$\ell(p) = \ln L(p) = \ln \prod_{i=1}^n f(x_i|p)$$

Dengan aturan logaritma, kita memperoleh

$$\ell(p) = \ln \prod_{i=1}^n f(x_i|p) = \sum_{i=1}^n \ln f(x_i|p) = \sum_{i=1}^n \left[\ln \binom{10}{x_i} + x_i \ln p + (10 - x_i) \ln(1 - p) \right]$$

Sekarang, ambil turunan $\ell(p)$ terhadap p .

$$\frac{d}{dp}\ell(p) = \sum_{i=1}^n \left[0 + \frac{x_i}{p} - \frac{(10 - x_i)}{1 - p} \right] = \frac{\sum x_i}{p} - \frac{\sum(10 - x_i)}{1 - p}$$

Langkah berikutnya adalah menyamakan turunan dengan 0 dan menyelesaikannya terhadap p .

$$\begin{aligned} 0 &= \frac{\sum x_i}{p} - \frac{\sum(10 - x_i)}{1 - p}, & \Rightarrow \frac{\sum(10 - x_i)}{1 - p} &= \frac{\sum x_i}{p} \\ \Rightarrow p \sum(10 - x_i) &= (1 - p) \sum x_i \\ \Rightarrow 10np - \sum x_i p &= \sum x_i - \sum x_i p \\ \Rightarrow 10np &= \sum x_i \\ \Rightarrow p &= \frac{\sum x_i}{10n} \end{aligned}$$

Akhirnya, kita periksa bahwa nilai yang diperoleh merupakan maksimum. Kita ambil turunan kedua terhadap p .

$$\frac{d^2}{dp^2}\ell(p) = -\frac{\sum x_i}{p^2} - \frac{\sum(10 - x_i)}{(1 - p)^2}$$

Agar $p = \frac{\sum x_i}{10n}$ merupakan maksimum interior, nilai turunan kedua pada titik tersebut harus kurang dari 0.

$$-\frac{\sum x_i}{\left(\frac{\sum x_i}{10n}\right)^2} - \frac{\sum(10 - x_i)}{\left(1 - \frac{\sum x_i}{10n}\right)^2}$$

Karena setiap x_i berada di antara 0 dan 10, turunan kedua bernilai negatif selama sampel bukan seluruhnya 0 dan bukan seluruhnya 10, sehingga nilai di atas merupakan maksimum interior. Jika seluruh pengamatan bernilai 0 atau 10, maksimum dicapai masing-masing pada batas parameter 0 atau 1. Jika data masih dipandang sebagai peubah acak, kaidah ini membentuk penduga kemungkinan maksimum (MLE); setelah data diamati, hasilnya adalah nilai dugaan kemungkinan maksimum. Keduanya dilambangkan dengan simbol ‘topi’. Untuk data teramati, nilai dugaannya adalah $\hat{p} = \frac{\sum x_i}{10n}$.

Perhatikan!

Jika fungsi log-kemungkinan telah dibuktikan cekung tegas, atau unimodal dengan satu titik kritis di interior ruang parameter, $\ell(\theta)$ memiliki titik kritis tersebut sebagai maksimum global. Tanpa syarat tersebut, titik kritis saja tidak cukup: periksa batas ruang parameter, dukungan yang bergantung pada parameter, atau gunakan uji turunan kedua.

Sekarang kita nyatakan definisi formal Penduga Kemungkinan Maksimum (MLE).

Definisi 4.2 (Penduga Kemungkinan Maksimum) Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari suatu distribusi dengan parameter tak diketahui, $\theta_1, \theta_2, \dots, \theta_m$. Misalkan fungsi kepadatan peluang (atau fungsi massa peluang) dinotasikan dengan $f(x_i|\theta_1, \theta_2, \dots, \theta_m)$. Misalkan $(\theta_1, \theta_2, \dots, \theta_m)$ dibatasi pada suatu ruang parameter tertentu Ω . Fungsi kemungkinan adalah fungsi massa atau kepadatan peluang bersama sampel yang dievaluasi pada data teramati dan dipandang sebagai fungsi parameter. Jadi:

$$L(\theta_1, \theta_2, \dots, \theta_m) = \prod_{i=1}^n f(x_i|\theta_1, \theta_2, \dots, \theta_m)$$

Jika $[u_1(X_1, X_2, \dots, X_n), u_2(X_1, X_2, \dots, X_n), \dots, u_m(X_1, X_2, \dots, X_n)]$ merupakan m -tuple yang memaksimalkan fungsi kemungkinan, maka:

$$\hat{\theta}_i = u_i(X_1, X_2, \dots, X_n), \quad i = 1, 2, \dots, m$$

adalah **penduga kemungkinan maksimum** bagi θ_i . Nilai statistik tersebut yang bersesuaian setelah sampel diamati, yaitu,

$$[u_1(x_1, x_2, \dots, x_n), u_2(x_1, x_2, \dots, x_n), \dots, u_m(x_1, x_2, \dots, x_n)]$$

disebut **nilai dugaan kemungkinan maksimum** bagi θ_i , untuk $i = 1, 2, \dots, m$.

4.2 Kasus Satu Parameter

Pada bagian ini, kita merangkum langkah-langkah untuk menentukan penduga kemungkinan maksimum pada kasus satu parameter.

Langkah-Langkah Menentukan MLE (Kasus Satu Parameter)

1. Diberikan sampel acak $X_1, X_2, \dots, X_n$ dari suatu distribusi dengan parameter tak diketahui, θ , tentukan fungsi kemungkinan:

$$L(\theta) = \prod_{i=1}^n f(x_i|\theta)$$

2. Tentukan fungsi log-kemungkinan:

$$\ell(\theta) = \ln L(\theta) = \ln \prod_{i=1}^n f(x_i|\theta) = \sum_{i=1}^n \ln f(x_i|\theta)$$

3. Ambil turunan pertama fungsi log-kemungkinan:

$$\ell'(\theta) = \frac{d}{d\theta} \ell(\theta)$$

4. Samakan $\ell'(\theta) = 0$ dan selesaikan terhadap θ . Langkah ini menghasilkan sebuah titik kritis; titik tersebut baru menjadi kandidat MLE dan masih harus diperiksa terhadap bentuk fungsi serta batas ruang parameter.
5. Nilai kritis yang telah diverifikasi sebagai maksimum merupakan MLE bagi θ , yang dinotasikan dengan $\hat{\theta}$.

Setelah definisi formal dan langkah-langkahnya jelas, mari kita kerjakan beberapa contoh.

Contoh 4.4 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi Geometrik dengan parameter tak diketahui p . Carilah penduga kemungkinan maksimum (MLE).

Penyelesaian

Fungsi massa peluang (PMF) peubah acak Geometrik adalah $f(x) = (1-p)^{x-1}p$ untuk $x = 1, 2, 3, \dots$. Ikuti langkah-langkah di atas untuk mencari MLE.

1. Fungsi kemungkinannya adalah:

$$L(p) = \prod_{i=1}^n (1-p)^{x_i-1} p = (1-p)^{\sum_{i=1}^n (x_i-1)} p^n$$

2. Carilah fungsi log-kemungkinannya:

$$\ell(p) = \sum (x_i - 1) \ln(1-p) + n \ln p$$

3. Ambil turunan pertama dari $\ell(p)$ terhadap p .

$$\frac{d}{dp} \ell(p) = -\frac{\sum (x_i - 1)}{1-p} + \frac{n}{p}$$

4. Samakan turunan tersebut dengan 0 dan selesaikan terhadap p .

$$\begin{aligned} 0 &= -\frac{\sum (x_i - 1)}{1-p} + \frac{n}{p}, & \Rightarrow 0 &= \frac{-p \sum (x_i - 1) + n(1-p)}{p(1-p)} = \frac{-p \sum x_i + np + n - np}{p(1-p)} \\ \Rightarrow 0 &= -p \sum x_i + n, & \Rightarrow -n &= -p \sum x_i \\ \Rightarrow p &= \frac{n}{\sum x_i} \end{aligned}$$

5. MLE untuk p adalah $\hat{p} = \frac{n}{\sum x_i}$

Contoh 4.5 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi Gamma dengan parameter tak diketahui θ dan parameter diketahui α . Carilah MLE untuk θ .

Penyelesaian

Fungsi kepadatan peluang (PDF) peubah acak Gamma adalah $f(x) = \frac{1}{\Gamma(\alpha)\theta^\alpha} x^{\alpha-1} e^{-x/\theta}$ untuk $x > 0$. Ikuti langkah-langkah tersebut untuk mencari MLE.

1. Fungsi kemungkinannya adalah:

$$L(\theta) = \prod_{i=1}^n \frac{1}{\Gamma(\alpha)\theta^\alpha} x_i^{\alpha-1} e^{-x_i/\theta} = \left(\frac{1}{\Gamma(\alpha)\theta^\alpha} \right)^n \left(\prod_{i=1}^n x_i \right)^{\alpha-1} e^{-\frac{\sum x_i}{\theta}}$$

2. Carilah fungsi log-kemungkinannya:

$$\ell(\theta) = -n \ln \Gamma(\alpha) - n\alpha \ln \theta + (\alpha - 1) \sum \ln x_i - \frac{\sum_{i=1}^n x_i}{\theta}$$

3. Ambil turunan pertama dari $\ell(\theta)$ terhadap θ .

$$\frac{d}{d\theta} \ell(\theta) = -\frac{n\alpha}{\theta} + \frac{\sum x_i}{\theta^2}$$

4. Samakan turunan tersebut dengan 0 dan selesaikan terhadap θ .

$$\begin{aligned} 0 &= -\frac{n\alpha}{\theta} + \frac{\sum x_i}{\theta^2} = \frac{-n\alpha\theta + \sum x_i}{\theta^2} \\ \Rightarrow 0 &= -n\alpha\theta + \sum x_i, & \Rightarrow n\alpha\theta &= \sum x_i \\ \Rightarrow \theta &= \frac{\sum x_i}{n\alpha} \end{aligned}$$

5. MLE untuk θ adalah $\hat{\theta} = \frac{\sum x_i}{n\alpha}$

Pada dua contoh terakhir, kita diberi sampel acak dan memperoleh penduga kemungkinan maksimum bagi parameter yang tidak diketahui. Sekarang mari kita lihat beberapa contoh untuk mencari nilai dugaan kemungkinan maksimum ketika sekumpulan nilai pengamatan diberikan.

Contoh 4.6 Misalkan kita mempunyai tiga nilai pengamatan dari distribusi Geometrik. Nilai-nilai pengamatan itu adalah $x_1 = 12, x_2 = 19, x_3 = 10$. Carilah nilai dugaan kemungkinan maksimum untuk p .

Penyelesaian

Pada contoh sebelumnya, MLE yang kita peroleh adalah $\hat{p} = \frac{n}{\sum x_i}$. Jadi, nilai dugaan kemungkinan maksimumnya adalah:

$$\hat{p} = \frac{n}{\sum x_i} = \frac{3}{12 + 19 + 10} = \frac{3}{41}$$

Contoh 4.7 Misalkan kita mempunyai tiga nilai pengamatan dari distribusi Gamma dengan $\alpha = 3$ dan parameter tak diketahui θ . Nilai-nilai pengamatannya adalah $x_1 = 3.4, x_2 = 8.1, x_3 = 5.5$. Carilah nilai dugaan kemungkinan maksimum untuk θ .

Penyelesaian

Pada contoh sebelumnya, MLE yang kita peroleh adalah $\hat{\theta} = \frac{\sum x_i}{n\alpha}$. Jadi, nilai dugaan kemungkinan maksimumnya adalah:

$$\hat{\theta} = \frac{\sum x_i}{n\alpha} = \frac{3.4 + 8.1 + 5.5}{3(3)} = \frac{17}{9} \approx 1.8889$$

Contoh 4.8 Misalkan kita mempunyai nilai-nilai pengamatan berikut dari distribusi Poisson dengan parameter λ .

$$\begin{array}{ccc} 14, & 21, & 17 \\ 11, & 22 & \end{array}$$

Carilah nilai dugaan kemungkinan maksimum untuk λ .

Penyelesaian

Pertama-tama, kita perlu mencari MLE dengan langkah-langkah biasa. Fungsi kemungkinannya adalah:

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod x_i!}$$

Fungsi log-kemungkinannya adalah:

$$\ell(\lambda) = -n\lambda + \left(\sum x_i\right) \ln \lambda - \sum_{i=1}^n \ln(x_i!)$$

Turunan pertamanya adalah:

$$\frac{d\ell(\lambda)}{d\lambda} = -n + \frac{\sum x_i}{\lambda}$$

Dengan menyamakan turunan tersebut dengan 0 dan menyelesaikannya terhadap λ , kita memperoleh MLE berikut:

$$\begin{aligned} 0 &= -n + \frac{\sum x_i}{\lambda}, & \Rightarrow n &= \frac{\sum x_i}{\lambda} \\ \Rightarrow \hat{\lambda} &= \frac{\sum x_i}{n} = \bar{x} \end{aligned}$$

Jadi, nilai dugaan kemungkinan maksimum untuk λ adalah $\hat{\lambda} = \frac{14+21+17+11+22}{5} = \frac{85}{5} = 17$.

4.3 Maksimalkan Fungsi Kemungkinan secara Langsung: Himpunan Dukungan yang Bergantung pada Parameter

Pada bagian ini, kita akan melanjutkan pembahasan pendugaan kemungkinan maksimum. Perhatikan contoh berikut.

Contoh 4.9 Misalkan kita mempunyai sampel acak berukuran n dari distribusi Uniform pada interval $(0, a)$, dengan a merupakan bilangan real yang tidak diketahui. Apa MLE untuk a ?

Penyelesaian

Mari kita telaah masalah ini dengan langkah-langkah biasa. Fungsi kepadatan peluang (PDF) distribusi Uniform ini adalah $f(x) = \frac{1}{a}$, untuk $0 < x < a$. Fungsi kemungkinannya adalah:

$$L(a) = \prod_{i=1}^n \frac{1}{a} = \frac{1}{a^n} = a^{-n}$$

Fungsi log-kemungkinannya adalah:

$$\ell(a) = -n \ln a$$

Turunannya adalah:

$$\frac{d}{da} \ell(a) = -\frac{n}{a}$$

Namun, apa yang terjadi jika kita menyamakan turunan dengan 0 dan mencoba menyelesaikannya terhadap a ? Jika kita menetapkan $-\frac{n}{a} = 0$, persamaan tersebut tidak memiliki penyelesaian; jadi MLE-nya bukan $\hat{a} = \infty$.

Apa yang membedakan contoh ini dari contoh-contoh MLE sebelumnya? Fungsi kemungkinan tersebut monoton turun, bukan monoton naik, sehingga tidak memiliki titik kritis interior. Maksimum atau supremumnya ditentukan oleh batas himpunan dukungan yang bergantung pada parameter.

Pada contoh di atas, kita belum memperhitungkan kendala yang ditetapkan oleh a terhadap data. Dalam contoh-contoh sebelumnya, himpunan dukungan tidak bergantung pada parameter yang tidak diketahui. Sebagai contoh, himpunan dukungan X sebagai peubah acak Normal adalah $-\infty < x < \infty$. Pada contoh Gamma, himpunan dukungan X adalah $x > 0$, dan seterusnya.

Namun, untuk distribusi Uniform, himpunan dukungan bergantung pada parameter a dan kita belum memperhitungkan kendala yang ditetapkan oleh a terhadap data. Jadi, apa yang harus kita lakukan?

Mari kita definisikan dahulu fungsi indikator.

Def. 4.3 (Fungsi indikator) Misalkan terdapat suatu kejadian A . **Fungsi indikator untuk A** didefinisikan sebagai:

$$\mathbf{1}_A = \begin{cases} 1, & \text{if } A \text{ occurs} \\ 0, & \text{if } A \text{ does not occur} \end{cases}$$

Mari kita lihat contoh penggunaan fungsi indikator untuk mencari penduga kemungkinan maksimum.

Contoh 4.10 Misalkan $Y_1, \dots, Y_n$ merupakan sampel acak dari distribusi Bernoulli dengan parameter p . Fungsi massa peluang (PMF) dari Y adalah:

$$f(y) = \begin{cases} p^y(1-p)^{1-y} & y = 0, 1 \\ 0 & \text{otherwise} \end{cases}$$

PMF tersebut dapat ditulis dengan cara lain. Salah satu bentuknya adalah

$$f(y) = \begin{cases} p & y = 1 \\ 1-p & y = 0 \end{cases}$$

Bentuk lainnya menggunakan fungsi indikator:

$$f(y) = p^y(1-p)^{1-y} \mathbf{1}_{\{y \in \{0,1\}\}}$$

dengan

$$\mathbf{1}_{\{y \in \{0,1\}\}} = \begin{cases} 1 & \text{if } y = 0 \text{ or } y = 1 \\ 0 & \text{otherwise} \end{cases}$$

Dengan menggunakan bentuk PMF ini, carilah penduga kemungkinan maksimum untuk p .

Penyelesaian

Fungsi kemungkinannya adalah:

$$L(p) = \prod_{i=1}^n p^{y_i} (1-p)^{1-y_i} \mathbf{1}_{\{y_i \in \{0,1\}\}} = p^{\sum_i y_i} (1-p)^{n-\sum_i y_i} \prod_{i=1}^n \mathbf{1}_{\{y_i \in \{0,1\}\}}$$

Fungsi log-kemungkinannya adalah:

$$\ell(p) = \sum y_i \ln p + (n - \sum y_i) \ln(1-p) + \sum \ln(\mathbf{1}_{\{y_i \in \{0,1\}\}})$$

Selanjutnya, ambil turunan terhadap p .

$$\frac{d\ell(p)}{dp} = \frac{\sum_i y_i}{p} - \frac{n - \sum_i y_i}{1-p}$$

Pada tahap ini, perhatikan bahwa fungsi indikator tidak muncul lagi karena konstan terhadap p . Sekarang, lanjutkan untuk mencari MLE.

$$\begin{aligned} \frac{\sum_i y_i}{p} &= \frac{n - \sum_i y_i}{1-p}, & \Rightarrow \sum_i y_i - p \sum_i y_i &= np - p \sum_i y_i \\ \Rightarrow \sum_i y_i &= np, & \Rightarrow \hat{p} &= \frac{\sum_i y_i}{n} \end{aligned}$$

Bagaimana hal ini membantu kita dalam kasus Uniform $(0, a)$ tersebut? Pada contoh di atas, kita tahu bahwa X merupakan peubah acak Uniform pada interval $(0, a)$. Jadi, alih-alih menuliskan PDF sebagai

$$f(x) = \begin{cases} \frac{1}{a}, & 0 < x < a \\ 0, & \text{otherwise} \end{cases}$$

kita dapat menulisnya ulang dengan fungsi indikator.

$$f(x) = \frac{1}{a} \times \mathbf{1}_{x \in (0,a)}$$

dengan

$$\mathbf{1}_{x \in (0,a)} = \begin{cases} 1, & \text{if } x \in (0, a) \\ 0, & \text{if } x \notin (0, a) \end{cases}$$

Contoh 4.11 Carilah penduga kemungkinan maksimum untuk a pada contoh Uniform tersebut.

Penyelesaian

Sekali lagi, kita mulai dengan fungsi kemungkinan

$$L(a) = \prod_{i=1}^n \frac{1}{a} \mathbf{1}_{\{x_i \in (0,a)\}} = a^{-n} \prod_{i=1}^n \mathbf{1}_{\{x_i \in (0,a)\}}$$

Perhatikan bahwa jika $x_i > a$, maka fungsi kemungkinan bernilai 0. Dengan kata lain, a tidak boleh lebih kecil daripada satu pun x_i . Oleh karena itu, untuk memaksimalkan $L(a)$, kita harus membuat a sekecil mungkin sambil tetap lebih besar daripada maksimum sampel. Karena batas kanan himpunan dukungan ditulis terbuka, maksimum tidak tercapai; nilai berikut adalah batas supremumnya:

$$a \downarrow X_{(n)} = Y_n$$

Jadi, untuk model dengan batas terbuka sebagaimana ditulis, batas supremum bagi a diberikan oleh statistik urutan maksimum, Y_n , karena supremum fungsi kemungkinan didekati ketika $a \downarrow \max_i x_i$.

Contoh 4.12 Misalkan kita mempunyai $X_i \sim \text{Pareto}(m, \alpha = 2)$ merupakan sampel iid berukuran n , dan misalkan parameter $\alpha = 2$. PDF distribusi Pareto adalah:

$$f(x) = \frac{\alpha m^\alpha}{x^{\alpha+1}} = \frac{2m^2}{x^3}, \quad x \geq m$$

Tentukan penduga kemungkinan maksimum bagi m .

Penyelesaian

Seperti biasa, langkah pertama adalah menentukan fungsi kemungkinan:

$$L(m) = \prod_{i=1}^n \frac{2m^2}{x_i^3} \mathbf{1}_{\{x_i \geq m\}} = \frac{2^n m^{2n}}{\prod x_i^3} \prod_{i=1}^n \mathbf{1}_{\{x_i \geq m\}}$$

Untuk memaksimumkan fungsi kemungkinan, kita meninjau suku-suku yang memuat m . Yaitu,

$$m^{2n} \prod_{i=1}^n \mathbf{1}_{\{x_i \geq m\}}$$

Hasil kali fungsi indikator sama dengan 1 hanya jika $x_1 \geq m, x_2 \geq m, \dots, x_n \geq m$. Ini setara dengan menyatakan bahwa statistik urutan minimum lebih besar daripada atau sama dengan m . Dengan kata lain, jika Y_1 (statistik urutan pertama atau minimum) lebih besar daripada atau sama dengan m , maka semua pengamatan lebih besar daripada atau sama dengan m . Oleh karena itu, penduga kemungkinan maksimum bagi m adalah statistik urutan pertama, Y_1 .

Catatan!

Pendekatan ini diperlukan ketika fungsi kemungkinan bersifat monoton setelah faktor himpunan dukungan dipisahkan, dan arah batas layak harus diperhatikan. Ketika $L(\theta)$ monoton naik dan himpunan dukungan memberi batas atas pada parameter, MLE sering kali adalah $\hat{\theta} = \min(x_i)$. Demikian pula, ketika $L(\theta)$ monoton turun dan himpunan dukungan memberi batas bawah pada parameter, MLE sering kali adalah $\hat{\theta} = \max(x_i)$.

Contoh 4.13 Misalkan kita mempunyai sampel acak $X_1, \dots, X_4$ dari distribusi Seragam pada $[3c, 10]$. Tentukan nilai dugaan kemungkinan maksimum bagi c dengan menggunakan pengamatan berikut.

$$\begin{aligned} x_1 &= -5, & x_2 &= 6 \\ x_3 &= -1, & x_4 &= 2 \end{aligned}$$

Penyelesaian

Langkah pertama adalah menentukan PDF dari X_i .

$$f(x_i|c) = \frac{1}{10-3c} \mathbf{1}_{\{3c \leq x_i \leq 10\}}, \quad i = 1, 2, 3, 4, \quad c < \frac{10}{3}.$$

Selanjutnya, kita menentukan fungsi kemungkinan.

$$\begin{aligned} L(c) &= \prod_{i=1}^4 \frac{1}{10-3c} \mathbf{1}_{\{3c \leq x_i \leq 10\}} \\ &= \left(\frac{1}{10-3c} \right)^4 \mathbf{1}_{\{3c \leq x_1 \leq 10, 3c \leq x_2 \leq 10, 3c \leq x_3 \leq 10, 3c \leq x_4 \leq 10\}} \end{aligned}$$

Kita dapat menunjukkan bahwa $\left(\frac{1}{10-3c}\right)^4$ merupakan fungsi yang monoton naik. Sekarang, mari kita cermati fungsi indikatornya.

$$\mathbf{1}_{\{3c \leq x_1 \leq 10, 3c \leq x_2 \leq 10, 3c \leq x_3 \leq 10, 3c \leq x_4 \leq 10\}}$$

Cobalah yakinkan diri Anda bahwa fungsi indikator tersebut juga dapat ditulis sebagai:

$$\mathbf{1}_{\{3c \leq x_1, 3c \leq x_2, 3c \leq x_3, 3c \leq x_4\}} \times \mathbf{1}_{\{x_1 \leq 10, x_2 \leq 10, x_3 \leq 10, x_4 \leq 10\}}$$

Suku kedua bukan fungsi dari c . Karena itu, suku tersebut dapat kita abaikan. Mari kita berfokus pada suku pertama yang merupakan fungsi dari c .

$$\mathbf{1}_{\{3c \leq x_1, 3c \leq x_2, 3c \leq x_3, 3c \leq x_4\}}$$

Seperti sebelumnya, kita dapat menulis ulang fungsi indikator sebagai:

$$\mathbf{1}_{\{3c \leq \min(x_1, \dots, x_4)\}} = \mathbf{1}_{\{c \leq \frac{\min(x_1, \dots, x_4)}{3}\}}$$

Oleh karena itu, penduga kemungkinan maksimum bagi c adalah

$$\hat{c} = \frac{\min(x_i)}{3}$$

Dengan menggunakan data kita, nilai dugaan kemungkinan maksimumnya adalah $\hat{c} = \frac{-5}{3}$.

4.4 Kasus Multiparameter

Sejauh ini, kita telah mempelajari penduga kemungkinan maksimum untuk distribusi berparameter tunggal. Sebagai contoh, $\text{Unif}(0, \theta)$ dan $\text{Bin}(10, p)$. Kita juga telah meninjau distribusi Normal ketika hanya satu parameternya yang tidak diketahui. Dalam bagian ini, kita akan mempelajari cara menentukan penduga ketika terdapat lebih dari satu parameter yang tidak diketahui. Sebagai contoh, $N(\mu, \sigma^2)$, $\text{Gamma}(\alpha, \beta)$, dan sebagainya...

Secara umum, untuk model multiparameter kita dapat mengikuti pendekatan yang serupa dengan pendekatan pada kasus berparameter tunggal.

Notasi

Kita akan menggunakan notasi vektor dalam bagian ini. Skalar tidak diberi garis bawah, sedangkan vektor diberi garis bawah. Sebagai contoh, skalar ditulis seperti

$$\begin{aligned} a &\in \mathbb{R} \\ \theta &\in \mathbb{R} \end{aligned}$$

Ketika merujuk pada vektor, kita menggunakan notasi bergaris bawah. Sebagai contoh,

$$\begin{aligned} \underline{x} &\in \mathbb{R}^n, & \underline{x} &= (x_1, x_2, \dots, x_n) \\ \underline{\theta} &\in \mathbb{R}^p, & \underline{\theta} &= (\theta_1, \theta_2, \dots, \theta_p) \end{aligned}$$

Jika terdapat lebih dari satu parameter, kita dapat menulis PDF (atau PMF) sebagai:

$$f(x|\underline{\theta})$$

fungsi kemungkinannya sebagai:

$$L(\underline{\theta}) = \prod_{i=1}^n f(x_i|\underline{\theta})$$

Fungsi log-kemungkinannya adalah:

$$\begin{aligned}\ell(\underline{\theta}) &= \sum_{i=1}^n \log f(x_i|\underline{\theta}) \\ &= \ell(\theta_1, \dots, \theta_p) = \sum_{i=1}^n \log f(x_i|\theta_1, \dots, \theta_p)\end{aligned}$$

Titik-titik kritis terjadi ketika

$$\begin{aligned}\frac{d}{d\theta_1}\ell(\underline{\theta}) &= 0 \\ \frac{d}{d\theta_2}\ell(\underline{\theta}) &= 0 \\ &\vdots \\ \frac{d}{d\theta_p}\ell(\underline{\theta}) &= 0\end{aligned}$$

Oleh karena itu, kita mempunyai p persamaan dan p peubah yang tidak diketahui. Penyelesaian sistem persamaan ini menghasilkan $\hat{\underline{\theta}} = (\hat{\theta}_1, \dots, \hat{\theta}_p)$.

Mari kita lihat contoh penentuan MLE untuk beberapa parameter.

Contoh 4.14 Misalkan kita mempunyai sampel acak berukuran n dari distribusi Normal dengan parameter yang tidak diketahui μ dan σ^2 . Tentukan MLE bagi $\underline{\theta} = (\mu, \sigma^2)$.

Penyelesaian

Fungsi kemungkinannya adalah:

$$L(\underline{\theta}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x_i-\mu)^2} = (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2}\sum (x_i-\mu)^2}$$

Fungsi log-kemungkinannya adalah:

$$\ell(\underline{\theta}) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \sum_{i=1}^n \frac{1}{2\sigma^2}(x_i - \mu)^2$$

Misalkan $\nu = \sigma^2$. Kita mempunyai:

$$\ell(\mu, \nu) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\nu) - \sum_{i=1}^n \frac{1}{2\nu}(x_i - \mu)^2$$

Sekarang, ambil turunan terhadap μ dan ν .

$$\begin{aligned}\frac{d\ell(\mu, \nu)}{d\mu} &= -2\frac{1}{2\nu} \sum (x_i - \mu)(-1) = \frac{\sum x_i - n\mu}{\nu} \\ \frac{d\ell(\mu, \nu)}{d\nu} &= -\frac{n}{2\nu} + \frac{\sum (x_i - \mu)^2}{2\nu^2} = \frac{-n\nu + \sum (x_i - \mu)^2}{2\nu^2}\end{aligned}$$

Dengan menyamakan turunan-turunan tersebut dengan 0 lalu menyelesaikannya, kita memperoleh:

$$0 = \frac{\sum x_i - n\mu}{\nu}, \quad \Rightarrow \mu = \frac{\sum x_i}{n} = \bar{x}$$

$$0 = \frac{-n\nu + \sum (x_i - \mu)^2}{2\nu^2}, \quad \Rightarrow \nu = \frac{\sum (x_i - \mu)^2}{n}$$

Kita mempunyai dua persamaan dan dua peubah yang tidak diketahui. Oleh karena itu, MLE yang diperoleh adalah:

$$\hat{\mu} = \bar{x}$$

$$\hat{\nu} = \hat{\sigma}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

Contoh 4.15 Misalkan $X_i \stackrel{iid}{\sim} \text{Laplace}(\mu, b)$, untuk $i = 1, \dots, n$. Tentukan MLE bagi $\underline{\theta} = (\mu, b)$.

Penyelesaian

PDF dari X adalah:

$$f(x|\underline{\theta}) = \frac{1}{2b} e^{-\frac{|x-\mu|}{b}}, \quad -\infty < x < \infty$$

Fungsi kemungkinannya adalah:

$$L(\underline{\theta}) = \prod_{i=1}^n \frac{1}{2b} e^{-\frac{|x_i-\mu|}{b}} = (2b)^{-n} e^{-\frac{\sum |x_i-\mu|}{b}}$$

Fungsi log-kemungkinannya adalah:

$$\ell(\underline{\theta}) = -n \ln 2 - n \ln b - \frac{\sum |x_i - \mu|}{b}$$

Mari kita mulai dengan mengambil turunan terhadap b .

$$\frac{d\ell(\underline{\theta})}{db} = -\frac{n}{b} + \frac{\sum |x_i - \mu|}{b^2} = \frac{-nb + \sum |x_i - \mu|}{b^2}$$

Dengan menyamakan turunan tersebut dengan 0, kita memperoleh:

$$0 = \frac{-nb + \sum |x_i - \mu|}{b^2}, \quad \Rightarrow \hat{b} = \frac{\sum |x_i - \mu|}{n}$$

Selanjutnya, mari kita tentukan turunan dari $\ell(\underline{\theta})$ terhadap μ .

$$\frac{d\ell(\underline{\theta})}{d\mu} = -\sum_{i=1}^n \left(\frac{1}{b} \right) \frac{d}{d\mu} |x_i - \mu|$$

Namun, bagaimana bentuk $\frac{d}{d\mu} |x_i - \mu|$? Di luar titik tekuk, kita mengetahui bahwa

$$|x_i - \mu| = \begin{cases} x_i - \mu & \text{if } x_i \geq \mu \\ -x_i + \mu & \text{if } x_i \leq \mu \end{cases}$$

Dengan demikian, jauh dari titik tekuk, turunannya adalah

$$\partial_{\mu} |x_i - \mu| = \begin{cases} -1, & \mu < x_i, \\ [-1, 1], & \mu = x_i, \\ 1, & \mu > x_i. \end{cases}$$

Kita dapat merangkum kedua sisi dengan fungsi indikator berikut; pada titik tekuk, ekspresi ini harus dipahami melalui subgradien:

$$\frac{d}{d\mu}|x_i - \mu| = \mathbf{1}_{\{x_i < \mu\}} - \mathbf{1}_{\{x_i > \mu\}}$$

Dengan memasukkan kondisi subgradien ini ke dalam fungsi log-kemungkinan, kita memperoleh:

$$\frac{d}{d\mu}\ell(\underline{\theta}) = -\frac{1}{b} \sum_{i=1}^n (\mathbf{1}_{\{x_i < \mu\}} - \mathbf{1}_{\{x_i > \mu\}})$$

Dengan memilih subgradien yang sama dengan 0, kita memperoleh:

$$0 \in \sum_{i=1}^n \partial_{\mu}|x_i - \mu| \iff \#\{i : x_i < \mu\} \leq \frac{n}{2}, \#\{i : x_i > \mu\} \leq \frac{n}{2}.$$

Perhatikan setiap suku pada persamaan terakhir. $\sum \mathbf{1}_{\{x_i < \mu\}}$ menyatakan banyaknya x_i , yang nilainya lebih kecil daripada μ . Demikian pula, $\sum \mathbf{1}_{\{x_i > \mu\}}$ menyatakan banyaknya x_i , yang nilainya lebih besar daripada μ . Kondisi subgradien nol terpenuhi apabila μ merupakan salah satu median sampel; untuk ukuran sampel genap, setiap nilai di antara dua statistik urutan tengah dapat memaksimumkan fungsi kemungkinan. Dengan demikian, MLE bagi μ dapat dipilih sebagai $\hat{\mu} \in \text{Median}(x_1, \dots, x_n)$.

Oleh karena itu, dengan kedua syarat optimalitas dan kedua parameter yang tidak diketahui tersebut, kita memperoleh MLE bagi $\underline{\theta}$ sebagai:

$$\begin{aligned}\hat{\mu} &\in \text{Median}(x_1, \dots, x_n), \\ \hat{b} &= \frac{1}{n} \sum_{i=1}^n |x_i - \hat{\mu}|.\end{aligned}$$

Satu contoh terakhir..

Contoh 4.16 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi Gamma dengan parameter α dan θ . Misalkan kita hendak menentukan MLE bagi $\underline{\theta} = (\alpha, \theta)$. Seperti biasa, kita mulai dengan fungsi kemungkinan.

$$L(\underline{\theta}) = \prod_{i=1}^n \frac{1}{\Gamma(\alpha)\theta^\alpha} x_i^{\alpha-1} e^{-\frac{x_i}{\theta}} = (\Gamma(\alpha))^{-n} (\theta)^{-n\alpha} \left(\prod_{i=1}^n x_i^{\alpha-1} \right) e^{-\frac{\sum x_i}{\theta}}$$

Fungsi log-kemungkinannya adalah:

$$\ell(\underline{\theta}) = -n \ln \Gamma(\alpha) - n\alpha \ln \theta + (\alpha - 1) \sum \ln x_i - \frac{\sum x_i}{\theta}$$

Langkah berikutnya adalah mengambil turunan terhadap α dan θ .

$$\begin{aligned}\frac{\partial \ell}{\partial \theta} &= -\frac{n\alpha}{\theta} + \frac{\sum_i x_i}{\theta^2}, \\ \frac{\partial \ell}{\partial \alpha} &= -n\psi(\alpha) - n \ln \theta + \sum_i \ln x_i.\end{aligned}$$

Langkah berikutnya tentu menyamakan turunan-turunan tersebut dengan nol lalu menyelesaikan parameter, sebab kita mempunyai dua persamaan dan dua peubah yang tidak diketahui. Namun, sebelum melakukannya, mari kita tinjau $\frac{d}{d\alpha} \Gamma(\alpha)$. Ingat bahwa fungsi gamma pada a adalah

$$\Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt$$

Fungsi gamma dan turunannya terdefinisi dengan baik, tetapi persamaan skor bagi parameter bentuk melibatkan fungsi digamma dan pada umumnya tidak mempunyai solusi bentuk tertutup elementer. Karena itu, setelah hubungan bagi parameter skala diturunkan, persamaan satu dimensi bagi parameter bentuk perlu diselesaikan

secara numerik untuk memperoleh MLE.

Kita akan membahas pendugaan kemungkinan maksimum numerik selanjutnya; untuk menentukan MLE secara numerik, kita menggunakan perangkat lunak. Sebelum itu, kita berhenti sejenak dari penentuan MLE untuk memperkenalkan R.

4.5 Ringkasan

Dalam pelajaran ini, kita diperkenalkan pada metode pendugaan kemungkinan maksimum (MLE) sebagai perangkat dasar dalam inferensi statistik. Kita mempelajari cara membentuk fungsi kemungkinan dan fungsi log-kemungkinan berdasarkan model peluang tertentu, serta, apabila memungkinkan, cara menentukan secara analitik nilai parameter yang memaksimumkan fungsi kemungkinan. Kita berlatih menurunkan MLE untuk distribusi diskret maupun kontinu dan meninjau kasus ketika pembatasan himpunan dukungan harus ditangani secara cermat menggunakan fungsi indikator.

Pokok-Pokok Penting:

- Fungsi kemungkinan $L(\theta_1, \theta_2, \dots, \theta_m)$ adalah fungsi massa atau kepadatan peluang bersama yang dievaluasi pada sampel teramati dan dipandang sebagai fungsi parameter; fungsi ini bukan distribusi peluang atas parameter.
- Penduga kemungkinan maksimum (MLE) adalah statistik yang, sebagai fungsi sampel acak, memilih nilai parameter θ yang memaksimumkan fungsi kemungkinan $L(\theta)$.
- Sering kali lebih mudah memaksimumkan $\ell(\theta) = \ln L(\theta)$.

1. [Pelajaran](#)
2. [5 Pendugaan Kemungkinan Maksimum \(MLE\) \(Bagian II\)](#)

5 Pendugaan Kemungkinan Maksimum (MLE) (Bagian II)

Dasar-dasar R
Vektor dan Kerangka Data (Data Frame)
Statistik Ringkasan dan Grafik
Distribusi Statistik dalam R
Pencarian Grid
Metode Newton–Raphson
Optimisasi Numerik

Ikhtisar

Pelajaran ini memperdalam pemahaman Anda tentang pendugaan kemungkinan maksimum (MLE) dengan berfokus pada penerapan praktisnya, khususnya melalui metode numerik dalam R. Anda akan mempelajari cara menghitung MLE untuk model berparameter tunggal dan model multiparameter menggunakan teknik seperti pencarian grid dan algoritma Newton–Raphson, dengan penekanan pada fungsi optim dalam R. Selain itu, pelajaran ini memperkenalkan keterampilan pemrograman R yang penting, termasuk operasi dasar, manipulasi vektor dan kerangka data (data frame), statistik ringkasan, pembuatan grafik, serta penggunaan distribusi statistik seperti distribusi Normal dan Eksponensial. Melalui berbagai contoh, Anda akan mempelajari cara mengevaluasi fungsi kemungkinan dan fungsi log-kemungkinan, menyimulasikan peubah acak, serta menduga parameter secara numerik. Setelah menyelesaikan pelajaran ini, Anda akan mampu menerapkan MLE dalam situasi dunia nyata dan memanfaatkan R untuk analisis statistik sebagai landasan bagi teknik inferensi yang lebih lanjut.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Melakukan pendugaan kemungkinan maksimum (MLE) secara numerik untuk berbagai model berparameter tunggal dan model multiparameter menggunakan optim dalam R ketika nilai data tersedia, dan
2. Menggunakan R untuk menyimulasikan peubah acak secara numerik dari distribusi baku, serta menentukan PDF, CDF, dan kuantil distribusi baku, termasuk distribusi Normal, Eksponensial, Poisson, Geometrik, dan Binomial.

5.1 Pengantar R

5.1.1 Operasi Dasar dalam R

R dapat digunakan sebagai kalkulator ilmiah. Berikut ini ditunjukkan sebagian kecil operasi serupa kalkulator yang dapat dilakukan dalam R.

```
3+2
3-2
3*2
3/2
3^2
exp(3)
sqrt(3)
log(3)
```

Perhatikan bahwa dalam R, dan dalam statistika serta peluang secara umum, fungsi “log” secara bawaan adalah logaritma natural (berbasis e). Dalam matematika, fungsi ini biasanya dinotasikan sebagai $\ln(x)$, tetapi dalam statistika, fungsi ini hampir selalu dinotasikan hanya sebagai $\log(x)$.

Hal ini dapat dilihat dari kode berikut:

```
e=exp(1)
e
```

```
[1] 2.718282
```

```
## log basis e dari e = 1
log(e)
```

```
[1] 1
```

```
## log basis e dari 10 TIDAK = 1
log(10)
```

```
[1] 2.302585
```

5.1.2 Mendefinisikan dan menyimpan skalar serta vektor

Secara umum, sebaiknya Anda mengetik kode R dalam berkas teks berekstensi “.r” atau “.R”, lalu mengirim baris atau blok kode tersebut ke konsol R. Dengan cara ini, Anda dapat mengubah kode dengan mudah, menyimpan pekerjaan, serta menyalin dan menempelkannya untuk digunakan dalam situasi lain.

Anda akan sering perlu menyimpan bilangan sebagai variabel. Variabel tersebut kemudian dapat digunakan dalam perhitungan. Berikut contoh yang sangat sederhana untuk mengalikan dua bilangan:

```
a=4
b=3
a*b
```

```
[1] 12
```

Kita sering perlu bekerja dengan beberapa bilangan yang disimpan dalam sebuah “vektor” bilangan. R menangani vektor (dan matriks!) secara alami. Kita dapat membuat vektor menggunakan perintah `c` dalam R (singkatan dari “concatenate” atau menggabungkan)

```
## Vektor
v=c(1,4,3,2)
v
```

```
[1] 1 4 3 2
```

```
u=1:4  
u
```

```
[1] 1 2 3 4
```

Kode tersebut telah membuat dua vektor, `u` dan `v`, yang masing-masing memiliki empat elemen. Jika kita menerapkan operasi matematika baku pada vektor, perilaku bawaan R adalah menerapkan operasi tersebut pada setiap elemen. Kode berikut mengilustrasikan hal ini.

```
## operasi per elemen  
v+2
```

```
[1] 3 6 5 4
```

```
v*2
```

```
[1] 2 8 6 4
```

```
u^2
```

```
[1] 1 4 9 16
```

```
u+v
```

```
[1] 2 6 6 6
```

```
u*v
```

```
[1] 1 8 9 8
```

5.1.3 Membuat subset vektor

Data atau parameter sering disimpan dalam sebuah vektor, tetapi kita mungkin hanya ingin mengakses satu atau beberapa elemen vektor tersebut. Pengindeksan dalam R dilakukan menggunakan tanda kurung siku: `[ ]`

```
## Membuat subset vektor  
v
```

```
[1] 1 4 3 2
```

```
v[1]
```

```
[1] 1
```

```
v[2]
```

```
[1] 4
```

```
v[3]
```

```
[1] 3
```

```
v[4]
```

```
[1] 2
```

```
v[1:3]
```

```
[1] 1 4 3
```

```
v[c(1,4)]
```

```
[1] 1 2
```

```
v[c(3,4)]
```

```
[1] 3 2
```

5.1.4 Pernyataan logis dan perintah which dalam R

Salah satu cara penting untuk membuat subset vektor adalah melalui argumen logis. R memungkinkan kita memeriksa apakah suatu pernyataan logis bernilai TRUE atau FALSE. Pemeriksaan ini paling sering dilakukan menggunakan operator <, >, atau == sebagai operator. Perhatikan bahwa pengujian apakah dua bilangan sama harus dilakukan menggunakan dua tanda sama dengan ==, bukan satu tanda sama dengan =, yang digunakan untuk menetapkan nilai pada suatu variabel.

Berikut beberapa contoh pemeriksaan pernyataan logis dalam R. Perhatikan bahwa pernyataan logis dapat diterapkan per elemen pada vektor, sama seperti operasi matematika.

```
## pernyataan logis  
3>4
```

```
[1] FALSE
```

```
3>2
```

```
[1] TRUE
```

```
3==4
```

```
[1] FALSE
```

```
3==3
```

```
[1] TRUE
```

```
v
```

```
[1] 1 4 3 2
```

```
v>2
```

```
[1] FALSE TRUE TRUE FALSE
```

```
v==2
```

```
[1] FALSE FALSE FALSE TRUE
```

```
v>=2
```

```
[1] FALSE TRUE TRUE TRUE
```


Tugas yang umum dalam analisis statistik (lihat Bagian 4 sebagai contoh!) adalah menentukan elemen vektor mana yang memenuhi kriteria tertentu. Perintah R untuk melakukannya berpusat pada `which` tersebut. Berikut beberapa contohnya:

```
## membuat subset dengan argumen logis  
v
```

```
[1] 1 4 3 2
```

```
which(v>2)
```

```
[1] 2 3
```

```
v[which(v>2)]
```

```
[1] 4 3
```

```
idx=which(v>2)  
idx
```

```
[1] 2 3
```

```
v[idx]
```

```
[1] 4 3
```

5.1.5 Membuat Kerangka Data

Struktur data `.frame` dalam R merupakan struktur data yang sangat penting. Struktur ini memungkinkan Anda menyimpan sebuah “matriks” data yang memadukan kolom numerik (seperti peubah respons) dan kolom karakter (seperti nama perlakuan yang mudah dibaca manusia). Pertimbangkan sebuah contoh pertanian dengan 10 petak yang diberi Pupuk X (petak 1-5) atau Pupuk Y (petak 6-10). Kita akan membuat sebuah kerangka data yang memuat informasi ini beserta responsnya (hasil panen jagung pada setiap petak).

Pertama, kita akan membuat vektor numerik berisi nomor petak. Kode berikut menunjukkan dua cara yang setara untuk melakukannya.

```
plot.ID=1:10  
plot.ID=c(1,2,3,4,5,6,7,8,9,10)
```

Selanjutnya, kita akan membuat vektor karakter untuk perlakuan. Perhatikan bahwa karakter harus ditulis di dalam tanda kutip; jika tidak, R akan menganggapnya sebagai nama vektor atau skalar yang telah didefinisikan dalam R. Lihat Subbagian 5.1.2 sebagai contoh.

```
treatment=c("X","X","X","X","X","Y","Y","Y","Y","Y")  
treatment=c(rep("X",5),rep("Y",5))
```

Sekarang kita akan membuat sebuah vektor respons

```
response=c(14,12,11,18,20,21,20,17,23,25)
```

Terakhir, kita akan menggabungkan semuanya ke dalam sebuah data `.frame`.

```
corn.yield=data.frame(plot.ID,treatment,response)  
corn.yield
```

	plot.ID	treatment	response
1	1	X	14
2	2	X	12
3	3	X	11
4	4	X	18
5	5	X	20
6	6	Y	21
7	7	Y	20
8	8	Y	17
9	9	Y	23
10	10	Y	25

5.1.6 Statistik ringkasan dalam R

Fungsi `summary` dapat memberikan banyak informasi tentang sebuah kerangka data karena fungsi ini menghitung nilai minimum, maksimum, rata-rata, dan median setiap kolom numerik.

```
summary(corn.yield)
```

plot.ID	treatment	response
Min. : 1.00	Length:10	Min. :11.00
1st Qu.: 3.25	Class :character	1st Qu.:14.75
Median : 5.50	Mode :character	Median :19.00
Mean : 5.50		Mean :18.10
3rd Qu.: 7.75		3rd Qu.:20.75
Max. :10.00		Max. :25.00

Anda juga dapat menggunakan R untuk memperoleh rata-rata, varians, dan simpangan baku seluruh vektor:

```
mean(response)
```

```
[1] 18.1
```

```
var(response)
```

```
[1] 21.43333
```

```
sd(response)
```

```
[1] 4.629615
```

atau bahkan subset vektor

```
mean(response[treatment=="X"])
```

```
[1] 15
```

```
mean(response[treatment=="Y"])
```

```
[1] 21.2
```

```
sd(response[treatment=="X"])
```

```
[1] 3.872983
```


```
sd(response[treatment=="Y"])
```

```
[1] 3.03315
```

5.1.7 Pembuatan Grafik Sederhana dalam R

R juga dapat digunakan untuk membuat grafik data. Menyimpan data dalam sebuah `data.frame` dapat mempermudah pembuatan grafik dan analisis data. Sebagai contoh, kita dapat membuat boxplot data hasil panen jagung menggunakan perintah `boxplot` tersebut

```
boxplot(response~treatment,data=corn.yield,  
        main="Boxplot of Corn Yield With Different Fertilizers",  
        xlab="Fertilizer",ylab="Yield (kg)")
```




Gambar 5.1

Histogram dapat dibuat menggunakan perintah `hist` tersebut.

```
hist(response,main="Histogram of Corn Yield (All Plots)")
```


Histogram of Corn Yield (All Plots)



Gambar 5.2

Data numerik juga dapat ditampilkan sebagai diagram pencar menggunakan perintah `plot` tersebut.

```
plot(x=plot.ID,y=response)
```



Gambar 5.3

Anda akan sering perlu menyertakan grafik R dalam jawaban pekerjaan rumah. Setelah membuat grafik, Anda dapat mengeklik kanan gambar tersebut di RStudio, menyalinnya, lalu menempelkannya ke dokumen Word (atau dokumen sejenis).

5.1.8 Distribusi Statistik dalam R

Berkas bantuan dalam R

Ada banyak fungsi dalam R - terlalu banyak untuk dihafal seluruhnya oleh siapa pun ketika melakukan sebagian besar analisis. R juga memiliki sistem dokumentasi yang sangat lengkap, asalkan Anda mengetahui apa yang perlu dicari. Khususnya, jika Anda mengetahui nama fungsi yang memerlukan bantuan, R dapat membantu dengan sangat mudah (lihat di bawah). Namun, jika Anda tidak mengetahui nama fungsi yang melakukan sesuatu yang ingin dikerjakan, pilihan terbaik adalah mencari fungsi tersebut di internet menggunakan mesin pencari pilihan Anda.

Sebagai contoh, jika ingin mengetahui cara memperoleh CDF distribusi Normal dalam R, pencarian seperti “CDF distribusi normal dalam R” akan segera memberikan banyak hasil yang mengarahkan Anda ke fungsi `pnorm` dalam R.

Setelah mengetahui fungsi yang ingin digunakan, Anda dapat membuka berkas bantuan R untuk fungsi tersebut dengan mengetik `help(pnorm)` atau `?pnorm` pada konsol R. Perhatikan bahwa Anda harus mengganti `pnorm` dengan nama fungsi yang ingin Anda cari bantuannya.

Fungsi R untuk Distribusi Statistik

R merupakan perangkat lunak statistik yang sangat baik untuk bekerja dengan distribusi. Tiga tugas utama terkait

peubah acak yang dapat ditangani R dengan sangat baik adalah:

1. Membangkitkan peubah acak dari suatu distribusi tertentu
2. Menghitung nilai fungsi kepadatan peluang (PDF) untuk distribusi kontinu atau fungsi massa peluang (PMF) untuk distribusi diskret pada suatu nilai amatan
3. Menghitung kuantil dan CDF suatu distribusi.

Dalam R, fungsi-fungsi yang berkaitan dengan distribusi mengikuti suatu pola. Jika nama singkat suatu distribusi dalam R adalah “XXX”, maka “rXXX” membangkitkan peubah acak dari distribusi tersebut, “dXXX” menghitung nilai kepadatan untuk distribusi kontinu atau nilai massa peluang untuk distribusi diskret, “pXXX” menghitung fungsi distribusi kumulatif, dan “qXXX” menghitung kuantil. Dengan amatan yang ditetapkan dan parameter yang diperlakukan sebagai peubah, nilai dari “dXXX” dapat menjadi satu faktor dalam fungsi kemungkinan.

Contoh dari Distribusi Gaussian (Normal)

Sebagai contoh, anggap bahwa setiap $x_i \sim N(3, 4)$ merupakan peubah acak berdistribusi Normal yang saling bebas, dengan rata-rata 3 dan varians 4. Nama singkat peubah berdistribusi Normal dalam R adalah “norm”, sehingga kita dapat menggunakan kode berikut untuk membangkitkan satu peubah acak; seed 4150501 dicatat agar keluarannya dapat direproduksi:

```
set.seed(4150501)
rnorm(n=1, mean=3, sd=2)
```

```
[1] 6.688992
```

Perhatikan bahwa R menggunakan simpangan baku sd alih-alih varians. Jika ingin membangkitkan 10 peubah acak iid, saya dapat mengubah argumen n pada rnorm; blok ini menggunakan seed 4150502:

```
set.seed(4150502)
rnorm(n=10, mean=3, sd=2)
```

```
[1] -1.9913396  5.7018791  2.7175272  3.9104060  1.8026764  9.2187028
[7] -0.2472842  3.3046301  2.2024390 -0.6402799
```

Saya juga dapat menyimpan satu nilai yang dibangkitkan ini dalam sebuah variabel untuk digunakan kemudian; blok berikut mencatat seed 4150503 sehingga nilai simulasinya dapat direproduksi

```
set.seed(4150503)
x=rnorm(n=1, mean=3, sd=2)

x
```

```
[1] 3.880108
```

Sekarang, jika ingin mengevaluasi PDF suatu peubah acak $x \sim N(3, 4)$ pada nilai tertentu $u = 2$, saya dapat menggunakan dnorm sebagai berikut:

```
dnorm(2, mean=3, sd=2)
```

```
[1] 0.1760327
```

Kode di atas menghasilkan $f_X(2)$. Untuk memperoleh CDF, kita menggunakan pnorm sebagai fungsi CDF, sedangkan $F_X(2) = P(X \leq 2)$ diperoleh melalui:

```
pnorm(2, mean=3, sd=2)
```

```
[1] 0.3085375
```

Fungsi-fungsi ini juga bekerja pada vektor. Sebagai contoh, jika ingin mengevaluasi nilai kepadatan untuk data simulasi yang tersimpan dalam “x”, saya dapat melakukannya dengan

```
dnorm(x, mean=3, sd=2)
```

```
[1] 0.1810632
```

Kepadatan bersama untuk semua peubah acak simulasi $L(\mu, \sigma; \mathbf{x}) = \prod_{i=1}^n f(x_i | \mu, \sigma)$ kemudian diberikan oleh

```
prod(dnorm(x, mean=3, sd=2))
```

```
[1] 0.1810632
```

dan log-kepadatan bersamanya $\ell(\mu, \sigma; \mathbf{x}) = \sum_{i=1}^n \log f(x_i | \mu, \sigma)$ dapat dihitung dengan

```
sum(log(dnorm(x, mean=3, sd=2)))
```

```
[1] -1.708909
```

R menyediakan sebuah argumen untuk `dnorm` guna memperoleh log-kepadatan alih-alih kepadatan:

```
dnorm(x, mean=3, sd=2)
```

```
[1] 0.1810632
```

```
dnorm(x, mean=3, sd=2, log=TRUE)
```

```
[1] -1.708909
```

yang juga sering berguna.

Contoh dari distribusi Eksponensial

Sebagai contoh kedua, pertimbangkan distribusi Eksponensial $z_i \sim \text{Exp}(\lambda)$. Kita dapat membangkitkan 30 peubah acak, masing-masing dari $z_i \sim \text{Exp}(2)$ (sehingga $E(z_i) = 0.5$) dengan kode berikut; seed 4150504 dicatat untuk mengikat hasilnya

```
set.seed(4150504)
z=rexp(n=30, rate=2)
z
```

```
[1] 0.902386372 0.279482659 0.013538371 0.169541551 0.516750996 0.221434825
[7] 0.437782802 0.364390418 0.012766121 0.104971642 0.097908754 0.007348964
[13] 0.041360434 0.224170113 0.924014265 0.368705531 0.009524764 0.690829892
[19] 0.046744257 0.500347289 0.624012383 0.841702328 0.019394894 0.621367328
[25] 0.017981748 0.048043481 1.555176392 1.321141629 0.341612630 0.330359658
```

Mari kita hitung rata-rata dan median data simulasi tersebut

```
mean(z)
```

```
[1] 0.3884931
```

```
median(z)
```

```
[1] 0.3049212
```

yang mendekati rata-rata teoretis (sebesar $1/\lambda = 0.5$) dan median (sebesar $\ln(2)/\lambda = 0.34657$)


Sekarang, mari kita simulasikan 1000 peubah acak dengan seed 4150505

```
set.seed(4150505)
z=rexp(n=1000,rate=2)
```

Jumlah ini terlalu banyak untuk dicetak, jadi mari kita tampilkan dalam bentuk histogram

```
hist(z)
```

Histogram 1.000 simulasi Eksponensial (laju = 2)



Data ini tampak mengikuti distribusi Eksponensial, sebagaimana mestinya. Seed yang dicatat membuat kode, keluaran, dan histogram target dapat direproduksi. Selanjutnya, kita akan menghitung beberapa besaran teoretis peubah acak Eksponensial berlaju 2 dan membandingkannya dengan nilai dugaan besaran tersebut dari peubah acak simulasi $z_i, i = 1, 2, \dots, 1000$.

Pertama, mari kita periksa nilai CDF - fungsi distribusi kumulatif. Peluang $P(z < 1)$ adalah $F_Z(1)$, yang di R dihitung melalui pemanggilan `pexp` tersebut

```
pexp(1,rate=2)
```

```
[1] 0.8646647
```

dan hampiran berbasis sampelnya diperoleh dari banyaknya nilai sampel z_i yang kurang dari atau sama dengan 1, dibagi dengan jumlah sampel keseluruhan (di sini $n=1000$).

```
n.less.than.1=length(which(z<=1))
n.less.than.1
```

```
[1] 856
```

```
cdf.val=n.less.than.1/1000
cdf.val
```



```
[1] 0.856
```

yang cukup mendekati nilai sebenarnya yang ditampilkan di atas.

Jika kita ingin menghitung nilai kepadatan bersama untuk $(z_1, z_2, \dots, z_{1000})$, kita dapat memperolehnya dengan $f_Z(z_1, z_2, \dots, z_{1000}) = \prod_{i=1}^{1000} f_Z(z_i) = \prod_{i=1}^{1000} \lambda e^{-\lambda z_i}$, yang dapat kita hitung langsung di R

```
prod(2*exp(-2*z))
```

```
[1] 1.352596e-141
```

atau dapat diperoleh melalui pemanggilan `dexp` tersebut

```
prod(dexp(z, rate=2))
```

```
[1] 1.352596e-141
```

5.2 Pendugaan Kemungkinan Maksimum secara Numerik

Sekarang mari kita kembali ke MLE!

Pada bagian sebelumnya, kita meninjau contoh ketika MLE tidak dapat diperoleh secara analitis sehingga diperlukan optimisasi numerik. Pada bagian ini, kita menyajikan dua metode untuk mencari nilai dugaan kemungkinan maksimum secara numerik. Metode pertama menggunakan pencarian grid (grid search) dalam R. Metode lainnya menggunakan fungsi `optim` di R.

5.2.1 MLE melalui Pencarian Grid

Salah satu cara mencari MLE adalah melalui pencarian grid. Gagasannya ialah menggunakan perangkat lunak, seperti R, untuk melakukan perhitungan. Kita mengetahui distribusi yang mendasarinya sehingga dapat menentukan fungsi kemungkinan. Kemudian, berdasarkan sekumpulan data dan nilai-nilai yang mungkin bagi parameter yang tidak diketahui, θ , kita dapat mencari nilai θ yang memaksimalkan fungsi kemungkinan.


Untuk mengilustrasikannya, misalkan kita memiliki titik-titik data berikut. Anggaplah data berasal dari distribusi eksponensial dengan rata-rata yang tidak diketahui θ .

```
x=c(1, 5, 10, 1, 3, 11, 10, 23, 2, 6, 1, 24, 6, 11, 19)
x
```

```
> [1] 1 5 10 1 3 11 10 23 2 6 1 24 6 11 19
```

```
hist(x,breaks=7)
```

Histogram of x



Gambar 5.4

Jika kita tidak mengetahui parameter θ , kita dapat mencoba menduganya dengan pendugaan kemungkinan maksimum (MLE), dengan nilai dugaan berupa nilai yang memaksimumkan fungsi kemungkinan

$$\hat{\theta} = \arg \max_{\theta > 0} L(\theta; \mathbf{x})$$

Kita dapat mencoba beberapa nilai θ untuk dicoba:

```
lik.exp.2=function(theta,x){
  prod(dexp(x,rate=1/theta))
}
lik.exp.2(2,x)
```

```
[1] 4.017603e-34
```

```
lik.exp.2(10,x)
```

```
[1] 1.674493e-21
```

```
lik.exp.2(20,x)
```

```
[1] 3.949042e-23
```

Di antara kumpulan kecil nilai tersebut, $\theta = 10$ menghasilkan nilai fungsi kemungkinan tertinggi.

Untuk mencoba serangkaian nilai, kita akan membuat perulangan “for”. Tujuan kita adalah memperoleh vektor nilai fungsi kemungkinan bagi parameter θ pada serangkaian nilai. Kita mulai dengan menentukan nilai θ yang ingin kita pertimbangkan.


```
theta.vals=seq(1,100,by=0.1)
theta.vals
```

```
[1] 1.0 1.1 1.2 1.3 1.4 1.5 1.6 1.7 1.8 1.9 2.0 2.1 2.2 2.3 2.4 2.5 2.6 2.7 2.8
[20] 2.9 3.0 3.1 3.2 3.3 3.4
...
[1] 97.6 97.7 97.8 97.9 98.0 98.1 98.2 98.3 98.4 98.5 98.6 98.7
[13] 98.8 98.9 99.0 99.1 99.2 99.3 99.4 99.5 99.6 99.7 99.8 99.9
[25] 100.0
```

Selanjutnya, kita membuat vektor kosong untuk nilai fungsi kemungkinan (nilainya akan kita isi nanti)

```
lik.vals=rep(NA_real_,length(theta.vals))
for(i in seq_along(theta.vals)){
  lik.vals[i]=lik.exp.2(theta.vals[i],x)
}
```

Sebelum hasilnya digunakan, kita harus membuat perulangan for yang (1) mengevaluasi fungsi kemungkinan untuk setiap nilai theta, dan (2) menyimpan nilai tersebut pada posisi yang tepat di `lik.vals`.



Gambar 5.5

Pendekatan ini sering disebut “pencarian grid”, karena kita menelusuri rentang nilai parameter yang luas. Dari grafik, terlihat bahwa hampiran MLE pada grid berada di sekitar 10. Kita dapat mencari nilai θ terbaik di antara nilai yang kita coba dengan menerapkan `which.max` pada vektor; perintah ini mencari indeks nilai maksimum.

```
idx.mle=which.max(lik.vals)
idx.mle
```

```
[1] 80
```

```
theta.hat.grid=theta.vals[idx.mle]
theta.hat.grid
```

```
[1] 8.9
```

Jadi, pencarian grid menghasilkan hampiran pertama berikut, sedangkan nilai kedua adalah MLE analitik sebagai pembanding: $\hat{\theta}_{\text{grid}} = 8.9$, $\hat{\theta}_{\text{ML}} = 133/15 \approx 8.866667$.


Ini merupakan metode kasar untuk menghampiri MLE. Metode berikutnya yang kita sajikan lebih menyeluruh.

5.2.2 MLE Numerik: Gagasan Dasar

Alternatif yang lebih baik daripada pencarian grid di atas adalah menggunakan salah satu dari banyak metode iteratif untuk memaksimumkan suatu fungsi. Salah satunya disebut metode Newton–Raphson, yang juga kadang disebut metode Newton. Kita mulai dengan gagasan umum yang mendasari metode optimisasi numerik iteratif.

Optimisasi numerik merupakan bidang yang sangat luas! Tersedia banyak algoritma optimisasi. Sebagian besar algoritma optimisasi memiliki beberapa langkah umum. Langkah-langkah tersebut meliputi:

1. Memerlukan nilai awal untuk parameter, $\theta = (\theta_1, \theta_2, \dots, \theta_p)$, yang dinotasikan dengan θ_0 .
2. Mencari secara iteratif serangkaian parameter baru, $\theta^{(1)}, \theta^{(2)}, \dots$
3. Berhenti ketika $\theta^{(k)}$ “dekat” dengan maksimum lokal.



Gambar 5.6

Pendekatan yang akan kita pelajari dalam mata kuliah ini adalah **Metode Newton–Raphson** atau **Metode Newton**.

5.2.3 Gagasan Dasar Metode Newton

Video 5.1: Metode Newton [tanpa suara]

Pengganti statis Video 5.1: mulai dari nilai awal, evaluasi fungsi skor h , gambar garis singgung h , lalu gunakan titik potongnya dengan sumbu horizontal sebagai iterasi berikutnya.

Gagasannya adalah memaksimumkan fungsi log-kemungkinan, $\ell(\theta)$. Hal ini kita lakukan dengan mencari $\frac{d}{d\theta}\ell(\theta) = 0$. Fungsi skor didefinisikan sebagai turunan fungsi log-kemungkinan; persamaan yang harus diselesaikan adalah $\frac{d}{d\theta}\ell(\theta) = 0$ dan fungsi skor tersebut bergantung pada θ , sehingga kita mendefinisikannya sebagai $h(\theta) = \frac{d}{d\theta}\ell(\theta)$.

Kita perlu mencari “akar” dari $h(\theta)$. Dengan kata lain, kita perlu mencari suatu θ sedemikian sehingga $h(\theta) = 0$.

Kita mendekati akar ($h(\theta) = 0$) dengan menghampiri $h(\theta)$ dengan garis singgung pada nilai θ . Jadi, kita mulai dengan suatu nilai, $\theta^{(0)}$. Kita mengevaluasi fungsi skor pada nilai awal, yaitu $h(\theta^{(0)}) = \frac{d}{d\theta}\ell(\theta^{(0)})$. Garis singgung pada $\theta^{(0)}$ adalah

$$y = h'(\theta^{(0)})(\theta - \theta^{(0)}) + h(\theta^{(0)})$$

Dengan menetapkan $y = 0$ kita memperoleh titik tempat garis singgung ini memotong sumbu x .

$$0 = h'(\theta^{(0)})(\theta - \theta^{(0)}) + h(\theta^{(0)})$$

Sekarang, kita selesaikan persamaan tersebut terhadap θ sehingga diperoleh:

$$\theta^{(1)} = \theta^{(0)} - \frac{h(\theta^{(0)})}{h'(\theta^{(0)})}$$

Ringkasan statis berikut menunjukkan cara metode ini mencari akar. Kita mulai dengan nilai awal θ , $\theta^{(0)}$ (titik biru). Kita mengevaluasi fungsi skor pada nilai tersebut. Lalu kita menentukan garis singgung fungsi skor pada nilai awal. Kita cari titik potong garis singgung dengan sumbu x . Titik itu menjadi nilai “baru” untuk θ , $\theta^{(1)}$. Kemudian, kita mengulangi langkah yang sama seperti untuk nilai awal θ tersebut. Iterasi dilanjutkan sampai diperoleh akar fungsi skor; akar itu kemudian harus diperiksa sebagai maksimum dalam domain parameter.

Video 5.2: Metode Newton [tanpa suara]

Pengganti statis Video 5.2: ulangi pembaruan Newton–Raphson pada fungsi skor hingga perubahan kecil; setelah itu tetap periksa domain dan bahwa akar tersebut memaksimumkan fungsi log-kemungkinan.

Langkah-langkahnya adalah:

1. Tentukan nilai awal, $\theta^{(0)}$.
2. Pada setiap $t = 0, 1, 2, \dots$ hitung pembaruan berikut:

$$\theta^{(t+1)} = \theta^{(t)} - \frac{h(\theta^{(t)})}{h'(\theta^{(t)})} = \theta^{(t)} - \frac{\frac{d}{d\theta}\ell(\theta^{(t)})}{\frac{d^2}{d\theta^2}\ell(\theta^{(t)})}$$

5.2.4 Optimisasi Numerik di R

Bagian ini bertujuan memberi Anda intuisi tentang cara kerja optimisasi numerik menggunakan fungsi `optim`. Secara umum, kita cukup MENGGUNAKAN algoritma yang sudah ada, sehingga sebagian besar pekerjaan rumah Anda tidak akan berfokus pada cara kerja algoritma seperti metode Newton. Subbagian berikutnya (Optimisasi Numerik) memuat kode yang paling berguna untuk menerapkan algoritma optimisasi guna mencari MLE. Subbagian ini dimaksudkan untuk membantu Anda memahami apa yang terjadi di balik `optim` dan rutinitas optimisasi numerik lainnya. Perhatikan bahwa secara default `optim` menjalankan Nelder–Mead, bukan langkah pembaruan metode Newton–Raphson yang dikodekan secara manual di atas.

Jika tujuan kita adalah memaksimumkan fungsi kemungkinan $L(\theta, \mathbf{x})$, kita juga dapat memaksimumkan fungsi log-kemungkinan

$$\ell(\theta; \mathbf{x}) = \sum_{i=1}^n \log f(x_i | \theta) = \sum_{i=1}^n \left[-\log \theta - \frac{x_i}{\theta} \right], \quad \theta > 0$$

Maksimum ini dapat dicari dengan terlebih dahulu mengidentifikasi setiap titik kritis yang memenuhi $\frac{d}{d\theta} \ell(\theta) = \ell'(\theta) = 0$. Oleh karena itu, kita perlu mencari nilai θ yang merupakan akar dari $\ell'(\theta)$ - yaitu nilai θ yang membuat fungsi $\ell'(\theta)$ sama dengan nol.

Metode Newton adalah algoritma pencarian akar yang bekerja dengan menghampiri fungsi skor secara iteratif menggunakan garis. Rincian metode Newton dibahas dalam kuliah, dengan algoritma sebagai berikut. Diberikan nilai awal $\theta^{(0)}$, kita memperbarui $\theta^{(t)}$ secara iteratif sebagai berikut

$$\theta^{(t+1)} = \theta^{(t)} - \frac{\ell'(\theta^{(t)})}{\ell''(\theta^{(t)})}$$

Mari kita tulis fungsi untuk mengevaluasi turunan pertama dan kedua dari fungsi log-kemungkinan. Dalam contoh ini, kita menurunkan secara aljabar lalu mengodekan hasilnya sebagai fungsi R

$$\begin{aligned} \ell'(\theta) &= \sum_{i=1}^n \left(\frac{-\theta + x_i}{\theta^2} \right) = \sum_{i=1}^n (x_i - \theta) \theta^{-2} \\ \ell''(\theta) &= \sum_{i=1}^n \left(\frac{-2x_i + \theta}{\theta^3} \right) \end{aligned}$$

Fungsi R untuk mengevaluasi kedua turunan tersebut adalah

```
l.first.der=function(theta,x){
  sum((x-theta)*theta^(-2))
}
l.scnd.der=function(theta,x){
  sum((-2*x+theta)/theta^3)
}
sumx=sum(x)
n=length(x)
```

Kemudian, metode Newton dapat dijalankan dengan melakukan iterasi:

```
## nilai awal
theta0=5
## iterasi pertama
theta1=theta0-l.first.der(theta0,x)/l.scnd.der(theta0,x)
theta1
```

```
[1] 6.518325
```

```
## iterasi ke-2
theta2=theta1-l.first.der(theta1,x)/l.scnd.der(theta1,x)
theta2
```

```
[1] 7.883215
```

```
## iterasi ke-3
theta3=theta2-l.first.der(theta2,x)/l.scnd.der(theta2,x)
theta3
```

```
[1] 8.670288
```

```
## iterasi ke-4
theta4=theta3-l.first.der(theta3,x)/l.scnd.der(theta3,x)
theta4
```

```
[1] 8.858156
```

```
## iterasi ke-5  
theta5=theta4-l.first.der(theta4,x)/l.scnd.der(theta4,x)  
theta5
```

```
[1] 8.86665
```

```
## iterasi ke-6  
theta6=theta5-l.first.der(theta5,x)/l.scnd.der(theta5,x)  
theta6
```

```
[1] 8.86667
```

```
## iterasi ke-7  
theta7=theta6-l.first.der(theta6,x)/l.scnd.der(theta6,x)  
theta7
```

```
[1] 8.86667
```

```
## iterasi ke-8  
theta8=theta7-l.first.der(theta7,x)/l.scnd.der(theta7,x)  
theta8
```


```
[1] 8.86667
```

Terlihat bahwa iterasi berturut-turut tampaknya berkonvergensi ke nilai sekitar 8.86667, yang dekat dengan hampiran yang kita peroleh melalui pencarian grid.


Ilustrasi visual metode Newton tersedia dalam paket `animation` untuk R. Kode berikut tidak akan ditampilkan secara daring, tetapi jika dijalankan di konsol R Anda, kode tersebut akan menghasilkan ilustrasi metode Newton yang menarik.

```
install.packages("animation")  
library(animation)
```


Root-finding by Newton-Raphson Method: $(\text{sum}x - n\theta)/\theta^2 = 0$




Root-finding by Newton-Raphson Method: $(\text{sum}x - n\theta)/\theta^2 = 0$




Root-finding by Newton-Raphson Method: $(\text{sum}x - n\theta)/\theta^2 = 0$



Root-finding by Newton-Raphson Method: $(\text{sum}x - n\theta)/\theta^2 = 0$



Root-finding by Newton-Raphson Method: $(\text{sum}x - n\theta)/\theta^2 = 0$



Gambar 5.7

5.2.5 MLE Numerik di R

Bagian sebelumnya menjelaskan dan menerapkan dua pendekatan untuk menghampiri nilai dugaan kemungkinan maksimum secara numerik. Pada bagian ini, kita akan menjelaskan pendekatan optimisasi serbaguna yang lebih tangguh menggunakan `optim` di R.

`optim` di R melakukan optimisasi numerik serbaguna. Kita mulai dengan meninjau penggunaan `optim`: menggunakan `optim` untuk pendugaan kemungkinan maksimum. Tinjau kasus umum dengan

$$x_i \sim f_X(x_i; \theta)$$

dengan $\theta = (\theta_1, \theta_2, \dots, \theta_p)$ merupakan vektor seluruh parameter dalam model. Tujuan kita adalah mencari MLE untuk θ . Dalam situasi ini, `optim` menerima masukan berikut

1. Sekumpulan nilai awal untuk θ . Ini merupakan vektor tebakan awal untuk setiap parameter dalam model. Dalam kebanyakan kasus, Anda TIDAK perlu terlalu memikirkan nilai awal, tetapi Anda HARUS memastikan bahwa nilai awal tersebut sah. Namun, nilai awal yang sah saja tidak membatasi seluruh lintasan optimisasi ke domain parameter. Sebagai contoh, jika $x_i \sim N(\mu, \sigma^2)$, nilai awal untuk σ harus berupa bilangan positif, sedangkan nilai awal untuk μ dapat berupa bilangan apa pun.
2. Fungsi untuk mengevaluasi negatif fungsi log-kemungkinan (NLL) data bagi suatu himpunan parameter. Perhatikan bahwa kita menggunakan NEGATIF fungsi log-kemungkinan, bukan fungsi log-kemungkinan biasa - hal ini karena `optim` secara bawaan dirancang untuk meminimumkan, sehingga MLE bagi θ akan memaksimumkan fungsi log-kemungkinan tetapi meminimumkan negatif fungsi log-kemungkinan.

Penting!

Masukan pertama fungsi ini HARUS berupa VEKTOR yang memuat SEMUA PARAMETER. Masukan lainnya dapat berformat apa pun.

Pertama, kita akan melihat dua contoh yang sesuai dengan kerangka ini, lalu menyusun templat kode yang dapat digunakan untuk persoalan lain.


Contoh 5.1 Untuk mengilustrasikan pencarian nilai dugaan kemungkinan maksimum secara numerik, mula-mula kita meninjau data dari distribusi eksponensial. Kita mengasumsikan bahwa 15 titik data berikut berasal dari distribusi eksponensial dengan parameter rata-rata/skala yang belum diketahui θ , sehingga lajunya adalah kebalikan parameter tersebut dan $x_i \sim \text{Exp}(\text{rate} = 1/\theta)$, $\theta > 0$, dengan data

```
x=c(1, 5, 10, 1, 3, 11, 10, 23, 2, 6, 1, 24, 6, 11, 19)
```

```
[1] 1 5 10 1 3 11 10 23 2 6 1 24 6 11 19
```

```
hist(x,breaks=7)
```

Histogram of x



Gambar 5.8

Pertama, kita menulis fungsi R untuk mengevaluasi negatif fungsi log-kemungkinan data. Kita akan menggunakan `dexp` dari R untuk mengevaluasi log kepadatan setiap observasi, dengan `log=TRUE` opsi

```
nll.exp=function(theta,x){
  if(!is.finite(theta) || theta<=0) return(Inf)
  -sum(dexp(x,rate=1/theta,log=TRUE))
}
```

Mari kita uraikan fungsi ini bagian demi bagian. Kode `dexp(x, rate=1/theta)` akan mengevaluasi nilai fungsi kepadatan peluang (PDF) setiap titik data dalam `x` untuk suatu nilai `theta`, sehingga kode `dexp(x, rate=1/theta, log=TRUE)` mengevaluasi log kepadatan setiap titik data. Untuk data yang dianggap tetap, penjumlahan semua nilai tersebut dengan perintah `sum(...)` menghasilkan fungsi log-kemungkinan; tanda negatif di depannya menghasilkan negatif fungsi log-kemungkinan data.

Selanjutnya, kita dapat menggunakan `optim` untuk memperoleh hampiran numerik terhadap nilai dugaan kemungkinan maksimum bagi θ . Pertama, kita tampilkan kodenya, lalu menguraikan setiap bagiannya.

```
out=optim(2,nll.exp,x=x,method="L-BFGS-B",lower=.Machine$double.eps)
```

Sintaks `optim` adalah sebagai berikut. Masukan pertama harus berupa nilai awal untuk semua parameter. Karena hanya ada satu parameter, θ , kita memberikan satu nilai awal. Nilai ini dapat berupa bilangan apa pun yang sah untuk distribusi eksponensial. Karena parameter θ harus positif, kita memberikan nilai awal positif $\theta^{(0)} = 2$ dalam kode di atas. Meskipun demikian, nilai awal positif tidak menegakkan domain positif selama optimisasi; gunakan parameterisasi log atau batas positif untuk itu.

Masukan kedua adalah nama dari fungsi yang menghitung negatif fungsi log-kemungkinan yang baru saja kita tulis. Karena kita menamainya `nll.exp`, nama inilah yang dimasukkan ke `optim` pada posisi masukan kedua. Masukan ketiga (dan masukan lain jika diperlukan) untuk `optim` merupakan masukan tambahan apa pun yang diperlukan oleh fungsi yang menghitung negatif log-kemungkinan tersebut. Fungsi `nll.exp` memerlukan dua masukan: `theta` dan `x`. Masukan pertama, `theta`, pada dasarnya diberikan melalui nilai awal kita. Masukan kedua, `x`, adalah vektor data. Untuk memberi tahu `optim` nilai yang harus digunakan untuk `x`, sebagai masukan ketiga untuk `optim` kita memberikan argumen `x=x`. Sisi kiri `x` adalah nama masukan dalam fungsi `nll.exp`. Sisi kanan adalah nama nilai data (yang kita namai `x` pula). Pada contoh berikutnya, kita akan mencoba memperjelas hal ini.

Keluaran `optim` memuat beberapa peringatan. Dalam `optim`, setiap peringatan harus diperiksa, bukan diabaikan. Peringatan di sini muncul karena `optim`, sebagai bagian dari algoritma optimisasinya, mencoba beberapa nilai θ yang negatif. Nilai tersebut menghasilkan NA saat fungsi log-kemungkinan dievaluasi dan menunjukkan bahwa domain fungsi objektif belum ditegakkan. `optim` mungkin terus mencoba nilai lain ketika hal ini terjadi. Namun, penyelesaiannya ialah menegakkan kepositifan, misalnya dengan parameterisasi log atau opsi batas dalam `optim`; diagnosis lah setiap peringatan dan jangan mengabaikan peringatan dari `optim`.

`optim` menghasilkan keluaran berikut

```
out

$par
[1] 8.866665

$value
[1] 47.73448

$counts
function gradient
      12         12

$convergence
[1] 0

$message
[1] "CONVERGENCE: REL_REDUCTION_OF_F <= FACTR*EPSMCH"
```

Ada beberapa bagian keluaran yang relevan.

1. `out$par` merupakan hampiran numerik terhadap nilai dugaan kemungkinan maksimum, yaitu nilai parameter yang hampir memaksimumkan fungsi kemungkinan (dan dengan demikian hampir meminimumkan negatif fungsi log-kemungkinan) sesuai toleransi algoritma
2. `out$value` adalah negatif fungsi log-kemungkinan yang dievaluasi pada nilai parameter yang dilaporkan. Pemanggilan berikut mengevaluasi fungsi objektif pada parameter tersebut: `nll.exp(out$par, x)` menghasilkan 47.73448. Nilai objektif ini berguna untuk memeriksa dan membandingkan hasil; jangan mengabaikannya secara otomatis.
3. `out$counts` mencatat jumlah evaluasi fungsi objektif dan gradien, bukan jumlah iterasi algoritma. Keluaran ini menunjukkan 12 evaluasi fungsi objektif dan 12 evaluasi gradien numerik. Informasi tersebut berguna untuk mendiagnosis perilaku dan efisiensi optimisasi.

4. `out$convergence` diberi nilai 0 jika algoritma memenuhi kriteria konvergensi internalnya. Kode ini hanya menandakan bahwa kriteria penghentian terpenuhi; kode ini bukan bukti optimum global, domain yang sah, atau ketelitian numerik yang memadai. Jika `convergence` bernilai 1, algoritma BELUM konvergen; penyebabnya harus didiagnosis dan nilai dugaan belum dapat dipercaya.
5. `out$message` dapat memberikan informasi diagnostik dan tidak boleh diabaikan secara otomatis.

Perhatikan bahwa nilai awal yang berbeda dapat memberikan hasil yang sedikit berbeda. Sebagai contoh, nilai awal $\theta^{(0)} = 0.5$ menghasilkan

```
out2=optim(0.5,nll.exp,x=x,method="L-BFGS-B",lower=.Machine$double.eps)
out2
```

```
$par
[1] 8.866664

$value
[1] 47.73448

$counts
function gradient
      15         15

$convergence
[1] 0

$message
[1] "CONVERGENCE: REL_REDUCTION_OF_F <= FACTR*EPSMCH"
```

yang memberikan dua hampiran numerik yang sedikit berbeda, yaitu 8.866665 dan 8.866664. Keduanya dekat dengan MLE analitik 8.866666.... Jika selisihnya tidak sepele, pilih nilai dengan negatif fungsi log-kemungkinan yang LEBIH KECIL (ditampilkan dalam `out$value`), lalu periksa domain, konvergensi, dan kepekaannya terhadap nilai awal serta toleransi.

Secara umum, saat menelaah keluaran `optim` lakukan langkah-langkah berikut:


1. Periksa apakah `convergence` sama dengan 0, lalu periksa domain parameter, keterhinggaan nilai objektif, kepekaan terhadap nilai awal, metode, dan toleransi, serta gradien atau tolak ukur analitik bila tersedia.
2. Setelah pemeriksaan tersebut lulus, baca hampiran numerik terhadap nilai dugaan kemungkinan maksimum dari `par`

Contoh 5.2 (Contoh MLE: Distribusi Normal) Sekarang kita berikan contoh lain dengan menggunakan distribusi Normal. Kali ini, kita akan menyimulasikan data dari parameter yang diketahui

```
mu.true=-3
s2.true=16

set.seed(123)
y=rnorm(30,mean=mu.true,sd=sqrt(s2.true))

hist(y)
```



y

[1]	-5.2419026	-3.9207100	3.2348333	-2.7179664	-2.4828491	3.8602599
[7]	-1.1563352	-8.0602449	-5.7474114	-4.7826479	1.8963272	-1.5607447
[13]	-1.3969142	-2.5572691	-5.2233645	4.1476525	-1.0085981	-10.8664686
[19]	-0.1945764	-4.8911656	-7.2712948	-3.8718997	-7.1040178	-5.9155649
[25]	-5.5001571	-9.7467732	0.3511482	-2.3865075	-7.5525477	2.0152597

Gambar 5.9

Hasilnya adalah 30 nilai yang masing-masing memenuhi $y_i \sim N(-3, 16)$. Sekarang kita akan berpura-pura TIDAK mengetahui rata-rata dan varians yang sebenarnya, lalu menduganya secara numerik. Pertama, kita menulis fungsi negatif fungsi log-kemungkinan dengan masukan pertama berupa vektor semua parameter

```
nll.norm <- function(theta,y){
  ## ambil parameter
  mu=theta[1]
  s2=theta[2]
  if(!is.finite(s2) || s2<=0) return(Inf)
  ## hitung log-kemungkinan
  loglik=sum(dnorm(y,mean=mu,sd=sqrt(s2),log=TRUE))
  ## kembalikan negatif log-kemungkinan
  -loglik
}
```

Perhatikan bahwa masukan pertama kita, yang dinamai θ , merupakan vektor dengan unsur pertama berupa rata-rata μ , dan unsur kedua berupa varians σ^2 . Inilah parameter yang perlu kita duga. Pada contoh eksponensial di atas, kita hanya memiliki satu parameter, tetapi di sini kita memiliki dua parameter sehingga perlu terlebih dahulu “membongkar” parameter dari θ .

Perhatikan juga bahwa kita ingin mencari nilai dugaan kemungkinan maksimum bagi μ dan σ^2 , tetapi fungsi `R.dnorm` menerima rata-rata (μ) dan SIMPANGAN BAKU (σ), bukan varians σ^2 . Oleh karena itu, dalam pernyataan `dnorm` kita menetapkan simpangan baku `sd` sebagai `sd=sqrt(s2)`, yaitu akar kuadrat varians.

Sekarang kita menggunakan `optim` untuk memperoleh hampiran numerik terhadap nilai dugaan kemungkinan maksimum. Kita memerlukan vektor nilai awal. Untuk μ kita dapat menggunakan bilangan apa pun, sedangkan untuk σ^2 kita perlu memilih bilangan positif, sehingga kita memilih nilai awal $\theta = (-1, 1)$.

```
out=optim(c(-1,1),nll.norm,y=y,method="L-BFGS-B",
          lower=c(-Inf,.Machine$double.eps))
out
```

```
$par
[1] -3.188414 14.885495

$value
[1] 83.07392

$counts
function gradient
      17      17

$convergence
[1] 0

$message
[1] "CONVERGENCE: REL_REDUCTION_OF_F <= FACTR*EPSMCH"
```

Nilai awal positif saja tidak menegaskan domain varians selama optimisasi; fungsi objektif perlu menggunakan parameterisasi log-variens atau batas positif. Karena `convergence` bernilai 0, kita mengetahui bahwa `optim` telah memenuhi pemeriksaan konvergensi internalnya. Hal ini belum cukup untuk langsung memercayai hasil: periksa domain, nilai objektif, kepekaan numerik, dan bandingkan dengan MLE analitik. Setelah pemeriksaan tersebut, hampiran numerik berada dalam `par`, dan urutan kedua nilai dugaan sama dengan urutan θ - vektor parameter kita. Karena μ ditempatkan pertama, nilai dugaan kemungkinan maksimum bagi μ merupakan bilangan pertama, yaitu $\hat{\mu}_{ML} = -3.188414$. Demikian pula, nilai dugaan kemungkinan maksimum bagi σ^2 adalah $\hat{\sigma}_{ML}^2 = 14.885495$.

5.3 Ringkasan

Pelajaran ini memperdalam pemahaman Anda tentang pendugaan kemungkinan maksimum (MLE) dengan berfokus pada penerapan numeriknya dan implementasi dalam R. Kita mempelajari cara menyusun dan memaksimumkan fungsi kemungkinan serta fungsi log-kemungkinan untuk model berparameter tunggal dan model multiparameter dengan menggunakan pendekatan analitik maupun numerik.

Teknik utama mencakup pencarian grid (grid search) dan metode Newton–Raphson. Secara terpisah, optimisasi praktis dilakukan melalui fungsi `R.optim` untuk memperoleh hampiran numerik terhadap nilai dugaan kemungkinan maksimum; tanpa argumen `method`, fungsi ini menggunakan Nelder–Mead, bukan pembaruan Newton–Raphson. Pelajaran ini juga memperkenalkan keterampilan pemrograman R yang penting, seperti melakukan operasi dasar, memanipulasi vektor dan kerangka data (data frame), menghasilkan statistik ringkasan, membuat visualisasi seperti histogram dan diagram kotak, serta menggunakan distribusi statistik (misalnya Normal dan Eksponensial) untuk menyimulasikan data dan menghitung peluang.

Melalui berbagai contoh, Anda belajar menangani skenario data dunia nyata, seperti menduga parameter distribusi eksponensial dan Normal. Keterampilan ini menjadi landasan yang kuat untuk menerapkan MLE dalam inferensi statistik dan mempersiapkan Anda mempelajari topik lanjut seperti selang kepercayaan dan pengujian hipotesis.

1. [Pelajaran](#)
2. [6 Selang Kepercayaan](#)

6 Selang Kepercayaan

Selang Kepercayaan

Gambaran Umum

Dalam pelajaran ini, kita akan sejenak meninggalkan pembahasan penduga kemungkinan maksimum (MLE). Jangan khawatir! Kita akan kembali ke pendugaan kemungkinan maksimum.

Dalam pelajaran ini, kita akan mempelajari cara menyusun dan menghitung selang kepercayaan bagi parameter populasi. Seperti akan segera kita lihat, selang kepercayaan adalah selang (atau rentang) nilai yang diperoleh melalui prosedur dengan peluang cakupan tertentu bagi parameter populasi sejati yang tidak diketahui. Kita akan meluangkan waktu untuk memahami makna “kepercayaan” pada selang tersebut, sekaligus mempelajari faktor-faktor yang memengaruhi panjang selang.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Menafsirkan dengan benar selang kepercayaan yang diberikan dalam kaitannya dengan populasi,
2. Menyusun secara analitis selang kepercayaan bagi parameter yang tidak diketahui, dan
3. Menghitung secara numerik selang kepercayaan bagi parameter yang tidak diketahui berdasarkan sekumpulan data.

6.1 Pengantar Selang Kepercayaan

Sejauh ini, ketika membahas pendugaan, kita berfokus pada penentuan penduga titik; realisasinya setelah data diamati disebut **nilai dugaan titik**, dan keduanya berkaitan dengan suatu parameter. Pada bagian ini, kita akan memperkenalkan **pendugaan selang**.

1. Ketika kita menggunakan rata-rata sampel $\bar{x}$ untuk menduga rata-rata populasi μ , dapatkah kita yakin bahwa $\bar{x}$ dekat dengan μ ? Dan ketika kita menggunakan proporsi sampel $\hat{p}$ untuk menduga proporsi populasi p , dapatkah kita yakin bahwa $\hat{p}$ dekat dengan p ?
2. Apakah kita mengetahui seberapa dekat statistik sampel itu dengan parameter populasi?

Alih-alih hanya menggunakan nilai dugaan titik, kita dapat memakai prosedur yang, sebelum data diamati, menghasilkan selang acak dengan peluang cakupan tinggi bagi parameter populasi sejati yang tidak diketahui. Setelah data diamati, selang yang diperoleh tetap dan entah mencakup parameter tersebut atau tidak. Sebagai contoh, kita dapat menentukan batas bawah acak (L) dan batas atas acak (U) sehingga kejadian bahwa parameter populasi, θ , terletak di antara keduanya memiliki peluang yang tinggi:

$$L < \theta < U$$

Selang dari nilai-nilai tersebut disebut **selang kepercayaan**. Setiap selang memiliki **koefisien kepercayaan** (yang dinyatakan sebagai proporsi):

$$1 - \alpha$$

atau **tingkat kepercayaan** (yang dinyatakan sebagai persentase):

$$(1 - \alpha)100\%$$

Koefisien kepercayaan yang lazim adalah 0.90, 0.95, dan 0.99, dengan tingkat kepercayaan masing-masing 90%, 95%, dan 99%. Sebagai contoh, setelah menghitung selang kepercayaan bagi parameter θ dengan tingkat kepercayaan, misalnya, 95%, kita dapat mengatakan:

“Prosedur ini memiliki peluang cakupan 95% dalam pengambilan sampel berulang; untuk sampel ini, batas selang yang diperoleh adalah L dan U .”

Sesuai dengan intuisi, makin tinggi tingkat kepercayaan, makin besar pula peluang cakupan prosedur selang kepercayaan bagi parameter populasi yang sebenarnya.

6.2 Rataan Populasi dari Distribusi Normal

Mari kita tunjukkan cara melakukan pendugaan selang (atau menyusun selang kepercayaan) bagi rata-rata populasi dari distribusi Normal dengan varians yang **diketahui**, yaitu σ^2 .

Sebelum itu, kita perlu mendefinisikan notasi yang digunakan. Ingat bahwa $z_{\alpha/2}$ adalah nilai kritis dari peubah acak Z ; nilai tersebut diperoleh dari tabel normal baku dan dipilih sedemikian rupa sehingga luas daerah di sebelah kanannya di bawah kurva normal baku adalah $\frac{\alpha}{2}$. Artinya:

$$P(Z \geq z_{\alpha/2}) = \alpha/2$$


Demikian pula:

$$-z_{\alpha/2}$$

adalah nilai kritis dari peubah acak Z ; nilai tersebut diperoleh dari tabel normal baku dan dipilih sedemikian rupa sehingga luas daerah di sebelah kirinya di bawah kurva normal baku adalah $\frac{\alpha}{2}$. Artinya:

$$P(Z \leq -z_{\alpha/2}) = \alpha/2$$

Notasi ini dapat digambarkan dengan diagram kurva normal baku berikut:



Gambar 6.1. Kurva normal baku menunjukkan daerah tengah dengan luas $1 - \alpha$, dua ekor yang masing-masing memiliki luas $\alpha/2$, serta nilai kritis $-z_{\alpha/2}$ dan $z_{\alpha/2}$ sebagai batasnya.

Catatan koreksi Gambar 6.1: kedua titik batas adalah nilai kritis tetap $-z_{\alpha/2}$ dan $+z_{\alpha/2}$ (z huruf kecil), bukan peubah acak Z ; masing-masing ekor mempunyai peluang $\alpha/2$.

Setelah notasinya jelas, mari kita nyatakan rumus selang kepercayaan bagi rata-rata populasi.

Teorema 6.1 (Selang-Z untuk Rataan) $X_1, X_2, \dots, X_n$ merupakan sampel acak dari distribusi normal dengan rata-rata yang tidak diketahui μ dan varians **yang diketahui**, yaitu σ^2 . Maka, selang kepercayaan dengan tingkat $(1 - \alpha)100\%$ untuk rata-rata populasi μ adalah:

$$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Karena selang ini bergantung pada Z , selang tersebut sering disebut selang- **Z untuk rata-rata**..

Karena pada tahap ini kita hanya ingin mempelajari dasar-dasar penurunan selang kepercayaan, untuk sementara kita akan mengabaikan kenyataan bahwa asumsi kedua, yaitu varians populasi diketahui, tidak realistis. Lagi pula, kapan kita pernah mengetahui nilai varians populasi σ^2 , tetapi tidak mengetahui rata-rata populasi μ ? Aneh juga! Nanti kita akan mencari selang kepercayaan yang praktis untuk rata-rata μ di bagian selanjutnya. Untuk sekarang, mari kita turunkan selang yang satu ini.

Bukti:

Dari diagram kurva normal baku di atas, kita dapat melihat bahwa pernyataan peluang berikut benar:

$$P[-z_{\alpha/2} \leq Z \leq z_{\alpha/2}] = 1 - \alpha$$

Kemudian, cukup dengan mengganti Z , kita memperoleh:

$$P\left[-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{\alpha/2}\right] = 1 - \alpha$$

Sekarang, untuk sementara mari kita berfokus hanya pada manipulasi pertidaksamaan di dalam tanda kurung siku. Karena kita melakukan operasi yang sama pada ketiga ruas pertidaksamaan, setiap pernyataan berikut ekuivalen:

$$\begin{aligned} -z_{\alpha/2} &\leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{\alpha/2} \\ -z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) &\leq \bar{X} - \mu \leq z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) \\ -\bar{X} - z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) &\leq -\mu \leq -\bar{X} + z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) \\ \bar{X} - z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) &\leq \mu \leq \bar{X} + z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) \end{aligned}$$

Jadi, sebagai ringkasan, dengan memanipulasi pertidaksamaan kita telah menunjukkan bahwa pernyataan peluang berikut benar:

$$P\left[\bar{X} - z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) \leq \mu \leq \bar{X} + z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right)\right] = 1 - \alpha$$

Sebenarnya, pada bagian berikutnya kita akan mempelajari mengapa rumus selang-Z untuk rata-rata, yang menggunakan Z , tidak seharusnya (dan karena itu memang tidak) ditulis persis seperti itu. Sebagai gantinya, dengan tingkat kepercayaan $(1 - \alpha)100\%$, kita menyatakan hal berikut tentang rata-rata μ : rata-rata tersebut berada dalam selang:

$$\bar{x} \pm z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right) = \left[\bar{x} - z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right), \bar{x} + z_{\alpha/2} \left(\frac{\sigma}{\sqrt{n}}\right)\right]$$

6.3 Interpretasi

Topik interpretasi selang kepercayaan sering membuat ahli statistik frekuentis gerah. Mari kita pahami alasannya!

Meskipun penurunan selang-Z untuk rata-rata, yang didasarkan pada Z , secara teknis berakhir pada pernyataan peluang berikut:

$$P\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right] = 1 - \alpha$$

pernyataan berikut *tidak benar* :

“Peluang bahwa rata-rata populasi μ berada di antara batas bawah L dan batas atas U adalah $1 - \alpha$.”

Namun, mengapa? Pernyataan peluang menyangkut peubah acak. Rataan populasi μ adalah konstanta, bukan peubah acak. Tidak masuk akal membuat pernyataan peluang tentang konstanta yang nilainya tidak berubah.

Singkatnya, ahli statistik frekuentis tidak suka mendengar orang mencoba membuat pernyataan peluang tentang konstanta, padahal pernyataan peluang semestinya hanya dibuat tentang peubah acak. Jadi, jika pernyataan yang tampaknya jelas berdasarkan pernyataan peluang di atas ternyata tidak benar, bagaimana selang kepercayaan seharusnya dipahami? Berikut cara ahli statistik frekuentis ingin agar kita memandang selang kepercayaan:

1. Misalkan kita mengambil sejumlah besar sampel, katakanlah 1000.
2. Kemudian, kita menghitung selang kepercayaan 95% untuk setiap sampel.
3. Selanjutnya, “yakin 95%” berarti bahwa kita mengharapkan 95%, atau 950, dari 1000 selang tersebut benar, yakni memuat nilai rata-rata populasi sebenarnya yang belum diketahui, yaitu μ .

Jadi, apa arti semua ini dalam praktik?

Dalam praktiknya, kita hanya mengambil satu sampel acak. Selang yang kita peroleh itu **benar** atau **tidak benar**. Artinya, selang yang diperoleh berdasarkan sampel yang kita ambil memuat parameter populasi yang sebenarnya atau tidak memuatnya. Karena kita tidak mengetahui nilai parameter populasi yang sebenarnya, kita tidak akan pernah tahu secara pasti apakah selang kita benar atau tidak. Kita hanya dapat sangat yakin bahwa kita memperoleh selang yang benar (karena 95% dari seluruh selang yang mungkin kita peroleh adalah benar).

Contoh 6.1 Mari kita pertimbangkan contoh lain yang mungkin mengharuskan kita mengingat kembali sebagian materi yang dipelajari dalam STAT 414.

Misalkan Y merupakan peubah acak berdistribusi Gamma dengan parameter yang diketahui $\alpha = 2$ dan parameter yang tidak diketahui, yaitu θ . Kita ingin membentuk selang kepercayaan 90% untuk θ .

Untuk melakukannya, kita perlu menemukan besaran pivot (pivotal quantity). Besaran pivot memiliki dua karakteristik:

1. Besaran tersebut merupakan fungsi dari nilai-nilai pengamatan sampel dan **satu-satunya** parameter yang tidak diketahui, yaitu θ .
2. Distribusi besaran pivot tidak bergantung pada θ .

Oleh karena itu, kita harus membentuk suatu fungsi dari Y dan θ yang distribusinya tidak bergantung pada θ . Jadi, kita perlu menemukan besaran pivot. Untuk itu, ada baiknya kita mengingat kembali distribusi fungsi peubah acak yang dipelajari dalam STAT 414.

Perhatikan besaran $U = \frac{2Y}{\theta}$. Bagaimana distribusi U ? Mari kita gunakan metode fungsi pembangkit momen (MGF) untuk memperoleh distribusi U .

$$M_Y(t) = E(e^{tY}) = \frac{1}{(1 - \theta t)^2}$$

$$M_U(t) = E(e^{tU}) = E(e^{t(\frac{2Y}{\theta})}) = E(e^{(\frac{2t}{\theta})Y}) = \frac{1}{(1 - \theta(\frac{2t}{\theta}))^2} = \frac{1}{(1 - 2t)^2}$$

Berdasarkan sifat ketunggalan fungsi pembangkit momen, kita dapat melihat bahwa U berdistribusi Gamma dengan parameter bentuk $\alpha = 2$ dan parameter skala $\theta = 2$. Lebih berguna lagi, kita dapat melihat bahwa U mengikuti distribusi khi-kuadrat dengan $r = 4$ derajat kebebasan. Menyatakan distribusi ini sebagai distribusi khi-kuadrat sangat berguna karena kita dapat memanfaatkan perangkat lunak dan tabel untuk menghitung peluang.

Sekarang, mari kita bentuk selang kepercayaannya.

Dengan konvensi bahwa subskrip p pada kuantil khi-kuadrat menyatakan peluang ekor bawah p , kita menginginkan selang yang memenuhi:

$$q_p = F_{\chi^2_4}^{-1}(p), \quad P\left[q_{0.05} \leq \frac{2Y}{\theta} \leq q_{0.95}\right] = 0.90$$

Sekali lagi, dengan hanya meninjau pertidaksamaan di dalam tanda kurung, kita memperoleh:

$$\frac{1}{q_{0.95}} \leq \frac{\theta}{2Y} \leq \frac{1}{q_{0.05}}$$

$$\frac{2Y}{q_{0.95}} \leq \theta \leq \frac{2Y}{q_{0.05}}$$

Oleh karena itu, selang kepercayaan 90% untuk θ adalah:

$$\left[\frac{2Y}{q_{0.95}}, \frac{2Y}{q_{0.05}} \right]$$

Terakhir, mari kita hitung selang kepercayaan menggunakan data. Misalkan kita mengamati $y = 1.261552$ dari distribusi Gamma dengan parameter bentuk $\alpha = 2$ dan parameter skala θ . Mari kita tentukan dan tafsirkan selang kepercayaan 90% untuk θ .

$$\left[\frac{2(1.261552)}{9.4877}, \frac{2(1.261552)}{0.7107} \right] = [0.2659, 3.5502]$$

Kita yakin 90% bahwa nilai sebenarnya dari θ berada di antara 0.2659 dan 3.5502.

Tantangan terbesar dalam membentuk selang kepercayaan adalah menemukan besaran pivot. Dalam contoh-contoh di kelas ini, besaran pivot akan diberikan atau tersedia petunjuk yang membantu Anda menemukannya. Jangan khawatir, Anda akan memperoleh banyak latihan membentuk selang kepercayaan melalui tugas.

6.4 Selang Kepercayaan Sampel Besar

Misalkan kita memiliki penduga, $\hat{\theta}$, dengan galat baku $\sigma_{\hat{\theta}}$. Untuk sampel besar, dengan syarat yang sesuai (dibahas kemudian), statistik terstandarisasi berikut:

$$T_n = \frac{\hat{\theta} - \theta}{\widehat{SE}(\hat{\theta})} \xrightarrow{d} N(0, 1)$$

konvergen dalam distribusi ke distribusi normal baku. Selain itu, $T_n = \frac{\hat{\theta} - \theta}{\widehat{SE}(\hat{\theta})}$, merupakan besaran pivot hampiran yang dapat digunakan untuk membentuk selang kepercayaan bagi parameter yang tidak diketahui, θ .

Syarat-syarat yang relevan adalah:

1. Nilai harapan penduga $\hat{\theta}$ boleh berbeda dari θ . Namun, selisih ini harus dapat diabaikan secara asimtotik dibandingkan dengan galat bakunya; ketakbiasan eksak tidak diperlukan.
2. Galat baku penduga $\sigma_{\hat{\theta}}$ harus diketahui atau dapat dihitung. Jika digunakan taksiran galat baku, taksiran itu harus konsisten, atau hasil studentisasi yang ekuivalen harus berlaku.
3. Statistik terstudentisasi harus konvergen dalam distribusi ke distribusi normal baku. Teorema Limit Pusat, bersama syarat yang sesuai bagi taksiran galat baku, merupakan salah satu cara untuk memperoleh hasil tersebut.

Contoh 6.2 Waktu berbelanja dari $n = 64$ pelanggan yang dipilih secara acak di sebuah pasar swalayan setempat dicatat. Rataan dan varians dari 64 waktu berbelanja tersebut adalah 33 menit dan 256 minutes², secara berturut-turut. Dugalah rataannya sebenarnya waktu berbelanja per pelanggan dengan koefisien kepercayaan 0.9.

Penyelesaian

Selang kepercayaan hampiran tersebut berbentuk:

$$\hat{\theta} \pm z_{\alpha/2} \sigma_{\hat{\theta}}$$

Kita ingin menduga rataannya populasi waktu berbelanja, μ . Kita memiliki nilai dugaan untuk μ , yaitu $\hat{\mu} = 33$.

Taksiran galat baku rataannya sampel adalah 2. Secara eksplisit, $\widehat{SE}(\bar{X}) = \frac{s}{\sqrt{64}} = \frac{16}{8} = 2$. Selang hampiran tersebut adalah:

$$\hat{\mu} \pm z_{\alpha/2}(\hat{\sigma}_{\hat{\mu}}) = \left(33 \pm 1.645 \left(\frac{16}{8} \right) \right) = (29.71, 36.29)$$

6.5 Ringkasan

Dalam pelajaran ini, kita beralih dari nilai dugaan titik ke sesuatu yang lebih informatif—selang kepercayaan. Alih-alih hanya memberikan satu angka sebagai nilai dugaan (seperti rataannya sampel), kini kita memberikan rentang nilai yang kita yakini, pada tingkat kepercayaan tertentu, memuat parameter populasi yang sebenarnya.

Kita telah menguraikan arti sebenarnya dari tingkat kepercayaan tersebut. Selang kepercayaan 95% tidak berarti bahwa parameter memiliki peluang 95% untuk berada di dalam selang yang diperoleh—sebab parameter itu tetap. Artinya, jika prosedur ini diulang berkali-kali, 95% dari selang yang dihasilkan akan memuat nilai sebenarnya.

Anda telah mempelajari cara membentuk selang tersebut menggunakan distribusi yang diketahui, besaran pivot, dan hampiran sampel besar.

Inti keseluruhannya? Selang kepercayaan membantu kita mengomunikasikan ketidakpastian dengan jelas dan jujur, serta merupakan salah satu alat penting bagi statistikawan.

Pokok-Pokok Utama:

- Bentuk umum selang kepercayaan adalah: Point Estimate $\pm$ (Critical Value) $\times$ Standard Error
- Selang kepercayaan untuk rataannya populasi ketika varians distribusi Normal diketahui adalah:
$$\bar{X} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$
- Untuk sampel yang saling bebas dan berdistribusi identik (iid) dari distribusi Normal, selang kepercayaan eksak bagi rataannya populasi ketika varians tidak diketahui, dengan $df = n - 1$, adalah: $\bar{X} \pm t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}$
- Ukuran sampel, tingkat kepercayaan, dan variabilitas memengaruhi lebar selang.

1. [Pelajaran](#)
2. [7 Distribusi Asimtotik MLE \(Bagian I\)](#)

7 Distribusi Asimtotik MLE (Bagian I)

MLE

Selang Kepercayaan Asimtotik

Hampiran Numerik

Bootstrap

Gambaran Umum

Mari kita tinjau kembali penduga kemungkinan maksimum (MLE) untuk mempelajari sifat-sifat asimtotiknya dan penerapannya dalam membentuk selang kepercayaan. Pelajaran ini memperkenalkan dasar-dasar teoretis MLE, termasuk konsistensi, sifat ekuivarian, dan normalitas asimtotiknya di bawah syarat keteraturan. Anda akan mempelajari cara menurunkan informasi Fisher untuk model berparameter tunggal dan model multiparameter, lalu menggunakannya untuk membentuk selang kepercayaan asimtotik. Pelajaran ini juga membahas hampiran numerik untuk selang-selang tersebut dengan menggunakan fungsi dalam R, yaitu `optim` untuk optimisasi numerik. Pernyataan ikhtisar sumber tentang selang bootstrap parametrik dan nonparametrik, metode Delta, inferensi transformasi dengan bootstrap, serta contoh t dan Pareto bersifat antisipatif dan tidak didukung oleh isi Pelajaran 07 yang tersedia. Isi sebenarnya mencakup sifat MLE, selang Wald asimtotik skalar dan vektor, serta demonstrasi numerik Geometrik dan Normal. Mari kita mulai.

7.1 Sifat-Sifat MLE

Pendugaan kemungkinan maksimum populer karena terdapat sejumlah sifat yang dapat dibuktikan dan berlaku untuk **SETIAP MLE!**

Hasil berikut berlaku bagi setiap MLE, dengan beberapa “syarat keteraturan”. Syarat keteraturan tersebut mencakup

- Fungsi peluang yang mendasarinya, $f(x|\theta)$, bersifat “mulus”.
- Parameter sebenarnya, θ_0 , berada di bagian dalam ruang parameter, bukan pada batasnya. Syarat ini menyangkut ruang parameter dan tidak sama dengan himpunan dukungan data.

Kami tidak akan menyajikan daftar lengkap syarat maupun bukti bagi sifat-sifat berikut. Anda dapat menemukannya dalam buku teks Wasserman, Bab 9.13.

KiatSifat 1: Penduga, $\hat{\theta}_{mle}$ bersifat konsisten.

Ini berarti bahwa ketika ukuran sampel n mendekati tak hingga, $\hat{\theta}_{mle}$ mendekati nilai sebenarnya dari θ . Namun, konsistensi saja tidak cukup untuk menyimpulkan konvergensi nilai harapan. Jika keluarga penduga memenuhi integrabilitas seragam, maka ketika n mendekati tak hingga, $E(\hat{\theta}_{mle})$ mendekati nilai sebenarnya dari θ .

Catatan koreksi: integrabilitas seragam (uniform integrability; UI), bersama konvergensi dalam peluang ke θ , menghasilkan konvergensi L^1 ; karena itu $E(\theta_n) \rightarrow \theta$. Tanpa syarat tambahan ini, konsistensi saja tidak menjaga nilai harapan.

KiatSifat 2: Penduga, $\hat{\theta}_{mle}$, bersifat ekuivarian.

Jika suatu penduga, $\hat{\theta}$, merupakan MLE bagi θ , dan $g(\theta)$ merupakan fungsi yang dapat dibalik, maka MLE bagi $\tau = g(\theta)$ adalah $\hat{\tau} = g(\hat{\theta})$.

Artinya, MLE bagi suatu fungsi dari parameter diperoleh dengan menerapkan fungsi tersebut pada MLE bagi parameternya, selama fungsi itu dapat dibalik.

Contoh 7.1 Misalkan $X_i \sim N(\mu, \sigma^2)$. Artinya, misalkan $X_1, X_2, \dots, X_n$ merupakan peubah acak Normal yang saling bebas dan berdistribusi identik (iid), dengan rata-rata μ dan varians σ^2 . Kita mengetahui bahwa $\hat{\mu} = \bar{x}$ dan $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ adalah MLE bagi μ dan σ^2 , masing-masing. Berapakah MLE bagi simpangan baku, σ ?

Penyelesaian

Kita mengetahui bahwa $\sigma = g(\sigma^2) = \sqrt{\sigma^2}$. Oleh karena itu, berdasarkan sifat ekuivarian, MLE bagi σ adalah:

$$\hat{\sigma}_{mle} = \sqrt{\hat{\sigma}_{mle}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Contoh 7.2 Misalkan $X_i \sim \text{Bin}(5, p)$, untuk $i = 1, \dots, n$. Berapakah MLE bagi rasio odds, $\text{OR} = \frac{p}{1-p}$?

Penyelesaian

MLE bagi p adalah $\hat{p} = \frac{\sum_{i=1}^n x_i}{5n}$. Oleh karena itu, MLE bagi OR adalah

$$\hat{\text{OR}}_{mle} = \frac{\hat{p}}{1 - \hat{p}} = \frac{\frac{\sum_{i=1}^n x_i}{5n}}{1 - \frac{\sum_{i=1}^n x_i}{5n}}$$

KiatSifat 3: MLE Berdistribusi Normal secara Asimtotik.

Untuk $X_i \sim f(x_i|\theta)$ $i = 1, \dots, n$, MLE-nya adalah $\hat{\theta} = \text{argmax}_{\theta}(L(\theta))$. Ketika n mendekati tak hingga, MLE $\hat{\theta}$ memiliki hampiran distribusi Normal:

$$\hat{\theta} \approx N\left(\theta_{\text{true}}, \frac{1}{I(\hat{\theta}_{mle})}\right)$$

Di sini, “ $\approx$ ” berarti “memiliki distribusi yang secara hampiran diberikan oleh”. Fungsi $I(\theta)$ disebut “**Informasi Fisher**” atau fungsi “Informasi”. Fungsi ini didefinisikan sebagai

$$I_n(\theta) = -E_{\theta} \left[\frac{d^2}{d\theta^2} \ell_n(\theta) \right]$$

Contoh 7.3 Misalkan $X_1, \dots, X_n$ merupakan sampel iid dari distribusi Bernoulli dengan parameter p . Tentukan MLE bagi p dan tentukan $I(\hat{p})$. Kemudian, tentukan hampiran distribusi Normal bagi $\hat{p}$.

Penyelesaian

Fungsi massa peluang (PMF)-nya adalah $f(x|p) = p^x(1-p)^{1-x}$. Fungsi kemungkinannya adalah:

$$L(p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}$$

Fungsi log-kemungkinannya adalah:

$$\ell(p) = \sum x_i \ln(p) + (n - \sum x_i) \ln(1-p)$$

Turunan fungsi log-kemungkinannya adalah:

$$\frac{d}{dp}\ell(p) = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p}$$

Dengan menyamakan turunan tersebut dengan nol, kita memperoleh:

$$\begin{aligned} 0 &= \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1-p}, & \Rightarrow 0 &= \frac{\sum x_i - p \sum x_i - np + p \sum x_i}{p(1-p)} \\ 0 &= \sum x_i - np, & \hat{p} &= \frac{\sum x_i}{n} \end{aligned}$$

Oleh karena itu, MLE bagi p adalah $\hat{p} = \frac{\sum x_i}{n}$. Selanjutnya, mari kita tentukan $I(p) = -E\left(\frac{d^2}{dp^2}\ell(p)\right)$.

$$\frac{d^2}{dp^2}\ell(p) = -\frac{\sum x_i}{p^2} - \frac{n - \sum x_i}{(1-p)^2}$$

Selanjutnya, kita perlu menentukan negatif dari nilai harapan turunan kedua tersebut.

$$\begin{aligned} I(p) &= -E\left(\frac{d^2}{dp^2}\ell(p)\right) \\ &= -E\left(-\frac{\sum x_i}{p^2} - \frac{n - \sum x_i}{(1-p)^2}\right) \\ &= E\left(\frac{\sum x_i}{p^2} + \frac{n - \sum x_i}{(1-p)^2}\right) \\ &= \frac{\sum E(x_i)}{p^2} + \frac{n - \sum E(x_i)}{(1-p)^2} \end{aligned}$$

Untuk peubah acak Bernoulli, $E(X) = p$. Oleh karena itu,

$$\begin{aligned} I(p) &= \frac{\sum E(x_i)}{p^2} + \frac{n - \sum E(x_i)}{(1-p)^2} \\ &= \frac{np}{p^2} + \frac{n - np}{(1-p)^2} \\ &= \frac{np(1-p)^2 + np^2 - np^3}{p^2(1-p)^2} \\ &= \frac{np((1-p)^2 + p(1-p))}{p^2(1-p)^2} \\ &= \frac{np(1-p)(1-p+p)}{p^2(1-p)^2} \\ &= \frac{n}{p(1-p)} \end{aligned}$$

Jika $I(p) = \frac{n}{p(1-p)}$, maka $I(\hat{p}) = \frac{n}{\hat{p}(1-\hat{p})} = \frac{n}{\frac{\sum x_i}{n} \left(1 - \frac{\sum x_i}{n}\right)} = \frac{n}{\bar{x}(1-\bar{x})}$.

Dengan menggabungkan semua hasil ini, kita memperoleh $\hat{p} \approx N\left(p_{true}, \frac{1}{I(\hat{p})}\right)$. Hal ini ekuivalen dengan $\hat{p} \approx N\left(p_{true}, \frac{\bar{x}(1-\bar{x})}{n}\right)$.

Setelah menentukan distribusi asimtotik MLE (dengan syarat tertentu), kita dapat menggunakan informasi ini (dengan ukuran sampel besar) guna melakukan pendugaan selang bagi parameter yang tidak diketahui, θ .

7.2 Selang Kepercayaan Asimtotik

7.2.1 Kasus Satu Parameter

Pada bagian ini, kita menggabungkan sifat-sifat yang dibahas pada bagian sebelumnya untuk menyusun selang kepercayaan asimtotik bagi parameter yang tidak diketahui, θ , dengan menggunakan MLE.

Hampiran distribusi Normal bagi setiap MLE memberikan cara mudah untuk menentukan selang kepercayaan asimtotik bagi parameter yang tidak diketahui.

KiatSifat 4: Selang Kepercayaan Hampiran

Misalkan X_i mengikuti suatu distribusi dengan fungsi peluang $f(x_i|\theta)$. Misalkan $\hat{\theta}$ merupakan MLE bagi θ . Kita mempunyai $I(\theta) = -E\left(\frac{d^2}{d\theta^2} \ell(\theta)\right)$. Maka, selang kepercayaan asimtotik 95% bagi θ adalah

$$\hat{\theta} \pm 1.96 \sqrt{\frac{1}{I(\hat{\theta})}}$$

Contoh 7.4 Melanjutkan contoh sebelumnya, kita mengetahui $\hat{p} = \bar{x}$, $I(\hat{p}) = \frac{n}{\bar{x}(1-\bar{x})}$, dan $\hat{p} \approx N\left(p_{true}, \frac{\bar{x}(1-\bar{x})}{n}\right)$. Tentukan selang kepercayaan asimtotik 95% bagi p .

Penyelesaian

Selang kepercayaan hampiran 95% bagi p adalah:

$$\bar{x} \pm 1.96 \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}$$

Contoh 7.5 Misalkan kita memiliki 10 pengamatan berikut dari distribusi Bernoulli dengan parameter p . Hitung selang kepercayaan asimtotik 95% bagi p .

1	1	0	1	0
0	0	1	1	1

Penyelesaian

Melanjutkan contoh sebelumnya, kita mengetahui $\hat{p} = \bar{x}$, $I(\hat{p}) = \frac{n}{\bar{x}(1-\bar{x})}$, dan $\hat{p} \approx N\left(p_{true}, \frac{\bar{x}(1-\bar{x})}{n}\right)$.

Kita dapat menghitung $\bar{x} = 0.6$ dan mengetahui $n = 10$. Oleh karena itu,

Selang kepercayaan hampiran 95% bagi p adalah:

$$\bar{x} \pm 1.96 \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} = 0.6 \pm 1.96 \sqrt{\frac{0.6(1-0.6)}{10}} = 0.6 \pm 0.3036 = (0.2964, 0.9036)$$

Catatan!

Ukuran sampel dalam contoh ini tidak besar, tetapi contoh ini dipilih untuk tujuan latihan.

Contoh 7.6 Misalkan $X_1, X_2, \dots, X_n$ merupakan sampel acak dari $\text{Exp}(\theta)$. Tentukan selang kepercayaan asimtotik 95% bagi θ , dengan menggunakan MLE bagi θ .

Penyelesaian

Untuk $x_i \geq 0$ dan $\theta > 0$, fungsi kepadatan peluang (PDF)-nya adalah $f(x_i|\theta) = \frac{1}{\theta} e^{-\frac{x_i}{\theta}}$ dan $E(X_i) = \theta$.

Langkah 1: Tentukan fungsi kemungkinan.

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} e^{-\frac{x_i}{\theta}} = \theta^{-n} e^{-\frac{\sum x_i}{\theta}}$$

Langkah 2: Tentukan fungsi log-kemungkinan.

$$\ell(\theta) = -n \log \theta - \frac{\sum x_i}{\theta}$$

Langkah 3: Tentukan turunan fungsi log-kemungkinan terhadap θ .

$$\frac{d}{d\theta} \ell(\theta) = -\frac{n}{\theta} + \frac{\sum x_i}{\theta^2}$$

Langkah 4: Samakan turunan tersebut dengan 0, lalu selesaikan persamaannya untuk memperoleh θ .

$$\begin{aligned} 0 &= \frac{-n\theta + \sum x_i}{\theta^2}, & \Rightarrow 0 &= -n\theta + \sum x_i \\ \Rightarrow \hat{\theta} &= \frac{\sum x_i}{n} \end{aligned}$$

Langkah 5: Tentukan $I(\hat{\theta}) = -E\left(\frac{d^2}{d\theta^2} \ell(\hat{\theta})\right)$.

$$\begin{aligned} \frac{d^2}{d\theta^2} \ell_n(\theta) &= \frac{n}{\theta^2} - \frac{2 \sum x_i}{\theta^3}, \\ I_n(\theta) &= -E_\theta \left[\frac{d^2}{d\theta^2} \ell_n(\theta) \right] = \frac{n}{\theta^2}, \\ I_n(\hat{\theta}) &= \frac{n}{\hat{\theta}^2} = \frac{n}{\bar{x}^2} = \frac{n^3}{(\sum x_i)^2}. \end{aligned}$$

Oleh karena itu, selang kepercayaan asimtotik 95% bagi θ adalah:

$$\hat{\theta} \pm 1.96 \sqrt{\frac{1}{I_n(\hat{\theta})}} = \bar{x} \pm 1.96 \sqrt{\frac{\bar{x}^2}{n}} = \bar{x} \pm 1.96 \frac{\bar{x}}{\sqrt{n}}$$

7.2.2 Kasus Multiparameter

Dalam kasus multivariat, dengan dua atau lebih parameter yang akan diduga, $\theta = (\theta_1, \theta_2, \dots, \theta_p)$ adalah vektor yang terdiri atas p parameter yang akan diduga, dan distribusi asimtotiknya adalah sebagai berikut. Saat $n \rightarrow \infty$,

$$\hat{\theta}_{ML} \sim N(\theta_{\text{true}}, \mathbf{I}^{-1}(\hat{\theta}_{ML}))$$

dengan $\mathbf{I}(\theta)$ adalah “matriks informasi Fisher”, yang didefinisikan sebagai

$$\mathbf{I}(\theta) = \begin{bmatrix} -E_x \left[\frac{\partial^2}{\partial \theta_1^2} \ell(\theta) \right] & -E_x \left[\frac{\partial^2}{\partial \theta_1 \partial \theta_2} \ell(\theta) \right] & \cdots & -E_x \left[\frac{\partial^2}{\partial \theta_1 \partial \theta_p} \ell(\theta) \right] \\ -E_x \left[\frac{\partial^2}{\partial \theta_2 \partial \theta_1} \ell(\theta) \right] & -E_x \left[\frac{\partial^2}{\partial \theta_2^2} \ell(\theta) \right] & \cdots & -E_x \left[\frac{\partial^2}{\partial \theta_2 \partial \theta_p} \ell(\theta) \right] \\ \vdots & \vdots & \ddots & \vdots \\ -E_x \left[\frac{\partial^2}{\partial \theta_p \partial \theta_1} \ell(\theta) \right] & -E_x \left[\frac{\partial^2}{\partial \theta_p \partial \theta_2} \ell(\theta) \right] & \cdots & -E_x \left[\frac{\partial^2}{\partial \theta_p^2} \ell(\theta) \right] \end{bmatrix}$$

dengan ketentuan, seperti sebelumnya, bahwa $\ell(\theta) = \log(L(\theta))$ dan nilai harapan dihitung terhadap semua $x_1, x_2, \dots, x_n$.

7.2.3 Ringkasan: Selang Kepercayaan Asimtotik 95%

Untuk setiap MLE, hampiran distribusi Gaussian asimtotik dapat digunakan untuk membentuk selang kepercayaan. Misalkan $x_i \sim f_X(x|\theta)$, $i = 1, 2, \dots, n$ adalah n peubah acak yang saling bebas dan berdistribusi identik, yang berasal dari suatu distribusi dengan hanya satu parameter θ , dan misalkan $\hat{\theta} = \text{argmax}(L(\theta))$ adalah MLE bagi parameter yang tidak diketahui θ . Selanjutnya, berdasarkan hampiran distribusi Gaussian asimtotik bagi setiap MLE, hampiran selang kepercayaan asimtotik 95% untuk θ adalah

$$\hat{\theta} \pm 1.96 \sqrt{1/I(\hat{\theta}_{ML})}$$

Demikian pula, untuk model multiparameter, hampiran selang kepercayaan asimtotik 95% bagi parameter nomor k , yaitu θ_k adalah

$$\hat{\theta}_k \pm 1.96 \sqrt{\mathbf{I}^{-1}(\hat{\theta}_{ML})[k, k]}$$

dengan $\sqrt{\mathbf{I}^{-1}(\hat{\theta}_{ML})[k, k]}$ adalah akar kuadrat dari entri diagonal nomor k ; entri tersebut berasal dari $\mathbf{I}^{-1}(\hat{\theta}_{ML})$ sedangkan $\mathbf{I}^{-1}$ adalah matriks invers dari $\mathbf{I}$.

7.3 Hampiran Numerik untuk Selang Kepercayaan

Dalam sejumlah kasus yang relatif sederhana, kita dapat membentuk selang kepercayaan 95% bagi parameter secara analitik dengan MLE sebagai pusatnya. Untuk itu, kita harus dapat mencari MLE secara analitik (dengan mengambil turunan pertama fungsi log-kemungkinan dan menyamakannya dengan nol), kemudian mencari informasi Fisher secara analitik pula (dengan mengambil turunan kedua fungsi log-kemungkinan, lalu menghitung nilai harapan terhadap $x_1, x_2, \dots, x_n$). Seperti telah kita lihat, bahkan untuk distribusi statistik sederhana terdapat banyak kasus ketika MLE tidak mungkin dicari secara analitik. Dalam kasus-kasus ini, kita menghampiri MLE tersebut secara numerik dengan menggunakan `optim` dalam R. Sebagaimana kita dapat menghampiri MLE dengan menggunakan `optim`, kita juga dapat menghampiri informasi teramati (observed information) $I(\hat{\theta})$ (untuk kasus berparameter tunggal) atau $\mathbf{I}(\hat{\theta})$ (untuk kasus multiparameter) dengan menggunakan `optim`. Hal ini kita lakukan dalam `optim` dengan menyertakan satu argumen tambahan ketika memanggil `optim`.

Catatan domain: kode demonstrasi di bawah dibekukan sesuai sumber, tetapi pemanggilan `optim` tidak memaksakan domain parameter. Model Geometrik mensyaratkan $0 < p \leq 1$ dan model Normal mensyaratkan $\sigma^2 > 0$; gunakan reparameterisasi yang sah, fungsi objektif berpelindung, atau optimisasi berbatas. Kode konvergensi 0 hanya menyatakan penghentian algoritme, bukan bukti optimum global atau keamanan domain.


7.3.1 Kasus Berparameter Tunggal

Kita akan menelusuri hampiran numerik melalui kasus ketika data berasal dari distribusi Geometrik berikut:

```
## assume that x~geom(p)
x=c(4,11,2,5,1,0,11,9,0,0,1,2,17,9,6,
    0,0,12,3,1,3,0,0,1,27,0,2,0,24,9,
    4,0,0,8,13,8,6,1,4,9,12,11,2,5,3)
x
```

```
[1] 4 11 2 5 1 0 11 9 0 0 1 2 17 9 6 0 0 12 3 1 3 0 0 1 27
[26] 0 2 0 24 9 4 0 0 8 13 8 6 1 4 9 12 11 2 5 3
```

```
hist(x)
```



Gambar 7.1

Untuk mencari MLE secara numerik, pertama-tama kita menulis fungsi untuk mengevaluasi negatif fungsi log-kemungkinan, seperti yang telah dilakukan sebelumnya.

```
nll.geom=function(p,x){
  -sum(log(dgeom(x,p)))
}
```

Kemudian, gunakan `optim` untuk menghampiri MLE secara numerik:

```
out=optim(0.5,nll.geom,x=x)
out
```

```
$par
[1] 0.1546875
```

```
$value
[1] 125.3257

$counts
function gradient
      28      NA

$convergence
[1] 0

$message
NULL
```

Jika kita menjalankan `optim` yang sama, tetapi menyertakan opsi `hessian=TRUE`, maka `optim` akan menghampiri informasi teramati dan mengembalikannya dalam objek `optim` dengan nama `hessian`.

```
out=optim(0.5,nll.geom,x=x,hessian=TRUE)
out
```

```
$par
[1] 0.1546875

$value
[1] 125.3257

$counts
function gradient
      28      NA

$convergence
[1] 0

$message
NULL

$hessian
      [,1]
[1,] 2225.054
```

Objek `hessian` adalah hampiran informasi teramati pada titik optimum; dengan syarat keteraturan, besaran ini dapat dipakai sebagai hampiran plug-in untuk membentuk selang kepercayaan asimtotik 95% bagi parameter p dengan mengikuti rumus di atas:

```
## get the MLE
p.hat=out$par
p.hat
```

```
[1] 0.1546875
```

```
## get the Fisher Information
I=out$hessian
## get the 95% CI
p.hat-1.96*sqrt(1/I)
```

```
      [,1]
[1,] 0.1131361
```

```
p.hat+1.96*sqrt(1/I)
```

```
      [,1]
[1,] 0.1962389
```

Jadi, selang kepercayaan 95% berdasarkan MLE bagi parameter p adalah (0.113,0.196).

7.3.2 Kasus Multiparameter


Jika terdapat dua parameter atau lebih, optimisasi numerik dalam R serta hampiran numerik matriks informasi teramati $\mathbf{I}(\hat{\theta})$ juga dapat dilakukan dengan menggunakan `optim`. Untuk mengilustrasikannya, kita akan meninjau data yang dibangkitkan dari distribusi Normal. Kode berikut menyimulasikan data berdistribusi Normal dari

suatu distribusi dengan rata-rata -7 dan varians 16:

```
set.seed(1)
x=rnorm(100,mean=-7,sd=sqrt(16))
x
```

```
[1] -9.5058152 -6.2654267 -10.3425144 -0.6188768 -5.6819689 -10.2818735
[7] -5.0502838 -4.0467012 -4.6968746 -8.2215535 -0.9528753 -5.4406271
[13] -9.4849623 -15.8587995 -2.5002763 -7.1797344 -7.0647611 -3.2246552
[19] -3.7151152 -4.6243947 -3.3240905 -3.8714548 -6.7017401 -14.9574068
[25] -4.5206970 -7.2245150 -7.6231820 -12.8830095 -8.9126002 -5.3282338
[31] -1.5652818 -7.4111509 -5.4493136 -7.2152202 -12.5082382 -8.6599783
[37] -8.5771598 -7.2372536 -2.5998985 -3.9472970 -7.6580944 -8.0134467
[43] -4.2121465 -4.7733472 -9.7550228 -9.8299806 -5.5416722 -3.9258683
[49] -7.4493848 -3.4755691 -5.4075765 -9.4481056 -5.6355212 -11.5174524
[55] -1.2679052 0.9215996 -8.4688859 -11.1765385 -4.7211215 -7.5402184
[61] 2.6064710 -7.1569600 -4.2410426 -6.8879914 -9.9730928 -6.2448308
[67] -14.2198345 -1.1377806 -6.3869866 1.6904467 -5.0979619 -9.8397857
[73] -4.5570946 -10.7363905 -12.0145336 -5.8342151 -8.7731675 -6.9955786
[79] -6.7026347 -9.3580838 -9.2746749 -7.5407145 -2.2876520 -13.0942672
[85] -4.6242152 -5.6681985 -2.7476007 -8.2167357 -5.5199248 -5.9316048
[91] -9.1700801 -2.1685288 -2.3583895 -4.1991454 -0.6526662 -4.7660543
[97] -12.1063688 -9.2930617 -11.8984505 -8.8936025
```

```
hist(x)
```



Gambar 7.2

Untuk mencari MLE, pertama-tama kita menulis fungsi untuk mengevaluasi negatif fungsi log-kemungkinan:

```
nll.norm=function(theta,x){
  mn=theta[1]
  vr=theta[2]
  -sum(log(dnorm(x,mean=mn,sd=sqrt(vr))))
}
```

Kemudian, jalankan `optim` untuk mencari MLE. Kita menyertakan opsi `hessian=TRUE` untuk meminta `optim` menghampiri matriks informasi teramati pada titik optimum.

```
out=optim(c(-11,1),nll.norm,x=x,hessian=TRUE)
out
```

```
$par
[1] -6.564774 12.773473

$value
[1] 269.2845

$counts
function gradient
      61         NA

$convergence
[1] 0

$message
NULL

$hessian
      [,1]      [,2]
[1,] 7.8287246339 0.0001983622
[2,] 0.0001983622 0.3067152221
```

Nilai-nilai dugaan MLE bagi $\theta = (\mu, \sigma^2)$ adalah:

```
theta.hat=out$par
theta.hat
```

```
[1] -6.564774 12.773473
```

jadi, nilai dugaan MLE bagi μ adalah -6.564774 dan nilai dugaan MLE bagi σ^2 adalah 12.773473.

Untuk mencari selang kepercayaan bagi setiap parameter tersebut, kita menggunakan invers matriks informasi teramati $\mathbf{I}$, lalu mengambil akar kuadrat elemen-elemen diagonalnya. Karena nilai-nilai ini sering disebut “galat baku”, kita akan menuliskannya sebagai `se` dalam kode R:

```
## standard errors = sqrt(I.inv[p,p])
I=out$hessian
se=sqrt(diag(solve(I)))
se
```

```
[1] 0.357400 1.805645
```

Hasilnya adalah sebuah vektor. Untuk entri bernomor k , nilainya adalah $\sqrt{\mathbf{I}^{-1}(\hat{\theta}_{ML})[k,k]}$. Galat baku yang berkaitan dengan μ adalah nilai pertama dalam vektor tersebut (`se[1]`) dan galat baku yang berkaitan dengan σ^2 adalah nilai kedua. Urutannya sama dengan urutan nilai dugaan parameter dalam `out$par`. Dengan demikian, kita dapat membentuk selang kepercayaan 95% bagi μ

```
## CI for mu
c(theta.hat[1]-1.96*se[1] , theta.hat[1]+1.96*se[1])
```

```
[1] -7.265278 -5.864270
```

dan bagi σ^2 :

```
## CI for sigma^2
c(theta.hat[2]-1.96*se[2] , theta.hat[2]+1.96*se[2])
```

```
[1] 9.234409 16.312537
```

dan juga **secara asimtotik berdistribusi Normal**:

$$\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{I(\theta)}\right)$$

Di sini, $I(\theta)$ adalah **informasi Fisher per pengamatan**, yang mengukur banyaknya informasi yang diberikan data tentang parameter. Informasi tersebut didefinisikan sebagai:

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(X | \theta) \right)^2 \right]$$

Hasil ini penting karena memungkinkan kita menggunakan metode berbasis distribusi Normal, seperti selang kepercayaan dan pengujian hipotesis, bahkan dalam model yang kompleks. Intinya: MLE bukan hanya berguna, tetapi juga memiliki jaminan teoretis yang kuat seiring bertambahnya ukuran sampel.

7.4 Ringkasan

Dalam pelajaran ini, kita memperoleh keterampilan praktis untuk menganalisis data menggunakan pendugaan kemungkinan maksimum (MLE) dan membentuk selang kepercayaan yang andal. Kini kita dapat menghitung MLE bagi parameter pada distribusi seperti Bernoulli, Eksponensial, dan Normal, serta menggunakan informasi Fisher untuk mengukur ketidakpastian dan membentuk selang kepercayaan asimtotik. Dengan menggunakan `optim` dalam R, kita dapat memperoleh nilai dugaan MLE dan selang secara numerik untuk model yang kompleks, seperti distribusi Geometrik atau Normal, bahkan ketika penyelesaian analitik sulit diperoleh.

Ringkasan sumber menyatakan bahwa bootstrap parametrik dan nonparametrik telah dipelajari melalui data `t` dan Pareto, tetapi materi tersebut tidak terdapat dalam isi Pelajaran 07 yang tersedia.

Topik bootstrap, metode Delta, serta contoh `t` dan Pareto merupakan materi lanjutan, bukan keterampilan yang telah diajarkan dalam pelajaran ini.

1. [Pelajaran](#)
2. [8 Distribusi Asimtotik MLE \(Bagian II\)](#)

8 Distribusi Asimtotik MLE (Bagian II)

MLE

Selang Kepercayaan Asimtotik

Hampiran Numerik

Bootstrap

Gambaran Umum

Pelajaran ini memperkenalkan metode bootstrap—baik parametrik maupun nonparametrik—untuk menduga selang kepercayaan ketika solusi analitik tidak memungkinkan. Selain itu, Anda akan mempelajari metode delta dan pendekatan bootstrap untuk inferensi terhadap transformasi parameter. Melalui contoh yang melibatkan distribusi Bernoulli, Eksponensial, Normal, Geometrik, t , dan Pareto, Anda akan memperoleh keterampilan praktis dalam menerapkan teknik-teknik ini sebagai bekal untuk mempelajari inferensi statistik tingkat lanjut.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Secara analitik, menentukan selang kepercayaan asimtotik untuk transformasi parameter yang diduga dengan pendugaan kemungkinan maksimum (“metode delta”);
2. Menghampiri secara numerik selang kepercayaan asimtotik untuk MLE serta untuk transformasi parameter yang diduga dengan MLE menggunakan “optim” dan komputasi dalam R; dan
3. Memperoleh secara numerik selang kepercayaan bootstrap untuk MLE serta untuk transformasi parameter yang diduga dengan MLE.

8.1 Selang Kepercayaan Bootstrap

Selang kepercayaan yang dibentuk di atas bergantung pada pengetahuan kita tentang distribusi hampiran bagi nilai dugaan $\hat{\theta}$ dari parameter θ . Di atas kita menggunakan hampiran Normal (Gaussian) asimtotik untuk setiap MLE, tetapi ada cara lain untuk memperoleh distribusi hampiran bagi nilai dugaan $\hat{\theta}$.

Salah satu pendekatan yang sangat umum untuk memperoleh distribusi sampling hampiran dari suatu penduga adalah bootstrap. Bootstrap mengandalkan sampel acak dari suatu distribusi hampiran, bukan distribusi tertentu yang diketahui secara eksplisit. Keuntungan mengandalkan sampel adalah bahwa kita TIDAK perlu benar-benar mengetahui distribusi yang menjadi sumber sampel; kita hanya perlu dapat mengambil sampel dari distribusi tersebut!

Tujuan setiap bootstrap adalah membangun metode untuk mengambil sampel dari distribusi penduga. Bootstrap biasanya melakukannya dengan (1) menghampiri distribusi data, lalu (2) menyimulasikan banyak himpunan data dari distribusi tersebut. Setiap himpunan data simulasi itu kira-kira berdistribusi sama seperti data sebenarnya dan dapat digunakan untuk memperoleh nilai dugaan parameter yang diminati. Dengan demikian, kita memperoleh (3) banyak nilai dugaan parameter, masing-masing merupakan realisasi dari distribusi sampling hampiran bagi penduga tersebut. Kita tidak mengetahui distribusi nilai-nilai dugaan ini, tetapi memiliki banyak sampel darinya, sehingga kita dapat (4) menghampiri selang kepercayaan atau besaran lain dengan menggunakan hampiran berbasis sampel.

Dengan kata lain, langkah-langkah bootstrap adalah:

(1)-(2): Simulasikan M himpunan data, masing-masing berukuran n dari distribusi hampiran data.

(3): Hitung $\hat{\theta}^{(m)}$ dari setiap himpunan data, $m = 1, \dots, M$.


(4): Dengan menggunakan nilai-nilai dugaan parameter dari langkah (3), peroleh selang kepercayaan hampiran.

Pada bagian berikutnya, kami menunjukkan sebuah contoh.

8.1.1 Selang Kepercayaan Normal Asimtotik untuk Data Berdistribusi t

Sebagai ilustrasi, perhatikan data berikut dari distribusi t. Di sini kita akan menyimulasikan data:

```
y=c(-0.71,-1.30,-0.13,-2.03, 1.62, 2.38, 0.48, 0.51,-0.69,  
-2.32,-2.02,1.23,-0.25,0.76,0.65,-0.08,-1.20,0.99,  
2.58,0.73,-0.09,-0.03,0.56,-1.44,0.13)  
hist(y)
```



Gbr 8.1. Histogram 25 nilai y berdistribusi t , dengan sumbu mendatar y dari sekitar -3 hingga 3 dan sumbu tegak frekuensi; sebagian besar nilai berada antara -1 dan 1 , dengan beberapa nilai di kedua ekor.

Data ini saling bebas dan berasal dari $y_i \sim t(4)$, yaitu distribusi t dengan parameter derajat kebebasan sebesar 4. Jika kita tidak mengetahui nilai sebenarnya dari parameter derajat kebebasan (df), mula-mula kita dapat mencoba mencari nilai dugaan kemungkinan maksimumnya secara langsung. Namun, PDF distribusi t tidak menghasilkan MLE yang dapat diselesaikan secara analitik. Kita dapat menemukannya dari data dengan pendugaan kemungkinan maksimum numerik. Inferensi numerik di R dapat dilakukan dengan menulis fungsi negatif log-kemungkinan, lalu mengoptimisasikannya menggunakan `optim`.

```
## fungsi negatif log-kemungkinan dengan df dibatasi positif
nll.t=function(df,y){
  if(length(df)!=1L || !is.finite(df) || df<=0) return(Inf)
  value=-sum(dt(y,df=df,log=TRUE))
  if(is.finite(value)) value else Inf
}
## MLE numerik terbatas; simpan dan periksa diagnostik pengoptimal
out=optim(4,fn=nll.t,y=y,method="L-BFGS-B",
  lower=sqrt(.Machine$double.eps),hessian=TRUE)
if(out$convergence!=0L || !is.finite(out$value) ||
  any(!is.finite(out$par))) stop("Pendugaan MLE t gagal")
df.hat=unname(out$par)
df.hat
```

```
[1] 6.63125
```

Terlihat bahwa MLE kita untuk df adalah $\hat{df} = 6.63125$.

Selanjutnya, kita dapat membentuk selang kepercayaan dengan menggunakan hampiran Normal asimtotik untuk MLE sebagai berikut:

```
## informasi teramati: Hessian negatif log-kemungkinan pada nilai dugaan
J.n=drop(out$hessian)
if(length(J.n)!=1L || !is.finite(J.n) || J.n<=0)
  stop("Informasi teramati tidak positif dan berhingga")
## selang Wald asimtotik dengan informasi teramati plug-in
c(df.hat-1.96*sqrt(1/J.n),df.hat+1.96*sqrt(1/J.n))
```

```
[1] -6.6074 19.8699
```

Perhatikan bahwa selang kepercayaan ini cukup lebar dan bahkan memuat nilai negatif, yang mustahil bagi parameter derajat kebebasan dalam distribusi t!

Selang kepercayaan ini mengandalkan hampiran distribusi Normal yang diketahui menjadi hampiran akurat ketika ukuran sampel n menuju tak hingga. Namun, untuk setiap ukuran sampel tetap ($n = 25$ dalam contoh ini), kita tidak mengetahui seberapa baik hampiran tersebut. Karena himpunan dukungan distribusi Normal adalah seluruh garis bilangan real, nilai negatif wajar muncul dalam distribusi hampiran itu. Karena parameter df harus positif, kita mengetahui bahwa distribusi hampiran ini mungkin kurang sesuai untuk situasi sekarang.

Pada bagian berikutnya, kami menyajikan cara lain untuk membentuk selang kepercayaan hampiran menggunakan sampel bootstrap. Kita akan membahas bootstrap parametrik dan bootstrap nonparametrik.

8.1.2 Bootstrap Parametrik

Jenis bootstrap pertama yang akan kita pelajari adalah **bootstrap parametrik**. Dalam setiap metode bootstrap, kita memerlukan cara untuk menyimulasikan data dari hampiran terhadap distribusi yang menghasilkan data tersebut.

Dalam bootstrap parametrik, pertama-tama kita menduga parameter model data, lalu menggunakan nilai dugaan parameter itu sebagai parameter dalam model data untuk menyimulasikan data.

Misalkan $x_i \sim f_X(x_i|\theta)$, $i = 1, \dots, n$, merupakan titik-titik data yang saling bebas dan diasumsikan berasal dari distribusi $f_X(x|\theta)$ yang bergantung pada parameter tak diketahui θ .

Perhatikan!

θ berpotensi terdiri atas beberapa parameter.

Algoritme **bootstrap parametrik** adalah sebagai berikut:

1. Peroleh Nilai Dugaan $\hat{\theta}$

Dengan menggunakan data $\{x_1, x_2, \dots, x_n\}$, dugalah parameter tersebut dengan penduga

$$\hat{\theta} = h(\{x_1, x_2, \dots, x_n\}).$$

Pendugaan ini dapat dilakukan dengan MLE analitik, MLE numerik, atau bahkan pendekatan lain seperti metode momen.

2. Simulasikan Sampel Bootstrap

Dengan menggunakan nilai dugaan parameter $\hat{\theta}$ dari langkah 1, simulasikan M himpunan data yang saling bebas.

Setiap himpunan data berukuran sama, yaitu n seperti data asli, dan masing-masing berasal dari $x_i^{(m)} \sim f_X(x|\hat{\theta})$.

Perhatikan!

kami menggunakan superskrip “ (m) ” untuk menandai himpunan data urutan m . Ini menghasilkan M himpunan data simulasi yang berbeda, masing-masing berisi n nilai data simulasi:

$$\begin{aligned} &\{x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}\} \\ &\{x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)}\} \\ &\vdots \\ &\{x_1^{(M)}, x_2^{(M)}, \dots, x_n^{(M)}\} \end{aligned}$$

3. Peroleh Nilai Dugaan $\{\hat{\theta}^{(m)}\}_{m=1}^M$ dengan Data Bootstrap

Sekarang gunakan masing-masing dari M himpunan data tersebut untuk memperoleh nilai dugaan bagi θ , dengan metode yang sama seperti pada langkah 1.

Hasilnya adalah M nilai dugaan parameter yang berbeda: $\{\hat{\theta}^{(1)}, \hat{\theta}^{(2)}, \dots, \hat{\theta}^{(M)}\}$, masing-masing berasal dari himpunan data simulasi yang berbeda

$$\begin{aligned} &\{x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)}\} \rightarrow \hat{\theta}^{(1)} \\ &\{x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)}\} \rightarrow \hat{\theta}^{(2)} \\ &\vdots \\ &\{x_1^{(M)}, x_2^{(M)}, \dots, x_n^{(M)}\} \rightarrow \hat{\theta}^{(M)} \end{aligned}$$

Kumpulan M nilai dugaan parameter tersebut kira-kira berdistribusi seperti sampel-sampel dari distribusi nilai dugaan kita $\hat{\theta}$; hampiran itu timbul karena kita menyimulasikan data dari $f_X(x|\hat{\theta})$ —distribusi pembangkit data dengan mengasumsikan bahwa parameter sebenarnya sama dengan nilai dugaan kita $\hat{\theta}$, bukan dari distribusi pembangkit yang sebenarnya $f_X(x|\theta)$.

4. Inferensi terhadap $\hat{\theta}$

Selanjutnya, kumpulan nilai dugaan parameter ini dapat digunakan untuk menghampiri secara numerik sifat-sifat distribusi nilai dugaan kita $\hat{\theta}$.

Sebagai contoh, jika kita tertarik pada selang kepercayaan 95% untuk θ , kita dapat menghampirinya dengan selang probabilitas 95% dari distribusi sampling ini, yakni dengan mencari kuantil 0,025 dan 0,975 dari sampel-sampel $\{\hat{\theta}^{(1)}, \hat{\theta}^{(2)}, \dots, \hat{\theta}^{(M)}\}$.

$$\text{SK 95\% untuk } \theta \approx \left(\hat{q}_{.025}\{\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(M)}\}, \hat{q}_{.975}\{\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(M)}\} \right)$$

Untuk menghampiri kuantil 0,025 dan 0,975 dengan baik, kita memerlukan banyak M sampel bootstrap.

Selang Kepercayaan Bootstrap Parametrik untuk Data Berdistribusi t

Sebagai ilustrasi pendekatan ini, kita akan membentuk selang kepercayaan bootstrap 95% untuk df dari contoh data berdistribusi t kita. Agar jelas, kita akan menyajikan kembali data dan modelnya. Datanya adalah sebagai berikut:

```
x=c(-0.71,-1.30,-0.13,-2.03, 1.62, 2.38, 0.48, 0.51,-0.69,  
-2.32,-2.02,1.23,-0.25,0.76,0.65,-0.08,-1.20,0.99,  
2.58,0.73,-0.09,-0.03,0.56,-1.44,0.13)
```

dan kita mengasumsikan bahwa $x_i \sim t(df)$, dengan df merupakan parameter tak diketahui yang akan diduga, yaitu θ .

Mengikuti empat langkah di atas:

1. Peroleh Nilai Dugaan $\hat{\theta}$

Dengan menggunakan data $\{x_1, x_2, \dots, x_n\}$, kita memperoleh nilai dugaan $\hat{\theta}$ dengan pendugaan kemungkinan maksimum secara numerik.

```
## fungsi negatif log-kemungkinan dengan df dibatasi positif  
nll.t=function(df,y){  
  if(length(df)!=1L || !is.finite(df) || df<=0) return(Inf)  
  value=-sum(dt(y,df=df,log=TRUE))  
  if(is.finite(value)) value else Inf  
}  
## MLE numerik terbatas; simpan dan periksa diagnostik pengoptimal  
out=optim(4,fn=nll.t,y=x,method="L-BFGS-B",  
          lower=sqrt(.Machine$double.eps),hessian=TRUE)  
if(out$convergence!=0L || !is.finite(out$value) ||  
    any(!is.finite(out$par))) stop("Pendugaan MLE t gagal")  
df.hat=unname(out$par)  
df.hat
```

```
[1] 6.63125
```

Nilai dugaan untuk θ adalah $\hat{\theta} = 6.63125$.

2. Simulasikan Sampel Bootstrap

Sekarang kita menyimulasikan $M = 1000$ himpunan data yang saling bebas, masing-masing berukuran sama $n = 25$ seperti data asal, dan masing-masing berasal dari $x_i^{(m)} \sim f_X(x|\hat{\theta})$, dengan $\hat{\theta} = 6.63125$.

```
## protokol RNG eksplisit untuk eksekusi turunan  
RNGversion("4.3.0")  
RNGkind("Mersenne-Twister","Inversion","Rejection")  
set.seed(4150801)  
n=length(x)  
M=1000L  
sim.data=replicate(M,rt(n,df=df.hat),simplify=FALSE)
```

3. Duga $\{\hat{\theta}^{(m)}\}_{m=1}^M$ dengan Menggunakan Data Bootstrap

Sekarang gunakan masing-masing dari M himpunan data ini untuk memperoleh nilai dugaan bagi θ , dengan menggunakan metode yang sama seperti pada langkah 1.


```
## simpan nilai dugaan dan diagnostik untuk tepat M replikasi  
theta.hat.vals=rep(NA_real_,M)  
convergence=rep(NA_integer_,M)  
for(m in seq_len(M)){  
  out.sim=tryCatch(  
    optim(df.hat,nll.t,y=sim.data[[m]],method="L-BFGS-B",  
          lower=sqrt(.Machine$double.eps)),  
    error=function(e) NULL  
  )  
  if(is.null(out.sim)) next  
  convergence[m]=out.sim$convergence  
  if(out.sim$convergence==0L && is.finite(out.sim$value) &&  
      all(is.finite(out.sim$par))) theta.hat.vals[m]=out.sim$par  
}
```

```
failed=is.na(convergence) | convergence!=0L | !is.finite(theta.hat.vals)
if(any(failed)) stop(sprintf("%d pendugaan bootstrap gagal",sum(failed)))
sessionInfo()
```

Dengan demikian, kita memperoleh sebuah vektor berisi M nilai dugaan untuk θ , yang masing-masing dihasilkan dengan mencari MLE dari suatu himpunan data simulasi. Nilai-nilai ini disebut “nilai dugaan bootstrap” untuk $\hat{\theta}$.

Untuk memvisualisasikannya, berikut histogramnya:

```
hist(theta.hat.vals,main="Bootstrap samples",xlab="theta.hat",ylab="")
```



Gambar 8.2

4. Inferensi untuk $\hat{\theta}$

Sekarang kita dapat membentuk selang kepercayaan 95% dari nilai-nilai dugaan bootstrap ini dengan mencari kuantil empiris 0,025 dan 0,975-nya. Hal ini dapat dilakukan dengan menggunakan perintah `quantile` di R:

```
## 95% CI
quantile(theta.hat.vals,c(.025,.975))
```

```
2.5%      97.5%
2.612500e+00 1.342177e+07
```

Catatan reproduktibilitas: angka dan histogram di atas adalah cuplikan sumber hulu tanpa seed, versi RNG, atau rekaman lingkungan. Kode turunan menetapkan RNG R 4.3.0, seed 4150801, pemeriksaan kegagalan, dan `sessionInfo()`; cuplikan dipertahankan sebagai ilustrasi, bukan diklaim sebagai keluaran verifikasi protokol turunan. Teks interval diselaraskan dengan cuplikan yang tampil.

Oleh karena itu, hampiran selang kepercayaan bootstrap parametrik 95% untuk $\theta = \text{df}$ adalah $(2.612500, 1.342177 \times 10^7)$. Meskipun, tidak seperti selang kepercayaan sebelumnya, selang ini tidak memuat nilai negatif, lebarnya tetap sangat besar!

Mari kita pertimbangkan metode bootstrap lainnya.

8.1.3 Selang Kepercayaan Bootstrap Nonparametrik

Bootstrap parametrik yang diperkenalkan di atas menyimulasikan himpunan data baru dari distribusi yang (secara hampiran) sama dengan distribusi data teramati kita, dengan menggunakan model yang diasumsikan (distribusi t dalam contoh di atas) dan parameter yang diduga dari data teramati (MLE untuk df dalam contoh di atas).

Pendekatan alternatif untuk bootstrap adalah menyimulasikan himpunan data baru langsung dari data teramati melalui pengambilan sampel ulang (resampling). Pendekatan ini disebut **bootstrap nonparametrik**.

Penalaran di balik bootstrap nonparametrik adalah sebagai berikut. Jika kita telah mengamati data $x_i \sim f_X(x)$ yang saling bebas dan berdistribusi identik, maka informasi terbaik yang kita miliki tentang distribusi f_X sebenarnya adalah data itu sendiri. Kita dapat menghampiri satu pengamatan baru dari f_X hanya dengan memilih secara acak salah satu nilai teramati $x_1, x_2, \dots, x_n$. Hal ini disebut “pengambilan sampel dari **distribusi empiris data**”.

Distribusi empiris dari suatu himpunan data $x_1, x_2, \dots, x_n$ adalah distribusi diskret dengan himpunan dukungan berupa nilai-nilai unik dalam data $x_1, x_2, \dots, x_n$ dan PMF yang didefinisikan oleh

$$P_n(X = x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{x_i = x\}$$

Dengan demikian, distribusi empiris memberikan bobot $1/n$ kepada setiap pengamatan; suatu nilai yang berulang memperoleh massa sebesar frekuensi relatifnya dalam data.

Selang Kepercayaan Bootstrap Nonparametrik untuk Data Berdistribusi t

Sekarang kita membentuk selang kepercayaan 95% untuk parameter df dari data berdistribusi t kita dengan menggunakan bootstrap nonparametrik.

Seperti pada contoh data parametrik, kita akan menyatakan kembali model dan datanya. Datanya adalah sebagai berikut:

```
x=c(-0.71,-1.30,-0.13,-2.03, 1.62, 2.38, 0.48, 0.51,-0.69,
    -2.32,-2.02,1.23,-0.25,0.76,0.65,-0.08,-1.20,0.99,
    2.58,0.73,-0.09,-0.03,0.56,-1.44,0.13)
```

dan kita mengasumsikan bahwa $x_i \sim t(\text{df})$, dengan df merupakan parameter tak diketahui yang akan diduga, θ .

Dengan mengikuti empat langkah di atas:

1. Duga $\hat{\theta}$

Dengan menggunakan data $\{x_1, x_2, \dots, x_n\}$, kita memperoleh nilai dugaan $\hat{\theta}$ dengan pendugaan kemungkinan maksimum secara numerik.

```
## fungsi negatif log-kemungkinan dengan df dibatasi positif
nll.t=function(df,y){
  if(length(df)!=1L || !is.finite(df) || df<=0) return(Inf)
  value=-sum(dn(y,df=df,log=TRUE))
  if(is.finite(value)) value else Inf
}
## MLE numerik terbatas; simpan dan periksa diagnostik pengoptimal
out=optim(4,fn=nll.t,y=x,method="L-BFGS-B",
          lower=sqrt(.Machine$double.eps),hessian=TRUE)
if(out$convergence!=0L || !is.finite(out$value) ||
    any(!is.finite(out$par))) stop("Pendugaan MLE t gagal")
df.hat=unname(out$par)
df.hat
```

Sekali lagi, nilai dugaan kita untuk θ adalah $\hat{\theta} = 6.63125$.

2. Simulasikan Sampel Bootstrap

Sekarang kita menyimulasikan $M = 1000$ himpunan data yang saling bebas, masing-masing berukuran sama n seperti data asal, dan masing-masing berasal dari distribusi empiris. Kita dapat melakukannya dengan menggunakan perintah `sample` di R:

```
## protokol RNG eksplisit untuk eksekusi turunan
RNGversion("4.3.0")
RNGkind("Mersenne-Twister", "Inversion", "Rejection")
set.seed(4150802)
n=length(x)
M=1000L
sim.data=replicate(M,sample(x,size=n,replace=TRUE),simplify=FALSE)
```

3. Duga $\{\hat{\theta}^{(m)}\}_{m=1}^M$ dengan Menggunakan Data Bootstrap


Sekarang gunakan masing-masing dari M himpunan data ini untuk memperoleh nilai dugaan bagi θ , dengan menggunakan metode yang sama seperti pada langkah 1.

```
## simpan nilai dugaan dan diagnostik untuk tepat M replikasi
theta.hat.vals=rep(NA_real_,M)
convergence=rep(NA_integer_,M)
for(m in seq_len(M)){
  out.sim=tryCatch(
    optim(df.hat,nll.t,y=sim.data[[m]],method="L-BFGS-B",
      lower=sqrt(.Machine$double.eps)),
    error=function(e) NULL
  )
  if(is.null(out.sim)) next
  convergence[m]=out.sim$convergence
  if(out.sim$convergence==0L && is.finite(out.sim$value) &&
    all(is.finite(out.sim$par))) theta.hat.vals[m]=out.sim$par
}
failed=is.na(convergence) | convergence!=0L | !is.finite(theta.hat.vals)
if(any(failed)) stop(sprintf("%d pendugaan bootstrap gagal",sum(failed)))
sessionInfo()
```

Dengan demikian, kita memperoleh sebuah vektor berisi M nilai dugaan untuk θ , yang masing-masing dihasilkan dengan mencari MLE dari suatu himpunan data simulasi. Nilai-nilai ini disebut “nilai dugaan bootstrap” untuk $\hat{\theta}$.

Untuk memvisualisasikannya, berikut histogramnya:


```
hist(theta.hat.vals,main="Bootstrap samples (nonparametric bootstrap)",xlab="theta.hat",ylab="")
```



Gambar 8.3

4. Inferensi untuk $\hat{\theta}$

Sekarang kita dapat membentuk selang kepercayaan 95% dari nilai-nilai dugaan bootstrap nonparametrik ini dengan mencari kuantil empiris 0,025 dan 0,975-nya. Hal ini dapat dilakukan dengan menggunakan perintah `quantile` di R:

```
## 95% CI  
quantile(theta.hat.vals,c(.025,.975))
```

```
      2.5%      97.5%  
3.339766e+00 6.710887e+06
```

Catatan reproduktibilitas: angka dan histogram di atas adalah cuplikan sumber hulu tanpa seed, versi RNG, atau rekaman lingkungan. Kode turunan menetapkan RNG R 4.3.0, seed 4150802, pemeriksaan kegagalan, dan `sessionInfo()`; cuplikan dipertahankan sebagai ilustrasi, bukan diklaim sebagai keluaran verifikasi protokol turunan. Teks interval diselaraskan dengan cuplikan yang tampil.

Oleh karena itu, hampiran selang kepercayaan bootstrap nonparametrik 95% untuk $df = \theta$ adalah $(3.339766, 6.710887 \times 10^6)$. Selang ini tidak selebar selang parametrik, tetapi tetap sangat lebar!

8.1.4 Kode Templat untuk Selang Kepercayaan Bootstrap

Untuk mempermudah penerapan metode bootstrap, berikut seperangkat kode templat beserta beberapa komentar:

- [Bootstrap Parametrik](#)
- [Bootstrap Nonparametrik](#)

Pada kode di bawah ini, Anda perlu melakukan perubahan berikut: a. ubah baris data agar membaca data Anda; b. ubah fungsi `nll` agar menghitung negatif fungsi log-kemungkinan yang tepat untuk data dan model Anda; c. model. c. di dalam perulangan `for`, ubah kode `rexp` menjadi kode untuk menyimulasikan data dari model Anda, dengan parameter berupa MLE dari langkah (1); d. di dalam perulangan `for`, buat baris `opti` identik dengan baris `optim` Anda pada langkah (1), kecuali bahwa argumen data untuk pemanggilan `optim` dalam perulangan `for` haruslah `x=sim.data[[m]]`.

```
## baca data
x=c(1,2,3)

## (1) tentukan MLE; ganti ... dan batas dengan spesifikasi model
nll=function(theta,x){
  ## kode negatif log-kemungkinan model ditempatkan di sini
}
out=optim(...,nll,x=x,method="L-BFGS-B",lower=...,upper=...)
if(out$convergence!=0L || !is.finite(out$value) ||
  any(!is.finite(out$par))) stop("Pendugaan data asli gagal")
theta.hat=out$par
## siapkan bootstrap yang dapat direproduksi
RNGversion("4.3.0")
RNGkind("Mersenne-Twister","Inversion","Rejection")
set.seed(4150803)
M=1000L
n=length(x)
sim.data=vector("list",M)
theta.hat.vals=rep(NA_real_,M)
convergence=rep(NA_integer_,M)

for(m in seq_len(M)){
  ## (2) ganti rexp(...) dengan pembangkitan dari model yang dipasang
  sim.data[[m]]=rexp(n,theta.hat)
  ## (3) pasang model yang sama pada data bootstrap
  out.sim=tryCatch(
    optim(...,nll,x=sim.data[[m]],method="L-BFGS-B",lower=...,upper=...),
    error=function(e) NULL
  )
  if(is.null(out.sim)) next
  convergence[m]=out.sim$convergence
  if(out.sim$convergence==0L && is.finite(out.sim$value) &&
    all(is.finite(out.sim$par))) theta.hat.vals[m]=out.sim$par
}
failed=is.na(convergence) | convergence!=0L | !is.finite(theta.hat.vals)
if(any(failed)) stop(sprintf("%d pendugaan bootstrap gagal",sum(failed)))
quantile(theta.hat.vals,c(.025,.975))
sessionInfo()
```

Pada kode di bawah ini, Anda perlu melakukan perubahan berikut: a. ubah baris data agar membaca data Anda; b. ubah fungsi `nll` agar menghitung negatif fungsi log-kemungkinan yang tepat untuk data dan model Anda; c. model. c. di dalam perulangan `for`, buat baris `opti` identik dengan baris `optim` pada langkah (1), kecuali bahwa argumen data untuk pemanggilan `optim` dalam perulangan `for` haruslah `x=sim.data[[m]]`.

```

## baca data
x=c(1,2,3)

## (1) tentukan MLE; ganti ... dan batas dengan spesifikasi model
nll=function(theta,x){
  ## kode negatif log-kemungkinan model ditempatkan di sini
}
out=optim(...,nll,x=x,method="L-BFGS-B",lower=...,upper=...)
if(out$convergence!=0L || !is.finite(out$value) ||
  any(!is.finite(out$par))) stop("Pendugaan data asli gagal")
theta.hat=out$par
## siapkan bootstrap yang dapat direproduksi
RNGversion("4.3.0")
RNGkind("Mersenne-Twister","Inversion","Rejection")
set.seed(4150804)
M=1000L
n=length(x)
sim.data=vector("list",M)
theta.hat.vals=rep(NA_real_,M)
convergence=rep(NA_integer_,M)

for(m in seq_len(M)){
  ## (2) resampel dari distribusi empiris
  sim.data[[m]]=sample(x,size=n,replace=TRUE)
  ## (3) pasang model yang sama pada data bootstrap
  out.sim=tryCatch(
    optim(...,nll,x=sim.data[[m]],method="L-BFGS-B",lower=...,upper=...),
    error=function(e) NULL
  )
  if(is.null(out.sim)) next
  convergence[m]=out.sim$convergence
  if(out.sim$convergence==0L && is.finite(out.sim$value) &&
    all(is.finite(out.sim$par))) theta.hat.vals[m]=out.sim$par
}
failed=is.na(convergence) | convergence!=0L | !is.finite(theta.hat.vals)
if(any(failed)) stop(sprintf("%d pendugaan bootstrap gagal",sum(failed)))
quantile(theta.hat.vals,c(.025,.975))
sessionInfo()


```

8.1.5 Contoh Dua Parameter dengan Data Berdistribusi Pareto

Contoh 8.1 Pertimbangkan data berikut, yang kita asumsikan berasal dari distribusi Pareto

```
## load the library needed for "dpareto"
library(EnvStats)
## read in data
x=c(5.92, 10.87, 6.50, 14.62, 20.49, 5.12, 7.28, 15.24,
    7.47, 6.78, 24.07, 6.76, 8.81, 7.65, 5.28, 15.80,
    5.76, 5.11, 6.10, 23.44, 15.04, 9.02, 8.34, 66.05,
    8.52, 9.26, 7.40, 7.85, 5.93, 5.41, 26.00, 16.00,
    8.99, 11.06, 5.06, 6.92, 10.17, 5.65, 6.06, 5.70)
hist(x)
```

Histogram of x



Gbr 8.4

Misalkan $x_i \sim \text{Pareto}(L, a)$ untuk $1, \dots, n$, dengan a merupakan parameter “bentuk” dan L merupakan parameter “lokasi” yang menjadi nilai minimum yang mungkin bagi x_i . Dengan kata lain, himpunan dukungan distribusi ini adalah $x_i \in [L, \infty)$.

Jika kita mengasumsikan bahwa nilai sebenarnya dari kedua parameter tidak diketahui, kita dapat menduga keduanya dengan pendugaan kemungkinan maksimum secara numerik, lalu menentukan selang kepercayaan 95% bagi keduanya menggunakan bootstrap.

Di bawah ini, kita akan menggunakan bootstrap nonparametrik dan memodifikasi kode templat dari bagian sebelumnya. Perubahan utamanya ialah membuat kode tersebut dapat menangani dua parameter, bukan hanya satu.

```
## MLE analitik Pareto-I; domain dan kegagalan diperiksa eksplisit
pareto.mle=function(z){
  if(!length(z) || any(!is.finite(z)) || any(z<=0))
    stop("Data Pareto harus positif dan berhingga")
  L.hat=min(z)
  denominator=sum(log(z/L.hat))
  if(!is.finite(denominator) || denominator<=0)
    stop("Pendugaan bentuk Pareto gagal")
  a.hat=length(z)/denominator
  if(!is.finite(a.hat) || a.hat<=0) stop("Pendugaan bentuk Pareto gagal")
  c(L=L.hat,a=a.hat)
```

```

}
theta.hat=pareto.mle(x)
L.hat=unname(theta.hat["L"])
a.hat=unname(theta.hat["a"])

RNGversion("4.3.0")
RNGkind("Mersenne-Twister", "Inversion", "Rejection")
set.seed(4150805)
M=1000L
n=length(x)
L.hat.vals=rep(NA_real_,M)
a.hat.vals=rep(NA_real_,M)
for(m in seq_len(M)){
  sim.data=sample(x,size=n,replace=TRUE)
  fit=tryCatch(pareto.mle(sim.data),error=function(e) NULL)
  if(is.null(fit)) next
  L.hat.vals[m]=fit["L"]
  a.hat.vals[m]=fit["a"]
}
failed=!is.finite(L.hat.vals) | !is.finite(a.hat.vals)
if(any(failed)) stop(sprintf("%d pendugaan bootstrap gagal",sum(failed)))

## Hanya kontraexample: kuantil ini bukan selang kepercayaan sah untuk L
quantile(L.hat.vals,c(.025,.975))
sessionInfo()

```

```

2.5% 97.5%
5.06 5.28

```

```

## (4) find a 95% CI for a using the bootstrap samples
quantile(a.hat.vals,c(.025,.975))

```

```

2.5% 97.5%
1.277910 2.270643

```

Catatan reproduktibilitas: keluaran Pareto ini adalah cuplikan sumber hulu tanpa keadaan RNG. Kode turunan menetapkan RNG R 4.3.0, seed 4150805, MLE analitik dengan pemeriksaan domain, dan sessionInfo(); cuplikan tidak diklaim sebagai keluaran verifikasi protokol turunan. Angka bentuk pada teks diselaraskan dengan snapshot, sedangkan kuantil lokasi dipertahankan hanya sebagai kontracontoh.

Kuantil persentil bootstrap nonparametrik bagi parameter lokasi, L , adalah (5.06, 5.28); bagi lokasi Pareto angka ini adalah kontracontoh kegagalan, bukan selang kepercayaan 95%. Kuantil persentil bootstrap nonparametrik bagi parameter bentuk, a , adalah (1.277910, 2.270643), sesuai dengan keluaran tetap yang ditampilkan.

Koreksi inferensi titik ujung: (5.06, 5.28) bukan selang kepercayaan 95% yang sah bagi L . Setiap minimum resampel sedikitnya sebesar minimum teramati 5.06, sedangkan pada model Pareto kontinu minimum sampel melebihi L dengan peluang satu. Karena itu, selang persentil ini mengecualikan L hampir pasti dan dipertahankan hanya sebagai kontracontoh; klaim afirmatif memerlukan metode inferensi titik ujung yang valid.

8.2 Inferensi terhadap Transformasi Parameter

Salah satu situasi yang umum ialah kita memiliki data $x_1, x_2, \dots, x_n$ dari model $x_i \sim f_X(x|\theta)$ dengan satu atau beberapa parameter θ , yang kita duga dengan pendugaan kemungkinan maksimum atau metode lain.

Bagaimana jika kita ingin melakukan inferensi terhadap transformasi parameter $\tau = g(\theta)$?

Ada beberapa pendekatan yang dapat digunakan, baik analitik maupun numerik. Pertama, kita menyajikan metode Delta, lalu pendekatan bootstrap.

8.2.1 Metode Delta

Jika kita menduga parameter θ dengan pendugaan kemungkinan maksimum, maka—di bawah konsistensi, identifiabilitas, parameter benar yang interior, diferensiabilitas, pertukaran turunan dan integral yang sah, serta informasi tak singular—distribusi limit MLE $\hat{\theta}$ adalah

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I_1(\theta_0)^{-1})$$

dengan $I_n(\theta)$ merupakan informasi Fisher harapan untuk sampel, yang didefinisikan sebagai

$$I_n(\theta) = -E_{\theta}[\ell''_n(\theta; X)]$$

dengan $\ell(\theta) = \log(L(\theta))$ dan nilai harapannya diambil terhadap semua $x_1, x_2, \dots, x_n$.

Syarat koreksi: hasil limit ini memerlukan model terdominasi dan dapat diidentifikasi, parameter benar yang interior, konsistensi, diferensiabilitas dan pertukaran integral-turunan yang sah, serta informasi Fisher yang positif dan taksingular. I_1 adalah informasi harapan per pengamatan; J_n pada nilai dugaan hanya merupakan besaran plug-in untuk galat baku, bukan varians acak dalam hukum limit.

Jika $g(\theta)$ terdiferensialkan pada parameter benar—tanpa perlu dapat dibalik—maka pendekatan umum untuk inferensi adalah metode delta. Metode ini memakai distribusi limit Gaussian MLE untuk memperoleh hampiran bagi distribusi penduga parameter yang ditransformasi $\hat{\tau} = g(\hat{\theta})$. Ketika $n \rightarrow \infty$,

$$\sqrt{n}\{g(\hat{\theta}_n) - g(\theta_0)\} \xrightarrow{d} N(0, [g'(\theta_0)]^2 I_1(\theta_0)^{-1})$$

dan dengan demikian, selang kepercayaan asimtotik hampiran 95% bagi parameter yang ditransformasi $\tau = g(\theta)$ adalah

$$g(\hat{\theta}_n) \pm 1.96 \frac{|g'(\hat{\theta}_n)|}{\sqrt{J_n(\hat{\theta}_n)}}$$

Metode delta orde pertama hanya memerlukan g terdiferensialkan pada parameter benar. Turunan dalam varians limit dievaluasi pada nilai benar; turunan pada nilai dugaan dipakai hanya sebagai plug-in. Jika turunannya nol, limit orde pertama degenerat dan metode orde lebih tinggi mungkin diperlukan.

8.2.2 Bootstrap dan Transformasi

Ketika bootstrap digunakan untuk mengambil sampel dari distribusi penarikan sampel bagi nilai dugaan parameter, hasilnya berupa sejumlah besar nilai, yaitu M nilai dugaan bootstrap $\hat{\theta}^{(1)}, \hat{\theta}^{(2)}, \dots, \hat{\theta}^{(M)}$. Jika kita ingin melakukan inferensi terhadap transformasi θ , kita cukup mentransformasi nilai-nilai dugaan ini secara langsung lalu melakukan inferensi terhadap sampel yang dihasilkan. Artinya, jika kita ingin melakukan inferensi terhadap $\tau = g(\theta)$, kita melakukan langkah-langkah berikut:

1. Dapatkan M nilai dugaan bootstrap sebagaimana ditunjukkan pada Bagian 8.1. Hasilnya adalah $\hat{\theta}^{(1)}, \hat{\theta}^{(2)}, \dots, \hat{\theta}^{(M)}$
2. Transformasikan masing-masing dari M nilai dugaan tersebut sehingga diperoleh $g(\hat{\theta}^{(1)}), g(\hat{\theta}^{(2)}), \dots, g(\hat{\theta}^{(M)})$
3. Kemudian, inferensi—misalnya menentukan selang kepercayaan—dapat dilakukan secara langsung pada nilai-nilai dugaan bootstrap yang telah ditransformasi ini. Sebagai contoh, selang kepercayaan bootstrap 95% bagi $\tau = g(\theta)$ ditentukan oleh kuantil .025 dan .975 dari $\{g(\hat{\theta}^{(1)}), g(\hat{\theta}^{(2)}), \dots, g(\hat{\theta}^{(M)})\}$

Bootstrap dan pendekatan berbasis sampel lainnya sering menjadi pilihan utama untuk melakukan inferensi terhadap transformasi parameter karena alasan berikut:

- Menerapkan transformasi pada setiap replikasi bootstrap tidak menuntut fungsi g dapat dibalik. Namun, keabsahan inferensi bootstrap tetap bergantung pada statistik, transformasi, skema resampling, desain sampel, dan syarat keteraturan; bootstrap parametrik juga mengasumsikan keluarga distribusi yang dipasang. Untuk metode delta orde pertama, g harus terdiferensialkan pada parameter benar.

- Jika model memiliki lebih dari satu parameter (yaitu $\theta = (\theta_1, \theta_2)$) dan transformasi g merupakan fungsi dari beberapa parameter: $\tau = g(\theta_1, \theta_2)$, pendekatan bootstrap sangat mudah diterapkan karena kita hanya perlu menerapkan fungsi g pada nilai dugaan bootstrap bagi θ_1 dan θ_2 .

8.3 Ringkasan

Dalam pelajaran ini, kita menerapkan teori sampel besar untuk melakukan inferensi tentang parameter yang diduga melalui kemungkinan maksimum. Kita mulai dengan membentuk **selang kepercayaan asimtotik** menggunakan hampiran Normal terhadap distribusi MLE. Selanjutnya, kita memperkenalkan **Metode Delta**, yang memperluas hampiran ini ke fungsi parameter. Terakhir, kita mempelajari dua pendekatan **bootstrap** — parametrik dan nonparametrik—untuk membentuk selang kepercayaan ketika metode analitik sulit diterapkan atau tidak andal.

Pokok-Pokok Utama

- **Selang Kepercayaan Asimtotik bagi MLE**

Ketika MLE $\hat{\theta}$ secara hampiran berdistribusi Normal:

$$\hat{\theta}_n \pm z_{\alpha/2} \frac{1}{\sqrt{J_n(\hat{\theta}_n)}}$$

dengan $J_n(\hat{\theta}_n)$ merupakan informasi teramati pada nilai dugaan; besaran ini berbeda dari informasi Fisher harapan.

- **Metode Delta**

Jika $\hat{\theta}$ secara hampiran berdistribusi Normal dan g merupakan fungsi mulus:

$$g(\hat{\theta}) \sim N\left(g(\theta), (g'(\theta))^2 \cdot \text{Var}(\hat{\theta})\right)$$

Hal ini memberikan cara untuk membentuk selang kepercayaan bagi $g(\theta)$.

- **Bootstrap Parametrik**

1. Duga $\hat{\theta}$ dari sampel asli.
2. Bangkitkan banyak sampel dari model dengan menggunakan $\hat{\theta}$.
3. Hitung MLE bagi setiap sampel bootstrap.
4. Gunakan distribusi nilai-nilai dugaan tersebut untuk membentuk selang.

- **Bootstrap Nonparametrik**

1. Lakukan pengambilan sampel ulang (dengan pengembalian) dari data asli.
2. Hitung statistik yang menjadi perhatian bagi setiap sampel bootstrap.
3. Gunakan distribusi empiris untuk membentuk selang kepercayaan.

Teknik-teknik ini memungkinkan kita mengukur ketidakpastian penduga, baik secara analitik maupun komputasional, bahkan ketika rumus baku tidak tersedia.

Kita juga mempelajari bootstrap parametrik dan nonparametrik untuk membentuk selang hampiran. Bootstrap parametrik mengasumsikan keluarga distribusi yang dipasang; bootstrap nonparametrik tetap memerlukan desain sampling dan syarat keteraturan yang sesuai. Karena itu, keandalannya harus dievaluasi untuk statistik dan masalah yang sedang dipelajari.

Koreksi cakupan: bootstrap bukan prosedur bebas-asumsi. Keabsahannya bergantung pada statistik, transformasi, skema resampling, desain sampel, dan keteraturan; bootstrap parametrik secara khusus mengasumsikan keluarga distribusi yang dipasang.

Teknik bootstrap berguna untuk data dunia nyata, tetapi sampel kecil, batas parameter, statistik takmulus, dan identifikasi lemah memerlukan pemeriksaan validitas khusus sebelum hasil dipakai untuk keputusan.

1. [Pelajaran](#)
2. [9 Uji Hipotesis \(Bagian I\)](#)

9 Uji Hipotesis (Bagian I)

Uji Hipotesis
Uji Proporsi
Uji Satu Rataan
Nilai-p

Gambaran Umum

Pada bagian-bagian sebelumnya, kita mengembangkan metode statistika, terutama berupa selang kepercayaan, untuk menjawab pertanyaan “berapakah nilai parameter θ ?” Pada bagian ini, kita akan mempelajari cara menjawab pertanyaan yang sedikit berbeda, yaitu “apakah nilai parameter θ adalah nilai tertentu?” Sebagai contoh, alih-alih mencoba menduga μ , rataan suhu tubuh orang dewasa, kita mungkin tertarik untuk menguji apakah μ , rataan suhu tubuh orang dewasa, benar-benar 37 derajat Celsius. Kita akan mencoba menjawab pertanyaan semacam itu dengan metode statistika yang dikenal sebagai pengujian hipotesis.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Menyusun uji hipotesis dengan menggunakan distribusi suatu penduga,
2. Menarik kesimpulan pengujian dengan pendekatan nilai-p,
3. Menarik kesimpulan pengujian dengan pendekatan nilai kritis,
4. Menafsirkan dengan jelas hasil uji hipotesis, dan
5. Menafsirkan dengan jelas jenis-jenis galat beserta peluangnya masing-masing.

9.1 Pengantar Uji Hipotesis

9.1.1 Istilah Dasar

Sebelum mempelajari teori statistika yang mendasari uji hipotesis, terlebih dahulu kita perlu memahami istilah-istilah dasarnya.

Langkah pertama dalam pengujian hipotesis adalah merumuskan dua hipotesis yang saling bersaing (dan saling lepas). Ini merupakan aspek terpenting dalam uji hipotesis. Jika hipotesisnya keliru, kesimpulan pengujiannya juga akan keliru.

Kedua hipotesis itu disebut hipotesis nol dan hipotesis alternatif.

Def. 9.1 (Hipotesis Nol) Istilah **hipotesis nol** biasanya dilambangkan dengan H_0 . Hipotesis nol menyatakan “status quo”. Hipotesis ini **dianggap benar** sampai ada bukti yang menunjukkan sebaliknya.

Def. 9.2 (Hipotesis Alternatif) Istilah **hipotesis alternatif** biasanya dilambangkan dengan H_a atau H_1 . Inilah pernyataan yang ingin kita simpulkan. Hipotesis ini juga disebut hipotesis penelitian.

Contoh 9.1 Seorang pria, Tn. Orangejuice, diadili atas tuduhan membunuh mantan istrinya. Ia bersalah atau tidak bersalah. Rumuskan hipotesis nol dan hipotesis alternatif untuk contoh ini.

Solusi

Dalam kerangka pengujian hipotesis, hipotesis yang diuji adalah: 1. Pria itu bersalah. 2. Pria itu tidak bersalah.

Mari kita rumuskan hipotesis nol dan hipotesis alternatif.

H_0 : Mr. Orangejuice is innocent

H_a : Mr. Orangejuice is guilty

Ingatlah bahwa kita menganggap hipotesis nol benar dan berusaha melihat apakah ada bukti yang menentangnya. Oleh karena itu, dalam contoh ini masuk akal untuk menganggap pria tersebut tidak bersalah, lalu menguji apakah ada bukti bahwa ia bersalah.

9.1.2 Logika Pengujian Hipotesis

Kita ingin mengetahui jawaban atas suatu pertanyaan penelitian. Kita menentukan hipotesis nol dan hipotesis alternatif. Sekarang saatnya mengambil keputusan.

Keputusannya akan berupa salah satu dari berikut ini...

1. Menolak hipotesis nol atau...
2. Gagal menolak hipotesis nol

Perhatikan!

Mengapa kita tidak boleh mengatakan “menerima hipotesis nol”? Alasannya, kita menganggap hipotesis nol benar dan berusaha melihat apakah ada bukti yang menentangnya. Oleh karena itu, kesimpulan harus dinyatakan dalam bentuk penolakan terhadap hipotesis nol.

Perhatikan tabel berikut. Tabel tersebut menunjukkan keputusan atau kesimpulan uji hipotesis dan “kenyataan”, atau kebenaran, yang tidak diketahui. Kita tidak mengetahui apakah hipotesis nol benar atau salah. Jika hipotesis nol salah dan kita menolaknya, kita mengambil keputusan yang benar. Jika hipotesis nol benar dan kita gagal menolaknya, kita juga mengambil keputusan yang benar.

Keputusan pengujian menurut keadaan hipotesis nol (tanpa label galat).

Keputusan	Kenyataan	
	H_0 benar	H_0 salah
Menolak H_0 (Menyimpulkan H_a)		Keputusan yang benar
Gagal Menolak H_0	Keputusan yang Benar	

Lalu, apa yang terjadi ketika kita tidak mengambil keputusan yang benar?

Dalam pengujian hipotesis, ada dua jenis galat yang dapat terjadi, yaitu galat tipe I dan galat tipe II. Jika kita menolak hipotesis nol ketika hipotesis tersebut benar, kita melakukan galat tipe I. Jika hipotesis nol salah dan kita gagal menolaknya, kita melakukan galat lain yang disebut galat tipe II.

Keputusan, keadaan hipotesis nol, serta galat tipe I dan tipe II.

Keputusan	Kenyataan	
	H_0 benar	H_0 salah
Menolak H_0 (Menyimpulkan H_a)	Galat Tipe I	Keputusan yang benar
Gagal Menolak H_0	Keputusan yang benar	Galat Tipe II

Jenis-Jenis Galat

- **Galat Tipe I:** Terjadi ketika kita menolak hipotesis nol padahal hipotesis nol benar.
- **Galat Tipe II:** Terjadi ketika kita gagal menolak hipotesis nol padahal hipotesis nol salah.

“Kenyataan”, atau kebenaran, mengenai hipotesis nol tidak diketahui. Karena itu, kita tidak mengetahui apakah kita telah mengambil keputusan yang benar atau melakukan galat. Namun, kita dapat mendefinisikan peluang kejadian-kejadian tersebut.

Def. 9.3 (α (“alfa”)) Peluang melakukan galat tipe I. Juga dikenal sebagai **tingkat signifikansi**.

Def. 9.4 (β (“beta”)) Peluang melakukan galat tipe II.

9.1.3 Kuasa Uji

Pada nilai parameter alternatif tertentu θ , kuasa uji adalah peluang menolak hipotesis nol ketika nilai θ itu benar, yaitu $\text{kuasa}(\theta) = 1 - \beta(\theta)$.

α dan $\beta(\theta)$ adalah peluang melakukan galat, sehingga kita menginginkan keduanya kecil. Untuk ukuran sampel, keluarga uji, dan nilai parameter alternatif yang tetap, penurunan salah satunya umumnya menaikkan yang lain. Namun, penambahan informasi—misalnya dengan memperbesar ukuran sampel—dapat menurunkan keduanya. Ketika α menurun, $\beta(\theta)$ meningkat.

Perhatikan!

Galat tipe I juga dapat dipandang sebagai kejadian ketika kita menolak hipotesis nol DENGAN SYARAT hipotesis nol benar. Dengan kata lain, galat tipe I adalah kejadian bersyarat dan α adalah peluang bersyarat. Gagasan yang sama berlaku untuk galat tipe II dan β .

Contoh 9.2 Seorang pria, Tn. Orangejuice, diadili atas tuduhan membunuh mantan istrinya. Ia bersalah atau tidak bersalah. Sebelumnya kita telah memperoleh bahwa...

H_0 : Mr. Orangejuice is innocent

H_a : Mr. Orangejuice is guilty

Tafsirkan galat tipe I, galat tipe II, α , dan β .

Solusi

Galat Tipe I:

Galat tipe I terjadi jika kita menolak H_0 ketika hipotesis tersebut benar. Dengan kata lain, ketika pria itu tidak bersalah tetapi dinyatakan bersalah.

Galat Tipe II:

Galat tipe II terjadi jika kita gagal menolak H_0 ketika hipotesis tersebut salah. Dengan kata lain, ketika pria itu bersalah tetapi dinyatakan tidak bersalah.

α :

peluang terjadinya galat tipe I, atau dengan kata lain, peluang bahwa Tn. Orangejuice tidak bersalah tetapi dinyatakan bersalah.

β :

peluang terjadinya galat tipe II, atau dengan kata lain, peluang bahwa Tn. Orangejuice bersalah tetapi dinyatakan tidak bersalah.

Seperti yang terlihat di sini, galat tipe I (memasukkan orang yang tidak bersalah ke penjara) merupakan galat yang lebih serius. Dari segi etika, memasukkan orang yang tidak bersalah ke penjara lebih serius daripada membiarkan orang yang bersalah bebas. Jadi, untuk memperkecil peluang galat tipe I, kita akan memilih tingkat signifikansi yang lebih kecil.

Cobalah!

Seorang pemeriksa harus memilih antara menyatakan bahwa sebuah bangunan aman atau menyatakan bahwa bangunan tersebut tidak aman. Ada dua hipotesis:

1. Bangunan tidak aman
2. Bangunan aman

Rumuskan hipotesis nol dan hipotesis alternatif. Tafsirkan galat tipe I dan galat tipe II.

Jawaban

Solusi

Keputusan uji keselamatan bangunan menurut keadaan sebenarnya.

	H_0 benar	H_0 salah
Menolak H_0 (Menyimpulkan H_a)	Menolak “Bangunan tidak aman” ketika bangunan itu aman. (<i>Galat Tipe I</i>)	Keputusan yang benar
Gagal Menolak H_0	Keputusan yang Benar	Gagal menolak “bangunan tidak aman” ketika bangunan itu tidak aman (<i>Galat Tipe II</i>)

Kuasa uji dan β merupakan komplemen satu sama lain. Oleh karena itu, keduanya berhubungan terbalik, yaitu ketika yang satu meningkat, yang lain menurun.

Masuk akal bagi kita untuk menetapkan H_0 dan H_a seperti di atas (yaitu, menganggap bangunan tidak aman sampai terbukti sebaliknya), karena jika kita menukar H_0 dan H_a (yaitu, jika H_0 menyatakan bahwa bangunan itu tidak aman) dan jika kita gagal menolak H_0 , kita tidak dapat begitu saja menyimpulkan bahwa bangunan itu aman (kita hanya dapat gagal menolak H_0 , kita tidak dapat menerima H_0).

9.1.4 Langkah-Langkah Pengujian Hipotesis

Dalam statistika, hipotesis adalah pernyataan tentang suatu parameter populasi, dan pernyataan ini biasanya direpresentasikan oleh nilai numerik tertentu. Dalam menguji hipotesis, kita menggunakan metode dengan mengumpulkan data guna memperoleh bukti mengenai hipotesis tersebut.

Bagaimana kita memutuskan apakah akan menolak hipotesis nol?

1. Jika data sampel konsisten dengan hipotesis nol, kita tidak menolaknya.
2. Jika data sampel tidak konsisten dengan hipotesis nol, tetapi konsisten dengan hipotesis alternatif, kita menolak hipotesis nol. Data itu memberikan bukti yang cukup untuk mendukung hipotesis alternatif, tetapi tidak membuktikannya benar karena galat tipe I tetap mungkin terjadi.

Enam Langkah Uji Hipotesis

Dalam pengujian hipotesis, ada langkah-langkah tertentu yang harus diikuti. Langkah-langkah tersebut dirangkum di bawah ini menjadi enam langkah untuk melakukan uji hipotesis.

1. **Rumuskan hipotesis dan periksa syarat-syaratnya:** Setiap uji hipotesis mencakup dua hipotesis tentang populasi. Yang pertama adalah hipotesis nol, yang dilambangkan dengan H_0 , yaitu pernyataan mengenai suatu nilai parameter tertentu. Hipotesis ini dianggap benar sampai ada bukti yang menunjukkan sebaliknya. Hipotesis kedua disebut hipotesis alternatif, atau hipotesis penelitian, yang dilambangkan dengan H_a . Hipotesis alternatif adalah pernyataan mengenai rentang nilai alternatif yang mungkin memuat nilai parameter. Kita juga harus memeriksa bahwa setiap syarat (asumsi) yang diperlukan untuk menjalankan uji telah terpenuhi, misalnya kenormalan data, kebebasan, serta banyaknya hasil sukses dan gagal.
2. **Tentukan tingkat signifikansi, α :** Nilai ini digunakan sebagai batas peluang untuk mengambil keputusan mengenai hipotesis nol. Nilai alfa ini menyatakan peluang terjadinya keputusan keliru yang bersedia kita tanggung dalam pengujian ketika menolak hipotesis nol. Nilai α yang paling umum adalah 0.05 atau 5%.

Pilihan lain yang populer adalah 0.01 (1%) dan 0.1 (10%).

3. **Hitung statistik uji:** Kumpulkan data sampel dan hitung statistik uji dengan membandingkan statistik sampel terhadap nilai parameter. Statistik uji dihitung dengan menganggap hipotesis nol benar serta memperhitungkan ukuran galat baku dan asumsi (syarat) yang berkaitan dengan distribusi penarikan sampel. Catatan: Kita perlu mengetahui distribusi statistik uji di bawah hipotesis nol.

4. **Hitung nilai peluang (nilai-p), atau tentukan daerah penolakan:** Nilai-p adalah peluang, di bawah hipotesis nol, memperoleh statistik uji yang sekurang-kurangnya sama ekstrem dengan nilai teramati. Dalam edisi ini, H_0 ditolak ketika $\text{nilai-p} \leq \alpha$. Daerah penolakan ditentukan dengan menggunakan alfa untuk mencari nilai kritis; daerah penolakan adalah wilayah yang sekurang-kurangnya sama ekstrem dengan batas kritis. Misalkan statistik uji kita dilambangkan dengan T^* . Untuk menentukan daerah penolakan, dicari suatu nilai kritis, c , yang berfungsi sebagai nilai batas. Sebagai contoh,

Jika $|T^*| \geq c$, kita mengambil satu keputusan, yaitu menolak H_0

Jika $|T^*| < c$, kita mengambil keputusan lainnya, yaitu gagal menolak H_0 .

Konvensi batas edisi ini: tolak H_0 bila $|T^*| \geq c$ dan gagal menolaknya bila $|T^*| < c$. Untuk hukum nol kontinu yang sesuai, kejadian $|T^*| = c$ biasanya berpeluang nol. Pada uji diskret bertaraf eksak, tindakan pada himpunan kesamaan harus ditetapkan secara deterministik atau diacak agar ukuran yang diminta tercapai.

Nilai batas, c , ditentukan oleh tingkat pengujian, α .

Nilai-p dan daerah penolakan akan kita bahas secara lebih terperinci pada bagian-bagian berikutnya.

5. **Ambil keputusan mengenai hipotesis nol:** Pada langkah ini, kita memutuskan untuk menolak hipotesis nol atau gagal menolak hipotesis nol. Perhatikan bahwa kita tidak mengambil keputusan untuk menerima hipotesis nol.

6. **Nyatakan kesimpulan keseluruhan:** Setelah memperoleh nilai-p atau daerah penolakan dan mengambil keputusan statistika mengenai hipotesis nol (yaitu menolak atau gagal menolak hipotesis nol), kita merangkum hasil tersebut menjadi kesimpulan keseluruhan dari pengujian.

Sepanjang bagian selanjutnya dari pelajaran ini, kita akan mengikuti keenam langkah tersebut, meskipun langkah-langkahnya mungkin tidak dijelaskan secara eksplisit.

Langkah 1 sangat penting untuk dirumuskan dengan benar. Jika hipotesis Anda keliru, kesimpulan Anda juga akan keliru. Pada bagian-bagian berikutnya, kita akan terus berlatih menerapkan Langkah 1.

9.2 Uji Proporsi

Setiap kali melakukan uji hipotesis, kita akan mengikuti prosedur dasar berikut:

1. Kita akan membuat asumsi awal mengenai parameter populasi.
2. Kita akan mengumpulkan bukti atau menggunakan bukti yang dikumpulkan orang lain (dalam kedua kasus, bukti tersebut berbentuk data).
3. Berdasarkan bukti (data) yang tersedia, kita akan memutuskan apakah akan “menolak” atau “gagal menolak” asumsi awal.

Mari kita buat prosedur yang telah diuraikan ini menjadi lebih konkret dengan mengkaji uji untuk satu proporsi. Setelah itu, kita akan menguraikan beberapa uji statistika umum lainnya.

Mari kita perhatikan contoh berikut.

Contoh 9.3 Sebuah dadu bersisi empat (berbentuk tetrahedron) dilempar 1000 kali, dan sisi empat muncul 290 kali. Apakah terdapat bukti untuk menyimpulkan bahwa dadu tersebut tidak seimbang, yaitu bahwa sisi empat muncul lebih sering daripada yang diharapkan?



Dadu tetrahedral bersisi empat pada Contoh 9.3; setiap lemparan menghasilkan salah satu dari empat sisi.

Solusi

Sebagaimana diuraikan dalam prosedur dasar pengujian hipotesis di atas, langkah pertama mencakup pernyataan asumsi awal dan penentuan parameter yang menjadi perhatian. Parameter yang menjadi perhatian di sini adalah p , peluang memperoleh angka 4. Asumsinya adalah bahwa dadu itu seimbang. Jika dadu itu seimbang, setiap sisi (1, 2, 3, dan 4) memiliki peluang yang sama. Jadi, kita akan menganggap bahwa p , peluang memperoleh angka 4, adalah 0.25.

Oleh karena itu, hipotesis nol, atau “status quo”, menyatakan bahwa parameter populasi p sama dengan 0.25. Secara simbolis:

$$H_0 : p = 0.25$$

Dalam informasi yang diberikan, dipertanyakan apakah angka empat muncul lebih sering daripada yang diharapkan. Oleh karena itu, hipotesis alternatifnya adalah:

$$H_a : p > 0.25$$

Langkah kedua adalah menentukan tingkat signifikansi, α . Pada umumnya, tingkat signifikansi yang paling sering digunakan adalah $\alpha = 0.05$. Oleh karena itu, mari kita pilih $P(\text{Type I error}) = \alpha = 0.05$. Dengan demikian, peluang kita menolak hipotesis nol dengan syarat hipotesis nol benar adalah 5%.

Sekarang, langkah berikutnya menyatakan bahwa kita perlu mengumpulkan bukti (data) yang mendukung atau menentang asumsi awal. Dalam kasus ini, hal tersebut sudah dilakukan. Kita diberi tahu bahwa dadu dilempar $n = 1000$ kali, dan tercatat $y = 290$ untuk banyaknya kemunculan angka empat. Kita dapat menggunakan proporsi sampel untuk menduga parameter populasi. Dengan demikian, kita memperoleh:

$$\hat{p} = \frac{y}{n} = \frac{290}{1000} = 0.29$$

Sekarang kita hanya perlu menyelesaikan langkah ketiga, yaitu memutuskan apakah akan menolak asumsi awal bahwa proporsi populasi adalah 0.25. Kita perlu menggunakan perangkat yang sejauh ini telah kita kembangkan dalam mata kuliah ini dan STAT 414. Ingat bahwa Teorema Limit Pusat menyatakan bahwa proporsi sampel:

$$\hat{p} = \frac{Y}{n}$$

berdistribusi Normal secara hampiran dengan rata-rata (yang diasumsikan)

$$p_0 = 0.25$$


dan simpangan baku (yang diasumsikan):

$$\sqrt{\frac{p_0(1-p_0)}{n}} = \sqrt{\frac{0.25(1-0.25)}{1000}} = 0.01369$$

Artinya:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

mengikuti hukum $N(0, 1)$ yang merupakan distribusi Normal baku. Kita dapat “memetakan” proporsi sampel teramati sebesar 0.29 ke skala Z berikut. Gambar berikut merangkum situasinya:



Gambar 9.1 — Distribusi Normal hampiran bagi $\hat{p}$ ketika $H_0: p = 0,25$; luas ekor kanan mulai 0,29 adalah peluang memperoleh hasil yang sekurang-kurangnya sama ekstrem dengan hasil teramati.

Catatan reproduisibilitas: gambar ini adalah keluaran beku dari sumber resmi. Sumber tidak memublikasikan kode pembangkit, data masukan, kunci lingkungan, atau keadaan acak; karena itu yang dapat diverifikasi secara deterministik di sini hanyalah bita keluaran gambar, bukan regenerasi plot dari sumber.

Jadi, kita menganggap proporsi populasi adalah 0.25, tetapi kita mengamati proporsi sampel sebesar 0.290 yang terletak jauh di ekor kanan distribusi Normal. Memperoleh proporsi sampel 0.29 jelas bukan hal yang mustahil. Namun, kita tetap harus memutuskan apakah proporsi sampel 0.290 lebih ekstrem daripada yang diharapkan jika proporsi populasi p memang sama dengan 0.25.

Langkah berikutnya adalah menentukan cara mengambil keputusan. Ada dua pendekatan untuk mengambil keputusan dalam pengujian hipotesis:

1. Salah satunya disebut pendekatan **“daerah penolakan”** (atau “nilai kritis” atau “daerah kritis”).
2. Pendekatan lainnya menggunakan **“nilai- p ”** sebagai dasar pengambilan keputusan.


Pertama, mari kita perhatikan pendekatan daerah penolakan.

Baiklah, sekarang mari kita pikirkan. Kita mungkin tidak akan menolak asumsi awal bahwa proporsi populasi $p = 0.25$ jika proporsi sampel teramati sebesar 0.255. Kita mungkin juga masih belum cenderung menolak asumsi awal bahwa proporsi populasi $p = 0.25$ jika proporsi sampel teramati sebesar 0.27. Di sisi lain, kita hampir pasti ingin menolak asumsi awal bahwa proporsi populasi $p = 0.25$ jika proporsi sampel teramati sebesar 0.35. Ini menunjukkan adanya suatu nilai “ambang” yang, setelah “dilampaui”, membuat kita cenderung menolak asumsi awal. Singkatnya, itulah pendekatan nilai kritis. Pendekatan ini menetapkan nilai ambang yang disebut “nilai kritis”, sehingga jika “statistik uji” lebih ekstrem daripada nilai kritis, kita menolak hipotesis nol.

Ingatlah bahwa kita menetapkan tingkat signifikansi, α , sebesar 5%. Karena kita menggunakan distribusi Normal baku, kita akan mencari nilai Z yang lebih besar daripada 1.645. Dengan kata lain, kita memutuskan untuk menolak hipotesis nol $H_0 : p = 0.25$ demi mendukung “hipotesis alternatif” $H_a : p > 0.25$ jika:

$$Z > 1.645 \iff \hat{p} > 0.272525 \dots \iff Y \geq 273 \iff \hat{p} \geq 0.273$$

Berikut gambar dari “daerah penolakan” semacam itu (atau “daerah kritis”):



Gambar 9.2 — Daerah penolakan ekor kanan mulai $\hat{p} = 0.273$ untuk uji proporsi; aturan diskretnya adalah menolak H_0 ketika $Y \geq 273$.

Catatan reproduktibilitas: gambar ini adalah keluaran beku dari sumber resmi. Sumber tidak memublikasikan kode pembangkit, data masukan, kunci lingkungan, atau keadaan acak; karena itu yang dapat diverifikasi secara deterministik di sini hanyalah bita keluaran gambar, bukan regenerasi plot dari sumber.

Dengan hampiran Normal yang digunakan di sini, ‘ukuran’ daerah kritis sekitar 0,05, bukan tepat 0,05. Untuk aturan diskret $Y \geq 273$, ukuran Binomial eksaknya 0,0511947; tingkat eksak 0,05 memerlukan pengacakan pada $Y = 273$. Hal ini akan berkaitan dengan peluang galat yang dibahas di bawah.

Bagaimanapun, mari kembali memutuskan apakah proporsi sampel khusus kita tampak terlalu ekstrem. Tampaknya kita harus menolak hipotesis nol (asumsi awal kita bahwa $p = 0.25$) karena:

$$\hat{p} = 0.29 > 0.273$$

atau, secara ekuivalen, karena statistik uji kita:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}} = \frac{0.29 - 0.25}{\sqrt{\frac{0.25(0.75)}{1000}}} = 2.92$$

lebih besar daripada 1.645.

Kesimpulan kita: kita menyatakan bahwa terdapat bukti yang cukup untuk menyimpulkan $H_a : p > 0.25$, yaitu bahwa dadu tersebut tidak seimbang.

Sebagai tambahan, contoh ini melibatkan apa yang disebut **uji satu sisi**, atau lebih khusus lagi, **uji sisi kanan**, karena daerah kritis hanya terletak di salah satu dari dua ekor distribusi Normal, yaitu ekor kanan.

Sebelum melanjutkan ke halaman berikutnya dan melihat dua contoh lain, mari kita tinjau kembali prosedur dasar pengujian hipotesis yang diuraikan di atas. Kali ini, mari kita nyatakan prosedur tersebut dalam konteks **melakukan uji hipotesis untuk proporsi populasi** dengan menggunakan **pendekatan nilai kritis**. Prosedur dasarnya adalah:

1. Nyatakan hipotesis nol H_0 dan hipotesis alternatif H_a .
2. Hitung statistik uji (yang diperoleh dengan menggunakan distribusi statistik uji di bawah hipotesis nol):

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}}$$


3. Tentukan **daerah penolakan**.
4. **Ambil keputusan.** Tentukan apakah statistik uji berada di daerah kritis. Jika ya, tolak hipotesis nol. Jika tidak, kita gagal menolak hipotesis nol.

Sekarang, mari kembali membahas kemungkinan galat yang dapat kita lakukan ketika menjalankan uji hipotesis semacam itu.

9.3 Kemungkinan Galat

Aduh! Setiap kali melakukan uji hipotesis, kita berpeluang melakukan galat. (Astaga, mengapa saya tidak memilih profesi lain?!)

1. Jika kita menolak hipotesis nol H_0 (demi mendukung hipotesis alternatif) ketika hipotesis nol sebenarnya benar, kita dikatakan telah melakukan **galat tipe I**. Untuk contoh di atas, kita menetapkan $P(\text{galat tipe I})$ sama dengan 0.05:



Gambar 9.3 — Di bawah $H_0: p = 0,25$, batas $Z = 1,645$ atau $\hat{p} = 0,273$ memisahkan daerah gagal menolak dari daerah penolakan ekor kanan dengan $\alpha \approx 0,05$.

Kita ingin memperkecil peluang melakukan galat tipe I! Secara umum, kita melambangkannya dengan $\alpha = P(\text{Type I error}) = \text{the significance level}$. Jelas, kita ingin memperkecil α . Oleh karena itu, nilai α yang umum adalah 0.01, 0.05, dan 0.10.

2. Jika kita gagal menolak hipotesis nol ketika hipotesis nol salah, kita dikatakan telah melakukan galat tipe II. Untuk contoh ini, misalkan (tanpa kita ketahui) proporsi populasi p sebenarnya 0.27. Dalam hal ini, peluang galat tipe II adalah:

$$\begin{aligned}\beta(0.27) &= P_{p=0.27}(\hat{p} < 0.273) \\ &\approx P\left(Z < \frac{0.273 - 0.27}{\sqrt{0.27(0.73)/1000}}\right) = P(Z < 0.214) \approx 0.5847\end{aligned}$$

Secara umum, kita melambangkannya dengan $\beta = P(\text{Type II error})$. Sama seperti kita ingin memperkecil $\alpha = P(\text{Type I error})$, kita juga ingin memperkecil $\beta = P(\text{Type II error})$. Nilai β yang umum adalah 0.05, 0.10, dan 0.20.

9.4 Pendekatan Nilai-p

Hingga saat ini, kita menggunakan pendekatan daerah kritis dalam melakukan uji hipotesis. Sekarang, mari kita lihat contoh yang menggunakan apa yang disebut **pendekatan nilai-p**.

Contoh 9.4 (Kanker Paru) Bagian I

Di antara pasien kanker paru, biasanya 90% atau lebih meninggal dalam waktu tiga tahun. Dengan adanya bentuk-bentuk pengobatan baru, angka ini diduga telah menurun. Misalkan dalam suatu studi terbaru terhadap $n = 150$ pasien kanker paru, $y = 128$ meninggal dalam waktu tiga tahun. Apakah, pada tingkat $\alpha = 0.05$, terdapat bukti yang cukup untuk menyimpulkan bahwa angka kematian akibat kanker paru telah menurun?

Solusi

Proporsi sampelnya adalah:

$$\hat{p} = \frac{128}{150} = 0.853$$


Hipotesis nol dan hipotesis alternatif adalah:

$$H_0: p = 0.90 \text{ and } H_A: p < 0.9$$

Dengan demikian, statistik ujinya adalah:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} = \frac{0.853 - 0.90}{\sqrt{\frac{0.90(0.10)}{150}}} = -1.92$$

Daerah penolakannya adalah:



Uji ekor kiri bertaraf 0,05: tolak H_0 bila $Z \leq -1,645$; di sebelah kanan batas itu, gagal menolak H_0 .


Karena statistik uji $Z = -1.92 < -1.645$, kita menolak hipotesis nol. Terdapat bukti yang cukup pada tingkat $\alpha = 0.05$ untuk menyimpulkan bahwa angka kematian telah menurun.

Bagian II

Bagaimana jika kita menetapkan tingkat signifikansi $\alpha = P(\text{Type I error}) = 0.01$? Apakah masih terdapat bukti yang cukup untuk menyimpulkan bahwa angka kematian akibat kanker paru telah menurun?

Solusi

Dalam kasus ini, dengan $\alpha = 0.01$, daerah penolakannya adalah $Z \leq -2.33$. Artinya, kita menolak jika statistik uji berada dalam daerah penolakan yang ditentukan oleh $Z \leq -2.33$:



Gambar 9.4 — Pada taraf 0,01, tolak H_0 bila $Z \leq -2,33$; nilai $Z = -1,92$ berada di luar daerah penolakan.


Karena statistik uji $Z = -1.92 > -2.33$, kita gagal menolak hipotesis nol. Tidak terdapat bukti yang cukup pada tingkat $\alpha = 0.01$ untuk menyimpulkan bahwa angka kematian telah menurun.

Bagian III

Pada bagian pertama contoh ini, kita menolak hipotesis nol ketika $\alpha = 0.05$. Pada bagian kedua contoh ini, kita gagal menolak hipotesis nol ketika $\alpha = 0.01$. Jadi, pasti ada suatu tingkat α tempat kita melintasi ambang dari menolak menjadi tidak menolak hipotesis nol. Berapakah tingkat α —terkecil yang masih membuat kita menolak hipotesis nol?

Penyelesaian

Tentu saja, kita akan menolak setiap kali nilai kritis lebih kecil daripada statistik uji kita, -1.92 :



Gambar 9.5 — Nilai-p uji ekor kiri adalah luas di bawah kurva Normal baku untuk $Z \leq -1.92$, yaitu 0,0274; karena $0,0274 \leq 0,05$, H_0 ditolak.

Artinya, kita akan menolak jika nilai kritisnya -1.645 , -1.83 , dan -1.92 . Namun, kita tidak akan menolak jika nilai kritisnya -1.93 . Tingkat α —yang berkaitan dengan statistik uji -1.92 disebut nilai-p. Nilai-p adalah tingkat α —terkecil yang akan menghasilkan penolakan. Dalam kasus ini, nilai-p adalah:

$$P(Z < -1.92) = 0.0274$$

Mari kita rumuskan definisi nilai-p secara formal, lalu merangkum pendekatan nilai-p untuk melakukan uji hipotesis.

Def. 9.5 (Nilai-p) Istilah **Nilai-p** adalah tingkat signifikansi terkecil yang membuat kita menolak hipotesis nol.

Sebagai rumusan yang setara (dan cara yang saya sukai untuk memahami nilai-p), **nilai-p** adalah peluang, dengan menganggap hipotesis nol benar, untuk mengamati statistik uji yang sekurang-kurangnya sama ekstrem dengan statistik yang kita amati.

Jika nilai-p kecil, yaitu jika $P \leq \alpha$, maka kita menolak hipotesis nol. H_0 .

Sejauh ini, semua contoh yang kita bahas melibatkan uji hipotesis satu sisi dengan hipotesis alternatif yang memuat tanda kurang dari ($<$) atau lebih dari ($>$). Bagaimana jika kita tidak yakin ke arah mana proporsi dapat menyimpang dari nilai yang dihipotesiskan dalam hipotesis nol? Dengan kata lain, bagaimana jika hipotesis alternatif memuat tanda tidak sama dengan ($\neq$)? Mari kita lihat sebuah contoh.


Contoh 9.5 (Lanjutan Kanker Paru-Paru) Bagaimana jika kita ingin melakukan uji “dua sisi”? Dengan kata lain, bagaimana jika kita ingin menguji:

$$H_0 : p = 0.9 \text{ versus } H_a : p \neq 0.9$$

pada tingkat $\alpha = 0.05$?

Penyelesaian

Pertama-tama, mari kita tinjau **pendekatan nilai kritis**. Jika kita membuka kemungkinan bahwa proporsi sampel dapat terlalu besar ataupun terlalu kecil, kita perlu menetapkan satu nilai ambang, yakni nilai kritis, pada setiap ekor distribusi. Dalam kasus ini, kita membagi “tingkat signifikansi” α dengan 2 sehingga diperoleh $\frac{\alpha}{2}$:



Gambar 9.6 — Daerah penolakan uji dua sisi bertaraf 0,05 berada pada $Z \leq -1,96$ dan $Z \geq 1,96$; nilai teramati $Z = -1,92$ tidak masuk daerah itu.

Artinya, aturan penolakan kita adalah menolak hipotesis nol jika statistik uji berada pada ekor kiri, H_0 , atau pada ekor kanan, H_0 ; secara ekuivalen, kita menolak hipotesis nol jika $|Z| \geq 1.96$. Karena statistik uji kita adalah -1.92 , kita nyaris gagal menolak hipotesis nol, sebab $1.92 < 1.96$. Dalam kasus ini, kita mengatakan bahwa pada tingkat $\alpha = 0.05$ tidak terdapat bukti yang cukup untuk menyimpulkan bahwa proporsi populasi berbeda secara signifikan dari 0,90.

Sekarang, kita gunakan **pendekatan nilai-p**. Sekali lagi, karena perlu mengakomodasi kemungkinan bahwa proporsi sampel terlalu besar ataupun terlalu kecil, kita mengalikan nilai-p dari uji satu sisi dengan 2:

Dengan demikian, nilai-p adalah:

$$P = P(|Z| \geq 1.92) = P(Z > 1.92 \text{ or } Z < -1.92) = 2 \times 0.0274 = 0.055$$

Karena nilai-p 0,055 (nyaris) lebih besar daripada tingkat signifikansi $\alpha = 0.05$, kita nyaris gagal menolak hipotesis nol. Sekali lagi, kita mengatakan bahwa pada tingkat $\alpha = 0.05$ tidak terdapat bukti yang cukup untuk menyimpulkan bahwa proporsi populasi berbeda secara signifikan dari 0,90.

9.5 Uji tentang Satu Rata-Rata

Dalam pelajaran ini, kita melanjutkan pembahasan pengujian hipotesis. Perhatian kita akan dipusatkan pada uji hipotesis untuk rata-rata populasi, μ , dalam beberapa keadaan.

Varians Diketahui

Mari kita akui terlebih dahulu bahwa keadaan ketika varians populasi diketahui tetapi rata-rata populasi tidak diketahui sama sekali tidak realistis. Karena itu, metode pengujian hipotesis pada halaman ini memiliki kegunaan praktis yang terbatas. Kita mempelajarinya hanya karena kelak metode ini akan digunakan untuk mempelajari “kuasa” suatu uji hipotesis, melalui cara menghitung peluang galat tipe II. Seperti biasa, mari kita mulai dengan sebuah contoh.

Contoh 9.6 Anak laki-laki pada usia tertentu diketahui mempunyai rata-rata berat badan $\mu = 85$ pon. Ada keluhan bahwa anak-anak lelaki yang tinggal di sebuah panti asuhan kota kekurangan makanan. Sebagai salah satu bukti, $n = 25$ anak laki-laki (dengan usia yang sama) ditimbang dan didapati mempunyai rata-rata berat badan $\bar{x} = 80.94$ pon. Simpangan baku populasi σ diketahui sebesar 11,6 pon—bagian yang tidak realistis dari contoh ini. Berdasarkan data yang tersedia, apa yang harus disimpulkan mengenai keluhan tersebut?

Penyelesaian

Hipotesis nolnya adalah $H_0 : \mu = 85$, sedangkan hipotesis alternatifnya adalah $H_a : \mu < 85$. Secara umum, jika bobot berdistribusi Normal, kita mengetahui bahwa:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

mengikuti distribusi Normal baku $N(0, 1)$. Pernyataan ini eksak untuk sampel acak iid dari populasi Normal. Jika populasi tidak Normal, Teorema Limit Pusat hanya dapat memberikan hampiran di bawah syarat distribusi yang sesuai; tidak ada ukuran sampel hingga yang secara universal menjamin hampiran Normal yang memadai. Di sini ukuran sampel $n = 25$ dapat mendukung penggunaan hampiran tersebut jika syarat-syarat itu masuk akal.

Dalam hal itu, kita mengetahui bahwa Z , sebagaimana didefinisikan di atas, sekurang-kurangnya menghampiri distribusi Normal baku. Karena itu, statistik uji berikut layak digunakan:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

untuk menguji hipotesis nol


$$H_0 : \mu = \mu_0$$

terhadap salah satu hipotesis alternatif yang mungkin, yaitu $H_a : \mu \neq \mu_0$, $H_a : \mu < \mu_0$, dan $H_a : \mu > \mu_0$.

Untuk contoh ini, nilai statistik ujinya adalah:


$$Z = \frac{80.94 - 85}{11.6/\sqrt{25}} = -1.75$$

Pendekatan daerah kritis menyatakan bahwa pada tingkat $\alpha = 0.05$ kita menolak hipotesis nol jika $Z < -1.645$. Oleh karena itu, kita menolak hipotesis nol karena $Z = -1.75 < -1.645$, sehingga nilainya berada dalam daerah penolakan:



Gambar 9.7 — Pada uji rata-rata ekor kiri bertaraf 0,05, batas kritisnya -1,645; statistik $Z = -1,75$ berada di daerah penolakan.

Seperti biasa, kita memperoleh kesimpulan yang sama dengan menggunakan pendekatan nilai p . Ingat bahwa pendekatan nilai p menyatakan bahwa pada tingkat $\alpha = 0.05$ kita menolak hipotesis nol jika nilai p tersebut $\leq \alpha = 0.05$. Dalam kasus ini, nilai p adalah $P(Z < -1.75) = 0.0401$:



Gambar 9.8 — Nilai-p uji ekor kiri adalah $P(Z \leq -1,75) = 0,0401$; karena $0,0401 \leq 0,05$, H_0 ditolak.

Sesuai dugaan, kita menolak hipotesis nol karena nilai p memenuhi $0,0401 < 0,05$. $0.0401 < \alpha = 0.05$.

Varians Tidak Diketahui

Setelah, demi alasan pedagogis, menyelesaikan keadaan yang tidak realistis ketika varians populasi diketahui, sekarang kita beralih ke keadaan realistis ketika rata-rata dan varians populasi sama-sama tidak diketahui.

Contoh 9.7 Rata-rata tekanan darah sistolik diasumsikan sebesar $\mu = 120$ mmHg. Dalam Honolulu Heart Study, sampel sebanyak $n = 100$ orang mempunyai rata-rata tekanan darah sistolik 130,1 mmHg dengan simpangan baku 21,21 mmHg. Apakah kelompok ini berbeda secara signifikan—dalam hal tekanan darah sistolik—dari populasi biasa?

Penyelesaian

Hipotesis nolnya adalah $H_0 : \mu = 120$, dan karena tidak ada arah tertentu yang dinyatakan, hipotesis alternatifnya adalah $H_a : \mu \neq 120$.

Langkah berikutnya dalam pengujian hipotesis adalah menentukan tingkat signifikansi, yakni peluang galat tipe I. Untuk contoh ini, tetapkan $\alpha = 0.05$.

Langkah 3 adalah menghitung statistik uji. Ingat bahwa kita perlu menentukan statistik uji yang distribusinya diketahui di bawah asumsi model dan hipotesis nol. Dari STAT 414, kita mengetahui bahwa jika data merupakan sampel acak iid dari populasi Normal, maka:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

mengikuti distribusi t dengan $n - 1$ derajat kebebasan. Karena itu, statistik uji berikut layak digunakan:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

untuk menguji hipotesis nol $H_0 : \mu = 120$ terhadap salah satu hipotesis alternatif yang mungkin, yaitu $H_a : \mu \neq \mu_0$, $H_a : \mu < \mu_0$, dan $H_a : \mu > \mu_0$. Untuk contoh ini, nilai statistik ujinya adalah:

$$t = \frac{130.1 - 120}{21.21/\sqrt{100}} = 4.762$$

Pendekatan daerah kritis menyatakan bahwa pada tingkat $\alpha = 0.05$ kita menolak hipotesis nol jika $t \geq t_{0.025,99} = 1.9842$ atau jika $t \leq -t_{0.025,99} = -1.9842$. Oleh karena itu, kita menolak hipotesis nol karena $t = 4.762 > 1.9842$, sehingga nilainya berada dalam daerah penolakan:

Sekali lagi, kita memperoleh kesimpulan yang sama dengan menggunakan pendekatan nilai p . Pendekatan nilai p menyatakan bahwa pada tingkat $\alpha = 0.05$ kita menolak hipotesis nol jika nilai p tersebut ≤ 0.05 . Dalam kasus ini, nilai p adalah:

$$p = 2P(T_{99} \geq 4.762) \\ \approx 0.00000656 < 0.01 < 0.05$$

Sesuai dugaan, kita menolak hipotesis nol karena nilai p kurang dari 0,05; perhitungan dua sisi yang lengkap memberi nilai- p sekitar $0,00000656 \leq 0.01 < \alpha = 0.05$.

9.6 Ringkasan

Dalam pelajaran ini, kita memperkenalkan kerangka pengujian hipotesis—cara formal menggunakan data sampel untuk mengevaluasi klaim tentang parameter populasi. Gagasan utamanya adalah menyusun dua pernyataan yang bersaing: hipotesis nol (H_0), yang mewakili keadaan semula atau tidak adanya efek, dan hipotesis alternatif (H_a), yang menyatakan hal yang hendak kita dukung dengan bukti.

Kita menghitung statistik uji yang merangkum bukti dari sampel, lalu menentukan seberapa ekstrem nilainya dengan menganggap H_0 benar. Dari sini diperoleh pendekatan daerah penolakan atau nilai- p . Jika statistik uji berada di daerah penolakan, atau jika nilai- p tidak lebih besar daripada tingkat signifikansi α , kita menolak H_0 .

Pokok Penting:

- Bentuk umum statistik uji adalah: $Z = \frac{\hat{\theta} - \theta_0}{SE(\hat{\theta})}$
- Galat tipe I: menolak hipotesis nol ketika hipotesis nol sebenarnya benar, $P(\text{Type I error}) = \alpha$
- Galat tipe II: gagal menolak hipotesis nol ketika hipotesis alternatif benar pada nilai parameter yang ditentukan, $P(\text{Type II error}) = \beta$
- Kuasa uji adalah peluang menolak hipotesis nol dengan benar pada nilai alternatif yang ditentukan, H_0 :
Power = $1 - \beta$

Kita juga mendefinisikan dua jenis galat: — Galat tipe I: menolak H_0 ketika hipotesis itu sebenarnya benar (peluang α) — Galat tipe II: gagal menolak H_0 ketika H_a benar pada alternatif yang ditentukan (peluang β)

Adapun **Kuasa** suatu uji adalah peluang menolak hipotesis nol dengan benar pada nilai parameter alternatif yang ditentukan. H_0 :

$$\text{Power} = 1 - \beta$$

1. [Pelajaran](#)
2. [10 Uji Hipotesis \(Bagian II\)](#)

10 Uji Hipotesis (Bagian II)

Kuasa
Selang Kepercayaan
Uji Wald
Uji Hipotesis

Gambaran Umum

Pelajaran ini melanjutkan pembahasan awal kita tentang pengujian hipotesis melalui beragam contoh yang kurang dikenal serta menunjukkan bagaimana selang kepercayaan dan uji hipotesis merupakan dua sisi dari hal yang sama. Anda juga akan mempelajari mengapa mutu uji bergantung pada kuasa—peluang mendeteksi efek yang nyata—dan bagaimana faktor-faktor seperti ukuran sampel, tingkat signifikansi (α), dan ukuran efek saling berkaitan. Terakhir, kita meninjau sekilas uji Wald, suatu metode umum yang memanfaatkan penduga kemungkinan maksimum ketika statistik uji klasik sulit diturunkan.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Menghubungkan selang kepercayaan dengan uji hipotesis,
2. Menentukan kuasa suatu uji,
3. Menentukan ukuran sampel yang diperlukan untuk suatu tingkat signifikansi dan kuasa yang diinginkan,
4. Menyusun secara numerik uji hipotesis sederhana untuk parameter yang diduga melalui pendugaan kemungkinan maksimum numerik di R

10.1 Contoh Uji Hipotesis Lain

Pada bagian ini, kita akan melanjutkan dengan beberapa contoh uji hipotesis yang mungkin tidak seakrab contoh-contoh yang telah kita lihat sejauh ini.

Contoh 10.1 Bagian I

Misalkan kita memiliki sampel acak berukuran $n = 8$ dari distribusi Seragam pada selang $(0, \theta)$. Kita ingin menguji hipotesis berikut:

$$H_0 : \theta = 2 \text{ versus } H_a : \theta < 2$$

Turunkan suatu uji statistik untuk hipotesis-hipotesis ini.

Jawaban

Solusi

Langkah 1 telah ditentukan dalam soal. Langkah berikutnya adalah menetapkan tingkat signifikansi. Mari kita tetapkan peluang galat tipe I sebesar $\alpha = 0.10$.

Langkah selanjutnya adalah menentukan statistik uji. Kita perlu mengetahui distribusi statistik uji tersebut. Pilihan yang logis adalah statistik urutan maksimum. Jika hipotesis nol benar, statistik urutan terbesar, $Y_n = Y_8$, akan “dekat” dengan $\theta = 2$, dan nilai Y_8 yang jauh lebih **kecil** daripada $\theta = 2$ akan menjadi bukti yang mendukung hipotesis alternatif, $H_a : \theta < 2$.

Aturan keputusannya kira-kira berbentuk: tolak $H_0 : \theta = 2$ jika $Y_8 \leq c$, dengan

$$\alpha = 0.1 = P(Y_8 \leq c | H_0 \text{ is true})$$

Kita mengetahui bahwa statistik urutan tersebut memiliki distribusi berikut:

$$f_{y_n}(y) = \frac{n}{\theta^n} y^{n-1} = \frac{8}{\theta^8} y^7, \quad 0 \leq y \leq \theta$$

Di bawah hipotesis nol, distribusinya adalah:

$$f_{y_8}(y) = \frac{n}{2^n} y^{n-1} = \frac{8}{2^8} y^7 = \frac{1}{32} y^7, \quad 0 \leq y \leq 2$$

Kembali ke aturan keputusan kita, kita menolak jika $P(Y_8 \leq c | H_0) = 0.1$. Dengan menggabungkan semuanya, kita dapat menentukan c .

$$0.1 = \int_0^c \frac{1}{32} y^7 dy = \frac{1}{256} c^8$$

Dengan menyelesaikan persamaan untuk c , kita peroleh:

$$c = \sqrt[8]{25.6} \approx 1.4998$$

Dengan demikian, kita menolak hipotesis nol pada tingkat $\alpha = 0.1$, jika $Y_8 \leq 1.4998$.

Bagian II

Kita memiliki pengamatan berikut dari distribusi Seragam pada selang $(0, \theta)$.

0.3977 0.9518 0.4598 0.3963 0.5222 0.8519 0.5270 0.2767

Uji hipotesis $H_0 : \theta = 2$ melawan $H_a : \theta < 2$.

Jawaban

Solusi

Statistik urutan maksimum adalah 0,8519. Karena nilainya kurang dari 1,4998, kita menolak hipotesis nol. Kita menyimpulkan bahwa pada tingkat $\alpha = 0.1$ terdapat cukup bukti bahwa parameter populasi θ lebih kecil daripada 2.

Contoh 10.2 Empat pengukuran, 2, 0, 1, 0, dilakukan pada peubah acak Poisson X untuk menguji

$$H_0 : \lambda = 0.8 \text{ versus } H_a : \lambda > 0.8$$

Turunkan suatu uji statistik untuk hipotesis-hipotesis ini pada tingkat signifikansi 10%.

Jawaban

Solusi

Dua langkah pertama pengujian hipotesis telah diberikan dalam soal. Oleh karena itu, langkah berikutnya adalah menghitung statistik uji. Kita telah mengetahui sebelumnya bahwa $\bar{X}$ merupakan statistik cukup bagi λ . Kita juga telah mengetahui dalam STAT 414 bahwa $\sum_{i=1}^4 X_i$ merupakan peubah acak Poisson dengan parameter $\sum_{i=1}^4 \lambda = 4\lambda$. Untuk contoh ini, mari kita gunakan jumlah tersebut sebagai statistik uji.

Jika distribusi jumlah tersebut adalah Poisson 4λ , maka hipotesis awal kita dapat dituliskan kembali sebagai:

$$H_0 : 4\lambda = 4(0.8) = 3.2 \text{ versus } H_a : 4\lambda > 3.2$$

Dalam menyusun aturan keputusan, kita ingin menolak hipotesis nol jika $\sum x_i > c$, dengan

$$P_0(Y > c) \leq 0.10$$

Ingatlah bahwa distribusi Poisson bersifat diskret. Oleh karena itu, tingkat α yang kita inginkan mungkin tidak dapat dicapai secara tepat. Tabel di bawah menunjukkan fungsi massa peluang (PMF) suatu peubah acak Poisson dengan $\lambda = 3.2$. Kolom ketiga adalah $P(\sum X_i > x)$ untuk nilai x .

Peluang massa dan peluang ekor atas untuk peubah Poisson dengan parameter 3,2.

x	$P(X = x)$	$P(X > x) = 1 - P(X \leq x)$
0	0.0408	0.9592
1	0.1304	0.8288
2	0.2087	0.6201
3	0.2226	0.3975
4	0.1781	0.2194
5	0.1140	0.1054
6	0.0608	0.0446
7	0.0278	0.0168
8	0.0111	0.0057
9	0.0040	0.0018
10	0.0013	0.0005
11	0.0004	0.0001
12	0.0001	0.0000
13	0.0000	0.0000

Kita ingin memperoleh nilai sedekat mungkin dengan $\alpha = 0.1$. Nilai yang paling dekat dalam tabel adalah $P_0(Y \geq 6) = 0.105408105469177 \approx 0.1054 > 0.10$. Akan tetapi, nilai ini melebihi tingkat signifikansi nominal 0,10. Pernyataan sumber berikut menggunakan tingkat signifikansi $P_0(Y \geq 7) = 0.044619100955301 \approx 0.0446 \leq 0.10$, yang bahkan tidak konsisten dengan nilai tabel 0,1054. Aturan sumber untuk menolak hipotesis nol adalah ketika $Y \geq 7$.

Aturan tersebut berukuran 0,105408..., sehingga bukan uji bertingkat 0,10. Uji tak teracak yang konservatif menolak ketika jumlah sekurang-kurangnya 7; ukuran tepat 0,10 diperoleh dengan aturan yang sama serta penolakan dengan peluang 0,9110348 ketika jumlah sama dengan 6. Dengan data yang diberikan, jumlahnya adalah $Y = 2 + 0 + 1 + 0 = 3$. Karena jumlah tersebut kurang dari 6 (dan juga kurang dari ambang konservatif 7), kita gagal menolak hipotesis nol. Sumber melaporkan kesimpulan ini pada $\text{size} = 0.044619100955301 \approx 0.0446$; dengan uji bertingkat 0,10 yang telah dikoreksi, tetap tidak terdapat cukup bukti untuk menyimpulkan bahwa $4\lambda > 3.2$ atau, secara ekuivalen, $\lambda > 0.8$.

Catatan tingkat eksak: aturan nonacak $Y \geq 7$ bersifat konservatif dengan ukuran 0,044619100955301. Ukuran tepat 0,10 diperoleh dengan menolak ketika $Y \geq 7$ dan, ketika $Y = 6$, menolak dengan peluang 0,911034807817211.

10.2 Menghubungkan Selang Kepercayaan dengan Uji Hipotesis

Sampai di sini, kita telah menunjukkan cara melakukan pendugaan selang bagi parameter yang tidak diketahui dan cara menguji nilai tertentu dari parameter tersebut. Adakah hubungan antara pendugaan selang dan uji hipotesis? Jawabannya: ada!

Sejauh ini, kita hanya membahas selang kepercayaan dua sisi, yaitu selang yang memiliki batas atas dan batas bawah. Pembahasan kita akan berfokus pada selang dan uji dua sisi tersebut. Namun, hal yang kita pelajari di sini juga dapat diterapkan pada selang kepercayaan satu sisi kanan atau kiri dan uji hipotesis satu sisi.

Seperti biasa, mari kita perhatikan sebuah contoh.

Contoh 10.3 Mari kita tinjau kembali contoh sebelumnya. Rataan tekanan darah sistolik diasumsikan sebesar $\mu = 120$ mm Hg. Dalam Honolulu Heart Study, sampel sebanyak $n = 100$ orang memiliki rata-rata tekanan darah sistolik 130,1 mm Hg dengan simpangan baku 21,21 mm Hg. Tentukan selang kepercayaan 95% bagi rata-rata tekanan darah sistolik populasi.

Solusi

Selang kepercayaan 95% adalah:

$$\bar{x} \pm t_{0.025,99} \frac{s}{\sqrt{n}}$$

Dengan informasi yang diberikan, kita memperoleh selang:

$$130.1 \pm 1.984 \left(\frac{21.21}{\sqrt{100}} \right) = 130.1 \pm 4.2081 = (125.8919, 134.3081)$$

Kita yakin 95% bahwa rata-rata tekanan darah sistolik populasi berada di antara (125.8919, 134.3081).

Sebelumnya, kita bertanya: Apakah kelompok tersebut berbeda secara signifikan (dalam hal tekanan darah sistolik!) dari populasi umum? Kita menguji hipotesis:

$$H_0 : \mu = 120 \text{ versus } H_a : \mu \neq 120$$

Statistik ujinya adalah $t = 4.76$. Nilai-p untuk uji ini adalah $p = 2P(T_{99} \geq 4.761904 \dots) \approx 0.00000656270 > 0$. Nilai-p dua sisi yang lebih teliti adalah sekitar 0,00000656. Oleh karena itu, kita menolak hipotesis nol pada tingkat $\alpha = 0.05$.

Jika kita melihat selang kepercayaan tersebut, tampak bahwa nilai 120 TIDAK berada di dalamnya. Apakah ini suatu kebetulan?

Pendekatan daerah penolakan untuk uji hipotesis $\alpha = 0.05$ menyatakan bahwa kita menolak hipotesis nol bahwa $\mu = 120$:

$$\text{if } t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \geq 1.9842 \text{ or if } t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \leq -1.9842$$

yang ekuivalen dengan menolak jika:

$$\text{if } \bar{x} - \mu_0 \geq 1.9842 \left(\frac{s}{\sqrt{n}} \right) \text{ or if } \bar{x} - \mu_0 \leq -1.9842 \left(\frac{s}{\sqrt{n}} \right)$$

yang ekuivalen dengan menolak jika:

$$\text{if } \mu_0 \leq \bar{x} - 1.9842 \left(\frac{s}{\sqrt{n}} \right) \text{ or if } \mu_0 \geq \bar{x} + 1.9842 \left(\frac{s}{\sqrt{n}} \right)$$

yang, setelah data untuk contoh ini dimasukkan, ekuivalen dengan menolak jika:

$$\text{if } \mu_0 \leq 125.89 \text{ or if } \mu_0 \geq 134.31$$

yang ternyata (!) merupakan titik-titik ujung selang kepercayaan 95% bagi rata-rata. Jadi, hasilnya memang konsisten! Dengan selang tertutup 95% dan aturan penolakan nilai-p $< \alpha$ yang lazim, hipotesis nol ditolak tepat ketika nilai parameter yang ditetapkan berada di luar selang; jika aturan nilai-p $\leq \alpha$ digunakan, perlakuan pada titik ujung harus dinyatakan secara eksplisit.

10.3 Kuasa Uji

Setiap kali melakukan uji hipotesis, kita ingin memastikan bahwa uji tersebut bermutu tinggi. Salah satu cara mengukur mutunya adalah memastikan bahwa uji itu memiliki kuasa yang tinggi. Dalam pelajaran ini, kita akan mempelajari arti uji dengan kuasa tinggi dan cara menentukan ukuran sampel n yang diperlukan agar uji hipotesis yang kita lakukan memiliki kuasa tinggi. Pembahasan dan contoh kita berfokus pada pengujian rata-rata populasi yang tidak diketahui dari suatu distribusi Normal.

10.3.1 Definisi Kuasa

Mari kita mulai pembahasan kuasa statistik dengan mengingat kembali dua definisi yang kita pelajari ketika pertama kali memperkenalkan pengujian hipotesis:

- Galat tipe I terjadi jika kita menolak hipotesis nol H_0 (untuk mendukung hipotesis alternatif H_a) ketika hipotesis nol H_0 benar. Kita lambangkan $\alpha = P(\text{Type I error})$.
- Galat tipe II terjadi jika kita gagal menolak hipotesis nol H_0 ketika hipotesis nol H_0 salah (atau hipotesis alternatif benar). Kita lambangkan $\beta = P(\text{Type II error})$.

Anda benar-benar perlu memahami kedua definisi ini secara menyeluruh karena keduanya akan sering digunakan dalam pelajaran ini dan setiap kali kelak Anda perlu menghitung ukuran sampel, baik untuk diri sendiri maupun untuk orang lain.

Contoh 10.4 Bagian I

Skala kekerasan Brinell adalah salah satu dari beberapa definisi yang digunakan dalam ilmu material untuk mengukur kekerasan sepotong logam. Pengukuran kekerasan Brinell untuk jenis batang tulangan tertentu yang digunakan untuk memperkuat struktur beton dan pasangan bata diasumsikan berdistribusi Normal dengan simpangan baku 10 kilogram-gaya per milimeter persegi. Dengan menggunakan sampel acak sebanyak $n = 25$ batang, seorang insinyur hendak melakukan uji hipotesis berikut:




Batang baja tulangan yang menjadi konteks pengukuran kekerasan Brinell pada Contoh 10.4.

- hipotesis nol $H_0 : \mu = 170$
- melawan hipotesis alternatif $H_a : \mu > 170$

Jika insinyur tersebut memutuskan untuk menolak hipotesis nol apabila rata-rata sampel sekurang-kurangnya 172, yaitu $\bar{X} \geq 172$, berapakah peluang bahwa insinyur tersebut melakukan galat tipe I?

Solusi

Dalam kasus ini, insinyur tersebut melakukan galat tipe I jika rata-rata sampel yang diamatinya berada di daerah penolakan, yaitu sekurang-kurangnya 172, padahal rata-rata populasi yang sebenarnya (dan tidak diketahui) adalah 170. Secara grafis, α , peluang insinyur tersebut melakukan galat tipe I tampak seperti berikut:




Gambar 10.1 — Di bawah $H_0: \mu = 170$, rata-rata sampel sekurang-kurangnya 172 berada di daerah penolakan ekor kanan; luasnya adalah $\alpha = 0,1587$.

Sekarang, kita dapat menghitung nilai α bagi insinyur tersebut dengan mentransformasikan distribusi Normal yang memiliki rata-rata 170 dan simpangan baku 10 menjadi Z , distribusi Normal baku, dengan menggunakan:

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

Dengan demikian, kita peroleh:



Gambar 10.2 — Transformasi batas rata-rata sampel 172 memberi $Z = 1$; peluang ekor kanannya adalah 0,1587.

Dengan demikian, peluang insinyur melakukan galat tipe I dapat dihitung sebagai suatu peluang Normal. Nilainya adalah 0,1587, seperti diilustrasikan berikut:

$$\alpha = P(\bar{X} \geq 172 \text{ if } \mu = 170) = P(Z \geq 1.00) = 0.1587$$


Peluang 0,1587 agak tinggi. Dalam pelajaran ini, kita akan mempelajari cara insinyur tersebut dapat memperkecil peluang melakukan galat tipe I.

Bagian II

Melanjutkan contoh ini, jika—tanpa diketahui insinyur tersebut—rataan populasi yang sebenarnya adalah $\mu = 173$, berapakah peluang bahwa insinyur tersebut melakukan galat tipe II?


Solusi

Dalam kasus ini, insinyur tersebut melakukan galat tipe II jika rataan sampel yang diamatinya tidak berada di daerah penolakan, yaitu jika kurang dari 172, padahal rataan populasi yang sebenarnya (dan tidak diketahui) adalah 173. Secara grafis, β , peluang insinyur tersebut melakukan galat tipe II tampak seperti berikut:



Gambar 10.3 — Ketika $\mu = 173$, gagal menolak H_0 terjadi untuk rataan sampel kurang dari 172; luas daerah itu adalah $\beta = 0,3085$.

Sekali lagi, kita dapat menghitung nilai β bagi insinyur tersebut dengan mentransformasikan distribusi Normal yang memiliki rataan 173 dan simpangan baku 10 menjadi Z , distribusi Normal baku. Dengan demikian, kita peroleh:



Gambar 10.4 — Setelah standardisasi di bawah $\mu = 173$, peluang berada di bawah batas penolakan 172 adalah 0,3085.

Dengan demikian, peluang insinyur melakukan galat tipe II sekali lagi dapat dihitung sebagai suatu peluang Normal. Nilainya adalah 0,3085, seperti diilustrasikan berikut:

$$\beta = P(\bar{X} < 172 \text{ if } \mu = 173) = P(Z < -0.50) = 0.3085$$

Peluang 0,3085 agak tinggi. Dalam pelajaran ini, kita akan mempelajari cara insinyur tersebut dapat memperkecil peluang melakukan galat tipe II.



Metafora gelas setengah kosong atau setengah penuh: kuasa uji adalah komplemen peluang galat tipe II.

Jika dipikirkan, memperhatikan peluang melakukan galat tipe II mirip dengan memandang gelas sebagai setengah kosong. Alih-alih memperhatikan peluang bahwa insinyur tersebut melakukan galat, kita dapat memperhatikan peluang bahwa ia mengambil keputusan yang benar. Untuk itu, kita menghitung besaran yang disebut kuasa uji hipotesis.


Def. 10.1 (Kuasa Uji) Besarnya **kuasa** suatu uji hipotesis adalah peluang mengambil keputusan yang benar jika hipotesis alternatif benar. Artinya, kuasa uji hipotesis adalah peluang menolak hipotesis nol H_0 ketika hipotesis alternatif H_a merupakan hipotesis yang benar.

Mari kita kembali ke masalah insinyur tadi untuk melihat apakah kita dapat memandang gelas sebagai setengah penuh!

Contoh 10.5 Melanjutkan contoh sebelumnya, jika—tanpa diketahui insinyur tersebut—rataan populasi yang sebenarnya adalah $\mu = 173$, berapakah peluang bahwa insinyur tersebut mengambil keputusan yang benar dengan menolak hipotesis nol untuk mendukung hipotesis alternatif?

Solusi

Dalam kasus ini, insinyur tersebut mengambil keputusan yang benar jika rataan sampel yang diamatinya berada di daerah penolakan, yaitu jika sekurang-kurangnya 172, ketika rataan populasi yang sebenarnya (dan tidak diketahui) adalah 173. Secara grafis, kuasa uji hipotesis insinyur tersebut tampak seperti berikut:



Gambar 10.5 — Ketika $\mu = 173$, peluang rata-rata sampel masuk ke daerah penolakan mulai 172 adalah kuasa $0,6915 = 1 - 0,3085$.

Dengan demikian, kuasa uji hipotesis insinyur tersebut adalah 0,6915, seperti diilustrasikan berikut:

$$\text{Power} = P(\bar{X} \geq 172 \text{ if } \mu = 173) = P(Z \geq -0.50) = 0.6915$$

yang tentu saja juga dapat dihitung dengan mengurangi peluang melakukan galat tipe II dari 1, seperti berikut:

$$\text{Power} = 1 - \beta = 1 - 0.3085 = 0.6915$$

Bagaimanapun, jika rata-rata populasi yang tidak diketahui adalah 173, uji hipotesis insinyur tersebut setidaknya sedikit lebih baik daripada melempar koin seimbang, yang hanya memberinya peluang 50% untuk memilih hipotesis yang benar. Dalam kasus ini, peluangnya adalah 69,15%. Ia masih dapat memperbaikinya.

Secara umum, untuk setiap uji hipotesis yang kita lakukan, kita ingin:

1. **Meminimumkan peluang melakukan galat tipe I.** Artinya, meminimumkan $\alpha = P(\text{Type I error})$. Umumnya, tingkat signifikansi sebesar $\alpha \leq 0.10$ diinginkan.
2. **Memaksimumkan kuasa** (pada nilai parameter di bawah hipotesis alternatif yang bermakna secara ilmiah). Umumnya, kita menginginkan kuasa sebesar 0,80 atau lebih. Sebagai alternatif, kita dapat meminimumkan $\beta = P(\text{Type II error})$, dengan menargetkan tingkat galat tipe II sebesar 0,20 atau kurang.

Omong-omong, pada butir kedua, apa sebenarnya arti “pada nilai parameter di bawah hipotesis alternatif yang bermakna secara ilmiah”? Misalkan seorang peneliti medis ingin menguji hipotesis nol bahwa rata-rata kadar kolesterol total dalam darah pada suatu populasi pasien adalah 200 mg/dl melawan hipotesis alternatif bahwa rata-rata kadar kolesterol total dalam darah lebih besar daripada 200 mg/dl. Hipotesis alternatif tersebut memuat tak terhingga banyak kemungkinan nilai rata-rata. Di bawah hipotesis alternatif, rata-rata populasi dapat bernilai 201, 202, 210, dan nilai-nilai lainnya. Misalkan peneliti medis itu menolak hipotesis nol karena rata-ratanya 201. Lalu apa istimewanya—apakah itu akan menjadi kesimpulan yang menggemparkan? Mungkin tidak. Sebaliknya, misalkan peneliti medis itu menolak hipotesis nol karena rata-ratanya 215. Dalam kasus tersebut, rata-ratanya cukup jauh berbeda dari rata-rata yang diasumsikan di bawah hipotesis nol sehingga kita mungkin akan menganggap hasilnya menarik. Singkatnya, dalam contoh ini, kita mungkin semua sepakat menganggap rata-rata 215 “bermakna secara ilmiah”, sedangkan rata-rata 201 tidak.

Tentu saja, seluruh pembicaraan ini terdengar agak tidak masuk akal karena kita tidak akan pernah benar-benar mengetahui apakah rata-rata populasi yang sebenarnya dan tidak diketahui adalah 201 atau 215; jika mengetahuinya, kita tidak perlu menjalani proses pengujian hipotesis tentang rata-rata tersebut. Namun, ada hal

yang dapat kita lakukan. Kita dapat merencanakan penelitian ilmiah agar uji hipotesis kita memiliki kuasa yang memadai untuk menolak hipotesis nol guna mendukung nilai-nilai parameter di bawah hipotesis alternatif yang bermakna secara ilmiah.

10.3.2 Fungsi Kuasa


Mari kita lihat contoh lain yang melibatkan penghitungan kuasa uji hipotesis.

Contoh 10.6 Misalkan X menyatakan IQ seorang warga Amerika dewasa yang dipilih secara acak. Anggaplah, meskipun agak tidak realistis, bahwa X berdistribusi Normal dengan rata-rata yang tidak diketahui μ dan simpangan baku 16. Ambil sampel acak sebanyak $n = 16$ mahasiswa; namun, mahasiswa bukan dengan sendirinya kerangka sampel acak bagi populasi warga Amerika dewasa. Dengan keterbatasan itu, setelah menetapkan peluang melakukan galat tipe I sebesar $\alpha = 0.05$, kita dapat menguji hipotesis nol $H_0 : \mu = 100$ terhadap hipotesis alternatif bahwa $H_a : \mu > 100$.

Berapakah kuasa uji hipotesis jika rata-rata populasi yang sebenarnya adalah $\mu = 108$?

Solusi

Dengan menetapkan α , yaitu peluang melakukan galat tipe I, sebesar 0,05, berarti bahwa kita harus menolak hipotesis nol ketika statistik uji $Z \geq 1.645$, atau secara ekuivalen, ketika rata-rata sampel teramati sebesar 106,58 atau lebih:



Gambar 10.6 — Batas $Z = 1,645$, yang setara dengan rata-rata sampel 106,58, menentukan daerah penolakan ekor kanan bertaraf 0,05.

karena kita mentransformasikan statistik uji Z ke rata-rata sampel melalui:


$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}, \quad \bar{X} = \mu + Z \frac{\sigma}{\sqrt{n}}$$

$$\bar{X} = 100 + 1.645 \left(\frac{16}{\sqrt{16}} \right) = 106.58$$

Sekarang, hal itu berarti bahwa kuasa, yaitu peluang menolak hipotesis nol, ketika $\mu = 108$ adalah 0,6406 sebagaimana dihitung di sini (ingat bahwa $\Phi(z)$ merupakan notasi baku untuk fungsi distribusi kumulatif peubah acak Normal baku):

$$\begin{aligned}\text{Power} &= P(\bar{X} \geq 106.58 \mid \mu = 108) = P\left(Z \geq \frac{106.58 - 108}{16/\sqrt{16}}\right) \\ &= P(Z \geq -0.36) = 1 - P(Z < -0.36) = 1 - \Phi(-0.36)\end{aligned}$$

dan diilustrasikan di sini:



Gambar 10.7 — Untuk $\mu = 108$, peluang rata-rata sampel sekurang-kurangnya 106,58 adalah kuasa 0,6406.

Singkatnya, kita telah menentukan bahwa kita (hanya) memiliki peluang 64,06% untuk menolak hipotesis nol $H_0 : \mu = 100$ demi mendukung hipotesis alternatif $H_a : \mu > 100$, jika rata-rata populasi sebenarnya yang tidak diketahui pada kenyataannya adalah $\mu = 108$.

Bagian II


Melanjutkan contoh ini, berapakah kuasa uji hipotesis jika rata-rata populasi yang sebenarnya adalah $\mu = 112$?

Solusi

Karena kita menetapkan α , yaitu peluang melakukan galat tipe I, sebesar 0,05, kita kembali menolak hipotesis nol ketika statistik uji $Z \geq 1.645$, atau secara ekuivalen, ketika rata-rata sampel teramati sebesar 106,58 atau lebih. Artinya, peluang menolak hipotesis nol ketika $\mu = 112$, adalah 0,9131 sebagaimana dihitung di sini:

$$\begin{aligned}\text{Power} &= P(\bar{X} \geq 106.58 \text{ when } \mu = 112) \\ &= P\left(Z \geq \frac{106.58 - 112}{\frac{16}{\sqrt{16}}}\right) \\ &= P(Z \geq -1.36) \\ &= 1 - P(Z < -1.36) \\ &= 1 - \Phi(-1.36) \\ &= 1 - 0.0869 = 0.9131\end{aligned}$$

dan diilustrasikan di sini:



Gambar 10.8 — Untuk $\mu = 112$, peluang rata-rata sampel sekurang-kurangnya 106,58 adalah kuasa 0,9131.

Singkatnya, kita telah menentukan bahwa sekarang kita memiliki peluang 91,31% untuk menolak hipotesis nol $H_0 : \mu = 100$ demi mendukung hipotesis alternatif $H_a : \mu > 100$ jika rata-rata populasi sebenarnya yang tidak diketahui pada kenyataannya adalah $\mu = 112$. Hmm.... seharusnya masuk akal bahwa peluang menolak hipotesis nol lebih besar untuk nilai rata-rata, seperti 112, yang jauh dari rata-rata yang diasumsikan di bawah hipotesis nol.

Bagian III


Sekali lagi, melanjutkan contoh sebelumnya. Berapakah kuasa uji hipotesis jika rata-rata populasi yang sebenarnya adalah $\mu = 116$?

Solusi

Sekali lagi, karena kita menetapkan α , yaitu peluang melakukan galat tipe I, sebesar 0,05, kita menolak hipotesis nol ketika statistik uji $Z \geq 1.645$, atau secara ekuivalen, ketika rata-rata sampel teramati sebesar 106,58 atau lebih. Artinya, peluang menolak hipotesis nol ketika $\mu = 116$ adalah 0,9909 sebagaimana dihitung di sini:

$$\begin{aligned}
 \text{Power} &= P(\bar{X} \geq 106.58 \text{ when } \mu \\
 &= 116) = P\left(Z \geq \frac{106.58 - 116}{\frac{16}{\sqrt{16}}}\right) \\
 &= P(Z \geq -2.36) \\
 &= 1 - P(Z < -2.36) \\
 &= 1 - \Phi(-2.36) \\
 &= 1 - 0.0091 = 0.9909
 \end{aligned}$$

dan diilustrasikan di sini:



Gambar 10.9 — Untuk $\mu = 116$, peluang rata-rata sampel sekurang-kurangnya 106,58 adalah kuasa 0,9909.

Singkatnya, kita telah menentukan bahwa dalam kasus ini kita memiliki peluang 99,09% untuk menolak hipotesis nol $H_0 : \mu = 100$ demi mendukung hipotesis alternatif $H_a : \mu > 100$ jika rata-ran populasi sebenarnya yang tidak diketahui pada kenyataannya adalah $\mu = 116$. Peluang menolak hipotesis nol adalah yang terbesar di antara semua peluang yang telah kita hitung, karena rata-ran 116 paling jauh dari rata-ran yang diasumsikan di bawah hipotesis nol.

Apakah Anda mulai jenuh dengan pembahasan ini? Mari kita rangkum beberapa hal yang telah kita pelajari dari latihan ini:

1. Pertama dan terutama, pengajar saya terkadang bisa menjemukan..... eh, maksud saya, pertama dan terutama, kuasa uji hipotesis bergantung pada nilai parameter yang dikaji. Dalam contoh di atas, kuasa uji hipotesis bergantung pada nilai rata-ran μ .
2. Ketika rata-ran sebenarnya μ bergerak semakin jauh ke kanan dari nilai rata-ran $\mu = 100$ di bawah hipotesis nol, kuasa uji hipotesis meningkat.

Pokok pertama itulah yang membawa kita pada sesuatu yang disebut **fungsi kuasa uji hipotesis**. Jika kembali melihat uraian di atas, Anda akan melihat bahwa setiap penghitungan kuasa yang kita lakukan melibatkan sebuah langkah yang tampak seperti ini:


$$\text{Power} = 1 - \Phi(z)$$

Artinya, jika kita menggunakan notasi baku $K(\mu)$ untuk menyatakan fungsi kuasa yang bergantung pada μ , kita memperoleh:

$$K(\mu) = 1 - \Phi\left(\frac{106.58 - \mu}{16/\sqrt{16}}\right)$$

Jadi, sebenarnya pengajar Anda bisa saja jauh lebih menjemukan dengan menghitung kuasa untuk **setiap** nilai yang mungkin dari μ di bawah hipotesis alternatif! Sebagai gantinya, kita dapat membuat grafik fungsi kuasa, dengan rata-ran μ pada sumbu horizontal dan kuasa $K(\mu)$ pada sumbu vertikal. Dengan melakukannya, dalam kasus ini kita memperoleh grafik yang tampak seperti berikut:

The power function of $K(\mu)$




Gambar 10.10 — Fungsi kuasa $K(\mu)$ bagi uji $H_0: \mu = 100$ melawan $H_a: \mu > 100$ dengan $n = 16$ dan $\alpha = 0,05$.

Sekarang, apa yang dapat kita pelajari dari grafik ini?

Nah:

1. Kita dapat melihat bahwa α (peluang terjadinya galat tipe I), β (peluang terjadinya galat tipe II), dan $K(\mu)$ semuanya ditampilkan pada grafik fungsi kuasa, seperti diilustrasikan di sini:

The power function of $K(\mu)$



Gambar 10.11 — Pada fungsi kuasa, $K(100) = \alpha$; untuk μ alternatif, $K(\mu)$ adalah kuasa dan $\beta(\mu) = 1 - K(\mu)$.

- Kita dapat melihat bahwa peluang terjadinya galat tipe I adalah $\alpha = K(100) = 0.05$, yaitu peluang menolak hipotesis nol ketika hipotesis nol benar adalah 0,05.
- Kita dapat melihat kuasa uji $K(\mu)$, serta peluang terjadinya galat tipe II $\beta(\mu)$, untuk setiap nilai yang mungkin dari μ .
- Kita dapat melihat bahwa $\beta(\mu) = 1 - K(\mu)$ dan sebaliknya, yakni $K(\mu) = 1 - \beta(\mu)$.
- Dan secara grafis kita dapat melihat bahwa, memang, ketika rata-rata sebenarnya μ bergerak semakin jauh ke kanan dari rata-rata di bawah hipotesis nol $\mu = 100$, kuasa uji hipotesis meningkat.


Sekarang, menurut Anda apa yang akan terjadi pada kuasa uji hipotesis jika kita mengubah besarnya peluang galat tipe I yang bersedia kita tanggung? Apakah kuasa untuk nilai μ tertentu akan meningkat, menurun, atau tetap sama? Sebagai contoh, misalkan kita ingin menetapkan $\alpha = 0.01$ alih-alih $\alpha = 0.05$. Mari kita kembali ke contoh untuk menelaah pertanyaan ini.

Contoh 10.7 Misalkan X menyatakan IQ seorang warga Amerika dewasa yang dipilih secara acak. Anggaplah, meskipun agak tidak realistis, bahwa X berdistribusi Normal dengan rata-rata yang tidak diketahui μ dan simpangan baku 16. Ambil sampel acak sebanyak $n = 16$ mahasiswa; namun, mahasiswa bukan dengan sendirinya kerangka sampel acak bagi populasi warga Amerika dewasa. Dengan keterbatasan itu, setelah menetapkan peluang melakukan galat tipe I sebesar $\alpha = 0.01$, kita dapat menguji hipotesis nol $H_0 : \mu = 100$ terhadap hipotesis alternatif bahwa $H_a : \mu > 100$.

Berapakah kuasa uji hipotesis jika rata-rata populasi yang sebenarnya adalah $\mu = 108$?

Solusi

Dengan menetapkan α , yaitu peluang melakukan galat tipe I, sebesar 0,01, berarti bahwa kita harus menolak hipotesis nol ketika statistik uji $Z \geq 2.326$, atau secara ekuivalen, ketika rata-rata sampel teramati sebesar 109,304 atau lebih:




Gambar 10.12 — Batas $Z = 2,326$, atau rata-rata sampel 109,304, menentukan daerah penolakan ekor kanan bertaraf 0,01.

$$\bar{x} = \mu + z \left(\frac{\sigma}{\sqrt{n}} \right) = 100 + 2.326 \left(\frac{16}{\sqrt{16}} \right) = 109.304$$

Artinya, peluang menolak hipotesis nol ketika $\mu = 108$ adalah 0,3722 sebagaimana dihitung di sini:

$$\begin{aligned} \text{Power} &= P(\bar{X} \geq 109.304 \text{ when } \mu = 108) = P\left(Z \geq \frac{109.304 - 108}{\frac{16}{\sqrt{16}}}\right) \\ &= P(Z \geq 0.326) = 1 - P(Z < 0.326) = 1 - \Phi(0.326) \\ &= 1 - 0.6278 = 0.3722 \end{aligned}$$

Jadi, kuasa ketika $\mu = 108$ dan $\alpha = 0.01$ lebih kecil (0,3722) daripada kuasa ketika $\mu = 108$ dan $\alpha = 0.05$ (0,6406)! Mungkin kita dapat melihatnya secara grafis:




Gambar 10.13 — Pada $\mu = 108$, kuasa adalah 0,3722 untuk $\alpha = 0,01$ dan 0,6406 untuk $\alpha = 0,05$.

Omong-omong, sebagai alternatif kita dapat kembali memandang gelas sebagai setengah kosong. Dalam hal ini, peluang terjadinya galat tipe II ketika $\mu = 108$ dan $\alpha = 0.01$ adalah $1 - 0.3722 = 0.6278$. Dalam kasus ini, peluang terjadinya galat tipe II lebih besar daripada peluang terjadinya galat tipe II ketika $\mu = 108$ dan $\alpha = 0.05$.

Semua ini dapat dilihat secara grafis dengan memplot kedua fungsi kuasa, yang satu ketika $\alpha = 0.01$ dan yang lain ketika $\alpha = 0.05$, secara bersamaan. Dengan melakukannya, kita memperoleh grafik yang tampak seperti ini:

The power function of $K(\mu)$



Perbandingan fungsi kuasa untuk $\alpha = 0,01$ dan $\alpha = 0,05$ pada ukuran sampel yang sama.

Contoh terakhir ini mengilustrasikan bahwa dengan syarat ukuran sampel n tetap, penurunan α menyebabkan peningkatan β , dan, setidaknya secara teoretis, walaupun tidak secara praktis, penurunan β menyebabkan peningkatan α . Dalam pengaturan uji rata-rata Normal ini, dengan faktor lain tetap, α dan β dapat dikurangi secara bersamaan dengan meningkatkan ukuran sampel dalam rancangan ini. Di luar rancangan tetap tersebut, pengukuran yang lebih baik, varians yang lebih kecil, rancangan yang lebih kuat, atau uji yang lebih efisien juga dapat memperbaiki kedua galat. n .

10.3.3 Menghitung Ukuran Sampel


Sebelum mempelajari cara menghitung ukuran sampel yang diperlukan agar suatu uji hipotesis memiliki kuasa uji tertentu, ada baiknya kita memahami pengaruh ukuran sampel terhadap kuasa uji. Mari kita selidiki dengan kembali ke contoh IQ kita.

Contoh 10.8 Misalkan X menyatakan IQ seorang warga Amerika dewasa yang dipilih secara acak. Asumsikan, sekali lagi dengan sedikit tidak realistis, bahwa X berdistribusi Normal dengan rata-rata yang tidak diketahui μ dan simpangan baku (yang anehnya diketahui) sebesar 16. Kali ini, alih-alih mengambil sampel acak sebanyak $n = 16$ mahasiswa—dengan catatan bahwa mahasiswa bukan dengan sendirinya kerangka sampel acak bagi populasi warga Amerika dewasa—mari kita tingkatkan ukuran sampel menjadi $n = 64$. Sementara itu, dengan menetapkan peluang melakukan galat tipe I sebesar $\alpha = 0.05$, ujilah hipotesis nol $H_0 : \mu = 100$ terhadap hipotesis alternatif bahwa $H_a : \mu > 100$.

Berapakah kuasa uji hipotesis ketika $\mu = 108$, $\mu = 112$, dan $\mu = 116$?

Solusi

Menetapkan α , yaitu peluang melakukan galat tipe I, sebesar 0,05 berarti bahwa kita harus menolak hipotesis nol ketika statistik uji $Z \geq 1.645$, atau secara ekuivalen, ketika rata-rata sampel teramati sebesar 103,29 atau lebih:



Gambar 10.14 — Dengan $n = 64$ dan $\alpha = 0,05$, daerah penolakan dimulai pada rata-rata sampel 103,29.

karena:

$$\begin{aligned}\bar{x} &= \mu + z \left(\frac{\sigma}{\sqrt{n}} \right) \\ &= 100 + 1.645 \left(\frac{16}{\sqrt{64}} \right) = 103.29\end{aligned}$$

Oleh karena itu, fungsi kuasa $K(\mu)$, ketika $\mu > 100$ merupakan nilai sebenarnya, adalah:

$$\begin{aligned}K(\mu) &= P(\bar{X} \geq 103.29 | \mu) \\ &= P\left(Z \geq \frac{103.29 - \mu}{16/\sqrt{64}}\right) \\ &= 1 - \Phi\left(\frac{103.29 - \mu}{2}\right)\end{aligned}$$

Oleh karena itu, peluang menolak hipotesis nol pada tingkat $\alpha = 0.05$ ketika $\mu = 108$ bernilai 0,9907, sebagaimana dihitung di sini:

$$K(108) = 1 - \Phi\left(\frac{103.29 - 108}{2}\right) = 1 - \Phi(-2.355) = 0.9907$$

Selanjutnya, peluang menolak hipotesis nol pada tingkat $\alpha = 0.05$ ketika $\mu = 112$ bernilai lebih besar dari 0,9999, sebagaimana dihitung di sini:

$$\begin{aligned}K(112) &= 1 - \Phi\left(\frac{103.29 - 112}{2}\right) \\ &= 1 - \Phi(-4.355) \\ &= 0.9999 \dots\end{aligned}$$

Selanjutnya, peluang menolak hipotesis nol pada tingkat $\alpha = 0.05$ ketika $\mu = 116$ bernilai lebih besar dari 0,999999, sebagaimana dihitung di sini:

$$\begin{aligned}K(116) &= 1 - \Phi\left(\frac{103.29 - 116}{2}\right) \\ &= 1 - \Phi(-6.355) \\ &= 0.999999 \dots\end{aligned}$$


Singkatnya, dalam berbagai contoh di sepanjang pelajaran ini, kita telah menghitung kuasa uji untuk $H_0 : \mu = 100$ terhadap $H_a : \mu > 100$ untuk dua ukuran sampel ($n = 16$ dan $n = 64$) dan untuk tiga nilai rata-rata yang mungkin ($\mu = 108$, $\mu = 112$, dan $\mu = 116$). Berikut ringkasan perhitungan kuasa uji kita:

Kuasa $K(\mu)$ untuk $n = 16$ dan $n = 64$ pada $\mu = 108, 112$, dan 116 .

Kuasa Uji	$K(108)$	$K(112)$	$K(116)$
$n = 16$	0.6406	0.9131	0.9909
$n = 64$	0.9907	0.9999...	0.999999...

Seperti terlihat, hasil kita menunjukkan bahwa untuk nilai rata-rata tertentu μ di bawah hipotesis alternatif, makin besar ukuran sampel n , makin besar kuasa uji $K(u)$. Barangkali tidak ada cara yang lebih baik untuk melihat hal ini daripada secara grafis dengan memplot kedua fungsi kuasa secara bersamaan, yang satu ketika $n = 16$ dan yang lain ketika $n = 64$:

The power function of $K(\mu)$



Gambar 10.15 — Pada α yang sama, memperbesar ukuran sampel dari 16 menjadi 64 meningkatkan kuasa untuk $\mu > 100$.


Seperti ditunjukkan oleh grafik ini, jika kita ingin meningkatkan peluang menolak hipotesis nol ketika hipotesis alternatif benar, kita dapat melakukannya dengan meningkatkan ukuran sampel n . Manfaat ini mungkin paling besar untuk nilai rata-rata yang dekat dengan nilai rata-rata yang diasumsikan di bawah hipotesis nol. Mari kita lihat dua contoh yang menggambarkan perhitungan ukuran sampel yang dapat kita lakukan untuk memastikan uji hipotesis kita memiliki kuasa uji yang memadai.

Contoh 10.9 Misalkan X menyatakan hasil panen jagung yang diukur sebagai banyaknya bushel per ekar. Asumsikan (secara tidak realistis) bahwa X berdistribusi Normal dengan rata-rata yang tidak diketahui μ dan simpangan baku $\sigma = 6$. Seorang peneliti pertanian sedang berupaya meningkatkan hasil panen rata-rata yang

saat ini sebesar 40 bushel per ekar. Oleh karena itu, ia ingin menguji, dengan $\alpha = 0.05$ sebagai tingkat signifikansi, hipotesis nol $H_0 : \mu = 40$ terhadap hipotesis alternatif bahwa $H_a : \mu > 40$. Tentukan ukuran sampel n yang diperlukan untuk mencapai kuasa uji 0,90 pada nilai alternatif $\mu = 45$.

Solusi

Seperti biasa, kita perlu memulai dengan menentukan nilai ambang c , sedemikian sehingga jika rata-ran sampel lebih besar daripada c , kita akan menolak hipotesis nol:




Gambar 10.16 — Batas c dipilih agar peluang ekor kanan di bawah $H_0: \mu = 40$ sama dengan taraf yang ditentukan.

Dengan kata lain, agar uji hipotesis kita dilakukan dengan $\alpha = 0.05$ sebagai tingkat signifikansi, pernyataan berikut harus berlaku (dengan menggunakan transformasi Z yang biasa kita gunakan):

$$c = 40 + 1.645 \left(\frac{6}{\sqrt{n}} \right)$$

Namun, itu bukan satu-satunya syarat yang harus c penuhi, karena c juga perlu ditentukan untuk memastikan bahwa kuasa uji kita sebesar 0,90 atau, secara ekuivalen, bahwa peluang galat tipe II sebesar 0,10. Hal itu akan terjadi jika ada peluang 10% bahwa statistik uji kita kurang dari c ketika $\mu = 45$, sebagaimana ditunjukkan dengan warna biru pada gambar berikut:



Gambar 10.17 — Satu batas c memenuhi sasaran galat tipe I di bawah $\mu = 40$ dan galat tipe II di bawah $\mu = 45$.

Ilustrasi ini menunjukkan bahwa agar uji hipotesis kita memiliki kuasa uji 0,90, pernyataan berikut harus berlaku (dengan menggunakan transformasi Z yang biasa kita gunakan):

$$c = 45 - 1.28 \left(\frac{6}{\sqrt{n}} \right)$$

Aha! Kita memiliki dua persamaan ((1) dan (2)) dan dua variabel yang tidak diketahui! Kita hanya perlu menyamakan kedua persamaan itu dan menyelesaikannya untuk n . Dengan demikian, kita memperoleh:

$$\begin{aligned} 40 + 1.645 \left(\frac{6}{\sqrt{n}} \right) &= 45 - 1.28 \left(\frac{6}{\sqrt{n}} \right) \\ \Rightarrow 5 &= (1.645 + 1.28) \left(\frac{6}{\sqrt{n}} \right), \quad \Rightarrow 5 = \frac{17.55}{\sqrt{n}}, \quad n = (3.51)^2 = 12.3201 \approx 13 \end{aligned}$$

Setelah mengetahui bahwa kita akan menetapkan $n = 13$, kita dapat menentukan nilai ambang c :

$$c = 40 + 1.645 \left(\frac{6}{\sqrt{13}} \right) = 42.737$$

Jadi, singkatnya, jika peneliti pertanian tersebut mengumpulkan data dari $n = 13$ petak jagung, dan menolak hipotesis nolnya $H_0 : \mu = 40$ jika rata-rata hasil panen dari 13 petak tersebut lebih besar daripada 42,737445 bushel per ekar, ia akan memiliki peluang galat tipe I sekitar 4,9985% dan peluang galat tipe II sekitar 8,6974% (kuasa sekitar 91,3026%) jika rata-rata populasi μ benar-benar sebesar 45 bushel per ekar.

Bagian II


Misalkan p , yaitu proporsi sebenarnya pemilih yang mendukung kandidat politik tertentu. Seorang pelaksana jajak pendapat ingin menguji, dengan $\alpha = 0.01$ sebagai tingkat signifikansi, hipotesis nol $H_0 : p = 0.5$ terhadap hipotesis alternatif bahwa $H_a : p > 0.5$. Tentukan ukuran sampel n yang diperlukan untuk mencapai kuasa uji 0,80 pada nilai alternatif $p = 0.55$.

Solusi

Dalam kasus ini, karena kita ingin melakukan uji hipotesis mengenai proporsi populasi p , kita menggunakan statistik Z :

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

Sekali lagi, kita mulai dengan menentukan nilai ambang c , sedemikian sehingga jika proporsi sampel teramati lebih besar daripada c , kita akan menolak hipotesis nol:




Gambar 10.18 — Dalam rancangan hampiran, batas $\hat{p} = 0.5367$ menentukan daerah penolakan ekor kanan bertarget $\alpha = 0.01$.

Dengan kata lain, agar uji hipotesis kita dilakukan dengan $\alpha = 0.01$ sebagai tingkat signifikansi, pernyataan berikut harus berlaku:

$$c = 0.5 + 2.326\sqrt{\frac{(0.5)(0.5)}{n}}$$

Namun, sekali lagi, c tidak hanya harus memenuhi syarat itu, karena c juga perlu ditentukan untuk memastikan bahwa kuasa uji kita sebesar 0,80 atau, secara ekuivalen, bahwa peluang galat tipe II sebesar 0,20. Hal itu akan terjadi jika ada peluang 20% bahwa statistik uji kita kurang dari c ketika $p = 0.55$, sebagaimana ditunjukkan dengan warna biru pada gambar berikut:



Gambar 10.19 — Batas $\hat{p} = 0,5367$ menghubungkan sasaran hampiran α di bawah $p = 0,50$ dan β di bawah $p = 0,55$.

Ilustrasi ini menunjukkan bahwa agar uji hipotesis kita memiliki kuasa uji 0,80, pernyataan berikut harus berlaku:

$$c = 0.55 - 0.842 \sqrt{\frac{(0.55)(0.45)}{n}}$$

Sekali lagi, kita memiliki dua persamaan ((3) dan (4)) dan dua variabel yang tidak diketahui! Kita hanya perlu menyamakan kedua persamaan itu dan menyelesaikannya untuk n . Dengan demikian, kita memperoleh:

$$\begin{aligned} 0.5 + 2.326 \sqrt{\frac{0.5(0.5)}{n}} &= 0.55 - 0.842 \sqrt{\frac{0.55(0.45)}{n}} \\ 2.326 \frac{\sqrt{0.25}}{\sqrt{n}} + 0.842 \frac{\sqrt{0.2475}}{\sqrt{n}} &= 0.55 - 0.5 \\ \frac{1}{\sqrt{n}} (1.5818897) &= 0.05 \\ \Rightarrow n &\approx \left(\frac{1.5818897}{0.05} \right)^2 \\ &= 1000.95 \approx 1001 \end{aligned}$$

Setelah mengetahui bahwa kita akan menetapkan $n = 1001$, kita dapat menentukan nilai ambang c :

$$c = 0.5 + 2.326 \sqrt{\frac{(0.5)(0.5)}{1001}} = 0.5367$$

Jadi, singkatnya, jika pelaksana jajak pendapat tersebut mengumpulkan data dari $n = 1001$ pemilih, dan menolak hipotesis nolnya $H_0 : p = 0.5$ jika proporsi pemilih dalam sampel yang mendukung kandidat politik tersebut lebih besar daripada 0,5367 (yakni sekurang-kurangnya 538 dari 1001 pemilih), rancangan hampiran Normal ini menargetkan peluang galat tipe I 1% dan peluang galat tipe II 20%; secara Binomial eksak, peluangnya masing-masing sekitar 0,9647% dan 20,3437% jika proporsi populasi p benar-benar sebesar 0,55.

Sebagai catatan, kita selalu dapat memeriksa perhitungan hampiran Normal tersebut! Jika survei dan uji hipotesis selanjutnya dilakukan sebagaimana dijelaskan di atas, peluang hampiran melakukan galat tipe I adalah:

$$\begin{aligned}\hat{p} > 0.5367 &\iff X \geq 538, \\ \alpha_{\text{Normal}} &\approx 0.01, \\ \alpha_{\text{exact}} &= P_{p=0.50}(X \geq 538) = 0.009647335485396\end{aligned}$$

dan peluang hampiran melakukan galat tipe II adalah:

$$\begin{aligned}\beta_{\text{Normal}} &\approx 0.199, \\ \beta_{\text{exact}} &= P_{p=0.55}(X \leq 537) = 0.203436671383695\end{aligned}$$

sesuai dengan target hampiran Normal yang diinginkan oleh pelaksana jajak pendapat tersebut, tetapi bukan nilai Binomial eksak.

Kita telah mengilustrasikan beberapa perhitungan ukuran sampel. Sekarang, mari kita rangkum informasi yang digunakan dalam perhitungan ukuran sampel. Untuk menentukan ukuran sampel bagi suatu uji hipotesis, Anda perlu menetapkan:

1. Tingkat signifikansi α yang diinginkan, yaitu kesediaan Anda untuk melakukan galat tipe I.
2. Kuasa uji yang diinginkan atau, secara ekuivalen, tingkat β yang diinginkan, yaitu kesediaan Anda untuk melakukan galat tipe II.
3. Perbedaan yang bermakna dari nilai parameter yang ditentukan dalam hipotesis nol.
4. Simpangan baku statistik sampel atau, setidaknya, suatu nilai dugaan bagi simpangan baku (“galat baku”) statistik sampel.

10.4 Uji Wald Hampiran

Dalam uji hipotesis yang telah kita kembangkan sejauh ini, kita perlu menentukan statistik uji dan mengetahui distribusi statistik uji tersebut di bawah hipotesis nol. Namun, bagaimana kita memilih statistik uji? Dapatkah kita selalu menentukan distribusinya? Apakah statistik uji itu didasarkan pada suatu statistik (atau penduga) yang memiliki sifat-sifat yang diinginkan?

Berdasarkan apa yang telah kita pelajari sejauh ini dalam mata kuliah ini, kita mengetahui bahwa MLE memiliki sifat-sifat yang diinginkan, khususnya di bawah syarat tertentu. Dalam pelajaran ini, kita memperkenalkan uji Wald. Uji ini secara umum dapat diterapkan dengan menggunakan MLE dan bertumpu pada normalitas asimtotik MLE.

10.4.1 Langkah Berikutnya

Seperti telah kita catat sebelumnya, jika setiap titik data x_i dipandang sebagai peubah acak, dengan

$$x_i \sim f_X(x|\theta)$$

maka setiap fungsi dari titik-titik data tersebut merupakan peubah acak. Secara khusus, MLE $\hat{\theta} = \operatorname{argmax}(L(\theta))$ merupakan fungsi dari data sehingga juga merupakan peubah acak. Dalam beberapa kasus sederhana, kita dapat menentukan distribusi $\hat{\theta}$ secara langsung, tetapi dalam banyak kasus kita tidak dapat melakukannya. Untungnya, di bawah syarat keteraturan yang sesuai terdapat hasil normalitas asimtotik untuk MLE pada model dengan distribusi f_X yang menghasilkan data tersebut; hasil ini memerlukan keteridentifikasi, parameter sebenarnya di bagian dalam ruang parameter, konsistensi, informasi nonsingular, serta syarat diferensiasi dan pertukaran yang sesuai, dan dapat gagal pada kasus tak teratur atau batas.

Untuk model berparameter tunggal, hasilnya adalah sebagai berikut:

Jika $L(\theta|x_1, x_2, \dots, x_n)$ adalah fungsi kemungkinan dan $\hat{\theta} = \operatorname{argmax}(L(\theta))$ adalah MLE, maka, ketika $n \rightarrow \infty$,

$$\sqrt{n}(\hat{\theta}_{ML} - \theta_0) \xrightarrow{d} N(0, I_1(\theta_0)^{-1})$$

dengan $I(\theta)$ adalah “informasi Fisher”, yang didefinisikan sebagai

$$I(\theta) = -E_x \left[\frac{\partial^2}{\partial \theta^2} \ell(\theta) \right]$$

dengan $\ell(\theta) = \log(L(\theta))$ dan nilai harapan diambil atas semua $x_1, x_2, \dots, x_n$.

Dalam kasus multivariat, ketika ada dua parameter atau lebih yang akan diduga, $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_p)$ adalah vektor dari p parameter yang akan diduga, dan distribusi asimtotiknya adalah sebagai berikut. Ketika $n \rightarrow \infty$,

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_{ML} - \boldsymbol{\theta}_0) \xrightarrow{d} N_p(\mathbf{0}, \mathbf{I}_1(\boldsymbol{\theta}_0)^{-1})$$

dengan $\mathbf{I}(\boldsymbol{\theta})$ adalah “matriks informasi Fisher”, yang didefinisikan sebagai

$$\mathbf{I}(\boldsymbol{\theta}) = \begin{bmatrix} -E_x \left[\frac{\partial^2}{\partial \theta_1^2} \ell(\boldsymbol{\theta}) \right] & -E_x \left[\frac{\partial^2}{\partial \theta_1 \partial \theta_2} \ell(\boldsymbol{\theta}) \right] & \cdots & -E_x \left[\frac{\partial^2}{\partial \theta_1 \partial \theta_p} \ell(\boldsymbol{\theta}) \right] \\ -E_x \left[\frac{\partial^2}{\partial \theta_2 \partial \theta_1} \ell(\boldsymbol{\theta}) \right] & -E_x \left[\frac{\partial^2}{\partial \theta_2^2} \ell(\boldsymbol{\theta}) \right] & \cdots & -E_x \left[\frac{\partial^2}{\partial \theta_2 \partial \theta_p} \ell(\boldsymbol{\theta}) \right] \\ \vdots & \vdots & & \vdots \\ -E_x \left[\frac{\partial^2}{\partial \theta_p \partial \theta_1} \ell(\boldsymbol{\theta}) \right] & -E_x \left[\frac{\partial^2}{\partial \theta_p \partial \theta_2} \ell(\boldsymbol{\theta}) \right] & \cdots & -E_x \left[\frac{\partial^2}{\partial \theta_p^2} \ell(\boldsymbol{\theta}) \right] \end{bmatrix}$$

di mana, sekali lagi, $\ell(\boldsymbol{\theta}) = \log(L(\boldsymbol{\theta}))$ dan nilai harapan diambil atas semua $x_1, x_2, \dots, x_n$. Hasil ini menjelaskan distribusi bersama hampiran dari MLE semua parameter. Dalam banyak situasi (termasuk sebagian besar uji hipotesis), hasil yang lebih berguna adalah distribusi marginal yang dihasilkan bagi setiap MLE. Jika komponen k -nya adalah θ_k , dan MLE untuk parameter ini adalah $\hat{\theta}_k$, maka langsung dari distribusi bersama di atas diperoleh bahwa distribusi marginal $\hat{\theta}_k$ secara asimtotik mendekati distribusi Gaussian, dengan

$$\hat{\theta}_k \approx N\left(\theta_{0,k}, [\mathbf{I}_n(\hat{\boldsymbol{\theta}})^{-1}]_{kk}\right)$$

Artinya, MLE $\hat{\theta}_k$ secara hampiran berdistribusi Normal univariat, dengan rata-rata berupa parameter sebenarnya θ_k dan varians yang sama dengan entri diagonal nomor k —yang terdapat pada invers $\mathbf{I}^{-1}(\hat{\boldsymbol{\theta}})$ dari matriks informasi Fisher.

Kita dapat menggunakan distribusi Gaussian hampiran asimtotik dari MLE yang dijelaskan sebelumnya untuk membentuk statistik uji yang berguna dalam menguji $H_0 : \theta_k = c$ terhadap $H_A : \theta_k \neq c$.

Karena kita mengetahui bahwa

$$\hat{\theta}_k \approx N\left(\theta_{0,k}, [\mathbf{I}_n(\hat{\boldsymbol{\theta}})^{-1}]_{kk}\right)$$

jika hipotesis nol menyatakan bahwa $\theta_k = c$, maka di bawah H_0 , distribusi MLE adalah

$$\hat{\theta}_k \approx N\left(c, [\mathbf{I}_n(\hat{\boldsymbol{\theta}})^{-1}]_{kk}\right) \quad \text{under } H_0$$

Mengikuti notasi di atas, kita memiliki statistik uji (yang kita tuliskan sebagai $\hat{\theta}_k$ di sini, sedangkan dalam uraian umum di atas kita menyebutnya T^*), dan kita mengetahui distribusi (hampiran) statistik ini ($T \sim N(c, \mathbf{I}^{-1}(\hat{\boldsymbol{\theta}})_{[k,k]})$ di bawah hipotesis nol). Namun, nilai- p yang benar harus didasarkan pada jarak T dan nilai MLE teramati dari c ; rumus sumber berikut tidak terpusat pada c dan tidak benar jika $c \neq 0$.

$$p = P_0(|T - c| \geq |\hat{\theta}_k - c|), \quad T \sim N(c, \widehat{se}_k^2)$$

Kita dapat menyederhanakannya sedikit. Jika terlebih dahulu kita mendefinisikan galat baku bernomor k , yaitu se_k sebagai

$$se_k = \sqrt{\mathbf{I}^{-1}(\hat{\boldsymbol{\theta}})_{[k,k]}}$$

kemudian, dengan mengurangkan rata-rata dan membaginya dengan se_k kita memperoleh

$$Z^* = \frac{\hat{\theta}_k - c}{se_k} \sim N(0, 1)$$

dengan $Z^* \approx N(0, 1)$. Nilai-p (peluang mengamati nilai yang sekurang-kurangnya sama ekstrem jika hipotesis nol benar) kemudian dapat ditulis sebagai

$$p = P(|Z| \geq |Z^*|) = P(Z \leq -|Z^*|) + P(Z \geq |Z^*|)$$

yang, dengan perlakuan batas kesamaan yang konsisten dan karena simetri distribusi Normal baku, sama dengan

$$p = 2 * P(Z \leq -|Z^*|) = 2\Phi(-|Z^*|)$$

Uji semacam ini, yang didasarkan pada distribusi Gaussian hampiran asimtotik dari MLE, disebut **uji Wald**.

10.4.2 Langkah-langkah Uji Wald

Untuk merangkum hasil di atas, jika $x_i \sim f_X(x|\boldsymbol{\theta})$ merupakan peubah acak yang saling bebas, dan kita ingin menguji hipotesis nol bahwa $H_0 : \theta_k = c$ terhadap hipotesis alternatif bahwa $H_A : \theta_k \neq c$, maka uji Wald untuk hipotesis ini dilakukan dengan langkah-langkah berikut:

1. Pertama, kita menentukan MLE semua parameter $\hat{\boldsymbol{\theta}}$ dalam model dan informasi Fisher yang bersesuaian $\mathbf{I}(\hat{\boldsymbol{\theta}})$.
2. Kemudian kita menentukan galat baku bernomor k , yaitu $se_k = \sqrt{\mathbf{I}^{-1}(\hat{\boldsymbol{\theta}})_{[k,k]}}$ dan membentuk statistik uji

$$Z^* = \frac{\hat{\theta}_k - c}{se_k}$$

3. Nilai-p Wald untuk uji ini adalah

$$p = 2 * P(Z \leq -|Z^*|) = 2\Phi(-|Z^*|)$$

4. Jika nilai-p yang dihitung di atas adalah $p \leq \alpha$ maka kita menolak H_0 dan menyatakan bahwa hasil uji konsisten dengan H_A . Jika nilai-p sama dengan α , tindakan pada batas harus ditetapkan secara eksplisit. Jika nilai-p yang dihitung di atas adalah $p > \alpha$ maka kita gagal menolak H_0 dan menyimpulkan bahwa bukti yang tersedia tidak cukup untuk menolak H_0 .

10.4.3 Contoh Pengujian Hipotesis

Pada bagian ini, kita menyajikan contoh pengujian hipotesis dengan berfokus pada uji Wald untuk MLE.

Contoh 10.10 (Contoh Pengujian Hipotesis Bernoulli/Binomial) Anggaplah sebuah kasino memiliki permainan peluang dengan peluang menang yang diumumkan sebesar 0.25. Anggaplah seseorang memainkan permainan peluang itu 20 kali dan menang tepat sekali. Berdasarkan pengalaman tersebut, apakah ada cukup bukti untuk menyimpulkan bahwa permainan peluang itu sebenarnya tidak memiliki tingkat kemenangan 25%?

Untuk merumuskan masalah ini sebagai uji hipotesis, terlebih dahulu kita memerlukan model statistika parametrik untuk data teramati. Kita mengasumsikan bahwa masing-masing dari 20 permainan yang dimainkan saling bebas dan masing-masing memiliki peluang p untuk menghasilkan “kemenangan”. Jadi

$$x_i \sim \text{Bern}(p), \quad i = 1, 2, \dots, 20$$

Data yang benar-benar teramati mencakup tepat satu kemenangan (tanpa mengurangi keumuman, misalkan $x_1 = 1$) dan 19 kekalahan (misalkan $x_2 = 0, x_3 = 0, \dots, x_{20} = 0$).

Tujuan kita adalah menentukan apakah ada cukup bukti untuk menyimpulkan bahwa tingkat kemenangan BUKAN 25%. Karena itu, kita menetapkan hipotesis nol bahwa

$$H_0 : p = 0.25$$

dengan hipotesis alternatif yang bersesuaian bahwa $H_A : p \neq 0.25$. Kita akan mempertimbangkan uji Wald untuk hipotesis ini. Sebelum menyusun uji tersebut, kita menetapkan tingkat signifikansi uji sebesar $\alpha = 0.05$, sehingga kita bersedia menolak hipotesis nol jika peluang (di bawah H_0) untuk mengamati statistik uji yang akan kita bentuk adalah 5% atau kurang.

Uji Hipotesis Wald Analitik untuk Data Bernoulli

Pertama-tama, kita mengilustrasikan cara menyusun uji hipotesis Wald secara analitik dengan mengikuti prosedur yang diuraikan di atas.

1. Pertama, kita menentukan MLE dan informasi Fisher untuk parameter p .

Dari contoh-contoh sebelumnya di kelas, kita mengetahui bahwa MLE-nya adalah

$$\hat{p} = \frac{\sum_{i=1}^{20} x_i}{20} = \frac{1}{20} = 0.05$$

dan bahwa informasi Fisher adalah

$$I(\hat{p}) = -E_x(\ell''(\hat{p})) = \frac{20}{\hat{p}(1-\hat{p})} = \frac{20}{.05(.95)} = 421.0526$$

2. Kemudian kita menentukan galat baku

$$se = \sqrt{1/I(\hat{p})} = \sqrt{1/421.0526} = 0.0487$$

dan membentuk statistik uji Wald

$$Z^* = \frac{\hat{p} - 0.25}{se} = \frac{0.05 - 0.25}{0.0487} = -4.104$$

3. Kemudian kita menentukan nilai-p statistik uji ini di bawah hipotesis nol

$$pval = 2 * P(Z \leq -|Z^*|) = 2 * P(Z \leq -4.104)$$

yang kita evaluasi di R (kode sumber mengasumsikan R dasar, tetapi tidak menyatakan versi atau lingkungan eksekusinya):

```
phat=.05
I=421.0526
se=sqrt(1/I)
```

```
Z.star=(.05-.25)/se
pval=2*pnorm(-abs(Z.star))
pval
```

```
[1] 4.062198e-05
```

yang menghasilkan nilai-p sebesar 0.0000406. Untuk $n=20$ dengan hanya satu kemenangan dan parameter di dekat batas, hampiran Wald ini sangat tidak andal: nilai-p eksak dua sisi adalah sekitar 0.048625249730321 jika ekor kiri digandakan atau 0.038177041808922 jika hasil diurutkan menurut peluang.

4. Karena nilai-p Wald ini jauh lebih kecil daripada tingkat $\alpha = 0.05$, kita menolak $H_0 : p = 0.25$ dan menyimpulkan bahwa data memberikan bukti bahwa tingkat kemenangan permainan peluang tersebut berbeda dari tingkat 0.25 yang dinyatakan (angka .025 dalam sumber merupakan salah ketik).

Uji Hipotesis Wald Numerik

Sekarang kita menyusun uji hipotesis yang sama dengan analisis kemungkinan maksimum numerik. Pertama, kita memasukkan data

```
x=c(1,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0)
n=length(x)
```

Selanjutnya kita menulis fungsi untuk mengevaluasi negatif fungsi log-kemungkinan. Perhatikan bahwa kode sumber berikut tidak membatasi p pada $(0,1)$ atau menangani nilai fungsi kemungkinan yang tidak valid; Hessian numerik yang dikembalikan merupakan informasi teramat, bukan informasi Fisher harapan. Kode tersebut mencari MLE menggunakan `optim`.

```
## negative log likelihood function
nll.bern=function(p,x){
  if (!is.finite(p) || p <= 0 || p >= 1) return(Inf)
  -sum(dbinom(x, size=1, prob=p, log=TRUE))
}
## run optim
out=optim(.5,nll.bern,x=x,method="L-BFGS-B",lower=.Machine$double.eps,upper=1-.Machine$double.eps,hessian=TRUE)
## save MLE
p.hat=out$par
## distinguish numerical observed information from expected Fisher information
I.obs=as.numeric(out$hessian)
I.expected=n/(p.hat*(1-p.hat))
stopifnot(isTRUE(all.equal(I.obs,I.expected,tolerance=1e-3)))
I=I.expected
```

Dengan hasil tersebut, kita menentukan galat baku, lalu statistik uji Wald

```
se=sqrt(1/I)
## get Wald test statistic
T.star=(p.hat-0.25)/se
T.star
```

```
[1] -4.103913
```

Kemudian nilai-p-nya adalah

```
pval=2*pnorm(-abs(T.star),mean=0,sd=1)
pval
```

```
[1] 4.062196e-05
```

yang sekali lagi jauh lebih kecil daripada tingkat $\alpha = 0.05$, kita menolak $H_0 : p = 0.25$ dan menyimpulkan bahwa data memberikan bukti bahwa tingkat kemenangan permainan peluang tersebut berbeda dari tingkat 0.25 yang dinyatakan (angka .025 dalam sumber merupakan salah ketik).

Catatan reproduktibilitas: sumber resmi tidak menetapkan versi R, keadaan sesi, atau kontrak keluaran. Kode ini hanya memakai fungsi R dasar dari paket stats. Edisi turunan harus menjalankannya dalam runtime R yang dipatok dan mencatat `R.version.string`, `platform`, `sessionInfo()`, hash setiap blok kode, serta kecocokan numerik keluaran. Blok pengoptimalan dan dua keluarannya adalah koreksi terdaftar D019.

10.5 Ringkasan

Dalam pelajaran ini, kita memperdalam perangkat pengujian hipotesis dengan menghubungkan selang kepercayaan secara eksplisit dengan uji pasangannya, menelaah tarik-menarik antara galat tipe I dan II melalui kuasa uji, serta mengenal uji Wald—metode serbaguna untuk sampel besar yang dibangun di atas penduga kemungkinan maksimum (MLE). Anda juga akan melihat bagaimana pilihan rancangan seperti ukuran sampel, tingkat signifikansi (α), dan ukuran efek saling berinteraksi ketika merencanakan penelitian.

Pokok-pokok utama:

- Dengan selang kepercayaan tertutup dan aturan nilai- $p < \alpha$ yang lazim, nilai parameter pada hipotesis nol dalam uji dua sisi ditolak tepat ketika berada di luar selang pasangannya; aturan nilai- $p \leq \alpha$ memerlukan perlakuan titik ujung yang eksplisit.
- Memperbesar ukuran sampel mempersempit selang kepercayaan dan meningkatkan kuasa uji tanpa mengubah α .
- Perhitungan kuasa uji memungkinkan Anda memilih ukuran sampel yang memiliki peluang tinggi untuk mendeteksi efek yang bermakna.
- Uji Wald menyediakan uji-z hampiran untuk setiap parameter yang MLE-nya secara asimtotik berdistribusi Normal, sehingga memperluas perangkat pengujian hipotesis ke model-model yang rumus klasiknya sulit digunakan.

1. [Pelajaran](#)
2. [11 Metode Bayesian](#)

11 Metode Bayesian

Bayesian
Peluang Subjektif
Selang Kredibel

Ikhtisar



Gambar 11.1 — Potret Thomas Bayes, tokoh yang namanya digunakan untuk metode Bayesian.

Hak komponen: gambar resmi ini dibekukan byte demi byte dari laman sumber dan dipertahankan di bawah pemberitahuan CC BY-NC 4.0 tingkat laman; tidak ditemukan pengecualian khusus aset.

Semua metode yang sejauh ini telah kita kembangkan dan gunakan dalam mata kuliah ini dikembangkan dengan pendekatan yang oleh para statistisi disebut “frekuentis”. Pada bagian ini, kita meninjau kembali sebagian metode tersebut menggunakan pendekatan yang oleh para statistisi disebut “Bayesian”. Secara khusus, kita akan:

- mempelajari bagaimana seorang Bayesian menetapkan peluang bagi kejadian tertentu
- mempelajari bagaimana seorang Bayesian menangani pendugaan suatu parameter
- mempelajari bagaimana seorang Bayesian memperbarui informasi prior yang dimilikinya tentang nilai suatu parameter

Jika Anda penasaran, gambar di sebelah kanan menampilkan Pendeta Thomas Bayes, yang namanya diabadikan dengan tepat pada bidang statistika Bayesian.

Kita memerlukan setidaknya satu semester penuh, mungkin bahkan lebih, untuk membahas statistika Bayesian secara layak. Dalam mata kuliah ini, kita paling jauh hanya dapat mencicipinya dan melihat sepintas dunia dari sudut pandang seorang Bayesian. Pertama, kita akan mengkaji contoh yang memperlihatkan cara seorang Bayesian menetapkan peluang (subjektif) pada suatu kejadian berdasarkan informasi yang tersedia. Selanjutnya, kita akan menyelidiki cara seorang Bayesian menduga suatu parameter. Terakhir, kita akan membahas cara seorang Bayesian memperbarui informasi prior yang dimilikinya tentang nilai suatu parameter.

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Menentukan secara analitis distribusi posterior Bayesian bagi model berparameter tunggal dengan distribusi prior yang diberikan, baik ketika nilai data diketahui maupun ketika data dipandang sebagai peubah acak yang tidak teramati; dan
2. Menghitung selang kredibel untuk parameter tak diketahui, θ .

11.1 Peluang Subjektif

Mari kita telaah sebuah contoh yang memperlihatkan cara seorang Bayesian menggunakan data yang tersedia untuk menetapkan peluang bagi kejadian-kejadian tertentu.

Contoh 11.1 Besaran taruhan, dalam dolar, yang dipasang pada kuda A, B, C, dan D untuk memenangi sebuah pacuan lokal adalah sebagai berikut:

Jumlah taruhan pada tiap kuda sebelum pengurangan 17% untuk pengelola arena.

Kuda	Jumlah taruhan
A	10,000
B	30,000
C	22,000
D	38,000
Total	100,000

Tentukan pembayaran kemenangan untuk taruhan \$2 pada masing-masing dari keempat kuda jika pengelola arena pacuan ingin mengambil 17%, atau \$17,000, dari jumlah yang terkumpul.

Penyelesaian

Hal pertama yang perlu kita lakukan adalah menetapkan peluang subjektif, setiap kuda untuk menang. Kita dapat menetapkan peluang tersebut berdasarkan “firasat” sendiri. Wah... saya rasa Kuda A akan menang hari ini. Secara umum, itu mungkin bukan gagasan yang baik. Hasil kita barangkali jauh lebih baik jika memanfaatkan informasi yang tersedia, yaitu gabungan “firasat” seluruh petaruh! Artinya, jika taruhan senilai \$38,000 masuk untuk Kuda D sedangkan hanya \$10,000 untuk Kuda A, hal itu menunjukkan bahwa lebih banyak orang memperkirakan Kuda D akan menang daripada Kuda A. Karena itu, sebaiknya kita menggunakan jumlah taruhan untuk menetapkan peluang. Dengan demikian, peluang Kuda A menang adalah:

$$P(A) = \frac{10000}{100000} = 0.10$$

Selanjutnya, peluang Kuda B menang adalah:

$$P(B) = \frac{30000}{100000} = 0.30$$

Selanjutnya, peluang Kuda C menang adalah:

$$P(C) = \frac{22000}{100000} = 0.22$$

Selanjutnya, peluang Kuda D menang adalah:

$$P(D) = \frac{38000}{100000} = 0.38$$

Setelah menetapkan peluang kejadian Kuda A menang, kita dapat menentukan odds melawan kemenangan Kuda A. Nilainya adalah:

Istilah odds melawan kemenangan A menyatakan rasio $P(A \text{ tidak menang})/P(A \text{ menang}) = (1 - P(A))/P(A)$; pembayaran total berikutnya juga mengembalikan nilai taruhan awal.

$$\text{Odds against } A = \frac{1 - 0.1}{0.1} = 9 \text{ to } 1$$

Odds melawan A menunjukkan bahwa pengelola arena akan membayar \$9 untuk taruhan \$1. Selanjutnya, odds melawan kemenangan Kuda B adalah:

$$\text{Odds against } B = \frac{1 - 0.3}{0.3} = \frac{7}{3} \text{ to } 1$$

Odds melawan B menunjukkan bahwa pengelola arena akan membayar $\frac{\$7}{3} = \2.33 untuk taruhan \$1. Selanjutnya, odds melawan kemenangan Kuda C adalah:

$$\text{Odds against } C = \frac{1 - 0.22}{0.22} = \frac{39}{11} \text{ to } 1$$

Odds melawan C menunjukkan bahwa pengelola arena akan membayar $\frac{\$39}{11} = \3.55 untuk taruhan \$1. Terakhir, odds melawan kemenangan Kuda D adalah:

$$\text{Odds against } D = \frac{1 - 0.38}{0.38} = \frac{31}{19} \text{ to } 1$$

Odds melawan D menunjukkan bahwa pengelola arena akan membayar $\frac{\$31}{19} = \1.63 untuk taruhan \$1. Dengan menggunakan odds melawan kemenangan Kuda A, kita sekarang dapat menentukan jumlah yang dibayarkan pengelola arena untuk taruhan \$2 pada Kuda A, yaitu:

$$\text{Payout for } A = \$2 + \$9(\$2) = \$20$$

Dengan kata lain, petaruh menerima \$9 untuk setiap taruhan \$1, sehingga menerima \$18, ditambah \$2 yang semula dipertaruhkan. Selanjutnya, dengan menggunakan odds melawan kemenangan Kuda B, kita dapat menentukan jumlah yang dibayarkan pengelola arena untuk taruhan \$2 pada Kuda B, yaitu:

$$\text{Payout for } B = \$2 + \frac{\$7}{3}(\$2) = \$6.67$$

Selanjutnya, dengan menggunakan odds melawan kemenangan Kuda C, kita dapat menentukan jumlah yang dibayarkan pengelola arena untuk taruhan \$2 pada Kuda C, yaitu:

$$\text{Payout for } C = \$2 + \frac{\$39}{11}(\$2) = \$9.09$$

Selanjutnya, dengan menggunakan odds melawan kemenangan Kuda D, kita dapat menentukan jumlah yang dibayarkan pengelola arena untuk taruhan \$2 pada Kuda D, yaitu:

$$\text{Payout for } D = \$2 + \frac{\$31}{19}(\$2) = \$5.26$$

Kita hampir selesai. Kita tinggal memotong 17% untuk pengelola arena pacuan agar ia memperoleh keuntungan dari para petaruh. Dengan mengalikan setiap pembayaran yang telah dihitung dengan 0.83, kita memperoleh:

$$\text{Absolute Payout for } A = \$20.00(0.83) = \$16.60$$

$$\text{Absolute Payout for } B = \$6.67(0.83) = \$5.54$$

$$\text{Absolute Payout for } C = \$9.09(0.83) = \$7.54$$

$$\text{Absolute Payout for } D = \$5.26(0.83) = \$4.37$$

Kita juga selalu dapat memeriksa hasil. Misalkan, sebagai contoh, Kuda A menang. Arena kemudian akan membayarkan \$16.60 kepada 5000 petaruh yang masing-masing memasang \$2 pada Kuda A, sehingga biaya bagi arena adalah $\$16.60(5000) = \$83,000$. Karena arena menerima \$100,000 dalam taruhan, arena memang memperoleh \$17,000 seperti yang diinginkan. Pemeriksaan serupa dapat dilakukan untuk Kuda B, C, dan D, meskipun mungkin terdapat galat pembulatan karena kita memang membulatkan hasil perhitungan pembayaran. Namun, hasilnya tetap seharusnya sangat dekat dengan \$83,000 pada setiap kasus!

11.2 Pendugaan Bayesian

Ada satu perbedaan utama antara statistikawan frekuentis dan statistikawan Bayesian yang perlu kita akui sebelum kita bahkan dapat mulai membahas bagaimana seorang Bayesian dapat menduga suatu parameter populasi θ . Perbedaan itu berkaitan dengan apakah seorang statistikawan memandang parameter sebagai suatu konstanta yang tidak diketahui atau sebagai peubah acak. Mari kita lihat sebuah contoh sederhana untuk menegaskan perbedaan tersebut.

Contoh 11.2 Seorang insinyur pengendalian lalu lintas meyakini bahwa mobil yang melewati suatu persimpangan tertentu tiba dengan laju rata-rata λ yang sama dengan 3 atau 5 untuk suatu selang waktu tertentu. Sebelum mengumpulkan data apa pun, insinyur tersebut meyakini bahwa laju $\lambda = 3$ lebih mungkin daripada $\lambda = 5$. Bahkan, insinyur tersebut meyakini bahwa peluang priornya adalah:

$$P(\lambda = 3) = 0.7 \text{ and } P(\lambda = 5) = 0.3$$

Pada suatu hari, selama selang waktu yang dipilih secara acak, insinyur tersebut mengamati $x = 7$ mobil melewati persimpangan itu. Berdasarkan pengamatan insinyur tersebut, berapakah peluang bahwa $\lambda = 3$ Dan berapakah peluang bahwa $\lambda = 5$?

Penyelesaian

Hal pertama yang perlu Anda perhatikan dalam contoh ini adalah bahwa kita sedang membahas cara mencari peluang bahwa suatu parameter λ mengambil nilai tertentu. Dalam sekejap, kita baru saja membalikkan seluruh hal yang telah kita pelajari dalam Stat 414 dan Stat 415! Hal berikutnya yang perlu Anda perhatikan, setelah pulih dari rasa pusing akibat keadaan terbalik itu, adalah bahwa kita sebenarnya sudah memiliki perangkat yang diperlukan untuk menghitung peluang yang diinginkan. Cukup ambil Teorema Bayes dari kotak perangkat peluang kita.

Sekarang, hanya dengan menggunakan definisi peluang bersyarat, kita mengetahui bahwa peluang $\lambda = 3$ dengan syarat $X = 7$ adalah:

$$P(\lambda = 3|X = 7) = \frac{P(\lambda = 3, X = 7)}{P(X = 7)}$$

yang dapat dituliskan dengan menggunakan Teorema Bayes sebagai:

$$P(\lambda = 3|X = 7) = \frac{P(X = 7|\lambda = 3)P(\lambda = 3)}{P(X = 7|\lambda = 3)P(\lambda = 3) + P(X = 7|\lambda = 5)P(\lambda = 5)}$$

Kita dapat menggunakan tabel peluang kumulatif Poisson di bagian belakang buku teks untuk mencari

$$\begin{aligned} P(X = 7|\lambda = 3) \\ P(X = 7|\lambda = 5) \end{aligned}$$

Nilainya adalah:

$$\begin{aligned} P(X = 7|\lambda = 3) &= 0.988 - 0.966 = 0.022 \\ P(X = 7|\lambda = 5) &= 0.867 - 0.762 = 0.105 \end{aligned}$$

Sekarang kita memiliki semua yang diperlukan untuk menuntaskan penghitungan peluang yang diinginkan:

$$P(\lambda = 3|X = 7) = \frac{0.7(0.022)}{0.7(0.022) + 0.3(0.105)} = \frac{0.0154}{0.0154 + 0.0315} = 0.328$$

Hmm. Mari kita rangkum. Peluang awal, dalam kasus ini, $P(\lambda = 3) = 0.7$ disebut **peluang prior**. Hal itu karena peluang tersebut menyatakan peluang parameter mengambil nilai tertentu sebelum informasi baru diperhitungkan. Peluang yang baru dihitung, yaitu:

$$P(\lambda = 3|X = 7)$$

disebut **peluang posterior**. Hal itu karena peluang tersebut menyatakan peluang parameter mengambil nilai tertentu setelah informasi baru diperhitungkan. Dalam kasus ini, kita telah melihat bahwa peluang $\lambda = 3$ turun dari 0,7 (peluang prior) menjadi 0,328 (peluang posterior) setelah informasi dari pengamatan $x = 7$.

Penghitungan serupa dapat dilakukan untuk mencari $P(\lambda = 5|X = 7)$. Dengan melakukannya, kita memperoleh:

$$P(\lambda = 5|X = 7) = \frac{0.3(0.105)}{0.7(0.022) + 0.3(0.105)} = \frac{0.0315}{0.0154 + 0.0315} = 0.672$$

Dalam kasus ini, kita melihat bahwa peluang $\lambda = 5$ naik dari 0,3 (peluang prior) menjadi 0,672 (peluang posterior) setelah informasi dari pengamatan $x = 7$.

Catatan ketelitian: nilai eksak massa Poisson adalah 0,02160403145 untuk $\lambda = 3$ dan 0,10444486296 untuk $\lambda = 5$; nilai itu memberi peluang posterior $P(\lambda = 3 | X = 7) = 0,32552803889$. Angka 0,328 di atas berasal dari massa yang terlebih dahulu dibulatkan menjadi 0,022 dan 0,105.

Contoh terakhir tersebut baik untuk menggambarkan perbedaan antara peluang prior dan peluang posterior, tetapi kurang memadai sebagai contoh praktis di dunia nyata. Alasannya, parameter dalam contoh tersebut diasumsikan hanya dapat mengambil dua nilai, yaitu $\lambda = 3$ atau $\lambda = 5$. Jika ruang parameter bagi suatu parameter θ memuat tak terhingga banyak nilai yang mungkin, seorang Bayesian harus menentukan suatu **fungsi kepadatan peluang prior** $h(\theta)$, misalnya. Seluruh mata kuliah telah dikhususkan untuk topik pemilihan PDF prior yang baik, jadi tentu saja kita tidak akan membahasnya di sini! Sebagai gantinya, kita akan mengasumsikan bahwa kita diberi PDF prior yang baik $h(\theta)$ dan memusatkan perhatian pada cara mencari suatu **fungsi kepadatan peluang posterior** $k(\theta|y)$, misalnya, jika kita mengetahui fungsi kepadatan peluang $g(y|\theta)$ dari statistik Y .

Jika kita mengetahui $h(\theta)$ dan $g(y|\theta)$, kita dapat memperlakukan:

$$k(y, \theta) = g(y|\theta)h(\theta)$$

sebagai hukum bersama campuran dari statistik Y dan parameter θ . Kemudian, kita dapat mencari distribusi marginal Y dari distribusi bersama $k(y, \theta)$ dengan mengintegrasikan terhadap ruang parameter θ :

$$k_1(y) = \int_{\Theta} k(y, \theta) d\theta = \int_{\Theta} g(y|\theta)h(\theta) d\theta$$

Selanjutnya, kita dapat mencari PDF posterior dari θ , dengan syarat $Y = y$, dengan menggunakan Teorema Bayes. Yaitu:

$$k(\theta|y) = \frac{k(y, \theta)}{k_1(y)} = \frac{g(y|\theta)h(\theta)}{k_1(y)}$$

Mari kita buat pembahasan ini lebih konkret dengan melihat sebuah contoh.

Contoh 11.3 Misalkan Y mengikuti distribusi binomial dengan parameter n dan $p = \theta$, sehingga PMF dari Y dengan syarat θ adalah:

$$g(y|\theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y} \text{ untuk } y = 0, 1, \dots, n. \text{ Misalkan PDF prior dari parameter } \theta \text{ adalah PDF beta, yaitu:}$$

$$h(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

untuk $0 < \theta < 1$. Carilah PDF posterior dari θ , dengan syarat $Y = y$. Dengan kata lain, carilah $k(\theta|y)$.

Penyelesaian

Pertama, kita mencari hukum bersama campuran dari statistik Y dan parameter θ dengan mengalikan PDF prior $h(\theta)$ dan PMF bersyarat dari statistik Y dan parameter θ adalah:

$$k(y, \theta) = \binom{n}{y} \left(\frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \right) \theta^{y+\alpha-1} (1 - \theta)^{n-y+\beta-1}$$

pada himpunan dukungan $y = 0, 1, 2, \dots, n$ dan $0 < \theta < 1$.

Kemudian, kita mencari fungsi massa peluang marginal dari Y dengan mengintegrasikan $k(y, \theta)$ terhadap ruang parameter θ :

$$k_1(y) = \int_0^1 k(y, \theta) d\theta = \binom{n}{y} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^1 \theta^{y+\alpha-1} (1 - \theta)^{n-y+\beta-1} d\theta$$

Sekarang, jika kita mengalikan integralkan dengan 1 dalam suatu cara khusus:

$$k_1(y) = \binom{n}{y} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \left(\frac{\Gamma(y + \alpha)\Gamma(n - y + \beta)}{\Gamma(y + \alpha + n - y + \beta)} \right) \int_0^1 \left(\frac{\Gamma(y + \alpha + n - y + \beta)}{\Gamma(y + \alpha)\Gamma(n - y + \beta)} \right) \theta^{y+\alpha-1} (1 - \theta)^{n-y+\beta-1} d\theta$$

kita melihat bahwa kita memperoleh PDF beta dengan parameter $y + \alpha$ dan $n - y + \beta$ yang, berdasarkan definisi PDF yang sah, harus berintegral 1. Dengan menyederhanakannya, kita memperoleh bahwa fungsi massa peluang marginal dari Y adalah:

$$k_1(y) = \binom{n}{y} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \left(\frac{\Gamma(y + \alpha)\Gamma(n - y + \beta)}{\Gamma(y + \alpha + n - y + \beta)} \right)$$

pada himpunan dukungan $y = 0, 1, 2, \dots, n$. Kemudian, PDF posterior dari θ , dengan syarat $Y = y$ adalah:

$$k(\theta|y) = \frac{\binom{n}{y} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{y+\alpha-1} (1 - \theta)^{n-y+\beta-1}}{\binom{n}{y} \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \left(\frac{\Gamma(y + \alpha)\Gamma(n - y + \beta)}{\Gamma(y + \alpha + n - y + \beta)} \right)}$$

Karena beberapa faktor saling menghilangkan, kita melihat bahwa PDF posterior dari θ , dengan syarat $Y = y$ adalah:

$$k(\theta|y) = \frac{\Gamma(n + \alpha + \beta)}{\Gamma(\alpha + y)\Gamma(n + \beta - y)} \theta^{y+\alpha-1} (1 - \theta)^{n-y+\beta-1}$$

untuk $0 < \theta < 1$, yang mungkin Anda kenali sebagai PDF beta dengan parameter $y + \alpha$ dan $n - y + \beta$.

Mari kita pertimbangkan contoh lain.

Contoh 11.4 Untuk p yang tetap, misalkan kita mengamati satu pengamatan $Y = y$ dari suatu distribusi dengan PDF $p(1 - p)^y$, untuk $y = 0, 1, \dots$. Selain itu, informasi prior mengenai p menunjukkan bahwa p memiliki PDF $3p^2$ untuk $0 < p < 1$. Carilah distribusi posterior dari p dengan syarat $Y = y$.

Penyelesaian

Kita perlu mencari distribusi posterior dari p dengan syarat $Y = y$. Kita dapat mencari distribusinya melalui:

$$k(p, y) = g(y|p)h(p) = p(1 - p)^y(3p^2) = 3p^3(1 - p)^y$$

Langkah berikutnya adalah mencari $k_1(y)$ melalui:

$$k_1(y) = \int_0^1 3p^3(1 - p)^y dp$$

Alih-alih melakukan ini, mari kita perhatikan bahwa $k_1(y)$ adalah konstanta terhadap p . Mari kita nyatakan $k_1(y)$ sebagai c .

Sekarang, kita perlu mencari $k(p|y) = \frac{k(p,y)}{k_1(y)}$.

$$k(p|y) = \frac{k(p,y)}{k_1(y)} = \frac{3p^3(1-p)^y}{c} = \left(\frac{3}{c}\right)p^3(1-p)^y$$

Suku di dalam tanda kurung, $\left(\frac{3}{c}\right)$, adalah konstanta terhadap p . Mari kita nyatakan konstanta tersebut sebagai κ . Oleh karena itu, kita memperoleh:

$$k(p|y) = \kappa p^3(1-p)^y$$

Kita mengetahui bahwa $k(p|y)$ adalah PDF yang sah. Kita juga mengetahui bahwa p memiliki himpunan dukungan $0 < p < 1$ dan bahwa $k(p|y)$ berintegral 1 pada himpunan dukungan tersebut. Oleh karena itu, distribusi posterior dari p dengan syarat $Y = y$ harus berupa distribusi beta dengan parameter $\alpha = 4$ dan $\beta = y + 1$. Dengan kata lain,

$$k(p|y) = \frac{\Gamma(5+y)}{\Gamma(4)\Gamma(y+1)} p^{4-1}(1-p)^{(y+1)-1}$$

Kita menemukan distribusi posterior dari p dengan syarat $Y = y$ tanpa melakukan integrasi apa pun! Kita hanya mengenali dan mengelompokkan semua konstanta terhadap p serta menggunakan pengetahuan kita tentang syarat suatu fungsi menjadi PDF yang sah.

Perhatikan! Karena κ adalah konstanta terhadap p , kita dapat mengatakan bahwa $k(p|y)$ adalah **sebanding dengan** $p^3(1-p)^y$. Kita menyatakannya sebagai:

$$k(p|y) \propto p^3(1-p)^y$$

Teknik ini membantu kita mencari posterior dengan lebih cepat. Namun, teknik ini hanya dapat digunakan jika kita dapat mengenali distribusi posterior tersebut, sebagaimana kita mengenali bahwa $k(p|y)$ adalah distribusi beta.

Untuk memperagakan cara yang panjang, ujliah keterampilan kalkulus dan aljabar Anda untuk mencari

$$c = k_1(y) = \int_0^1 3p^3(1-p)^y dp = \frac{18}{(y+1)(y+2)(y+3)(y+4)}$$

Konstanta κ sama dengan

$$\frac{3}{c} = \frac{3}{\frac{18}{(y+1)(y+2)(y+3)(y+4)}} = \frac{(y+1)(y+2)(y+3)(y+4)}{6}$$

Bandingkan konstanta ini dengan konstanta distribusi beta yang kita peroleh sebagai posterior:

$$\frac{\Gamma(5+y)}{\Gamma(4)\Gamma(y+1)} = \frac{(y+4)(y+3)(y+2)(y+1)y!}{3!(y!)} = \frac{(y+4)(y+3)(y+2)(y+1)}{6}$$

Keduanya tepat sama! Sekali lagi, hal ini terjadi karena kita mengenali bahwa distribusi posterior tersebut adalah distribusi beta dan hanya ada satu konstanta yang dapat membuat PDF distribusi beta berintegral satu pada himpunan dukungannya.

Dalam contoh-contoh sejauh ini, kita hanya mempertimbangkan satu pengamatan. Kita dapat memulai dengan suatu sampel pengamatan, misalnya $X_1, X_2, \dots, X_n$ atau kita dapat memulai dengan suatu statistik sampel.

Jika kita memulai dengan suatu sampel, kita dapat mengganti $g(y|\theta)$ dengan fungsi kemungkinan

$$L(\theta) = f(x_1|\theta)f(x_2|\theta) \cdots f(x_n|\theta)$$

yang tidak lain adalah distribusi bersama dari $X_1, X_2, \dots, X_n$ dengan syarat parameter θ . Oleh karena itu, kita dapat mencari

$$k(\theta|x_1, \dots, x_n) \propto h(\theta)L(\theta)$$

Jika kita memulai dengan suatu statistik, misalnya W , kita perlu mencari distribusi dari $g(w|\theta)$ dan melanjutkan seperti biasa.

Contoh 11.5 Misalkan $X_1, X_2, \dots, X_n$ adalah sampel acak dari distribusi Bernoulli dengan PMF

$$f(x|\theta) = \theta^x(1-\theta)^{1-x}, \quad x = 0, 1$$

Informasi prior memberi tahu kita bahwa θ mengikuti distribusi beta dengan parameter α dan β . Carilah distribusi posterior dari θ dengan syarat data tersebut.

Penyelesaian

Pertama, kita perlu mencari fungsi kemungkinan:

$$L(\theta) = \prod_{i=1}^n f(x_i|\theta) = \prod_{i=1}^n \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{\sum x_i}(1-\theta)^{n-\sum x_i}$$

Langkah berikutnya adalah membentuk kernel bersama dari θ dan data tersebut.

$$k(\theta|x_1, \dots, x_n) \propto h(\theta)L(\theta) = \theta^{\alpha-1}(1-\theta)^{\beta-1}\theta^{\sum x_i}(1-\theta)^{n-\sum x_i}$$

Ingatlah, ketika kita mengatakan bahwa $k(\theta|x_1, \dots, x_n)$ sebanding dengan ruas kanan, kita mengabaikan semua suku yang konstan terhadap θ . Dengan menyederhanakannya, kita memperoleh:

$$k(\theta|x_1, \dots, x_n) \propto \theta^{\alpha+\sum x_i-1}(1-\theta)^{n-\sum x_i+\beta-1}$$

Kita dapat mengenali bahwa $\theta^{\alpha+\sum x_i-1}(1-\theta)^{n-\sum x_i+\beta-1}$ sebanding dengan distribusi beta dengan parameter $\alpha^* = \alpha + \sum x_i$ dan $\beta^* = n - \sum x_i + \beta$.

Sekarang, apakah Anda bertanya-tanya apa kaitan semua ini dengan pendugaan Bayesian, sebagaimana tersirat oleh judul halaman ini? Mari kita bahas! Seorang Bayesian meyakini bahwa segala sesuatu yang perlu diketahui tentang suatu parameter θ dapat ditemukan dalam PDF posteriornya $k(\theta|y)$. Jadi, jika seorang Bayesian diminta membuat nilai dugaan titik bagi θ , secara wajar ia akan merujuk pada $k(\theta|y)$ untuk memperoleh jawabannya. Namun, bagaimana caranya? Hal yang logis adalah menggunakan $k(\theta|y)$ untuk menghitung rata-rata atau median dari θ , karena keduanya merupakan dugaan yang masuk akal bagi nilai θ . Namun, hmm! Haruskah ia menghitung rata-rata atau median? Hal itu bergantung pada kerugian yang harus ditanggung akibat menggunakan salah satunya. Kerugian? Kita sedang membahas pendugaan parameter, bukan membeli bahan makanan. Misalkan ia dikenai kerugian tertentu karena menduga nilai sebenarnya dari parameter θ dengan dugaannya $w(y)$. Seorang perempuan Bayesian ini mungkin menginginkan agar kerugian akibat galatnya sekecil mungkin. Misalkan ia dikenai kerugian sebesar kuadrat galat antara θ dan dugaannya $w(y)$. Dengan kata lain, misalkan kerugiannya adalah:

$$(\theta - w(y))^2$$

Nah, itulah jawabannya! Karena ia ingin meminimumkan kerugiannya, ia harus menetapkan dugaannya $w(y)$ sebagai rata-rata bersyarat $E(\theta|y)$. Hal itu karena dalam STAT 414 kita telah menunjukkan bahwa jika Z adalah peubah acak, maka nilai harapan galat kuadrat, yaitu $E[(Z - b)^2]$ diminimumkan pada $b = E(Z)$. Dalam kasusnya, Z adalah θ dan b adalah $w(y) = E(\theta|y)$.

Di sisi lain, jika ia dikenai kerugian berupa nilai absolut galat antara θ dan dugaannya $w(y)$, yaitu:

$$|\theta - w(y)|$$

maka, untuk membuat kerugiannya sekecil mungkin, ia harus menetapkan dugaannya $w(y)$ sebagai median bersyarat. Hal itu karena, sekali lagi, dalam STAT 414 kita telah menunjukkan bahwa jika Z adalah peubah acak, maka nilai harapan dari nilai absolut galat, yaitu $E[|Z - b|]$ diminimumkan ketika b sama dengan median distribusi tersebut.

Catatan keputusan: rata-rata posterior meminimumkan kerugian posterior harapan untuk galat kuadrat jika momen kedua yang diperlukan hingga; untuk galat absolut, setiap median posterior merupakan peminimum, dan peminimum tidak harus tunggal.

Mari kita buat pembahasan ini konkret dengan kembali ke contoh binomial kita.

Contoh 11.6 Misalkan Y mengikuti distribusi binomial dengan parameter n dan $p = \theta$, sehingga PMF dari Y dengan syarat θ adalah:

$$g(y|\theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y}$$

untuk $y = 0, 1, \dots, n$. Misalkan PDF prior dari parameter θ adalah PDF beta, yaitu:

$$h(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

untuk $0 < \theta < 1$. Dugalah parameter θ dengan menggunakan fungsi kerugian galat kuadrat.

Solusi

Sebelumnya, kita telah menunjukkan bahwa PDF posterior dari θ dengan syarat $Y = y$ adalah PDF beta dengan parameter $y + \alpha$ dan $n - y + \beta$. Pembahasan sebelumnya memberi tahu kita bahwa untuk meminimumkan fungsi kerugian galat kuadrat:

$$(\theta - w(y))^2$$

kita harus menggunakan rata-rata bersyarat $w(y) = E(\theta|y)$ sebagai nilai dugaan bagi parameter θ . Secara umum, rata-rata PDF beta dengan parameter α dan β adalah:

$$\frac{\alpha}{\alpha + \beta}$$

Dalam kasus kita, PDF posterior dari θ dengan syarat $Y = y$ adalah PDF beta dengan parameter $y + \alpha$ dan $n - y + \beta$. Oleh karena itu, rata-rata bersyaratnya adalah:

$$w(y) = E(\theta|y) = \frac{\alpha + y}{\alpha + y + n - y + \beta} = \frac{\alpha + y}{\alpha + n + \beta}$$

Dalam situasi ini, nilai tersebut merupakan nilai dugaan terbaik seorang Bayesian bagi θ ketika menggunakan fungsi kerugian galat kuadrat.

11.3 Selang Kredibel

Sebelumnya, ketika kita mengasumsikan bahwa parameter yang tetap tetapi tidak diketahui adalah suatu konstanta, kita memperoleh nilai dugaan titik atau penduga titik untuk θ . Kita telah melakukan hal serupa dalam kerangka Bayesian pada bagian ini dengan mencari nilai yang meminimumkan fungsi kerugian galat kuadrat atau dengan meminimumkan nilai absolut galat.

Namun, dalam kerangka frekuentis, kita tidak berhenti pada nilai dugaan titik. Dengan menggunakan perangkat peluang, kita menyusun selang kepercayaan untuk parameter yang tidak diketahui. Dapatkah kita melakukan hal serupa di sini dengan dugaan Bayes?

Jawabannya ya. Kita dapat memperoleh apa yang disebut **selang kredibel**. Kita dapat menyusun selang kredibel dengan mencari dua batas parameter yang bergantung pada data y , misalkan $a(y)$ dan $b(y)$ sedemikian sehingga:

$$\int_{a(y)}^{b(y)} k(\theta|y) d\theta = 1 - \alpha$$

dengan α kecil, misalnya $\alpha = 0.05$. Selang yang dihasilkan dari $a(y)$ hingga $b(y)$ dapat menjadi nilai dugaan selang untuk θ sehingga peluang posterior bahwa θ berada dalam selang tersebut adalah $1 - \alpha$.

Peluang pada setiap ekor lazimnya dibuat sama. Oleh karena itu, selang harus disusun sedemikian sehingga:

$$\begin{aligned} \frac{\alpha}{2} &= \int_{-\infty}^{a(y)} k(\theta|y) d\theta \\ \frac{\alpha}{2} &= \int_{b(y)}^{\infty} k(\theta|y) d\theta \end{aligned}$$

Contoh 11.7 Perhatikan contoh sebelumnya, ketika kita memiliki satu pengamatan, Y , dari suatu distribusi dengan PMF $p(1-p)^y$ untuk $y = 0, 1, \dots$ dan sebuah parameter tak diketahui p dengan distribusi prior $3p^2$, untuk $0 < p < 1$. Tentukan selang kredibel 90% untuk p dengan $Y = 3$.

Solusi

Kita mengetahui bahwa distribusi posteriornya adalah distribusi beta dengan parameter $\alpha = 4$ dan $\beta = y + 1$. Dalam kasus ini, $Y = 3$, sehingga $\beta = 4$.

Untuk menentukan selang kredibel 90%, kita perlu menentukan $a(y)$ dan $b(y)$ sedemikian sehingga

$$0.90 = \int_{a(y)}^{b(y)} \frac{\Gamma(8)}{\Gamma(4)\Gamma(4)} p^3(1-p)^3 dp = \int_{a(y)}^{b(y)} 140p^3(1-p)^3 dp$$

Kita dapat menggunakan R untuk membantu menentukan selang ini. Kita dapat mencari persentil 5^{th} dan persentil 95^{th} dari distribusi beta dengan parameter $\alpha = 4$ dan $\beta = 4$ dengan menggunakan perintah berikut.

```
qbeta(0.05, shape1=4, shape2=4)
```

```
[1] 0.2253216
```

```
qbeta(0.95, shape1=4, shape2=4)
```

```
[1] 0.7746784
```

Kontrak reproduksi: kedua perintah memakai fungsi `stats::qbeta` dalam Base R. Keluaran yang diharapkan adalah 0,2253216 dan 0,7746784 (nilai lebih lengkap 0,2253215840 dan 0,7746784160); tidak ada bilangan acak sehingga seed tidak diperlukan.

Dengan demikian, selang kredibel 90% untuk p , dengan syarat $Y = 3$, adalah (0.2253, 0.7747).

11.3.1 Ringkasan

Dalam pelajaran ini, kita beralih dari cara pandang frekuentis ke cara berpikir Bayesian. Meskipun metode frekuentis memperlakukan parameter sebagai nilai yang tetap tetapi tidak diketahui, metode Bayesian memperlakukan parameter sebagai peubah acak yang memiliki distribusi peluang. Pergeseran ini memungkinkan kita memasukkan keyakinan prior dan memperbaruinya dengan data menggunakan Teorema Bayes.

Kita memulai dengan memahami **peluang subjektif**, yakni seorang statistisi Bayesian menggunakan informasi yang tersedia (seperti jumlah taruhan pada kuda) untuk menetapkan peluang bagi kejadian yang tidak pasti. Kemudian, kita menelaah cara statistisi Bayesian menduga parameter menggunakan suatu **distribusi prior** dan **fungsi kemungkinan** untuk memperoleh **distribusi posterior**.

Kita juga melihat bahwa pendugaan Bayesian sering menghasilkan distribusi posterior dengan bentuk yang sudah dikenal—seperti **distribusi beta** untuk data binomial dengan prior beta. Nilai dugaan titik Bayes bergantung pada **fungsi kerugian**. Jika yang diminimumkan adalah **galat kuadrat**, dugaan terbaiknya adalah **rataan posterior**.

Pelajaran ini memperkenalkan pandangan Bayesian tentang pembelajaran dari data: menggabungkan keyakinan prior dengan bukti yang diamati untuk membuat pernyataan probabilistik tentang parameter yang tidak diketahui. Walaupun ini baru sekilas tentang dunia Bayesian, pelajaran ini menunjukkan betapa fleksibel dan intuitifnya pendekatan tersebut.

Pokok-Pokok Penting:

- Secara matematis, jika θ adalah parameter dan y adalah data, distribusi posteriornya adalah:
$$k(\theta|y) = \frac{g(y|\theta)h(\theta)}{k_1(y)}$$
- **Selang kredibel**, yang memakai peluang posterior—berbeda dari cakupan pengulangan-sampel pada selang kepercayaan, memenuhi: $\int_{a(y)}^{b(y)} k(\theta|y)d\theta = 1 - \alpha$

1. [Pelajaran](#)
2. [12 Regresi Linear Sederhana](#)

12 Regresi Linear Sederhana

Regresi

Gambaran Umum

Regresi linear sederhana merupakan cara untuk mengevaluasi hubungan antara dua peubah kontinu. Satu peubah dipandang sebagai peubah prediktor, peubah penjelas, atau peubah bebas (x). Peubah lainnya dipandang sebagai peubah respons, peubah hasil, atau peubah terikat (y).

Sebagai contoh, kita mungkin tertarik untuk menyelidiki hubungan (linear?) antara:

- tinggi badan dan berat badan
- indeks prestasi kumulatif di sekolah menengah dan indeks prestasi kumulatif di perguruan tinggi
- kecepatan dan efisiensi bahan bakar
- suhu luar ruang dan laju penguapan
- indeks rata-rata industri Dow Jones dan indeks kepercayaan konsumen

Tujuan

Setelah menyelesaikan pelajaran ini, Anda diharapkan mampu:

1. Merumuskan dan menafsirkan model regresi linear untuk memprediksi hasil berdasarkan satu peubah prediktor;
2. Menentukan distribusi parameter kuadrat terkecil;
3. Melakukan uji hipotesis atau membangun selang kepercayaan untuk parameter kuadrat terkecil; dan
4. Membangun selang kepercayaan atau melakukan uji hipotesis untuk parameter korelasi ρ .
Batas cakupan sumber: tujuan inferensi untuk koefisien korelasi ρ tidak dipenuhi oleh isi Pelajaran 12. Prosedur tersebut tetap menjadi unit wajib dalam pendamping orisinal C140 dan tidak boleh dianggap tercakup di sini.

12.1 Jenis Hubungan

Sebelum membahas metode regresi linear sederhana, kita perlu membedakan dua jenis hubungan, yaitu:

- hubungan deterministik
- hubungan statistis

Seperti akan segera kita lihat, regresi linear sederhana membahas hubungan statistis.

12.1.1 Hubungan Deterministik (atau Fungsional)


Sebuah **hubungan deterministik** (atau **hubungan fungsional**) — merupakan hubungan eksak antara prediktor x dan respons y . Sebagai contoh, perhatikan hubungan konversi antara suhu dalam derajat Celsius (C) dan suhu dalam derajat Fahrenheit (F). Kita mengetahui bahwa hubungannya adalah:

$$F = \frac{9}{5}C + 32$$

Karena itu, jika suhunya 10 derajat Celsius, kita juga mengetahui bahwa suhunya 50 derajat Fahrenheit:

$$F = \frac{9}{5}(10) + 32 = 50$$

Secara grafis, beginilah bentuk hubungan (linear) eksak antara derajat Celsius dan derajat Fahrenheit:



Gambar 12.1 — Hubungan deterministik suhu Celsius dan Fahrenheit.

Hak komponen gambar: sembilan PNG resmi dibekukan dan didistribusikan kembali di bawah saksi lisensi tingkat laman CC BY-NC 4.0, kecuali jika dinyatakan lain; tidak ada pengecualian aset khusus yang diklaim tanpa bukti terpisah.


Contoh lain hubungan deterministik mencakup

- hubungan antara diameter (d) dan keliling lingkaran (C): $C = \pi d$
- hubungan antara beban yang diberikan (X) dan pertambahan panjang pegas (Y) (dikenal sebagai Hukum Hooke): $Y = \alpha + \beta X$
- hubungan antara tegangan yang diberikan (V), hambatan (r), dan arus (I) (dikenal sebagai Hukum Ohm):
$$I = \frac{V}{r}$$
- dan, pada suhu tetap, hubungan antara tekanan (P) dan volume gas (V) (dikenal sebagai Hukum Boyle):
$$P = \frac{\alpha}{V}$$
 dengan α merupakan konstanta yang diketahui untuk setiap gas.

12.1.2 Hubungan Statistis

Sebuah **hubungan statistis**, sebaliknya, bukanlah hubungan eksak. Hubungan ini memiliki suatu “**tren**” antara prediktor x dan respons y , tetapi juga memiliki sejumlah “**pencaran**”. Berikut grafik yang menggambarkan kemungkinan bentuk hubungan statistis:

Skin Cancer Mortality versus State Latitude



Gambar 12.2 — Hubungan statistik garis lintang dan mortalitas kanker kulit.

Dalam kasus ini, peneliti menyelidiki hubungan antara garis lintang (dalam derajat) pada pusat masing-masing dari 50 negara bagian Amerika Serikat dan mortalitas akibat kanker kulit (dalam kematian per 10 juta penduduk) di setiap negara bagian tersebut. Barangkali tidak mengherankan bahwa terdapat tren menurun, tetapi bukan hubungan eksak, antara garis lintang dan mortalitas kanker kulit. Artinya, ketika garis lintang meningkat menuju negara bagian yang lebih utara—tempat paparan sinar matahari lebih jarang dan kurang kuat—mortalitas akibat kanker kulit menurun, tetapi tidak secara sempurna.

Contoh lain hubungan statistik mencakup:

- hubungan positif antara tinggi badan dan berat badan
- hubungan positif antara jumlah alkohol yang dikonsumsi dan kadar alkohol dalam darah
- hubungan negatif antara kapasitas vital paru-paru dan pak-tahun merokok
- hubungan negatif antara kecepatan berkendara dan efisiensi bahan bakar

Jenis hubungan statistik yang tidak sempurna inilah yang menjadi perhatian kita ketika menyelidiki metode regresi linear sederhana.

12.2 Kuadrat Terkecil: Gagasan

Sebelum mendalami teori kuadrat terkecil, mari kita bangun intuisi mengenai metode kuadrat terkecil melalui sebuah contoh.

Contoh 12.1 Seorang mahasiswa ingin mengukur hubungan (linear) antara tinggi badan (dalam inci) dan berat badan (dalam pon). Ia mengukur tinggi dan berat sepuluh mahasiswa yang dipilih secara acak dari kelasnya. Setelah pengukuran, ia membuat diagram pencar di samping dari data tinggi dan berat yang diperoleh. Untuk merangkum hubungan antara tinggi dan berat, ia memperkirakan secara visual dua garis yang dianggap baik (garis utuh dan garis putus-putus), tetapi tidak dapat memilih di antara keduanya:

- $\text{weight} = -266.5 + 6.1 \times \text{height}$
- $\text{weight} = -331.2 + 7.1 \times \text{height}$

Manakah “garis dengan suaian terbaik” tersebut?


Solusi

Untuk memudahkan pencarian garis dengan suaian terbaik, mari kita tetapkan beberapa notasi. Ingat bahwa unit eksperimen adalah objek yang diukur (dalam kasus ini, seorang mahasiswa):

- misalkan y_i menyatakan **respons teramati** untuk unit eksperimen ke- i^{th} ;
- misalkan x_i menyatakan **nilai prediktor** untuk unit eksperimen ke- i^{th} ;

misalkan $\hat{y}_i$ menyatakan **respons terprediksi** (atau **nilai suaian**) untuk unit eksperimen ke- i^{th} .

Dengan demikian, untuk titik data yang dilingkari merah:



Gambar 12.3 — Tinggi dan berat badan dengan dua kandidat garis suaian.

kita memperoleh:

$$x_i = 75 \text{ and } y_i = 208$$

Dengan menggunakan versi tak dibulatkan dari garis yang diusulkan, berat terprediksi bagi mahasiswa yang dipilih secara acak dan memiliki tinggi 75 inci adalah:

$$\hat{y}_i = -266.534 + 6.13758(75) = 193.8 \text{ pounds}$$

Tentu saja, garis hasil pendugaan tersebut tidak memprediksi berat mahasiswa setinggi 75 inci dengan sempurna. Dalam kasus ini, prediksinya 193,8 pon, sedangkan berat sebenarnya 208 pon. Prediksi kita memiliki galat. Artinya, ketika menggunakan $\hat{y}_i$ untuk memprediksi respons aktual y_i kita menghasilkan **galat prediksi** (atau **galat sisaan**) sebesar:

$$e_i = y_i - \hat{y}_i$$

Garis yang menyuai data dengan baik adalah garis yang n galat prediksinya (satu untuk setiap n titik data— $n = 10$ dalam kasus ini) sekecil mungkin menurut suatu ukuran keseluruhan. Gagasan ini disebut “kriteria kuadrat terkecil”. Singkatnya, **kriteria kuadrat terkecil** menyatakan bahwa untuk menemukan persamaan garis dengan suaian terbaik:

$$\hat{y}_i = a_1 + bx_i$$

kita perlu memilih nilai a_1 dan b yang meminimumkan jumlah kuadrat galat prediksi. Artinya, carilah a_1 dan b yang meminimumkan:

$$Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (a_1 + bx_i))^2$$

Jadi, untuk menentukan dengan kriteria kuadrat terkecil garis mana di antara dua garis berikut:

- $\text{weight} = -266.5 + 6.1 \times \text{height}$
- $\text{weight} = -331.2 + 7.1 \times \text{height}$

yang paling baik menyuai data, kita hanya perlu menentukan Q , yaitu jumlah kuadrat galat prediksi untuk masing-masing garis, lalu memilih garis dengan nilai Q terkecil. Untuk garis putus-putus, yaitu garis:

$$\text{weight} = -331.2 + 7.1 \times \text{height}$$

perhitungannya adalah sebagai berikut:

Tabel 12.1

Tabel 12.1 — Galat dan kuadrat galat untuk garis putus-putus pada data tinggi-berat.

i	x_i	y_i	$\hat{y}_i$	$(y_i - \hat{y}_i)$	$(y_i - \hat{y}_i)^2$
1	63	127	116.1	10.9	118.8
2	64	121	123.2	-2.2	4.8
3	66	142	137.4	4.6	21.2
4	69	157	158.7	-1.7	2.9
5	69	162	158.7	3.3	10.9
6	71	156	172.9	-16.9	285.6
7	71	169	172.9	-3.9	15.2
8	72	165	180	-15	225.0
9	73	181	187.1	-6.1	37.2
10	75	208	201.3	6.7	44.9
Total					766.5

Kolom pertama yang berlabel i sekadar mencatat indeks titik data, $i = 1, 2, \dots, 10$. Kolom yang berlabel x_i dan y_i memuat titik data asli. Sebagai contoh, mahasiswa pertama yang diukur memiliki tinggi 64 inci dan berat 121 pon. Kolom keempat, berlabel $\hat{y}_i$, memuat berat terprediksi setiap mahasiswa. Sebagai contoh, berat terprediksi mahasiswa kedua, yang tingginya 64 inci, adalah:

$$\hat{y}_2 = -331.2 + 7.1(64) = 123.2 \text{ pounds}$$

Kolom kelima memuat galat ketika $\hat{y}_i$ digunakan untuk memprediksi y_i . Untuk mahasiswa kedua, galat prediksinya adalah:

$$e_2 = 121 - 123.2 = -2.2$$

Kolom terakhir memuat kuadrat galat prediksi. Kuadrat galat prediksi untuk mahasiswa kedua adalah:

$$e_2^2 = (-2.2)^2 = 4.84$$

Dengan menjumlahkan kolom terakhir, yakni kolom kuadrat galat prediksi, kita memperoleh $Q = 766.51$ untuk garis putus-putus. Sekarang, untuk garis utuh, yaitu garis:

$$\text{weight} = -266.5 + 6.1 \times \text{height}$$

perhitungannya adalah sebagai berikut:

Tabel 12.2

Tabel 12.2 — Galat dan kuadrat galat untuk garis utuh pada data tinggi-berat.

i	x_i	y_i	$\hat{y}_i$	$(y_i - \hat{y}_i)$	$(y_i - \hat{y}_i)^2$
1	63	127	117.8	9.2	84.6
2	64	121	123.9	-2.9	8.4
3	66	142	136.1	5.9	34.8
4	69	157	154.4	2.6	6.8
5	69	162	154.4	7.6	57.8
6	71	156	166.6	-10.6	112.4
7	71	169	166.6	2.4	5.8
8	72	165	172.7	-7.7	59.3
9	73	181	178.8	2.2	4.8
10	75	208	191	17	289.0
Total					663.7

Perhitungan setiap kolom sama seperti yang telah dijelaskan. Dalam kasus ini, jumlah kolom terakhir, yaitu jumlah kuadrat galat prediksi untuk garis utuh, adalah $Q = 663.7$. Dengan memilih persamaan yang meminimumkan Q , kita dapat menyimpulkan bahwa garis utuh, yaitu:

$$\text{weight} = -266.5 + 6.1 \times \text{height}$$

merupakan garis dengan suaian terbaik.

Contoh sebelumnya menyisakan satu masalah besar jika kita menyimpulkan bahwa garis utuh adalah garis dengan suaian terbaik: kita hanya mempertimbangkan dua kandidat. Padahal, terdapat tak terhingga banyak kandidat garis dengan suaian terbaik. Pendekatan di atas jelas tidak dapat digunakan dalam praktik. Pada halaman berikutnya, kita akan menurunkan rumus kemiringan dan intersep garis regresi kuadrat terkecil.

12.3 Kuadrat Terkecil: Teori

Setelah memahami gagasan kuadrat terkecil, mari kita buat metodenya lebih praktis dengan mencari rumus intersep a_1 dan kemiringan b . Kita telah mempelajari bahwa untuk menemukan garis regresi kuadrat terkecil, kita perlu meminimumkan jumlah kuadrat galat prediksi, yaitu:

$$Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Kita hanya perlu mengganti $\hat{y}_i$ tersebut dengan rumus persamaan garis:

$$\hat{y}_i = a_1 + bx_i$$

sehingga diperoleh:

$$Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (a_1 + bx_i))^2$$

Kita dapat langsung meminimumkan Q dalam bentuk itu, tetapi penulis buku teks memilih bentuk lain persamaan garis, yaitu:

$$\hat{y}_i = a + b(x_i - \bar{x})$$

Setiap bentuk persamaan garis memiliki kelebihan dan kekurangan. Perangkat lunak statistik, seperti R atau Minitab, biasanya menghitung garis regresi kuadrat terkecil menggunakan bentuk:

$$\hat{y}_i = a_1 + bx_i$$

Hal ini jelas menguntungkan jika komputer dapat mengerjakan perhitungannya. Namun, salah satu kekurangan kecil bentuk ini adalah bahwa intersep a_1 merupakan nilai respons terprediksi y ketika prediktor $x = 0$, yang biasanya tidak terlalu bermakna. Sebagai contoh, jika x adalah tinggi mahasiswa (dalam inci) dan y adalah berat mahasiswa (dalam pon), intersepnya merupakan berat terprediksi seorang mahasiswa yang tingginya 0 inci—Anda tentu memahami persoalannya. Sebaliknya, jika kita menggunakan persamaan:

$$\hat{y}_i = a + b(x_i - \bar{x})$$

maka intersep a merupakan nilai respons terprediksi y ketika prediktor $x_i = \bar{x}$, yaitu rata-rata nilai x . Sebagai contoh, jika x adalah tinggi mahasiswa (dalam inci) dan y adalah berat mahasiswa (dalam pon), maka intersep a merupakan berat terprediksi mahasiswa dengan tinggi rata-rata. Jauh lebih baik dan lebih bermakna. Kabar baiknya, perangkat lunak statistik seperti R atau Minitab juga mudah digunakan untuk menghitung garis regresi kuadrat terkecil dalam bentuk ini.

Baiklah, setelah penjelasan tersebut, sekarang kita sampai pada hasil utamanya.

12.3.1 Nilai Dugaan Kuadrat Terkecil

Perhatikan!

Rumus berikut memberikan bentuk komputasi alternatif bagi kemiringan garis regresi kuadrat terkecil.

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n x_i y_i - \left(\frac{1}{n}\right) \left(\sum_{i=1}^n x_i\right) \left(\sum_{i=1}^n y_i\right)}{\sum_{i=1}^n x_i^2 - \left(\frac{1}{n}\right) \left(\sum_{i=1}^n x_i\right)^2}$$

Teorema 12.1 Garis **regresi kuadrat terkecil** adalah:

$$\hat{y}_i = a + b(x_i - \bar{x})$$

dengan **nilai dugaan kuadrat terkecil**:

$$a = \bar{y} \text{ and } b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Bukti

Untuk menurunkan rumus intersep a dan kemiringan b , kita perlu meminimumkan:

$$Q = \sum_{i=1}^n (y_i - (a + b(x_i - \bar{x})))^2$$

Saatnya menggunakan kalkulus, sebab meminimumkan Q melibatkan penurunan Q terhadap a dan b , menyamakannya dengan 0, lalu menyelesaikannya untuk a dan b . Mari kita lakukan. Dimulai dengan turunan Q terhadap a , kita memperoleh:

Video 12.1: Bukti—Menurunkan rumus intersep a dan kemiringan b

Padanan teks luring untuk Video 12.1

Mulai dari jumlah kuadrat sisaan pada parameterisasi terpusat. Turunan terhadap intersep memberi persamaan normal pertama.

$$Q(a, b) = \sum_{i=1}^n \{y_i - a - b(x_i - \bar{x})\}^2$$
$$\frac{\partial Q}{\partial a} = -2 \sum_{i=1}^n \{y_i - a - b(x_i - \bar{x})\} = 0$$

Karena jumlah deviasi prediktor dari rata-ratanya adalah nol, persamaan ini menjadi $n(\bar{y} - a) = 0$, sehingga $a = \bar{y}$.

[Tautan provenance ke rekaman sumber eksternal](#); byte video tidak disalin atau didistribusikan dalam edisi ini.

Sekarang, karena diketahui bahwa a adalah $\bar{y}$, rata-rata respons, gantilah a dengan $\bar{y}$ dalam rumus untuk Q :

$$Q = \sum_{i=1}^n (y_i - (\bar{y} + b(x_i - \bar{x})))^2$$

lalu ambil turunan Q terhadap b . Dengan demikian, kita memperoleh:

Padanan teks luring untuk Video 12.2

Substitusikan $a=\bar{y}$, lalu turunkan jumlah kuadrat sisaan terhadap b . Persamaan normal kedua dan solusinya adalah:

$$0 = \sum_{i=1}^n (x_i - \bar{x}) \{ (y_i - \bar{y}) - b(x_i - \bar{x}) \}$$

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{y}_i = \bar{y} + b(x_i - \bar{x})$$

Syarat aljabarnya adalah $S_{xx} > 0$, yakni nilai prediktor tidak semuanya sama.

[Tautan provenance ke rekaman sumber eksternal](#); byte video tidak disalin atau didistribusikan dalam edisi ini.

Seperti yang hendak dibuktikan.

Perhatikan bahwa perhitungan aljabar di atas tidak memerlukan asumsi bahwa hubungan antara respons y dan prediktor x benar-benar linear; keberadaan kemiringan hanya memerlukan $S_{xx} > 0$, sedangkan linearitas diperlukan untuk interpretasi model dan inferensi.

Hal lain yang dapat diperhatikan adalah bahwa rumus kemiringan b mudah digunakan jika tersedia perangkat lunak statistik untuk melakukan perhitungannya. Namun, apa yang akan Anda lakukan jika terdampar di pulau terpencil dan perlu mencari garis regresi kuadrat terkecil bagi hubungan antara kedalaman pasang dan waktu? Anda mungkin menginginkan rumus perhitungan yang lebih sederhana. Anda mungkin juga ingin memahami hubungan antara kemiringan b dan koefisien korelasi sampel r .

. Dengan motivasi tersebut, mari kita turunkan rumus perhitungan alternatif untuk kemiringan b .

Teorema 12.2 Rumus alternatif untuk kemiringan b garis regresi kuadrat terkecil:

$$\hat{y}_i = a + b(x_i - \bar{x})$$

adalah:

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n x_i y_i - \left(\frac{1}{n}\right) \left(\sum_{i=1}^n x_i\right) \left(\sum_{i=1}^n y_i\right)}{\sum_{i=1}^n x_i^2 - \left(\frac{1}{n}\right) \left(\sum_{i=1}^n x_i\right)^2}$$

Bukti

Buktinya, yang mungkin muncul atau tidak muncul dalam kuis atau ujian, diserahkan kepada Anda sebagai latihan.

Penurunan lengkap Teorema 12.2

Karena jumlah $(x_i - \bar{x})$ adalah nol, pembilang dapat dipusatkan terhadap y tanpa mengubah nilainya. Mengembangkan kedua jumlah terpusat kemudian memberi bentuk komputasi.

$$\sum_i (x_i - \bar{x})y_i = \sum_i (x_i - \bar{x})(y_i - \bar{y})$$

$$\sum_i (x_i - \bar{x})(y_i - \bar{y}) = \sum_i x_i y_i - \frac{1}{n} \left(\sum_i x_i \right) \left(\sum_i y_i \right)$$


$$\sum_i (x_i - \bar{x})^2 = \sum_i x_i^2 - \frac{1}{n} \left(\sum_i x_i \right)^2$$

Membagi identitas kedua dengan identitas ketiga menghasilkan rumus alternatif yang dinyatakan dalam teorema, dengan syarat $S_{xx} > 0$.

12.4 Model

12.4.1 Apa yang Diduga oleh a dan b ?

Sejauh ini, kita telah merumuskan gagasan dan teori di balik pendugaan kuadrat terkecil. Namun, kini muncul sebuah persoalan. Ketika menurunkan rumus nilai dugaan kuadrat terkecil untuk intersep a dan kemiringan b , kita belum membahas parameter apa yang diduga oleh a dan b . Topik penting ini perlu diperhatikan. Mari kita selidiki jawabannya dengan mempertimbangkan hubungan (linear) antara indeks prestasi kumulatif (IPK) sekolah menengah dan skor ujian masuk perguruan tinggi, seperti ujian ACT. Kita pusatkan IPK sekolah menengah: jika x menyatakan IPK sekolah menengah, maka $x - \bar{x}$ adalah IPK sekolah menengah terpusat. Diagram $x - \bar{x}$, yakni IPK sekolah menengah terpusat, terhadap y , yakni skor ujian masuk perguruan tinggi, dapat berbentuk seperti berikut:



Gambar 12.4 — IPK sekolah menengah terpusat dan skor ujian masuk pada populasi.

Diagram tersebut memerlukan penjelasan:

Padanan teks luring untuk Video 12.3

Untuk prediktor terpusat, rata-rata bersyarat skor ujian adalah $\alpha + \beta(x_i - \bar{x})$. Intersep α adalah rata-rata skor pada $x_i = \bar{x}$, sedangkan β adalah perubahan rata-rata skor untuk setiap kenaikan satu unit prediktor. Pengamatan individual berbeda dari rata-rata itu sebesar ϵ_i . Garis sampel mengganti α dan β dengan nilai dugaan kuadrat terkecil a dan b .

$$E(Y_i | x_i) = \alpha + \beta(x_i - \bar{x}), \quad Y_i = E(Y_i | x_i) + \epsilon_i$$

[Tautan provenance ke rekaman sumber eksternal](#): byte video tidak disalin atau didistribusikan dalam edisi ini.

Ringkasnya, sejauh ini kita membuat dua asumsi. Pertama, dalam seluruh populasi mahasiswa terdapat suatu hubungan linear tak diketahui antara μ_y (atau, sebagai alternatif, $E(Y)$), yaitu rata-rata skor ujian masuk perguruan tinggi, dan $x - \bar{x}$, yaitu IPK sekolah menengah terpusat. Artinya:

$$\mu_Y = E(Y) = \alpha + \beta(x - \bar{x})$$


Kedua, setiap mahasiswa menyimpang dari skor ujian masuk perguruan tinggi rata-rata pada populasi mahasiswa dengan IPK sekolah menengah terpusat yang sama sebesar suatu nilai tak diketahui ϵ_i . Artinya, jika Y_i menyatakan skor ujian masuk perguruan tinggi untuk mahasiswa ke- i , maka:

$$Y_i = \alpha + \beta(x_i - \bar{x}) + \epsilon_i$$

Sayangnya, kita tidak mungkin mengumpulkan data seluruh mahasiswa dalam populasi. Karena itu, kita tidak pernah dapat mengetahui intersep populasi α atau kemiringan populasi β . Hal terbaik yang dapat dilakukan adalah menduga α dan β dengan mengambil sampel acak dari populasi mahasiswa. Misalkan kita memilih secara acak lima belas mahasiswa: tiga mahasiswa memiliki IPK sekolah menengah terpusat -2 , tiga mahasiswa memiliki IPK terpusat -1 , dan seterusnya. Kelima belas titik data tersebut dapat digunakan untuk menentukan garis dengan suaian terbaik (kuadrat terkecil):

$$\hat{y}_i = a + b(x_i - \bar{x})$$

Garis kuadrat terkecil kita tidak akan sempurna, tetapi semestinya menduga garis populasi sejati yang tak diketahui dengan cukup baik:



Gambar 12.5 — Sampel IPK terpusat dan skor ujian masuk beserta garis suaian.


PentingCatatan penyunting sumber: perbaiki persamaan parameter di atas agar sesuai dengan catatan lama.

Itulah inti pembahasannya. Intersep a dan kemiringan b garis regresi kuadrat terkecil masing-masing menduga intersep α dan kemiringan β garis populasi yang tak diketahui. Untuk menghitung garis kuadrat terkecil, kita tidak perlu mengasumsikan bahwa hubungan antara prediktor x dan respons y benar-benar linear; syarat aljabarnya adalah $S_{xx} > 0$. Model linear diperlukan untuk menafsirkan parameter populasi dan melakukan inferensi.

Jika kita hendak menurunkan selang kepercayaan untuk α dan β , seperti yang akan dilakukan pada halaman berikutnya, kita perlu membuat beberapa asumsi tambahan. Di sinilah model regresi linear sederhana berperan.

12.4.2 Model Regresi Linear Sederhana

Agar kurva normal dapat digambar dengan baik, mari kita gunakan sebuah contoh dari buku *Applied Linear Regression Models* (edisi keempat, oleh Kutner, Nachtsheim, dan Neter). Pertimbangkan hubungan antara x , yaitu jumlah proposal penawaran yang disiapkan perusahaan kontraktor, dan y , yaitu jumlah jam yang diperlukan untuk menyiapkan proposal tersebut:



Gambar 12.6 — Model jumlah jam terhadap jumlah proposal yang disiapkan.

Ada beberapa hal yang perlu diperhatikan pada grafik ini. Sekali lagi, rata-rata jumlah jam, $E(Y)$, diasumsikan **berhubungan secara linear** dengan X , jumlah proposal yang disiapkan. Itulah asumsi pertama. Penulis buku teks bahkan menetapkan nilai α dan β yang biasanya tidak diketahui. Dalam kasus ini, α adalah 9,5 dan β adalah 2,1.

Perhatikan bahwa jika $X = 45$ proposal disiapkan, jumlah jam yang diharapkan untuk menyiapkannya adalah:

$$\mu_Y = E(Y) = 9.5 + 2.1(45) = 104$$

Dalam satu kasus, sebuah perusahaan kontraktor memerlukan 108 jam untuk menyiapkan 45 proposal. Dalam kasus tersebut, suku galat ϵ_i bernilai 4. Artinya:

$$Y_i = 108 = E(Y) + \epsilon_i = 104 + 4$$

Kurva normal yang digambar untuk setiap nilai X dimaksudkan untuk menunjukkan bahwa suku galat ϵ_i , dan karena itu respons Y_i , **berdistribusi normal**. Itulah asumsi kedua.

Apakah Anda juga memperhatikan bahwa kedua kurva normal dalam diagram digambar dengan bentuk yang sama? Hal itu menunjukkan bahwa setiap populasi (yang ditentukan oleh X) memiliki varians yang sama. Itulah asumsi ketiga. Artinya, suku galat ϵ_i , dan karena itu respons Y_i , memiliki **varians yang sama** untuk semua nilai x .

Masih ada satu asumsi yang sulit digambarkan dalam grafik, yaitu **kebebasan** suku galat. Mari kita rangkum.

Singkatnya, model regresi linear sederhana menyatakan bahwa empat kondisi berikut harus dipenuhi:

Kondisi inferensi eksak: nilai $x_1, \dots, x_n$ diperlakukan tetap (atau semua pernyataan peluang dikondisikan pada X), $S_{xx} = \sum (x_i - \bar{x})^2 > 0$, suku galat saling bebas dan berdistribusi Normal dengan rata-rata 0 serta varians bersama σ^2 .

- Rataan respons, $E(Y_i)$, merupakan fungsi **L**inear terhadap x_i .
- Suku galat, ϵ_i , dan karenanya respons Y_i , bersifat **I**ndependen.
- Suku galat, ϵ_i , dan karenanya respons Y_i , berdistribusi **N**ormal.
- Suku galat, ϵ_i , dan karenanya respons Y_i , mempunyai **E**qual variances, yakni varians yang sama (σ^2) untuk semua nilai x .

Apakah Anda memperhatikan bahwa keempat kondisi tersebut diawali huruf kapital dan ditandai merah? Huruf awalnya membentuk kata **L - I - N - E**. Kita sedang menyelidiki garis regresi kuadrat terkecil, dan modelnya mengeja kata LINE. Mnemonik ini dapat membantu Anda mengingat keempat kondisi tersebut.

12.4.3 Penduga Kemungkinan Maksimum bagi α dan β

Kita mengetahui bahwa a dan b :

$$a = \bar{y} \text{ and } b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

merupakan penduga (“kuadrat terkecil”) bagi α dan β yang meminimumkan jumlah kuadrat galat prediksi. Ternyata, a dan b juga merupakan penduga kemungkinan maksimum bagi α dan β **asalkan keempat kondisi model regresi linear sederhana berlaku**.

Teorema 12.3 Jika keempat kondisi model regresi linear sederhana berlaku, maka:

$$a = \bar{y} \text{ and } b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

merupakan penduga kemungkinan maksimum bagi α dan β .

Bukti

Singkatnya, model regresi linear sederhana menyatakan bahwa suku galat ϵ_i saling bebas dan berdistribusi normal dengan rata-rata 0 dan varians σ^2 . Artinya:

$$\epsilon_i \sim N(0, \sigma^2)$$

Kondisi linearitas:

$$Y_i = \alpha + \beta(x_i - \bar{x}) + \epsilon_i$$

dengan demikian menyiratkan bahwa:

$$Y_i \sim N(\alpha + \beta(x_i - \bar{x}), \sigma^2)$$

Karena itu, fungsi kemungkinan adalah:

$$L_{Y_i}(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(Y_i - \alpha - \beta(x_i - \bar{x}))^2}{2\sigma^2} \right]$$

yang dapat ditulis ulang sebagai:

$$L = (2\pi)^{-n/2} (\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2 \right]$$

Dengan mengambil logaritma kedua ruas, diperoleh:

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2$$

Tanda negatif di depan penjumlahan pada ruas kanan:

$$\log L = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2$$

menunjukkan bahwa satu-satunya cara untuk memaksimumkan $\log L(\alpha, \beta, \sigma^2)$ terhadap α dan β adalah dengan meminimumkan:

$$\sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2$$

merupakan penduga kemungkinan maksimum bagi α dan β dengan asumsi bahwa suku galat saling bebas, berdistribusi normal dengan rata-rata 0 dan varians σ^2 . Seperti yang hendak dibuktikan.

12.4.4 Bagaimana dengan Varians (Tak Diketahui) σ^2 ?


Singkatnya, varians σ^2 mengukur seberapa besar respons (y) bervariasi di sekitar garis regresi rata-rata (tak diketahui) $E(Y)$. Mengapa besar varians σ^2 perlu diperhatikan? Contoh berikut dapat membantu menjawab pertanyaan tersebut.

Contoh 12.2 Kita mengetahui adanya hubungan sempurna antara derajat Celsius (C) dan derajat Fahrenheit (F), yaitu:

$$F = \frac{9}{5}C + 32$$

Namun, andaikan kita tidak mengetahui hubungan tersebut. Kita dapat mencoba mempelajarinya dengan mengumpulkan data suhu dan menghitung garis regresi kuadrat terkecil. Setelah itu, merek termometer mana yang menurut Anda akan menghasilkan prediksi suhu Fahrenheit mendatang yang lebih presisi: termometer yang datanya diplot di kiri atau di kanan?


Fahrenheit = 34.176 + 1.616 * Celsius
S = 4.781 R-Sq = 96.072 % R-Sq (adj) = 95.511 %



Gambar 12.7 — Pengukuran suhu dengan pencaran kecil di sekitar garis regresi.

$$\text{Fahrenheit} = 17.014 + 2.292 * \text{Celsius}$$

$$S = 22.092 \quad R\text{-Sq} = 69.877 \% \quad R\text{-Sq (adj)} = 65.573 \%$$




Gambar 12.8 — Pengukuran suhu dengan pencaran besar di sekitar garis regresi.

Solusi

Seperti terlihat, pada diagram kiri suhu Fahrenheit tidak banyak bervariasi atau “memantul” di sekitar garis regresi hasil pendugaan. Sebaliknya, pada diagram kanan suhu Fahrenheit cukup banyak bervariasi di sekitar garis regresi hasil pendugaan. Karena itu, wajar disimpulkan bahwa merek termometer di kiri akan memberikan prediksi suhu Fahrenheit mendatang yang lebih presisi.

Tentu saja, varians σ^2 merupakan parameter populasi yang tidak diketahui. Satu-satunya cara untuk mengukur varians itu adalah dengan menduganya. Dalam kasus satu populasi, misalnya populasi (normal) skor IQ:

Normal Distribution of IQ Scores




Gambar 12.9 — Distribusi normal skor IQ.

kita akan menduga varians populasi σ^2 menggunakan varians sampel:

$$s^2 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - 1}$$

Kita telah mempelajari bahwa s^2 merupakan penduga tak bias bagi σ^2 , varians satu populasi tersebut. Namun, bagaimana jika kita tidak lagi hanya memiliki satu populasi, melainkan banyak populasi? Dalam contoh proposal dan jam kerja, terdapat satu populasi untuk setiap nilai x :



Gambar 12.10 — Banyak populasi respons pada nilai prediktor yang berbeda.

Dalam kasus ini, kita harus menduga σ^2 , yaitu varians (bersama) dari banyak populasi. Ada dua kemungkinan: satu penduga bias dan satu penduga tak bias.

Teorema 12.4 Penduga kemungkinan maksimum bagi σ^2 adalah:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n}$$

Penduga ini merupakan penduga bias bagi σ^2 , yaitu varians bersama dari **banyak** populasi.

Bukti

Sebelumnya telah ditunjukkan bahwa logaritma fungsi kemungkinan adalah:

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2$$

Untuk memaksimumkan log-kemungkinan, kita harus mengambil turunan parsial log-kemungkinan terhadap σ^2 . Dengan demikian, diperoleh:

$$\frac{\partial \log L_{Y_i}(\alpha, \beta, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} - \frac{1}{2} \sum (Y_i - \alpha - \beta(x_i - \bar{x}))^2 \cdot \left(-\frac{1}{(\sigma^2)^2} \right)$$

Dengan menyamakan turunannya dengan 0 dan mengalikan kedua ruas dengan $2\sigma^4$:

$$\frac{\partial \log L_{Y_i}(\alpha, \beta, \sigma^2)}{\partial \sigma^2} = \left[-\frac{n}{2\sigma^2} - \frac{1}{2} \sum (Y_i - \alpha - \beta(x_i - \bar{x}))^2 \cdot -\frac{1}{(\sigma^2)^2} \stackrel{\text{SET}}{=} 0 \right] 2(\sigma^2)^2$$

, diperoleh:

$$-n\sigma^2 + \sum (Y_i - \alpha - \beta(x_i - \bar{x}))^2 = 0$$

Setelah menyelesaikannya dan menambahkan topi pada σ^2 , serta mengganti α dan β dengan penduga kemungkinan maksimumnya, diperoleh:

$$\hat{\sigma}^2 = \frac{\sum (Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x}))^2}{n} = \frac{\sum (Y_i - \hat{Y}_i)^2}{n}$$

Seperti yang hendak dibuktikan.

Def. 12.1 (Rataan Kuadrat Galat) Sebaliknya, **rataan kuadrat galat**:

$$MSE = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n - 2}$$

merupakan **penduga tak bias** bagi σ^2 , yaitu varians bersama dari **banyak** populasi.

Kita perlu menggunakan penduga σ^2 ini ketika menurunkan selang kepercayaan untuk α dan β pada bagian berikutnya.

12.5 Selang Kepercayaan bagi Parameter Regresi

Sebelum menurunkan selang kepercayaan untuk α dan β , pertama-tama kita perlu menurunkan distribusi peluang a , b dan $\hat{\sigma}^2$. Selama proses ini, mari gunakan notasi penduga yang lebih tradisional dengan menambahkan topi pada huruf Yunani. Jadi, di sini kita menggunakan:

$$a = \hat{\alpha} \text{ and } b = \hat{\beta}$$

Teorema 12.5 Di bawah asumsi model regresi linear sederhana:

$$\hat{\alpha} \sim N\left(\alpha, \frac{\sigma^2}{n}\right)$$

Bukti

Ingat bahwa penduga kemungkinan maksimum (dan kuadrat terkecil) bagi α adalah:

$$a = \hat{\alpha} = \bar{Y}$$

dengan respons Y_i saling bebas dan berdistribusi normal. Secara lebih khusus:

$$Y_i \sim N(\alpha + \beta(x_i - \bar{x}), \sigma^2)$$

Nilai harapan $\hat{\alpha}$ adalah α , seperti ditunjukkan berikut:

$$E(\hat{\alpha}) = E(\bar{Y}) = \frac{1}{n} \sum E(Y_i) = \frac{1}{n} \sum E(\alpha + \beta(x_i - \bar{x})) = \frac{1}{n} \left[n\alpha + \beta \sum (x_i - \bar{x}) \right] = \frac{1}{n} (n\alpha) = \alpha$$

Karena $\sum (x_i - \bar{x}) = 0$.

Varians $\hat{\alpha}$ diperoleh langsung dari varians rata-rata sampel, yaitu:

$$Var(\hat{\alpha}) = Var(\bar{Y}) = \frac{\sigma^2}{n}$$

Oleh karena kombinasi linear peubah acak normal juga berdistribusi normal, kita memperoleh:

$$\hat{\alpha} \sim N\left(\alpha, \frac{\sigma^2}{n}\right)$$

seperti yang hendak dibuktikan.

Teorema 12.6 Di bawah asumsi model regresi linear sederhana:

$$\hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

Bukti

Dengan mengingat salah satu rumus singkat penduga kemungkinan maksimum (dan kuadrat terkecil) bagi β

$$b = \hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

, kita melihat bahwa penduga kemungkinan maksimum tersebut merupakan kombinasi linear peubah acak normal yang saling bebas Y_i dengan:

$$Y_i \sim N(\alpha + \beta(x_i - \bar{x}), \sigma^2)$$

Nilai harapan $\hat{\beta}$ adalah β , seperti ditunjukkan berikut:

$$\begin{aligned} E(\hat{\beta}) &= \frac{1}{\sum (x_i - \bar{x})^2} \sum E[(x_i - \bar{x})Y_i] \\ &= \frac{1}{\sum (x_i - \bar{x})^2} \sum (x_i - \bar{x})(\alpha + \beta(x_i - \bar{x})) \\ &= \frac{1}{\sum (x_i - \bar{x})^2} \left[\alpha \sum (x_i - \bar{x}) + \beta \sum (x_i - \bar{x})^2 \right] \\ &= \beta \end{aligned}$$

karena $\sum (x_i - \bar{x}) = 0$.

Dan varians $\hat{\beta}$ adalah:

$$\text{Var}(\hat{\beta}) = \left[\frac{1}{\sum (x_i - \bar{x})^2} \right]^2 \sum (x_i - \bar{x})^2 (\text{Var}(Y_i)) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$$

Oleh karena kombinasi linear peubah acak normal juga berdistribusi normal, kita memperoleh:

$$\hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

Seperti yang hendak dibuktikan.

Teorema 12.7 Di bawah asumsi model regresi linear sederhana:

$$\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi_{(n-2)}^2$$

dan $a = \hat{\alpha}$, $b = \hat{\beta}$, serta $\hat{\sigma}^2$ saling bebas.

Argumen

Perhatikan bahwa judul bagian ini adalah Argumen, bukan Bukti. Alasannya, kita akan menggunakan penjelasan informal dan merujuk ke sumber lain karena buktinya berada di luar cakupan mata kuliah ini. Mari kita mulai. Sebagai tugas, Anda diminta menunjukkan bahwa:

$$\sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Jika kedua ruas persamaan dibagi dengan varians populasi σ^2 , diperoleh:

$$\frac{\sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2}{\sigma^2} = \frac{n(\hat{\alpha} - \alpha)^2}{\sigma^2} + \frac{(\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2} + \frac{\sum (Y_i - \hat{Y}_i)^2}{\sigma^2}$$

Dengan menulis ulang beberapa suku, diperoleh:

$$\frac{\sum_{i=1}^n (Y_i - \alpha - \beta(x_i - \bar{x}))^2}{\sigma^2} = \frac{(\hat{\alpha} - \alpha)^2}{\sigma^2/n} + \frac{(\hat{\beta} - \beta)^2}{\sigma^2 / \sum_{i=1}^n (x_i - \bar{x})^2} + \frac{n\hat{\sigma}^2}{\sigma^2}$$

Kini suku-suku tersebut ditulis sehingga distribusi masing-masing dapat dikenali. Distribusinya adalah:

$$\underbrace{\frac{\sum (Y_i - \alpha - \beta(x_i - \bar{x}))^2}{\sigma^2}}_{\chi_{(n)}^2} = \underbrace{\frac{(\hat{\alpha} - \alpha)^2}{\sigma^2/n}}_{\chi_{(1)}^2} + \underbrace{\frac{(\hat{\beta} - \beta)^2}{\sigma^2 / \sum (x_i - \bar{x})^2}}_{\chi_{(1)}^2} + \underbrace{\frac{n\hat{\sigma}^2}{\sigma^2}}_{?}$$

Tampaknya wajar bahwa suku terakhir merupakan peubah acak khi-kuadrat dengan $n - 2$ derajat kebebasan. Artinya:

$$\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi_{(n-2)}^2$$

dan, lebih lanjut, $a = \hat{\alpha}$, $b = \hat{\beta}$ serta $\hat{\sigma}^2$ saling bebas. (Buktinya dapat ditemukan dalam berbagai buku teks statistika matematis.)

Batas rigor: argumen sumber belum membuktikan dekomposisi ortogonal, peringkat ruang proyeksi, atau kebebasan komponen. Bukti matriks lengkap beserta syarat peringkat tetap menjadi unit wajib pendamping rigor orisinal C140; paragraf sumber ini tidak dipromosikan menjadi bukti lengkap.

Dengan hasil distribusional tersebut, kini kita dapat menurunkan selang kepercayaan $(1 - \alpha)100\%$ untuk α dan β !

Teorema 12.8 Di bawah asumsi model regresi linear sederhana, sebuah $(1 - \alpha)100\%$ **selang kepercayaan bagi parameter kemiringan** β adalah:

$$b \pm t_{\alpha/2, n-2} \times \left(\frac{\sqrt{n}\hat{\sigma}}{\sqrt{n-2}\sqrt{\sum (x_i - \bar{x})^2}} \right)$$

atau, secara ekuivalen:

$$\hat{\beta} \pm t_{\alpha/2, n-2} \times \sqrt{\frac{MSE}{\sum (x_i - \bar{x})^2}}$$

Bukti

Ingat kembali definisi peubah acak T . Yaitu, jika:

1. Z merupakan peubah acak normal baku ($N(0, 1)$);
2. U merupakan peubah acak khi-kuadrat dengan r derajat kebebasan;
3. Z serta U saling bebas, maka:

$$T = \frac{Z}{\sqrt{U/r}}$$

mengikuti distribusi T dengan r derajat kebebasan. Hasil kita di atas menyatakan bahwa:

$$\frac{\hat{\beta} - \beta}{\sigma / \sqrt{\sum (x_i - \bar{x})^2}} \sim N(0, 1) \text{ and } \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi_{(n-2)}^2 \text{ are independent}$$

Karena itu, kita memperoleh bahwa:

$$T = \frac{\frac{\hat{\beta} - \beta}{\sigma / \sqrt{\sum (x_i - \bar{x})^2}}}{\sqrt{\frac{n\hat{\sigma}^2}{\sigma^2} / (n-2)}} = \frac{\hat{\beta} - \beta}{\sqrt{\frac{n\hat{\sigma}^2}{n-2} / \sum (x_i - \bar{x})^2}} = \frac{\hat{\beta} - \beta}{\sqrt{MSE / \sum (x_i - \bar{x})^2}} \sim t_{n-2}$$

mengikuti distribusi T dengan $n - 2$ derajat kebebasan. Sekarang, penurunan selang kepercayaan bagi β cukup dilakukan dengan manipulasi biasa pada bagian dalam pernyataan peluang:

$$P\left(-t_{\alpha/2} \leq \frac{\hat{\beta} - \beta}{\sqrt{MSE / \sum (x_i - \bar{x})^2}} \leq t_{\alpha/2}\right) = 1 - \alpha$$

seperti yang hendak dibuktikan.

Selanjutnya, untuk selang kepercayaan bagi parameter intersep α .

Teorema 12.9 Di bawah asumsi model regresi linear sederhana, sebuah $(1 - \alpha)100\%$ selang kepercayaan bagi parameter intersep α adalah:

$$a \pm t_{\alpha/2, n-2} \times \left(\sqrt{\frac{\hat{\sigma}^2}{n-2}} \right)$$

atau, secara ekuivalen:

$$a \pm t_{\alpha/2, n-2} \times \left(\sqrt{\frac{MSE}{n}} \right)$$

Bukti

Buktinya, yang mungkin muncul atau tidak muncul pada penilaian mendatang, diserahkan kepada Anda sebagai latihan.

Contoh 12.3 Tabel berikut menunjukkan x , yaitu hasil tangkapan ikan teri Peru (dalam juta ton metrik), dan y , yaitu harga tepung ikan (dalam dolar berjalan per ton) selama 14 tahun berturut-turut. (Data dari Bardach, J. E. dan Santerre, R. M., “Climate and the Fish in the Sea”, Bioscience 31(3), 1981.)

Tabel 12.3 — Harga tepung ikan dan hasil tangkapan ikan teri Peru selama 14 tahun.

Baris	Harga	Tangkapan
1	190	7.23
2	160	8.53
3	134	9.82
4	129	10.26
5	172	8.96
6	197	12.27
7	167	10.28
8	239	4.45
9	542	1.87
10	372	4.00
11	245	3.30
12	376	4.30
13	454	0.80
14	410	0.50

Tentukan selang kepercayaan 95% bagi parameter kemiringan β .

Solusi

Bagian keluaran berikut diperoleh menggunakan paket analisis regresi Minitab, dengan komponen yang berguna bagi kita ditandai ($\hat{\beta} = -29.39$ dan $MSE = 5202$):

Persamaan Regresi

Harga = 452,3 – 29,39 Tangkapan

Koefisien

Tabel 12.4 — Koefisien regresi Minitab untuk contoh ikan teri.

Suku	Koef	GB Koef	Nilai-t	Nilai-p	VIF
Konstanta	452.3	37.1	12.18	0.000	
Tangkapan	-29.39	5.13	-5.73	0.000	1.00

Ringkasan Model

Tabel 12.5 — Ringkasan model regresi Minitab untuk contoh ikan teri.

S	R-kuadrat	R-kuadrat (d disesuaikan)	R-kuadrat (prediksi)
72.1265	73.22%	70.98%	61.97%

Analisis Varians

Tabel 12.6 — Analisis varians regresi Minitab untuk contoh ikan teri.

Sumber	DK	JK Disesuaikan	RK Disesuaikan	Nilai-F	Nilai-p
Regresi	1	170655	170655	32.80	0.000
Tangkapan	1	170655	170655	32.80	0.000
Galat	12	62427	5202		
Total	13	233082			

Analisis deskriptif dasar Minitab juga dapat menghitung simpangan baku nilai x , yaitu 3,91. Karena itu, rumus varians sampel memberi:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = 197.5043214285714$$

Dengan menggabungkan semua komponen tersebut dan menggunakan fakta bahwa $t_{0.025,12} = 2.179$, diperoleh:

$$-29.3948251765 \pm 2.178812829 \sqrt{\frac{5202.2296650893}{197.5043214286}}$$

yang menyederhana menjadi: $-29.3948251765 \pm 11.182177536$ Artinya, kita dapat yakin 95% bahwa parameter kemiringan berada di antara -40,5770 dan -18,2126. Dengan kata lain, prosedur ini menghasilkan selang yang menyatakan penurunan harga rata-rata tepung ikan antara 18,2126 dan 40,5770 dolar per ton untuk setiap kenaikan satu unit (satu juta ton metrik) hasil tangkapan ikan teri Peru.

Reproduksi terbuka untuk data ikan teri yang ditampilkan

```
catch <- c(7.23,8.53,9.82,10.26,8.96,12.27,10.28,4.45,1.87,4.00,3.30,4.30,0.80,0.50)
price <- c(190,160,134,129,172,197,167,239,542,372,245,376,454,410)
fit <- lm(price ~ catch)
sxx <- sum((catch - mean(catch))^2)
mse <- deviance(fit) / df.residual(fit)
tc <- qt(0.975, df.residual(fit))
c(slope=coef(fit)[2], Sxx=sxx, MSE=mse, slope_lo=coef(fit)[2]-tc*sqrt(mse/sxx), slope_hi=coef(fit)
[2]+tc*sqrt(mse/sxx), intercept_lo=mean(price)-tc*sqrt(mse/length(price)),
intercept_hi=mean(price)+tc*sqrt(mse/length(price)))
```

Kontrak keluaran Base R: slope = -29,3948251765; Sxx = 197,5043214286; MSE = 5202,2296650893; selang kemiringan [-40,577002713; -18,212647640]; selang intersep terpusat [228,499866913; 312,500133087]. Perhitungan deterministik ini tidak memakai bilangan acak sehingga seed tidak diperlukan.

Contoh 12.4 Tentukan selang kepercayaan 95% bagi parameter intersep α .

Solusi

Kita dapat menggunakan Minitab (atau kalkulator) untuk menentukan bahwa rata-rata 14 respons adalah:

$$\frac{190 + 160 + \dots + 410}{14} = 270.5$$

Dengan menggunakan nilai tersebut dan $MSE = 5202.2296650893$ yang diperoleh dari keluaran di atas, serta fakta bahwa $t_{0.025,12} = 2.179$, diperoleh:

$$270.5 \pm 2.178812829 \sqrt{\frac{5202.2296650893}{14}}$$

yang menyederhana menjadi 270.5 ± 42.000133087 Artinya, kita dapat yakin 95% bahwa parameter intersep berada di antara 228,4999 dan 312,5001 dolar per ton.

12.6 Uji Hipotesis Mengenai Kemiringan

Sebelumnya, kita telah mempelajari cara menghitung nilai dugaan titik dan selang bagi parameter intersep dan kemiringan, α dan β , dari model regresi linear sederhana:

$$Y_i = \alpha + \beta(x_i - \bar{x}) + \epsilon_i$$

dengan galat acak ϵ_i mengikuti distribusi normal dengan rata-rata 0 dan varians σ^2 . Dalam pelajaran ini, kita akan mempelajari cara melakukan uji hipotesis untuk menguji hipotesis nol bahwa parameter kemiringan sama dengan suatu nilai, misalnya β_0 . Secara khusus, kita akan mempelajari cara menguji hipotesis nol $H_0 : \beta = \beta_0$ menggunakan statistik T -t.

Sekali lagi, sebagian besar landasan teoretis untuk mengembangkan uji hipotesis bagi parameter kemiringan β dari model regresi linear sederhana telah dikerjakan ketika kita mengembangkan selang kepercayaan $(1 - \alpha)100\%$ bagi β . Saat itu, kita telah menunjukkan bahwa:

$$T = \frac{\hat{\beta} - \beta}{\sqrt{\frac{MSE}{\sum (x_i - \bar{x})^2}}}$$

mengikuti distribusi t_{n-2} . Karena itu, jika kita ingin menguji hipotesis nol:

$$H_0 : \beta = \beta_0$$

terhadap salah satu hipotesis alternatif:

$$H_A : \beta > \beta_0, \quad H_A : \beta < \beta_0, \quad H_A : \beta \neq \beta_0$$

kita dapat menggunakan statistik uji:

$$t = \frac{\hat{\beta} - \beta_0}{\sqrt{\frac{MSE}{\sum (x_i - \bar{x})^2}}}$$

dan mengikuti prosedur pengujian hipotesis baku.

12.7 Ringkasan

Batas pendamping: sumber ini tidak menyediakan korpus latihan mandiri, diagnostik sisaan, selang rata-rata-respons/prediksi, regresi berganda, maupun kontrak R/Minitab yang lengkap. Permukaan tersebut tetap wajib dalam pendamping orisinal C140 dan tidak diatribusikan kepada Penn State.

Pelajaran ini membahas pokok-pokok regresi linear sederhana, yaitu metode untuk memodelkan hubungan linear antara prediktor (x) dan respons (y).

Pokok-pokok pentingnya meliputi:

- Memodelkan tren linear yang memiliki pencaran dengan metode kuadrat terkecil untuk menemukan garis dengan suaian terbaik.
- Menduga intersep (a) dan kemiringan (b) untuk menghampiri parameter populasi α dan β .
- Asumsi (LINE): (L)inearitas, (I)ndependensi, (N)ormalitas, dan (E)qual variances atau varians yang sama.
- Menggunakan selang kepercayaan dan uji-t untuk inferensi parameter regresi.
- Menggunakan alat seperti R atau Minitab untuk menganalisis data dunia nyata dan menafsirkan hasilnya.

Provenance, hak, dan perubahan

Sumber resmi: Penn State STAT 415, Pelajaran 12, “Simple Linear Regression”, [laman sumber](#). Isi tingkat laman berlisensi CC BY-NC 4.0 kecuali jika dinyatakan lain; setiap pengecualian komponen tetap berlaku.

Edisi Bahasa Indonesia ini merupakan karya turunan: struktur, rumus, tabel, gambar, sitasi, dan identitas sumber dipertahankan; 24 koreksi atau disposisi target-only dicatat secara terpisah. Tidak ada dukungan atau pengesahan oleh sumber yang tersirat.

Provenance terjemahan dan rekonstruksi: OpenAI Codex gpt-5.6-sol, Ultra. Kredit sumber dan kontributor manusia tetap dipertahankan.

Provenans, hak, dan perubahan

Sumber. Rangkaian publik Penn State STAT 415, *Introduction to Mathematical Statistics*, laman utama dan Pelajaran 00-12. Distribusi resmi yang tersedia adalah HTML semantik hasil Quarto; edisi ini tidak mengklaim sebagai fork sumber QMD yang tidak dipublikasikan.

Hak. Konten Penn State dan adaptasi Bahasa Indonesianya tetap berada di bawah CC BY-NC 4.0 kecuali jika suatu komponen menyatakan lain. MathJax tetap berada di bawah Apache-2.0. Lapisan asli repositori mempunyai identitas lisensi terpisah sebagaimana dijelaskan dalam `LICENSE.md`; koleksi ini tidak direlisensi sebagai satu karya dengan lisensi seragam.

Perubahan. Struktur, rumus, contoh, solusi, kode, gambar, tabel, dan hubungan sumber dipertahankan. Perbaikan turunan yang terbukti dicatat secara terpisah; byte sumber resmi tidak diubah. Tidak ada dukungan atau pengesahan oleh Penn State yang tersirat.

Provenans terjemahan dan rekonstruksi. OpenAI Codex gpt-5.6-sol, Ultra.

Tautan. Sumber resmi: online.stat.psu.edu/stat415. Repositori edisi: [penn-state-stat-415-id](https://penn-state-stat-415-id.zenodo.org/). Konsep preservasi: [10.5281/zenodo.22077422](https://doi.org/10.5281/zenodo.22077422).